Spark

Big Data

본 자료에는 네이버에서 제공한 나눔글꼴이 적용되어 있습니다.

Learning Objectives

❖ 학습내용

- Apache Spark

❖ 학습목표

- Apache Saprk의 동작 원리와 구성요소를 이해한다.
- Spark의 RDD, DataFrame, Dataset에 대해 알아보고 특성에 대해 이해한다.

❖ Spark

- "A multi-language engine for executing data engineering, data science, and machine learning on single-node machines or clusters."
- In-memory 연산을 통해 디스크 기반 Hadoop의 성능을 향상
- RDD, DataFrame, Dataset 3가지 API 제공
- Java, Scala, Python을 통해 script 작성
- Amazon, Ebay, NASA JPL, TripAdviser, Yahoo

❖ Spark

○ Driver program

- Task 진행을 통제
- SparkContext를 생성하는 메인 process

○ Executor

- 다수의 worker node에서 실행되는 프로세스 (task 수행 후 결과 반환)
- Caching을 통해 빠르고 효율적으로 데이터 가공
- Executor는 cluster manager에 의해 spark 어플리케이션에 할당됨

○ Cluster manager

- Executor에 task를 할당하고 관리함
- Spark는 cluster manager와의 통신을 통해 할당 가능한 executor를 전달받음

❖ Spark

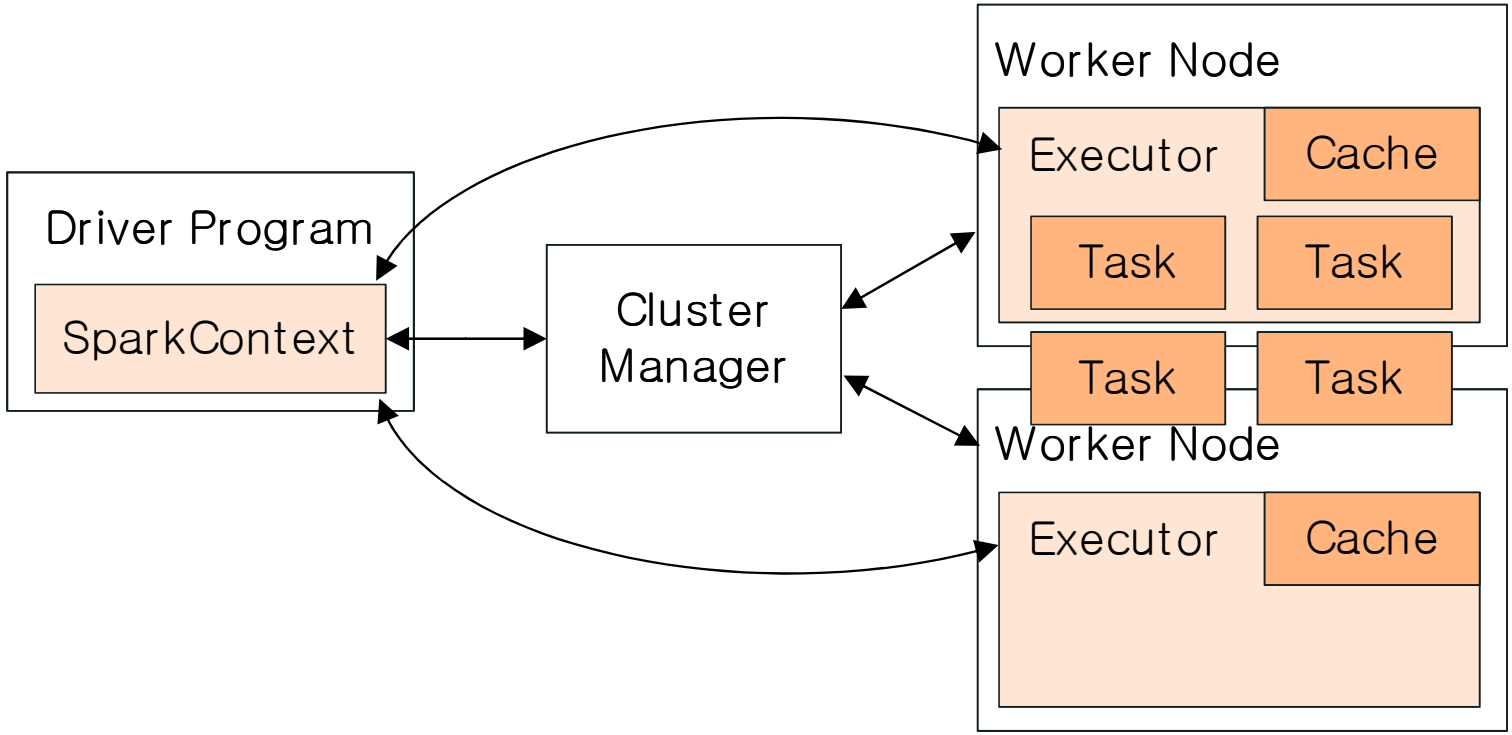
Driver Program
SparkContext
Cluster Manager
Worker Node
Executor
Cache
Task
Task
Task
Task
Worker Node
Executor
Cache

❖ Spark 구성

SparkContext

Spark 기능의 기본 진입점, Cluster와 통신

Spark SQL

- Spark의 SQL 인터페이스
- SQL query 또는 SQL 유사함수를 통해 Spark의 data 변환

Spark Streaming

- 실시간으로 streaming data를 처리할 수 있음

MLlib

- Spark data에 적용하는 machine learning이나 data mining library

GraphX

- 대용량 data의 분산 및 병렬 그래프 처리 지원

❖ RDD

- Spark의 기본 데이터 구조
- Resilient Distributed Dataset
  작업을 클러스터에 고르게 분산하고, 실패가 발생해도 회복할 수 있는 Dataset
- RDD 객체는 key-value 정보를 포함한 일반적인 정보를 저장하는 수단이며,
  클러스터에서 자동으로 작업함
- SparkContext는 Spark 내에서 driver program이 작동하는 환경이며,
  RDD를 만드는 주체임

❖ RDD

- Transforming RDD's
  - map, flatmap, filter, distinct, sample, union, intersection, subtract 등
- RDD actions
  - collect, count, countByValue, take, top, reduce 등
- Lazy evaluation
  - RDD action 호출 전까지 transform하지 않음
  - Action을 호출할 때, Spark는 결과물에 도달할 수 있는 최단 경로를 찾음

❖ RDD

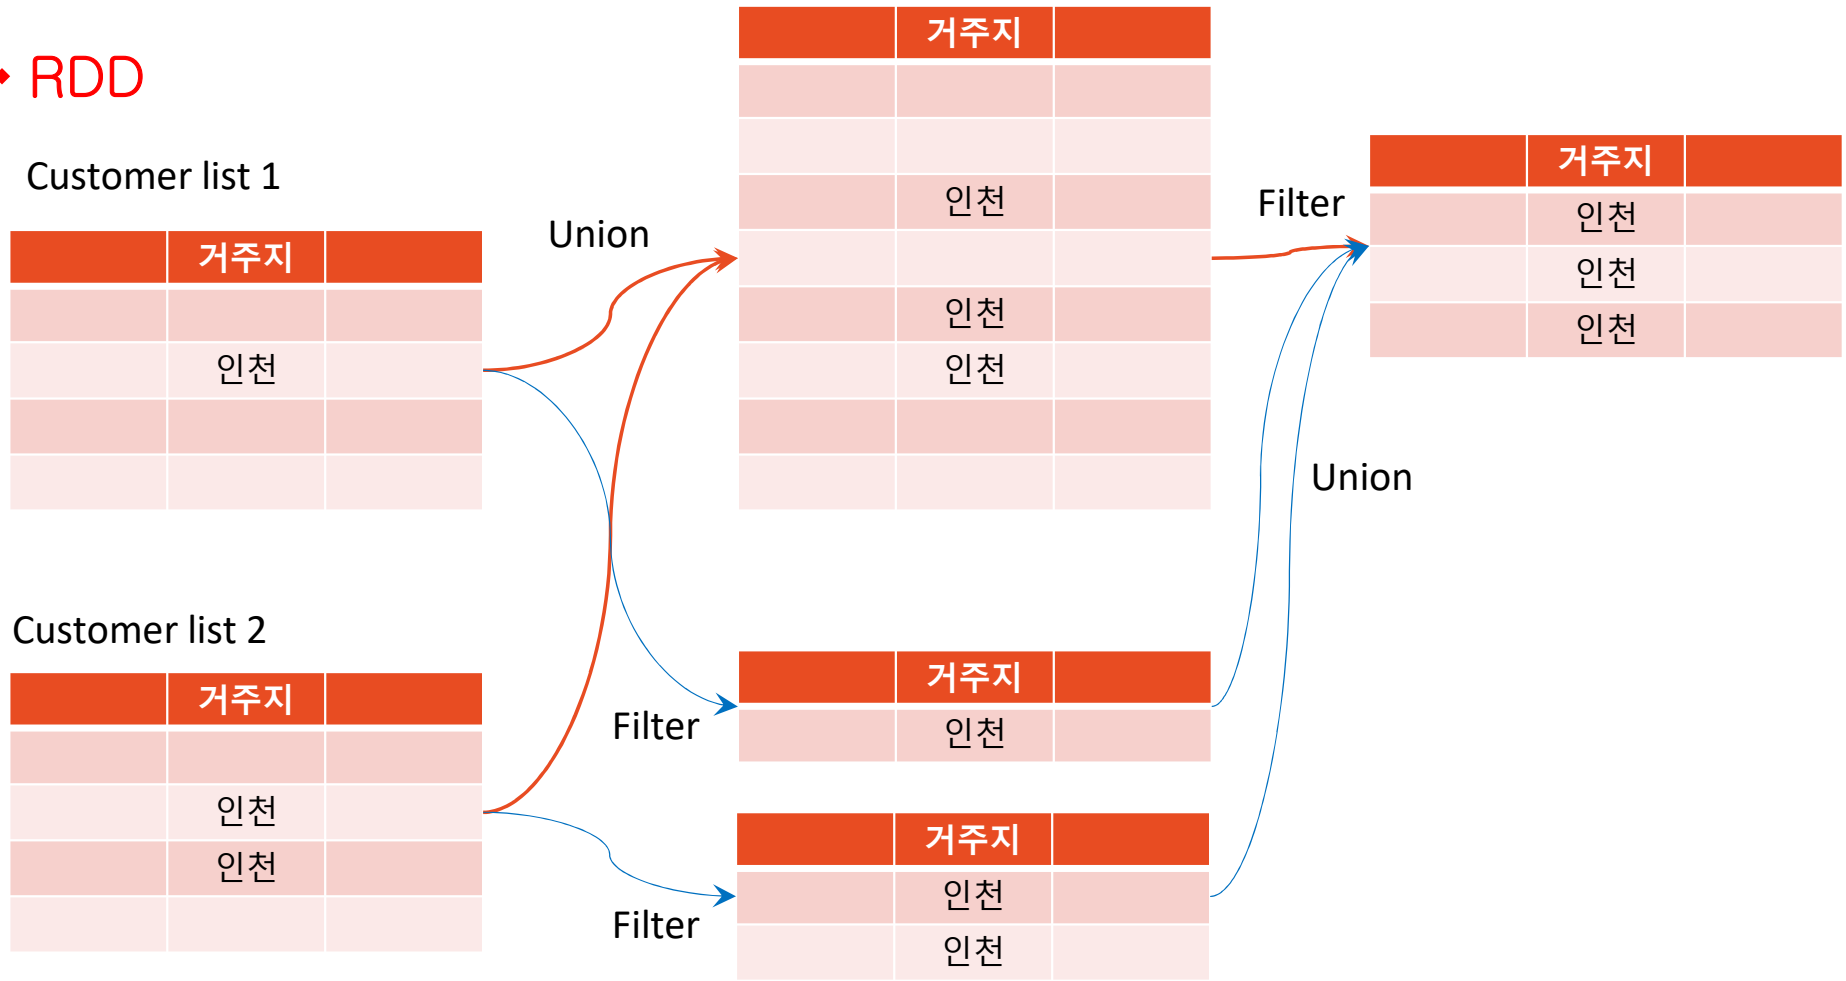
Customer list 1
거주지
인천
Customer list 2
거주지
인천
인천
Union
Filter
Filter
거주지
인천
인천
인천
거주지
인천
거주지
인천
인천
Filter
거주지
인천
인천
인천
Union

❖ DataFrames

- Row object를 포함하고 있음
- Schema를 가지고 있음
- SQL query를 실행할 수 있음
- JSON, Hive, parquet에 쓰거나 읽을 수 있음
- JDBC/ODBC, Tableau와 통신할 수 있음
- Catalyst optimizer를 통해 실행 시점에 코드를 최적화하여 성능 향상

이름	국어	영어	수학	총점
김민수	80	75	77	232
채영희	78	80	85	243
이수현	90	83	89	262
⋮	⋮	⋮	⋮	⋮
박승호	88	77	91	256

Row

❖ Dataset

- Spark 1.6에서 추가됨
- 데이터 처리 속도를 더욱 증가시킴
- Spark 2.0에서 DataFrame과 Dataset을 통합

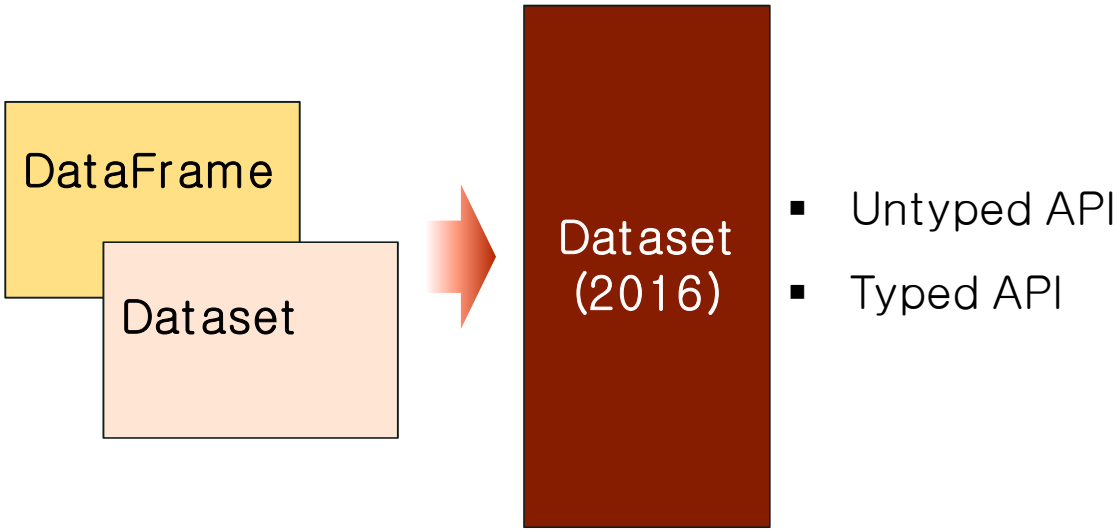

❖ Dataset

- Untyped API와 Strongly-typed API 2가지 특징을 가지고 있음
  - Untyped API: DataFrame, Row 객체 단위
  - Strongly-typed API: Dataset, Class object(사용자 정의 객체)
- 데이터에 문제가 있는 경우, Untyped API(DataFrame)는 runtime 시점에서 오류를 찾을 수 있으나, Strongly-typed API(Dataset)은 compile 시점에서 오류를 찾을 수 있음
- 높은 수준의 API로 사용 가능함

  –agg, select, sum, avg, map, filter, groupby 등

Summary

○ Spark

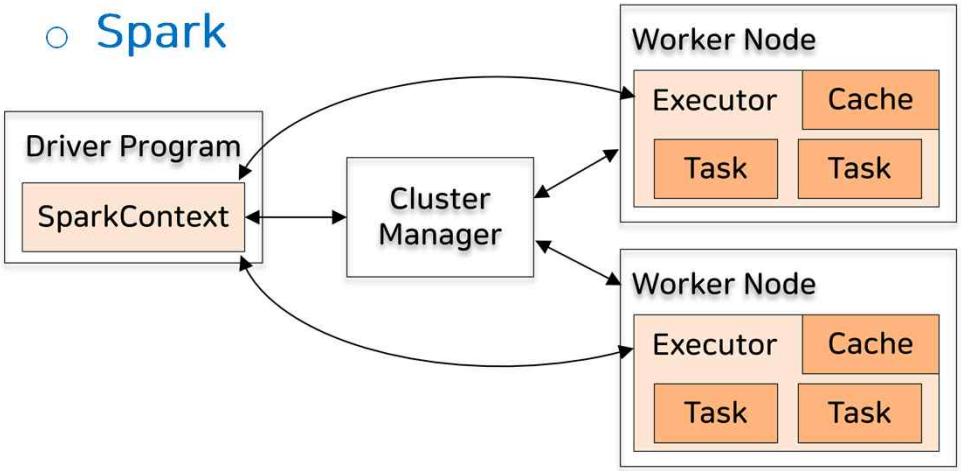

SparkContext

Spark Platform의 실행 engine, 외부로부터 memory 내 컴퓨팅 및 참조 데이터셋 제공

Spark SQL	Spark Streaming	MLlib	GraphX
• Spark의 SQL 인터페이스 • SQL query 또는 SQL 유사함수를 통해 Spark의 data 변환	• 실시간으로 streaming data를 처리할 수 있음	• Spark data에 적용하는 machine learning이나 data mining library	• 대용량 data의 분산 및 병렬 그래프 처리 지원