데이터의 가치와 미래

• MODULE 2

모듈 2-1

빅데이터의 이해

데이터의 가치와 미래

- 빅데이터의 정의
  - "빅데이터는 막대한 양(수십 테라바이트 이상)의 정형 및 비정형 데이터
  - 데이터로부터 가치를 추출하고 결과를 분석하는 기술의 의미로도 통용됨

데이터의 가치와 미래

- 빅데이터의 정의
  - "빅데이터는 일반적인 데이터베이스 소프트웨어로 저장, 관리, 분석할 수 있는 범위를 초과하는 규모의 데이터이다"(McKinsey, 2011)
    - ➢ 이는 활용하는 데이터 규모에 중점을 둔 정의
  - "빅데이터는 다양한 종류의 대규모 데이터로부터 저렴한 비용으로 가치를 추출하고 데이터의 초고속 수집·발굴·분석을 지원하도록 고안된 차세대 기술 및 아키텍처이다"(IDC, 2011)
    - ➢ 분석비용 및 기술에 초점을 맞춘 정의
  - "빅데이터란 대용량 데이터를 활용해 작은 용량에서는 얻을 수 없었던 새로운 통찰이나 가치를 추출해내는 일이며 나아가 이를 활용해 시장, 기업 및 시민과 정부의 관계 등 많은 분야에 변화를 가져오는 일(Mayer-Schonberger&Cukier, 2013)
    - ➢ 빅데이터로 인해 나타난 사회·정치 ·경제 ·문화적 변화의 정의

데이터의 가치와 미래

- 빅데이터의 정의
  - 데이터의 양(Volume), 데이터 유형과 소스 측면의 다양성(Variety), 데이터 수집과 처리 측면에서 속도(Velocity)의 3가지 측면의 급증으로 나타난 현상(가트너그룹 더그래니)
  - 협의의 정의로 정형 및 비정형 데이터를 말하며 광의적 의미로 인재조직, 데이터 처리 축적 분석기술, 데이터 등 3요소를 가지고 있음(노무라연구소)
  - 기존 데이터베이스 관리 도구의 데이터 수집, 저장, 분석의 역량을 넘어서는 대량(수십 테라바이트 이상)의 정형 또는 비정형 데이터 세트 및 이러한 데이터로부터 가치를 추출하고 결과를 분석하는 기술(위키피디아)

데이터의 가치와 미래

- 빅데이터의 특징

데이터 변화

- 규모(데이터의 양)
- 형태(다양성)
- 속도(처리속도 증가)

기술 변화

- 새로운 데이터 처리, 저장, 분석기술 및 아키텍처
- 클라우드 컴퓨팅 활용

인재·조직 변화

- 새로운 인재 필요(예:데이터사이언티스트)
- 데이터 중심 조직

➢ 기존 방식으로 얻을 수 없었던 통찰 및 가치창출

➢ 사업방식, 시장, 사회, 정부 등에서 변화와 혁신 주도

데이터의 가치와 미래

- 빅데이터의 특징
  - 가트너 그룹의 더그 래니는 데이터의 양(Volume), 데이터의 유형과 소스 측면의 다양성 (Variety), 데이터 수집과 처리 관점의 속도(Velocity)를 빅데이터 특징 3V로 정의함
  - 최근에는 5V(Value, Veracity 추가), 7V(Validity, Volatility 추가)로 확장되었음

특징	설명
규모 (Volume)	• ICT기술 발전으로 과거의 텍스트 데이터부터 SNS로부터 수집되는 사진, 동영상 등의 다양한 멀티미디어 데이터까지 디지털 정보량의 기하급수적 증가
다양성 (Variety)	• 정형 데이터뿐만 아니라 비정형, 반정형 데이터를 포함
속도 (Velocity)	• 사물 정보(센서, 모니터링), 스트리밍 정보 등 실시간성 정보의 생성 속도 증가에 따라 처리 속도 가속화 요구
가치 (Value)	• 비즈니스나 연구에 활용되어 유용한 가치를 끌어낼 수 있는가에 대한 문제 • 빅데이터의 가치는 데이터의 정확성 및 시간성과 관련됨

데이터의 가치와 미래

- 빅데이터의 특징
  - 가트너 그룹의 더그 래니는 데이터의 양(Volume), 데이터의 유형과 소스 측면의 다양성 (Variety), 데이터 수집과 처리 관점의 속도(Velocity)를 빅데이터 특징 3V로 정의함
  - 최근에는 5V(Value, Veracity 추가), 7V(Validity, Volatility 추가)로 확장되었음

특징	설명
신뢰성 (Veracity)	• 방대한 데이터에서 노이즈 및 오류 제거를 통해 활용 데이터에 대한 품질과 신뢰성 제고 요구
정확성 (Validity)	• 데이터의 규모가 아무리 크더라도 질 높은 데이터를 활용한 정확한 분석 수행이 없다면 의미가 없음
휘발성 (Volatility)	• 데이터가 얼마나 오래 저장될 수 있고, 타당하며 오랫동안 쓰일 수 있을지에 관한 사항

데이터의 가치와 미래

- 빅데이터의 유형

  - 빅데이터 유형은 데이터의 구조적 관점에서 정형, 반정형, 비정형 데이터로 구분됨

유형	설명
정형 데이터	• 정형화된 구조, DBMS에 내용이 저장될 수 있는 구조 • 고정된 필드에 저장된 데이터 • 예시) 관계형 데이터베이스, 엑셀, ERP, CRM, SCM 등
반정형 데이터	• 데이터 내부에 데이터 구조에 대한 메타 정보가 포함된 구조 • 고정된 필드에 저장되어 있지만 메타데이터나 데이터 스키마 정보를 포함하는 데이터 • 예시) XML, HTML, JSON, 로그 형태(웹 로그, 센서데이터 등), 모바일 데이터, 기상청 날씨 데이터 등
비정형 데이터	• 수집 데이터 각각이 데이터 객체로 구분 • 고정 필드 및 메타데이터가 정의되지 않음 • 예시) 자유형식의 텍스트 문서, 이미지, 음성, 동영상, QR코드 등

데이터의 가치와 미래

- 빅데이터 출현배경

구분	변화
학계	▪ 대량 데이터를 취급하는 학문 분야가 증가하면서 기술 아키텍처 및 통계 도구들이 지속적으로 발전 ▪ NASA의 기후 시뮬레이션센터에서는 약 32페타바이트(1페타바이트→1024테라바이트)의 기후관찰 정보를 활용해 슈퍼컴퓨터에서 시뮬레이션하고 있음
산업계	▪ 여러 거대 기업들이 온라인과 오프라인을 가리지 않고 사용자 및 소비자 행태 정보를 적극 수집·분석해 경영·경쟁전략에 활용하고 있음 ▪ 기업에서 가치 창출이 가능할 만큼 충분한 규모의 고객 데이터가 축적되고 활용이 증가함
기술 발전	▪ 디지털화의 급진전, 저장 기술의 발전과 가격하락, 인터넷의 발전과 모바일 시대의 진전에 따른 클라우드 컴퓨팅이 보편화되었음

데이터의 가치와 미래

- 빅데이터 기능
  - 산업혁명의 석탄과 철
    - ➢ 농업 중심의 1차 산업시대에 증기기관과 철도 도입으로 제조업의 생산성이 획기적으로 증가하여 사회전체가 2차산업시대로 옮겨 갔듯이 빅데이터는 지금의 제조업뿐 아니라 서비스 분야의 생산성을 획기적으로 끌어 올릴 것이라 기대됨
  - 21세기의 원유
    - ➢ 원유는 전기를 만드는 것부터 내연기관의 원료로서 각종 동력을 제공하는 에너지원으로 빅데이터도 각종 비즈니스, 공공기관 대국민 서비스 등에 필요한 정보를 제공함으로써 산업전반의 생산성을 향상시킬 것이라 기대됨

데이터의 가치와 미래

- 빅데이터 기능
  - 렌즈
    - ➢ 현미경의 렌즈가 발달하면서 각종 식물과 동물의 세포에서 일어나는 수많은 메커니즘을 밝혀내고 세포핵에 들어있는 DNA 구조까지 읽어낼 수 있게 되었듯이 수천만 권의 책을 디지털화해 빅데이터 서비스를 제공하는 것과 같이 방대한 데이터가 산업 전반에 대한 통찰을 가능하게 해줌
  - 플랫폼
    - ➢ 기존에 플랫폼이라 불리던 운영체제(OS: Operating System) 위에 수많은 소프트웨어가 작동했듯이 다양한 사람들이 공동으로 사용하는 플랫폼을 빅데이터 형태로 제공하여 이 데이터에 접근할 수 있도록 공개하여 빅데이터 자체가 플랫폼 역할을 수행하게 됨

데이터의 가치와 미래

- 빅데이터로 인한 본질적 변화
  - 사전처리 → 사후처리
    - ➢ 사전처리의 개념은 필요한 정보만 수집하고 필요하지 않은 정보를 버림으로 시스템으로 달성할 수 있는 효율성을 만들어 내는 것(예: 표준화한 문서포맷의 경우 원하는 정보만 수집하고 그 외 정보 수집은 포기)
    - ➢ 빅데이터 시대는 이미 가치가 있을 것이라고 정해진 특정한 정보만 모아서 처리하는 것이 아니라 가능한 한 많은 데이터를 모으고 그 데이터를 다양한 방식으로 조합
  - 표본조사 → 전수조사
    - ➢ 표본조사는 기본적으로 분석하고자 하는 바를 정하고 그에 필요한 정보를 수집하는 것이기에 질문이 바뀌면 데이터를 바뀐 질문에 맞도록 다시 수집해야 함
    - ➢ 전수조사의 경우 모든 데이터를 모아 놓기때문에 바뀐 질문에 따라 다양한 방식으로 데이터를 재가공할 수 있음

데이터의 가치와 미래

- 빅데이터로 인한 변화
  - 질 → 양
    - ➢ 빅데이터 성공사례로 구글의 자동번역 시스템 구축이 있음
    - ➢ IBM의 경우 의회에서 번역한 것처럼 고도로 정교하게 번역된 말뭉치를 중심으로 데이터베이스를 구축하였지만 구글은 번역에 참고할 말뭉치 데이터베이스에 오역이 있는 웹사이트 정보까지 다 수용함
    - ➢ IBM의 데이터베이스는 수백만건 수준이었지만 구글은 수십억건에 이르렀으며 이는 데이터가 지속적으로 추가될 때 양질의 정보가 오류 정보보다 많기에 전체적으로 좋은 결과가 나올 수 있음을 보여준 예임

데이터의 가치와 미래

- 빅데이터로 인한 변화
  - 인과관계 → 상관관계
    - ➢ 인과관계의 규명없이 상관관계로 비즈니스를 성공으로 이끈 사례로 아비바(Aviva)라는 보험회사는 보험 가입자들의 소득추정치, 취미, 방문웹사이트, TV시청습관 등의 정보를 이용하여 혈액 및 소변검사 없이 고혈압, 당뇨, 우울증과 같은 질병에 걸릴 확률을 예측함
    - ➢ 취미나 TV시청 습관이 고혈압과 어떤 인과관계가 있는지 설명하기는 쉽지 않지만 이 회사는 병원샘플 테스트에 소요했던 비용의 1/25로 좋은 예측결과를 가져왔음

퀴즈

- 다음 중 빅데이터 특징으로 옳지 않은 것은?

① 데이터 분석의 영향으로 표본조사가 중요한 기법으로 대두되고 있다.

② 데이터의 질보다 양을 강조한다.

③ 신속한 의사결정이 필요한 비즈니스에서는 인과관계보다 상관관계 분석으로 충분한 경우가 많다.

④ 사전 처리에서 사후처리 시대로 변화하였다.

퀴즈

- 데이터의 유형 중 정형 데이터 – 반정형 데이터 – 비정형 데이터 순서로 가장 바르게 나열한 것은?

① CRM 데이터 – 카카오톡 대화 데이터 - XML

② RFID – IoT 센서 데이터 - 보고서

③ 인스타그램 게시물 – 기상청 날씨 데이터 – 웹 로그 데이터

④ 물류 창고 재고 데이터 – XML – 이메일 전송 데이터

퀴즈

- 다음 중 빅데이터 출현 배경에 관한 설명으로 가장 올바르지 않은 것은?

① 데이터 구조는 분석 및 수집 관리가 가능한 형태로 정형화되었다.

② 데이터 생산량이 인터넷, 모바일 발전, SNS, IoT의 확산으로 증가하였다.

③ 데이터 저장기술은 발전하였고 가격은 하락하였다.

④ 기업이 데이터 축적 및 활용에 대한 필요성을 인지하였다.

퀴즈

- 다음 중 빅데이터를 분석할 때 처리 비용을 절감해준 결정적인 기술로 가장 적절한 것은?

① 텍스트 마이닝

② 5G 통신 기술의 발달

③ 인터넷의 확산

④ 클라우드 컴퓨팅

퀴즈

- 다음 중 빅데이터의 특징을 설명할 수 있는 4V에 속하지 않는 것은?

① 규모(Volume)

② 다양성(Variety)

③ 정확성(Validity)

④ 속도(Velocity)

퀴즈

- 다음 중 빅데이터 현상의 출현 배경으로 가장 옳지 않은 것은?

① 산업계에서의 고객 데이터 축적 및 활용 증가

② 학계에서의 대량 데이터를 활용하는 과학의 확산

③ 정부 주도의 공공데이터 개발 확산

④ 클라우드 컴퓨팅 등 ICT 기술의 발달

퀴즈

- 다음 중 데이터 유형이 나머지와 다른 것은?

① 고객센터에 접수된 고객의 불만 사항을 녹음한 음성 파일

② 지하철에 설치된 CCTV의 영상데이터

③ 기계에서 발생한 소음을 측정한 데시벨 단위의 센서데이터

④ SNS에 등록이 된 어느 제품의 사용 후기

퀴즈

- 일반적으로 통용되고 있는 빅데이터의 정의와 거리가 먼 것은?

① 빅데이터는 일반적인 데이터베이스 소프트웨어로 저장,관리,분석할 수 있는 범위를 초과하는 규모의 데이터이다.

② 빅데이터는 다양한 종류의 대규모 데이터로부터 저렴한 비용으로 가치를 추출하고 데이터의 초고속 수집,발굴,분석을 지원하도록 고안된 차세대 기술 및 아키텍처이다.

③ 빅데이터는 데이터의 양, 데이터의 유형과 소스 측면의 다양성, 데이터 수집과 처리 측면에서 속도의 3가지 측면의 급증으로 나타난 현상이다.

④ 빅데이터는 하둡을 기반으로 하는 대용량의 분산처리 기술이다.

퀴즈

- 빅데이터가 만든 본질적인 변화와 거리가 먼 것은?

① 정보기술의 발전으로 필요한 데이터만 수집하고 필요하지 않은 정보를 버리는 방식으로 변화하고 있다.

② 클라우드 컴퓨팅 기술의 발전으로 데이터 처리 비용이 급격히 감소하고 있다.

③ 데이터 규모가 커지면 소수의 오류데이터는 전체 데이터에 영향을 미치지 못하는 경향이 발생한다.

④ 비즈니스에서 인과관계보다 실시간 상관관계 분석에서 도출된 인사이트로 수익을 창출할 기회가 늘어나고 있다.

퀴즈

- 빅데이터가 만든 본질적인 변화에 대한 설명 중 적절하지 않은 것은?

① 사전 처리에서 사후 처리시대로의 변화

② 표본조사에서 전수조사로의 변화

③ 질보다 양을 강조하는 변화

④ 상관관계에서 인과관계로의 변화

퀴즈

- 빅데이터의 성공 사례 중 구글의 자동번역 시스템은 빅데이터의 어떤 특징에 해당하는가?

  ① 규모

  ② 가치

  ③ 속도

  ④ 다양성

모듈 2-2

빅데이터의 가치와 영향

데이터의 가치와 미래

- 빅데이터의 가치
  - 빅데이터의 가치 선정이 어려운 이유
    - ➢ 데이터의 재사용이나 재조합, 다목적용 데이터 개발 등이 일반화되면서 특정 데이터를 언제, 어디서, 누가 활용할지 알 수 없음
    - ➢ 다목적용 데이터 개발의 사례(CCTV를 통해 데이터를 수집할 때 데이터 수집가는 절도범을 구별해낼 뿐만 아니라 고객의 구매 정보도 동시에 얻을 수 있는 곳에 CCTV를 설치함)
    - ➢ 데이터가 기존에 없던 가치를 창출함에 따라 그 가치를 측정하기 어려움(예시: 아마존은 전자책 읽기 관련 데이터를 분석해 저자들에게 독자들이 어느 부분을 좋아하는지 등을 알려줄 수 있음)
    - ➢ 이러한 정보를 저자에게 주는 가치는 이전에 없던 것으로 어느 정도의 가치가 있는지 측정하기 어려움
    - ➢ 분석기술이 발달함에 따라 데이터의 가치에 영향을 줌(예시: 과거에는 분석비용이 높아 분석할 수 없던 빅데이터를 클라우드 분산 컴퓨팅에서 저렴한 비용에 분석하면서 활용도가 증가하고 있음(예시: 텍스트 마이닝을 통한 SNS 분석)

데이터의 가치와 미래

- 빅데이터의 영향
  - 빅데이터가 가치를 만들어 내는 방식(빅데이터 보고서, 2011, 맥킨지)
    - ➢ 투명성 제고로 연구개발 및 관리 효율성 제고
    - ➢ 시뮬레이션을 통한 수요 포착 및 주요 변수 탐색으로 경쟁력 강화
    - ➢ 고객 세분화 및 맞춤 서비스 제공
    - ➢ 알고리즘을 활용한 의사결정 보조 혹은 대체
    - ➢ 비즈니스 모델과 제품, 서비스의 혁신

데이터의 가치와 미래

- 빅데이터의 영향
  - 기업
    - ➢ 소비자의 행동을 분석하고 시장 변동을 예측해 비즈니스 모델을 혁신하거나 신사업을 발굴할 수 있음
    - ➢ 원가절감, 제품 차별화, 기업활동의 투명성 제고 등에 활용하면 경쟁사 대비 강한 경쟁력을 확보할 수 있음
    - ➢ 빅데이터의 활용으로 기업들의 운용 효율성이 증가하면 산업 전체의 생산성이 향상되고 국가 전체로서는 GDP(국내 총생산)가 올라가는 효과를 얻을 수 있음

데이터의 가치와 미래

- 빅데이터의 영향
  - 정부
    - ➢ 기상, 인구이동, 각종 통계, 법제 데이터 등을 수집해 사회 변화를 추정하고 각종 재해 관련 정보를 추출할 수 있음
    - ➢ 수집된 데이터를 바탕으로 사회관계망 분석이나 시스템 다이내믹스, 복잡계 이론과 같은 분석방식을 적용해 미래 의제를 도출할 수 있음
      - ✓ 시스템 다이내믹스: 사업이나 사회 시스템 등과 같은 복잡한 시스템을 연구하고 관리하는 방법
    - ➢ 도출한 미래 의제에 대한 대응 방안 역시 빅데이터를 통해 얻을 수 있음
  - 개인
    - ➢ 빅데이터 활용대상의 위치에 머물러 있지만 빅데이터를 서비스로 제공하는 기업들이 출현하여 적시에 필요한 정보를 획득할 수 있으며 저렴한 비용으로 활용할 수 있음

퀴즈

- 다음 중 빅데이터의 가치 산정이 어려운 이유로 가장 옳지 않은 것은?

① 기존 사업자에게 경쟁 우위를 가져다준다.

② 비용 문제로 인해 분석할 수 없었던 것을 저렴한 비용으로 분석할 수 있다.

③ 기존에 없던 새로운 가치를 창출한다.

④ 기존 데이터를 재사용, 재조합을 통해 새로운 가치를 창출할 수 있다.

퀴즈

- 다음 중 빅데이터 가치를 산정하기 어려운 이유로 가장 옳은 것은?

① 새로운 가치 창출

② 데이터의 폭증

③ 분석기술의 난이도 상승

④ 기업 경영의 난이도 상승

모듈 2-3

비즈니스 모델

데이터의 가치와 미래

- 빅데이터 활용 사례
  - 기업
    - ➢ 월마트: 고객의 구매 패턴을 분석해 상품 진열에 활용(허리케인이 올 때 손전등뿐만 아니라 비상음식 구매가 증가한 것을 보고 손전등과 비상음식을 함께 진열해 매출을 증대시킴)
    - ➢ 구글: 사용자의 로그 데이터를 활용하여 웹사이트 페이지의 중요도를 측정하는 알고리즘을 혁신하여 검색 결과를 개선함
    - ➢ IBM: 인공지능 컴퓨터인 왓슨을 병원에서 활용함(예: 신생아 인큐베이터)
    - ➢ 아마존: 전자책 독자의 데이터 기록을 분석하여 저자에게 제공함

데이터의 가치와 미래

- 빅데이터 활용 사례
  - 정부
    - ➢ 환경: 실시간 교통정보 수집, 기후 정보, 각종 지질 활동 모니터링 서비스를 위해 빅데이터 활용
    - ➢ 안전: 미국의 국가안보국(NSA)은 소셜미디어, CCTV, 통화기록, 문자 등을 모니터링하고 분석결과를 국가 안전확보 활동에 활용함
    - ➢ 의료 및 교육: 의료와 교육 빅데이터를 활용해 개선을 위한 해결책을 모색함

데이터의 가치와 미래

- 빅데이터 활용 사례
  - 개인
    - ➢ 정치인: 선거 승리를 위해 사회관계망 분석을 통해 유세 지역을 선정하고 해당 지역의 유권자에게 영향을 줄 수 있는 내용을 선정해 선거 활동 수행
    - ➢ 가수: 팬들의 음악 청취 기록 분석을 통해 실제 공연에서 부를 노래의 순서를 정하는 것에 활용

데이터의 가치와 미래

- 빅데이터 활용 사례
  - 산업
    - ➢ 의료·건강: 질병의 예후 진단 및 처방, 헬스케어 플랫폼 등을 통한 개인 건강정보의 축적
    - ➢ 과학기술: 주요 분야의 연구·개발 성과물을 바탕으로 대규모 과학기술 빅데이터 공유·활용 플랫폼 구축
    - ➢ 정보보안: 빅데이터 분석을 통해 해킹 등의 보안사고 징후 파악 및 조기 대응 시스템 구축
    - ➢ 제조: 완제품의 품질향상 등을 위해 빅데이터 시스템을 구축함
    - ➢ 소비·거래: 구매 패턴 및 트랜잭션 분석을 통한 소비 트랜드 예측
      - ✓ 트랜잭션: 업무 처리의 최소단위
    - ➢ 교통·물류: 수요예측, 물류·유통체계 최적화

데이터의 가치와 미래

- 빅데이터 활용 기본 테크닉
  - 연관분석
    - ➢ '커피를 구매하는 사람이 탄산음료를 더 많이 사는가?라는 문제에 답하고자 할 때 사용하는 기법으로 어떤 변인들 간에 주목할 만한 상관관계가 있는지를 찾아내는 방법
  - 분류분석
    - ➢ ' 이 사용자는 어떤 특성을 가진 집단에 속하는가?'와 같은 문제를 해결하고자 할 때 사용하여 새로운 사건이 속하게 될 범주를 찾아낼 때 이용되며 개인의 신용도 평가에 많이 사용됨
  - 유전자 알고리즘
    - ➢ '최대의 시청률을 얻으려면 어떤 프로그램을 어떤 시간대에 방송해야 하는가?', '응급실에서 의사를 어떻게 배치하는 것이 가장 효율적인가?'와 같은 문제를 해결할 때 사용되며 최적화가 필요한 문제의 해결책을 위해 사용됨

데이터의 가치와 미래

- 빅데이터 활용 기본 테크닉
  - 기계학습
    - ➢ '기존의 시청 기록을 바탕으로 시청자가 현재 보유한 영화 중에서 어떤 것을 가장 보고 싶어할까?'와 같은 예측의 문제를 해결할 때 사용됨(예: 유튜브 및 넷플릭스의 미디어 추천 시스템 등)
  - 회귀분석
    - ➢ '구매자의 나이가 구매 차량의 타입에 어떤 영향을 미치는가?' 같은 질문에 답할 때와 같이 독립변수와 종속변수의 관계를 파악함

데이터의 가치와 미래

- 빅데이터 활용 기본 테크닉
  - 감성분석
    - ➢ '새로운 환불정책에 대한 고객의 평가는 어떤가?'와 같이 특정 주제에 대한 사람의 감정을 분석함
    - ➢ 사용자가 사용한 문장에서 긍정적, 부정적인 단어의 발생 빈도를 파악함
    - ➢ 예) 6.25 전쟁의 아픔을 형제의 우애를 통해 너무 애절하게 잘 나타내었습니다. 영화를 보는 내내 눈물이 멈추질 않았습니다 → (6.25, 전쟁, 아픔, 형재, 우애, …) → (긍정 50%, 중립 40%, 부정 10%) → 좋은 호평을 받은 영화

데이터의 가치와 미래

- 빅데이터 활용 기본 테크닉
  - 소셜네트워크 분석
    - ➢ 개인과 집단 간의 관계를 노드와 링크로 그룹에 속한 사람들 간의 네트워크 특성과 구조를 분석하고 시각화하는 분석기법으로 '특정인과 다른 사람이 몇 촌정도의 관계인가?'를 파악할 때 사용하며 영향력 있는 사람을 찾아낼 수 있음

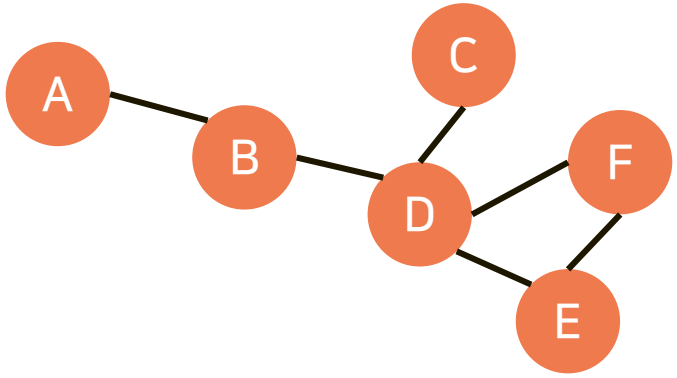

데이터의 가치와 미래

- 빅데이터 활용 기본 테크닉
  - 소셜네트워크 분석
    - ➢ 측정지표

측정지표	설명
연결정도	• 노드 간의 총 연결 관계 개수 • 한 노드가 몇 개의 노드와 연결되어 있는지의 정도
포괄성	• 네트워크 내에서 서로 연결된 노드의 개수
밀도	• 네트워크 내에서 노드 간의 전반적인 연결 정도 수준을 나타내는 지표 • 연결망 내 전체 구성원이 서로 간에 얼마나 많은 관계를 맺고 있는지를 표현

데이터의 가치와 미래

- 빅데이터 활용 기본 테크닉
  - 소셜네트워크 분석
    - ➢ 측정지표

<table>
<tr><th>측정지표</th><th>설명</th></tr>
<tr><td>중심성</td><td>• 노드의 상대적 중요도를 나타내는 척도
<table>
<tr><td>연결정도 중심성</td><td>• 특정 노드가 연결망내에서 직접 연결된 노드 또는 링크의 수</td></tr>
<tr><td>근접 중심성</td><td>• 각 노드 간의 거리를 바탕으로 중심성을 측정하는 방식</td></tr>
<tr><td>매개 중심성</td><td>• 특정 노드가 다른 노드들 사이에 위치하는 정도를 나타냄</td></tr>
<tr><td>위세 중심성</td><td>• 자신의 연결정도 중심성으로부터 발생하는 영향력과 자신과 연결된 타인의 영향력을 합하여 결정하는 방법</td></tr>
</table></td></tr>
</table>

데이터의 가치와 미래

- 기계학습 기반 분석 기법

기법	설명	활용 기법
지도학습	• 정답인 레이블에 포함되어 있는 학습 데이터를 통해 컴퓨터에게 학습시키는 방법 • 설명변수와 종속변수 간의 관계성을 표현하거나 예측함 • 인식, 분류, 진단, 예측 등의 문제해결에 적합	• 로지스틱 회귀, 인공신경망 분석, 의사결정나무 등
비지도학습	• 입력 데이터에 대한 정답인 레이블이 없는 상태에서 학습 데이터를 학습시키는 방법	• 군집분석, 연관분석, 자기 조직화 지도 등
강화학습	• 컴퓨터가 선택한 행동에 대한 반응에 따라 보상이 주어지며 보상을 최대화하는 행동 혹은 순서를 통해 학습을 진행	• 몬테카를로 학습, Q-learning

퀴즈

- 다음 중 빅데이터 활용 사례 관련성이 적절하지 않은 것은?

① 구글 – 사용자의 로그 데이터를 기존 페이지 랭크 알고리즘을 혁신, 다양한 차원의 신호를 추가하여 검색결과를 개선하였다.

② 월마트 – 고객의 구매 패턴을 분석해 상품 진열에 활용한다.

③ 페이스북 – 실시간 번역 서비스를 제공한다.

④ 아마존 – 전자책 독자의 데이터 기록을 분석하여 저자에게 제공한다.

퀴즈

- 다음은 빅데이터의 활용 기법 중 무엇에 대한 설명인가?

  커피를 구매하는 사람이 탄산음료를 더 많이 사는지 알아본다.

  ① 분류 분석

  ② 감정 분석

  ③ 연관 분석

  ④ 회귀 분석

퀴즈

- 다음 중 빅데이터 활용 기법 중 무엇에 관한 설명인가?

  최적화가 필요한 문제의 해결책을 자연선택, 돌연변이 등과 같은 메커니즘을 통해 점진적으로 진화시켜 나가는 방법이다.

  택배 차량을 어떻게 배치하는 것이 비용에 효율적인가?와 같은 문제를 해결할 때 사용된다.

퀴즈

- 다음 중 비즈니스 모델에서 빅데이터 분석 방법과 사례를 연결한 것으로 올바르지 않은 것은 무엇인가?

① 치킨을 먹는 사람은 어떤 종류의 음료를 많이 마실까? - 연관분석

② 응급실에서 응급 처리 프로세스를 어떻게 배치하는 것이 가장 효율적인가? - 분류분석

③ 고객들 간 관계망은 어떻게 구성되어 있는가? – 소셜네트워크 분석

④ 고객의 나이가 구매 차량의 유형에 어떤 영향을 미치는가? - 회귀분석

퀴즈

- 다음 중 감성분석에 대한 설명으로 가장 부적절한 것은?

① 제품에 대한 평판을 알아내고자 할 때 사용한다.

② 문장의 긍정, 부정에 대한 평가는 측정 주체에 따라 달라질 수 있다.

③ 문장에서 긍정적, 부정적인 단어의 발생 빈도를 파악한다.

④ 그룹에 속한 사람들 간의 네트워크 특성과 구조를 분석한다.

퀴즈

- 보기에서 설명하는 빅데이터 분석기법은?

  사용자는 어떤 특성을 가진 집단에 속하는가?와 같은 문제를 해결할 때 사용한다.

  문서를 분류하거나 조직을 그룹으로 나눌 때 온라인 수강생들을 특성에 따라 분류할 때 사용한다.

퀴즈

- 다음 데이터 분석기법에 대한 설명 중 가장 부적절한 것은?

① 소셜 네트워크 분석은 최근 핀테크 기업에서 대출을 제공할 때 활용되고 있다.

② 기계학습은 대규모 데이터를 처리 분석할 때 상당한 분석 인프라와 많은 시간이 소요될 수 있다.

③ 한국어는 언어적 특성으로 감성 분석에서 상대적으로 어려운 측면이 있다.

④ 개인의 신용도 평가에 가장 많이 활용되는 것은 연관 분석이다.

퀴즈

- 다음은 빅데이터 활용 기술에 관한 설명이다. 적절하지 않은 것은?

① 택배 차량을 어떻게 배치하는 것이 비용에 효율적인가? - 분류분석

② 응급실에서 의사를 어떻게 배치하는 것이 가장 효율적인가? – 유전자 알고리즘

③ 우유 구매자가 기저귀를 더 많이 구매하는가? - 연관분석

④ 사용자의 만족도가 충성도에 어떤 영향을 미치는가? - 회귀분석

퀴즈

- 다음 중 빅데이터를 활용하는 영역으로 적합하지 않은 것은?

① 데이터 수집 및 저장

② 실시간 교통정보 수집, 지역 인구기반 상권 분석

③ 질병의 예후 진단 및 처방

④ 고객 맞춤형 구매 서비스 제공

퀴즈

- 아래에 주어진 사회연결망의 그림에서 노드 B의 연결정도 중심성은?

① 0.2

② 0.3

③ 0.4

④ 0.5

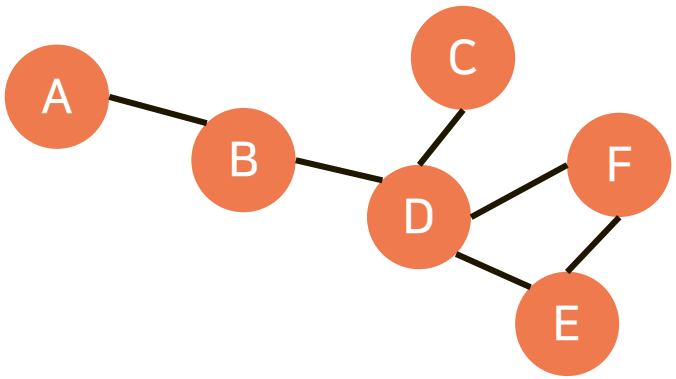

퀴즈

- 아래에 주어진 사회연결망의 그림에서 노드 B의 근접 중심성은?

① 1/2

② 1/3

③ 1/4

④ 1/5

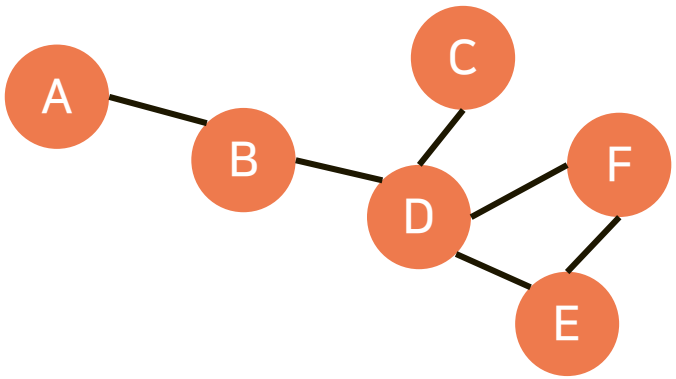

퀴즈

- 아래에 주어진 사회연결망의 그림에서 노드 B의 매개 중심성은?

① 2

② 3

③ 4

④ 5

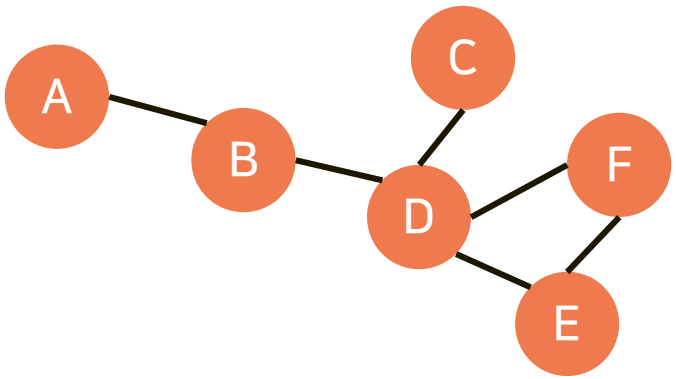

모듈 2-4

위기 요인과 통제 방안

데이터의 가치와 미래

- 위기 요인
  - 사생활침해
    - ➢ M2M(Machine to Machine)시대가 본격화되면서 우리를 둘러싼 정보 수집 센서들의 수가 점점 늘어나고 있으며 개인 정보의 가치가 증가함에 따라 보다 많은 사업자가 개인정보 습득에 보다 많은 자원을 투자하고 있음
    - ➢ 또한 특정 데이터가 본래 목적 외에 가공처리되어 2차·3차적 목적으로 활용될 가능성이 증가하면서 위험의 성격도 사생활침해를 넘어 사회·경제적 위협으로 변형될 수 있음
    - ➢ 이러한 상황을 방지하기 위해 익명화 기술이 발전하고 있으나 충분하지 않음
    - ➢ 2013년 가장 큰 정치 스캔들 가운데 하나는 미국 NSA(National Security Agency)가 매일 17억개의 이메일, 전화통화, 기타 통신 내용을 수집·저장하고 있다는 폭로였음

데이터의 가치와 미래

- 위기 요인
  - 책임 원칙의 훼손
    - ➢ 빅데이터 기반 분석과 예측 기술이 발전하면서 정확도가 증가하여 분석 대상이 되는 사람들은 예측 알고리즘의 희생양이 될 가능성이 올라감
    - ➢ 미국 경찰관들의 경우 컴퓨터 알고리즘 분석에 따라 특정지역을 순찰하며 강력범죄 발생률을 상당수 감소시켰으나 이를 조금 더 진전시키면 범죄 예측 프로그램에 의해 범행을 저지르기 전에 체포될 수도 있음
    - ➢ 이는 특정인이 빅데이터의 분석 결과에 따라 특정한 행위를 할 가능성이 높다는 이유만으로 처벌 받는 것으로 행위 결과에 대해서만 책임을 묻는다는 민주주의 사회 원칙을 훼손할 수 있음
    - ➢ 어떤 사람이 특정한 사회·경제적 특성을 가진 집단에 속한다는 이유로 자신의 신용도와 무관하게 부당하게 대출이 거절되는 상황도 알고리즘 예측의 피해 사례가 될 수 있음

데이터의 가치와 미래

- 위기 요인
  - 데이터의 오용
    - ➢ 베트남 전쟁 때 맥나마라는 적군 사망자 수를 전쟁의 진척 상황을 나타내는 지표로 활용하였음
    - ➢ 그 결과 적군 사망자 수는 과장되어 보고되는 경향이 강화되었으며 언론에 공개된 적군 사망자 수는 결과적으로 전쟁상황을 오도하는 결과를 가져왔음
    - ➢ 주어진 데이터에서 잘못된 인사이트를 얻어 비즈니스에 적용할 경우 손실을 불러올 수 있는데 예를 들어 구글이 검색 알고리즘에 잘못된 시그널을 사용할 경우 특정 거래 사이트가 검색 상단에서 밀려나 매출이 급감해 시장에서 퇴출될 가능성이 있음

데이터의 가치와 미래

- 위기요인의 통제 방안
  - 사생활침해 → 책임제의 시행
    - ➢ 사용자 정보는 수집된 후 한 번 사용하고 폐기되는 것이 아니라 1차적 목적 외에 2차·3차적 목적으로 가공·유통·활용될 수 있음
    - ➢ 개인정보의 활용에 대해 개인이 매번 동의하는 것은 경제적으로도 매우 비효율적이며 가능하지도 않은 상황이 발생할 수밖에 없음
    - ➢ 따라서 사생활침해 문제를 '개인정보 제공자의 동의'를 통해 해결하기 보다 '개인정보 사용자의 책임'으로 해결하는 것이 필요함

데이터의 가치와 미래

- 위기요인의 통제 방안
  - 책임원칙 훼손 → 결과 기반 책임 원칙
    - ➢ 특정 기업이 담합할 가능성이 높다고 판단한 예측 알고리즘의 판단을 근거로 해당 기업을 처벌하면 안되며 실제 담합한 결과에 대해 처벌해야 함
    - ➢ 특정인이 채용이나 담보대출, 신용카드 발급 여부 결정 등에서 예측 자료에 의해 불이익을 당할 가능성을 최소화하는 장치를 마련해야 함

데이터의 가치와 미래

- 위기요인의 통제 방안
  - 데이터 오용 → 알고리즘에 대한 접근권 제공
    - ➢ 알고리즘의 객관적 인증방안을 도입하자는 의견도 제시되고 있으며 알고리즘의 부당함을 반증할 수 있는 방법을 명시해 공개할 것을 주문하기도 함
    - ➢ 불이익을 받는 사람들을 대변해 피해자를 구제할 수 있는 능력을 가진 전문가(알고리즈미스트)가 필요하게 됨

퀴즈

- 다음 중 빅데이터 시대의 위기 요인으로 가장 올바르지 않은 것은?

① 사생활 침해

② 데이터 오용

③ 책임 원칙 훼손

④ 익명화

퀴즈

- 빅데이터 위기 요인 중 '책임 원칙의 훼손'에 대해 가장 적합한 사례는?

① 여행 사실을 페이스북에 올린 사람의 집을 도둑이 노리는 경우

② 잘못된 지표를 사용하는 경우

③ 범죄 예측 프로그램 때문에 범행이 발생하기 전에 체포

④ 미국 NSA가 매일 17억 개의 이메일, 전화통화 이력을 수집하고 저장하는 경우

퀴즈

- 다음 중 빅데이터로 인한 위기 요인과 통제 방안에 대한 설명으로 가장 올바르지 않은 것은?

① 데이터 오용의 위기 요소에 대한 대응책으로 알고리즘에 대한 접근권 보장과 알고리즈미스트가 필요하다.

② 특정인이 채용이나 담보 대출, 신용카드 발급 여부 결정 등에서 예측자료에 의한 불이익을 당할 가능성을 최소화하는 장치를 마련하는 것이 꼭 필요하다.

③ 사생활 침해 가능성도 함께 증가하자 개인정보 활용에 대한 정부 가이드라인 제정에 대한 요구가 급증하고 있다.

④ 사생활 침해의 통제 방안은 개인정보 활용에 대한 책임제를 동의제로 전환하는 것이다.

퀴즈

- 다음 중 빅데이터 위기 요인과 해결 방안을 연결한 것 중 잘못된 것을 고르시오.

㉠ 사생활 침해 → 동의제를 책임제로 전환

㉡ 책임 원칙의 훼손 → 알고리즘 접근 허용

㉢ 데이터 오용 → 결과 기반 책임 원칙

① ㉠, ㉡

② ㉠, ㉢

③ ㉡, ㉢

④ ㉠, ㉡, ㉢

퀴즈

- 빅데이터 위기 요인과 통제 방안으로 올바른 것은?

㉠ 사생활 침해의 위기 요인은 책임 원칙 강화뿐이다.

㉡ 알고리즘에 대한 접근 허용이 데이터 오용을 막을 수 있다.

㉢ 민주주의 사회의 책임 원칙에 따라 빅데이터 예측을 통한 통제를 강화해야 한다.

㉣ 책임 원칙의 훼손으로 인해 익명화의 기술이 발전되었다.

㉤ 알고리즈미스트는 데이터 오용의 피해를 막아주는 역할을 한다.

① ㉠, ㉡

② ㉡, ㉤

③ ㉠, ㉢

④ ㉣, ㉤

퀴즈

- 다음 중 빅데이터 시대의 위기와 통제에 대한 설명으로 타당한 것은?

㉠ 데이터 익명화는 사생활 침해에 대한 근본요인을 차단할 수 있어 빠른 기술 발전이 필요하다.

㉡ 빅데이터 분석은 일어난 일에 대한 데이터에 의존하므로 예측의 정확도는 높지만 항상 맞을 수는 없어 데이터 오용의 피해가 발생할 수 있다.

㉢ 개인정보 사용자의 정보사용에 대한 무한책임의 한계로 개인정보 사용 책임제보다 동의제를 더욱 강화해야 한다.

㉣ 민주주의에서 행동결과에 따른 처벌의 모순을 교훈삼아 빅데이터 '사전성향'분석을 통한 통제가 강화될 필요가 있다.

㉤ 빅데이터가 발생시키는 문제를 중간자 관점에서 중재하며 해결해주는 알고리즈미스트도 새로운 직업으로 부상하게 될 것이다.

① ㉠, ㉢ ② ㉡, ㉢ ③ ㉠, ㉣ ④ ㉡, ㉤

모듈 2-5

미래의 빅데이터

데이터의 가치와 미래

- 미래의 빅데이터
  - 빅데이터 활용에 필요한 기본적인 3요소는 데이터, 기술, 인력임
  - 데이터 분야
    - ➢ IBM, 구글, 아마존과 같은 인터넷 기업뿐 아니라 자동차 제조업, 스마트 홈 사업자들이 데이터 수집을 위한 다양한 기기 관련 특허를 출원중이며 자동차는 센서의 집합체로 변신중이며 각 가정은 각종 센서들이 온도와 전기를 제어하는 시대로 접어들고 있음
    - ➢ 모든 것들이 데이터화하는 시대가 피할 수 없는 물결로 밀려오고 있으며 센서로부터 수집되는 데이터는 기존 기업의 비즈니스 모델을 바꾸기도 함
    - ➢ 나이키는 신발 제조사이지만 신발, 의류 및 기타 액세서리 등에 각종 센서를 내장한 제품을 출시하고 여기서 수집된 사용자 정보를 분석해 건강관리 서비스를 새로운 상품으로 출시하는 등 핵심 비즈니스 모델이 제조업에서 서비스업으로 변화하고 있음

데이터의 가치와 미래

- 미래의 빅데이터
  - 기술 분야
    - ➢ 빅데이터 분석 알고리즘의 진화가 빠르게 진행되고 있음
    - ➢ 알고리즘은 데이터 양의 증가에 따라 정확도가 증가하는 일반적인 경향이 있는데 M2M, IoT의 확산으로 데이터 생산량이 기하급수적으로 증가함에 따라 빅데이터를 다루는 알고리즘의 효율성이 기하급수적으로 증가할 것임
    - ➢ 2013년 구글은 빅데이터를 활용해 자기학습이 가능한 인공신경망 개발에 성공하였음('고양이'라는 단어를 학습시키지 않았음에도 불구하고 유튜브 동영상에서 인공신경망이 고양이 이미지를 구분해내도록 함)
    - ➢ 스스로 학습이 가능한 인공지능 기술은 기존의 데이터 분석기법으로 처리가 불가능할 만큼 거대한 규모의 빅데이터 처리에 필수 불가결한 기술로 부상하고 있음

데이터의 가치와 미래

- 미래의 빅데이터
  - 인력 분야
    - ➢ 데이터 사이언티스트는 빅데이터에 대한 이론적 지식과 숙련된 분석 기술을 바탕으로 통찰력·전달력·협업능력을 두루 갖춘 전문인력을 의미함
    - ➢ 데이터 사이언티스트는 빅데이터의 다각적 분석을 통해 인사이트를 도출하고 이를 조직의 전략 방향 제시에 활용할 줄 아는 기획자로서 전문가 역할을 할 것으로 기대됨
    - ➢ 데이터 사이언티스트가 조직 내부에서 빅데이터의 가치를 실현하기 위해 필요하다면 알고리즈미스트는 데이터 사이언티스트가 한 일로 인해 부당하게 피해가 발생하는 것을 막기 위해 필요함
    - ➢ 알고리즈미스트 역시 컴퓨터, 수학, 통계뿐만 아니라 비즈니스 전반에 대한 이해가 필요하고 알고리즘 코딩 해석을 통해 빅데이터 알고리즘에 의해 부당하게 피해를 입은 사람들을 구제하는 전문가임

퀴즈

- 다음 중 빅데이터 활용에 필요한 3요소로 올바른 것은 무엇인가?

① 데이터, 기술, 인력

② 프로세스, 기술, 인력

③ 데이터, 프로세스, 인력

④ 인력, 데이터, 알고리즘

퀴즈

- 다음 괄호 안에 들어갈 용어는 무엇인가?

  (　　)은/는 인터넷을 기반으로 모든 사물을 연결해 사람과 사물, 사물과 사물 간의 정보를 상호 소통하는 지능형 기술 및 서비스이며 사물에서 생성되는 데이터를 활용한 분석을 통해 마케팅 등에 활용할 수 있다.

퀴즈

- 다음 중 빅데이터의 관점에서 사물인터넷의 시대를 바라볼 때 사물인터넷과 가장 관련이 큰 것은 무엇인가?

  ① 데이터화

  ② 인공지능

  ③ 지능적 서비스

  ④ 스마트 데이터