

- 결측값 처리와 이상값 검색

- 이상값 검색

- 이상값 개념

- ✓ 이상값은 관측된 데이터의 범위에서 많이 벗어난 아주 작은 값이나 큰 값을 의미함
 - ✓ 입력의 오류 또는 데이터처리 오류 등의 이유로 특정 범위에서 벗어난 데이터 값

- 이상값 검색방법

- ✓ 이상값 검출 방법으로 평균과 표준편차를 이용한 ESD(Extreme Studentized Deviation)방법과 사분위수를 이용한 방법을 많이 이용함
 - ✓ 데이터 분석에서 전처리 방법을 결정할 때 부정 사용 방지 시스템(FDS: Fraud Detection System)의 규칙발견에 사용할 수 있음

• 결측값 처리와 이상값 검색

- 이상값 검색

➤ 이상값 검색방법

- ✓ ESD는 평균으로부터 표준편차(σ)의 k 배 떨어진 값을 이상값으로 판별하는 방법으로 $k=3$ 으로 하는 것이 일반적임($\text{표본평균} - 3 \times \sigma < \text{데이터} < \text{표본평균} + 3 \times \sigma$ (정상범주))
- ✓ ESD는 평균을 이용하기 때문에 이상값에 민감하다는 단점이 존재함
- ✓ 기하평균을 이용하는 방법은 기하평균으로부터 표준편차의 2.5배보다 떨어져 있는 값을 이상값으로 판단함
- ✓ 기하평균 - $2.5 \times \sigma < \text{데이터} < \text{기하평균} + 2.5 \times \sigma$ (정상범주)
- ✓ 기하평균: n 개의 양수 값을 모두 곱한 것의 n 제곱근
- ✓ 2, 3, 6의 기하평균 $\rightarrow (2 \times 3 \times 6)^{\frac{1}{3}} = 3.3$

- 결측값 처리와 이상값 검색

- 이상값 검색

- 이상값 검색방법

- ✓ 사분위수를 이용한 방법으로 제1사분위수(Q_1), 제3사분위수(Q_3)를 기준으로 사분위 범위($Q_3 - Q_1$)의 1.5배 떨어져 있는 값을 이상값으로 판단
 - ✓ $Q_1 - 1.5 \times (Q_3 - Q_1) < data < Q_3 + 1.5 \times (Q_3 - Q_1)$ (정상범주)
 - ✓ 사분위수를 이용하므로 ESD와 달리 이상값에 민감하지 않음


- 결측값 처리와 이상값 검색

- 이상값 검색

- 이상값 검색방법

- ✓ 박스플롯(상자그림)을 이용한 이상값 탐색

```
> #airquality 데이터 세트의 ozone 변수 박스플롯 그리기  
> out_oz = boxplot(airquality$ozone)  
> #이상값 출력  
> out_oz$out  
[1] 135 168
```



- 다음의 결측값 처리에 대한 내용 중 가장 옳지 않은 것은?

- ① 단순확률대치법은 추정량의 과소추정이나 계산의 난해성 문제를 보완하는 방법이다.
- ② 다중대치법은 단순 대치법을 한 번 하지 않고 m 번 대치를 통해 m 개의 가상적 완전한 자료를 만들어서 분석하는 방법이다.
- ③ 평균대치법은 관측 또는 실험되어 얻어진 자료의 평균값으로 결측값을 대치하는 방법이다.
- ④ 완전분석법은 불완전 자료는 모두 무시하고 완전하게 관측된 자료만 사용하여 분석하는 방법이다.

- 다음 중 이상값 검색 방법으로 가장 옳지 않은 것은?

- ① 3-Sigma방법은 평균으로부터 표준편차(σ)의 3배보다 떨어진 값을 이상값으로 판별하는 방법이다.
- ② Q_2 (중위수)로부터 IQR(사분위범위)의 1.5배보다 크거나 작은 데이터를 이상값으로 규정한다.
- ③ ESD는 이상값에 민감하다는 단점이 있다.
- ④ 기하평균으로부터 표준편차의 2.5배보다 떨어져 있는 값을 이상값이라 판단한다.

- 이상값 검색 기법의 하나로 평균으로부터 표준편차의 k 배보다 떨어진 값들을 이상값으로 판단하는 방법은 무엇인가?

- 다음 중 박스 플롯(Boxplot)을 이용한 이상값 검색에 대한 설명으로 가장 옳지 않은 것은 무엇인가?
 - ① 평균에서 표준편차의 3배보다 떨어진 값을 이상값으로 판단한다.
 - ② 이상값을 반드시 제거해야 하는 것은 아니므로 이상값을 처리할지는 분석의 목적에 따라 적절한 판단이 필요하다.
 - ③ 중위수를 이용하므로 이상값에 민감하지 않다.
 - ④ $Q_1 - 1.5 \times IQR < data < Q_3 + 1.5 \times IQR$ 을 벗어나는 data를 이상값이라고 판단한다.(단, $IQR = Q_3 - Q_1$ 이라고 한다.)

• 다음 중에서 이상값 검색을 활용한 응용시스템으로 가장 적절한 것은 무엇인가?

- ① 부정 사용 방지 시스템
- ② 장바구니 분석 시스템
- ③ 분류 분석 시스템
- ④ 군집 분석 시스템

- 다음 중 이상값을 판정하는 방법으로 가장 적절하지 않은 것은 무엇인가?
 - ① $Q_2 \pm 1.5 * IQR$ 보다 크거나 작은 경우 이상값으로 판정한다.
 - ② 기하평균으로부터 표준편차의 2.5배가 넘는 범위의 데이터를 이상값으로 판정한다.
 - ③ 회귀분석 후 잔차 분석을 실시하여 이상값을 판정한다.
 - ④ 평균으로부터 표준편차의 3배가 넘는 범위의 데이터를 이상값으로 판정한다.

- 최소값, 1사분위수, 중위수, 3사분위수, 최대값, 평균값을 구할 수 있는 함수는?

- ① str
- ② summary
- ③ head
- ④ inform

- summary(cars)에 대한 설명 중 적절하지 않은 것은?

```
> summary(cars)
      speed      dist
Min.   : 4.0   Min.   :  2.00
1st Qu.:12.0   1st Qu.: 26.00
Median :15.0   Median : 36.00
Mean   :15.4   Mean    : 42.98
3rd Qu.:19.0   3rd Qu.: 56.00
Max.   :25.0   Max.    :120.00
```

- ① dist변수의 최소값과 최대값을 알 수 있다.
- ② 두 변수의 중위수를 알 수 있다.
- ③ speed 변수의 제2사분위는 알 수가 없다.
- ④ dist변수의 평균값을 알 수 있다.

- summary(mtcars)에 대한 설명 중 적절하지 않은 것은?

```
> summary(mtcars)
```

mpg	cyl	disp	hp
Min. :10.40	Min. :4.000	Min. : 71.1	Min. : 52.0
1st Qu.:15.43	1st Qu.:4.000	1st Qu.:120.8	1st Qu.: 96.5
Median :19.20	Median :6.000	Median :196.3	Median :123.0
Mean :20.09	Mean :6.188	Mean :230.7	Mean :146.7
3rd Qu.:22.80	3rd Qu.:8.000	3rd Qu.:326.0	3rd Qu.:180.0
Max. :33.90	Max. :8.000	Max. :472.0	Max. :335.0

- ① cyl변수의 중위수는 6.00이다.
- ② disp변수를 벡터로 추출하기 위해서 mtcars\$disp를 실행한다.
- ③ hp변수는 범주형 데이터 타입이다.
- ④ mpg 변수의 최대값은 33.90이다.

동계 분석

• MODULE 7

모듈 7-1


통계학 개론

- 통계학 개론

- 통계 분석 개요

- 모집단과 표본집단

- ✓ 통계학은 자료로부터 유용한 정보를 추출하는 학문으로 자료의 수집과 정리, 이를 해석하는 방법 등을 포함함



- 통계학 개론

- 통계 분석 개요

- 모집단과 표본집단

항목	설명
모집단	• 조사의 대상이 되는 전체 집단
표본	• 조사하는 모집단의 일부분
모수	• 모집단의 특성을 나타내는 대표값 • 예) 모평균, 모분산, 모표준편차 등
통계량	• 모수를 추론하기 위해 표본의 특성을 나타내는 대표값 • 예) 표본평균, 표본분산, 표본표준편차 등

• 통계학 개론

- 통계 분석 개요

➤ 표본 추출 오차의 유형

✓ 일반적으로 오차는 **참값**과 **추정값**의 차이를 의미함

구분	내용
표본오차	- 표본에서 얻은 자료를 통해 모집단 전체의 특성을 추론함으로써 생기는 오차 - 표본의 크기가 증가하면 표본오차가 작아짐
비표본오차	- 표본 오차를 제외한 모든 오차로 조사과정 중 발생하는 부주의, 실수, 알 수 없는 원인 등 모든 오차를 의미함 - 조사 대상이 증가하면 오차가 커짐 - 비표본오차 중 표본편의는 표본을 선택하는 과정에서 표본이 체계적/확률적으로 모집단을 대표하지 못하는 경우 발생하는 오차

• 통계학 개론

- 통계 분석 개요

➤ 표본분포 관련 법칙

법칙	설명
큰 수의 법칙	- 데이터를 많이 뽑을수록 표본평균의 분산은 0에 가까워진다는 법칙 $V(\bar{x}) = \frac{\sigma^2}{n}$
중심 극한 정리	- 데이터의 크기가 커지면 그 데이터가 어떠한 형태이든 그 데이터 표본의 분포는 최종적으로 정규분포를 따른다는 법칙 - 표본의 크기가 최소 30이상이어야 하며 표본의 크기가 증가할수록 표본의 평균과 표준편차가 모집단의 평균과 표준편차에 가까워짐

- 통계학 개론

- 표본 추출

- 표본의 추출은 모집단의 일부를 일정한 방법에 따라 **표본으로 선택**하는 과정임
 - 표본추출 기법에는 단순 무작위 추출, 계통 추출, 층화 추출, 군집 추출 기법 등이 있음
 - 단순 무작위 추출
 - ✓ 모집단에서 정해진 규칙없이 표본을 추출하는 방법으로 각 **표본이 선택될 확률이 같음**
 - ✓ 표본의 크기가 커질수록 통계량이 모수의 값에 가까워지며 산포(분산)의 값이 줄어듦
 - ✓ 예) 100개의 제품에서 무작위로 10개의 제품을 추출

- 통계학 개론

- 표본 추출

- 계통 추출

- ✓ 모집단을 **일정한 간격**으로 추출하는 방식임

- ✓ 예시) 100명의 사람에게 1~100의 번호를 부여하고 끝자리가 5로 끝나는 사람들을 선정

- 층화 추출

- ✓ 모집단을 여러 개의 층으로 나누고 **계층별로 무작위 추출**을 수행하는 방식

- ✓ 층화추출의 경우 층 내는 동질적이고 층간은 이질적임

- 통계학 개론

- 표본 추출

- 군집/집락 추출

- ✓ 모집단을 여러 군집으로 나누고 일부 군집의 전체를 추출하는 방식
 - ✓ 집단의 내부는 이질적으로 구성되어 있음

• 통계학 개론

- 자료 측정 척도 종류

구분	설명
명목척도	- 관측대상을 범주로 나누어 분류한 후 이에 따라 기호나 숫자를 부여하는 방법 예) 성별(남, 여), 혈액형, 국가분류 등
순서/서열/ 순위 척도	- 정성적(수치화하지 못함)인 변수를 관측하기 위해 여러 관측 대상을 적당한 기준에 따라 상대적인 비교 및 순위화를 통해 관측하는 방법 - 순서만 의미가 있고 수치의 크기나 차이는 의미가 없음 - 예시) 성적 순위, 만족도, 선호도 등

• 통계학 개론

- 자료 측정 척도 종류


구분	설명
등간/구간/ 간격/거리 척도	• 주로 정성적인 변수를 정량적인 방법으로 측정하기 위해 사용 • 서열척도는 여러 대상을 같이 놓고 이들을 상대적으로 평가하는 방법이며 등간 척도는 각각의 대상을 별도로 평가하는 방법 • 동일 간격화로 크기 간의 차이를 비교할 수 있게 만든 척도(온도, 지능지수 등)
비율 척도	• 균등 간격에 절대 영점이 있고 비율 계산이 가능한 척도 • 가장 일반적인 정량적인 변수로 사용 • 예시) 금액, 거리, 몸무게 등

- 통계학 개론

- 확률

- 확률의 개념

- ✓ 비슷한 현상이 반복해서 일어날 때 어떤 사건이 발생할 가능성을 0과 1사이의 숫자로 표현하는 방법
 - ✓ 확률의 계산은 $P(A) = \frac{n_A}{n_S}$ (S: 표본공간전체, A: 관심있는 사건)
 - ✓ 교사건은 사건 A와 B에 동시에 속하는 결과들로 $A \cap B$ 로 나타낼 수 있음




- 통계학 개론

- 확률

- 확률의 개념

- ✓ 비슷한 현상이 반복해서 일어날 때 어떤 사건이 발생할 가능성을 0과 1사이의 숫자로 표현하는 방법
 - ✓ 확률의 계산은 $P(A) = \frac{n_A}{n_S}$ (S: 표본공간전체, A: 관심있는 사건)
 - ✓ 합사건은 사건 A와 B를 모두 포함하는 결과들로 $A \cup B$ 로 나타낼 수 있음



- 통계학 개론

- 확률

- 조건부 확률

- ✓ 어떤 사건이 일어난다는 조건하에 다른 사건이 일어날 확률을 나타냄
 - ✓ 두 개의 사건 A와 B에 대해 **사건 A가 일어난다는 조건하에 사건 B가 일어날 확률**임
 - ✓ 조건부 확률공식: $P(B|A) = \frac{P(A \cap B)}{P(A)}, P(A) \neq 0$

- 통계학 개론

- 확률

- 조건부 확률


- ✓ 베이즈 정리는 어떤 사건에 대해 관측 전(사전 확률) 원인에 대한 가능성과 관측 후(사후 확률)의 원인 가능성 사이의 관계를 설명하는 확률이론
 - ✓ 베이즈 확률은 어떤 사건 B가 서로 배반인 $A_1, A_2, \dots, A_n$ 중 어느 한 가지가 발생하는 경우 실제 B가 일어날 때 A_i 가 발생하는 확률

• 통계학 개론

- 확률

➤ 조건부 확률

✓ 베이즈 정리 공식



$$✓ P(A_i|B) = \frac{P(A_i \cap B)}{P(B)} = \frac{P(A_i \cap B)}{\sum_{i=1}^n P(A_i \cap B)} = \frac{P(A_i) \times P(B|A_i)}{P(A_1) \times P(B|A_1) + P(A_2) \times P(B|A_2) + \dots + P(A_n) \times P(B|A_n)}$$

$$✓ P(B) = P(A_1 \cap B) + P(A_2 \cap B) + \dots + P(A_n \cap B)$$

- 통계학 개론

- 확률

- 조건부 확률

- ✓ 베이즈 정리 예제

- ✓ 회사에서 A공장은 부품을 50% 생산하고 불량률은 2%, B공장은 부품을 30% 생산하고 불량률은 3%, C공장은 부품을 20% 생산하고 불량률은 4%이다. 불량품을 선택했을 때 C공장에서 생산한 부품일 확률은?

- 통계학 개론

- 확률

- 조건부 확률

- ✓ 베이즈 정리 예제

- ✓ 회사에서 A공장은 부품을 50% 생산하고 불량률은 2%, B공장은 부품을 30% 생산하고 불량률은 3%, C공장은 부품을 20% 생산하고 불량률은 4%이다. 불량품을 선택했을 때 C공장에서 생산한 부품일 확률은?

- ✓ A_1 : A공장, A_2 : B공장, A_3 : C공장, B : 불량품 사건

- ✓
$$P(A_3|B) = \frac{P(A_3 \cap B)}{P(B)} = \frac{P(A_3 \cap B)}{\sum_{i=1}^3 P(A_i \cap B)} = \frac{P(A_3) \times P(B|A_3)}{P(A_1) \times P(B|A_1) + P(A_2) \times P(B|A_2) + P(A_3) \times P(B|A_3)}$$

- ✓
$$= \frac{0.2 \times 0.04}{0.5 \times 0.02 + 0.3 \times 0.03 + 0.2 \times 0.04} = 0.296$$

- 통계학 개론

- 확률

- 독립 사건

- ✓ 사건 A가 일어나는 것에 상관없이 사건 B가 발생할 확률이 일정할 때 두 사건 A, B는 서로 독립이라 하며 서로 독립인 두 사건을 독립 사건이라 함

- ✓ A, B 독립 사건의 공식

- ✓ $P(B|A) = \frac{P(A \cap B)}{P(A)} = P(B)$, $P(A \cap B) = P(A)P(B)$

• 통계학 개론

- 확률

➤ 확률변수

- ✓ 특정 확률로 발생하는 결과를 수치적 값으로 표현하는 변수
- ✓ 확률변수는 주로 대문자(X, Y, Z)로 표시함
- ✓ 예시) 1개의 동전을 2번 던지는 실험에서 전체 표본공간은 {(앞, 앞), (앞, 뒤), (뒤, 앞), (뒤, 뒤)}이며 앞면이 나올 개수를 X 라고 하면 X 가 가질 수 있는 값은 0, 1, 2가 됨

앞면의 수(X)	0	1	2	계
확률	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$	1

- 통계학 개론

- 확률

- 확률변수

- ✓ 확률변수는 이산확률변수와 연속확률변수로 나눌 수 있음

확률변수	설명
이산확률변수	• 개수, 인원 수 등 소수점 형태로 표현되지 않는 변수를 의미함
연속확률변수	• 시간, 길이 등 소수점 형태로 표현될 수 있는 변수를 의미함

• 통계학 개론

- 확률

➤ 확률함수

✓ 확률변수의 종류에 따라 확률함수를 나눌 수 있음

구분	함수	설명
이산확률변수	확률 질량 함수	• 이산확률변수에서 특정 값에 대한 확률을 나타내는 함수
	누적 질량 함수	• 이산확률변수가 특정 값보다 작거나 같을 확률을 나타내는 함수
연속확률변수	확률 밀도 함수	• 연속확률변수의 분포를 나타내는 함수
	누적 밀도 함수	• 연속확률변수가 특정 값보다 작거나 같을 확률을 나타내는 함수

- 통계학 개론

- 확률

- 확률변수의 기대값

- ✓ 기대값은 확률변수의 값에 해당하는 확률을 곱하여 모두 더한 값을 의미함
 - ✓ 해당 확률분포에서 **평균적으로 기대할 수 있는 값**이며 해당 확률분포의 **중심 위치**를 설명해주는 값
 - ✓ 이산확률변수의 기대값: $\mu = E(X) = \sum_{x=1}^N xp(x)$, x : 확률변수 X 의 값, $p(x)$: 확률질량함수
 - ✓ 연속확률변수의 기대값: $\mu = E(X) = \int_{-\infty}^{\infty} xf(x)dx$, x : 확률변수 X 의 값, $f(x)$: 확률밀도함수

- 통계학 개론

- 확률

- 확률변수의 분산

- ✓ 분산은 평균으로부터 얼마나 떨어져 있는지를 나타내는 값

- ✓ 확률분포의 산포도를 나타내는 값으로 $V(X)$ 라고 표시함

- ✓ 이산확률변수의 분산: $\sigma^2 = V(X) = E[(X - E(X))^2] = \sum_{x=1}^N (x - E(X))^2 p(x)$, x : 확률변수 X 의 값, $p(x)$: 확률질량함수

- ✓ 연속확률변수의 분산: $\sigma^2 = V(X) = E[(X - E(X))^2] = \int_{-\infty}^{\infty} (x - E(X))^2 f(x) dx$, x : 확률변수 X 의 값, $f(x)$: 확률밀도함수

- 통계학 개론

- 확률

- 공분산

- ✓ 두 확률변수 사이의 **관련성**의 척도
 - ✓ $Cov(X, Y) = \sigma_{XY} = E(XY) - E(X)E(Y)$, $E(XY)$: XY 의 기대값 $E(X)$: X 의 기대값 $E(Y)$: Y 의 기대값
 - ✓ 공분산의 범위는 **음의 무한대에서 양의 무한대**까지임
 - ✓ 공분산이 0이면 두 변수 간에 아무런 선형 관계가 없으며 두 변수는 **서로 독립**적인 관계
 - ✓ 공분산이 음수이면 **X 가 증가할 때 Y 는 감소**하고 공분산이 양수이면 **X 가 증가할 때 Y 도 증가**함
 - ✓ 공분산은 측정 단위에 영향을 받음 → **상관계수**는 측정 단위에 영향을 받지 않음

- 통계학 개론

- 확률분포


- 개념

- ✓ 확률분포는 확률변수가 특정한 값을 가질 확률을 나타내는 분포
 - ✓ 확률변수의 종류에 따라 이산확률변수이면 이산확률분포
 - ✓ 연속확률변수이면 연속확률분포로 나뉠 수 있음

- 통계학 개론

- 확률분포

- 개념



- 통계학 개론

- 확률분포

- 이산확률분포

- ✓ 이산확률변수 X 가 가지는 확률분포
 - ✓ 베르누이분포: 특정 실험의 결과가 **성공 또는 실패**로 두 가지의 결과 중 하나를 얻는 확률분포로
 - ✓ 성공 확률과 실패 확률의 합은 1이며 각 확률실험은 서로 독립적이며
 - ✓ 확률질량함수 $P(x) = p^x(1-p)^{1-x}$ (단, p 는 특정 실험의 결과가 성공할 확률, $x = 0, 1$)
 - ✓ 기대값 $E(X) = p$, 분산 $V(X) = p(1-p)$
 - ✓ 예) 동전 1회 던져서 앞면(관심있는 사건)이 1회 나올 확률은?
 - ✓ 답안) $\left(\frac{1}{2}\right)^1 \left(1 - \frac{1}{2}\right)^{1-1} = \frac{1}{2}$

- 통계학 개론

- 확률분포

- 이산확률분포

- ✓ 이항분포: 베르누이 시행을 n 번 독립적으로 반복 실행하는 분포로

- ✓ 확률질량함수 $P(x) = nCx \times p^x(1-p)^{n-x}$ (단 p 는 특정 실험의 결과가 성공 확률, $x = 0, 1, 2, \dots, n$, n : 시행횟수)

- ✓ 기대값 $E(X) = np, V(X) = np(1-p)$

- ✓ 이항분포의 시행 횟수(n)가 많아지면 정규분포에 근사하게 됨

- ✓ 예) 동전 3회 던져서 앞면(관심있는 사건)이 1회 나올 확률은?

- ✓ 답안) $3C1\left(\frac{1}{2}\right)^1\left(1-\frac{1}{2}\right)^{3-1} = 0.375$

- 통계학 개론

- 확률분포

- 이산확률분포

- ✓ 포아송분포: 단위시간, 단위면적당 발생하는 사건의 분포

- ✓ 확률질량함수 $P(x) = \frac{\lambda^x \times e^{-\lambda}}{x!}$ (단, λ 는 단위시간, 면적당 발생하는 사건의 수, $x = 0, 1, 2 \dots$)

- ✓ 기대값 $E(X) = \lambda, V(X) = \lambda$

- ✓ 예) 어떤 사람은 하루에 휴대폰으로 평균 5회의 문자서비스를 받는다고 한다. 어느 특정한 날에 이 사람이 4회의 문자서비스를 받을 확률은?

- ✓ 답안) $p(x = 4) = \frac{5^4 \times e^{-5}}{4!} = 0.1755$

- 통계학 개론

- 확률분포

- 연속확률분포

- ✓ 확률변수 X 가 실수와 같이 연속적인 값을 취할 때 연속확률변수라 하며 연속확률변수가 가지는 확률분포임

- ✓ 정규분포: 기대값($E(X) = \mu$)이고 모분산($V(X) = \sigma^2$)인 좌우대칭인 분포

- ✓ 확률밀도함수 $f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$ (단, x : 확률변수, e : 자연상수)

- ✓ 분산이 클수록 정규분포곡선이 양옆으로 퍼지는 모양

- 통계학 개론

- 확률분포

- 연속확률분포

- ✓ 확률변수 X 가 실수와 같이 연속적인 값을 취할 때 연속확률변수라 하며 연속확률변수가 가지는 확률분포임

- ✓ 표준정규분포: 기대값($E(X) = 0$)이고 모분산($V(X) = 1$)인 좌우대칭인 분포

- ✓ 정규분포를 표준화한 분포로 확률밀도함수 $f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}}$ (단, x : 확률변수, $z = \frac{x-\mu}{\sigma}$)

- 통계학 개론

- 확률분포

- 연속확률분포

- ✓ 확률변수 X 가 실수와 같이 연속적인 값을 취할 때 연속확률변수라 하며 연속확률변수가 가지는 확률분포임

- ✓ T분포: 모집단이 정규분포의 형태이나 모표준편차(σ)의 값을 모를 때 사용하며

- ✓ 기대값($E(X) = 0$)이고 모분산($V(X) = \frac{v}{v-2}$, 단, $v = n - 1$)인 좌우대칭인 분포

- ✓ 확률밀도함수 $f(x) = \frac{1}{\sqrt{\pi v}} \times \frac{\Gamma(\frac{v+1}{2})}{\Gamma(\frac{v}{2})} \times (1 + \frac{x^2}{v})^{-\frac{v+1}{2}}$ (단, x : 확률변수, v = 자유도)

- ✓ 표본의 크기가 30이상이면 표준정규분포와 비슷해짐

- 통계학 개론

- 확률분포

- 연속확률분포

- ✓ 확률변수 X 가 실수와 같이 연속적인 값을 취할 때 연속확률변수라 하며 연속확률변수가 가지는 확률분포임

- ✓ χ^2 분포: 한 개의 모집단의 모분산을 추정할 때 사용하는 분포로

- ✓ 기대값($E(X) = v$)이고 모분산($V(X) = 2v$)인 좌우비대칭인 분포

- ✓ 확률밀도함수 $f(x) = \frac{1}{2^{\frac{v}{2}}\Gamma(\frac{v}{2})} e^{-\frac{x}{2}} \times x^{\frac{v}{2}-1}$ (단, x : 확률변수, v = 자유도)

- 통계학 개론

- 확률분포

- 연속확률분포

- ✓ 확률변수 X 가 실수와 같이 연속적인 값을 취할 때 연속확률변수라 하며 연속확률변수가 가지는 확률분포임

- ✓ F 분포: 두 개 모집단의 모분산비를 추정할 때 사용하는 분포로 좌우비대칭인 분포

- ✓ 기대값($E(X) = \frac{\nu_2}{\nu_2-2}$)이고 모분산($V(X) = (\frac{\nu_2}{\nu_2-2})^2 \frac{2(\nu_1+\nu_2-2)}{\nu_1(\nu_2-4)}$)인 좌우비대칭인 분포

• 통계학 개론

- 가설 검정

➤ 가설

- ✓ 가설은 모집단의 특성, 특히 모수에 대한 가정 혹은 잠정적인 결론임
- ✓ 가설의 종류로 귀무가설과 대립가설이 있음

종류	설명
귀무가설(H_0)	• 현재까지 주장되어 온 것이나 기존과 비교하여 변화 혹은 차이가 없음을 나타내는 가설 • 예시) 모평균은 기존과 비교하여 차이가 없다.
대립가설(H_1)	• 표본을 통해 입증하고자 하는 가설 • 예시) 모평균은 기존과 비교하여 차이가 있다.

• 통계학 개론

- 가설 검정

➤ 가설 검정의 절차


- ✓ 가설 검정은 모집단에 대한 통계적 가설을 세우고 표본을 추출한 후 표본을 통해 얻은 정보를 이용하여 **통계적 가설의 진위 여부**를 판단하는 과정

순서	단계	설명
1	가설 설정	• 귀무가설과 대립가설 설정
2	유의수준 설정	• 검정이 오류를 범할 확률 α 설정(0.05가 많이 사용됨)
3	검정통계량 계산	• 표본집단을 대표하는 값을 구함
4	기각역 설정	• 귀무가설이 기각되는 구간을 설정하거나 p(유의확률)값 계산
5	판정	• 검정통계량이 기각역에 포함되거나 p값이 유의수준보다 작으면 귀무가설 기각

- 통계학 개론

- 가설 검정

- 가설 검정의 절차



• 통계학 개론

- 가설 검정

➤ 가설 검정의 방법

✓ 대립 가설의 형태에 따라 양측 검정과 단측 검정이 있음

검정	설명
양측 검정	- 귀무가설을 $H_0: \theta = \theta_0$, 대립가설을 $H_1: \theta \neq \theta_0$ (단, θ는 모수, θ_0는 관측치) 예) H_0: 한국 남자의 평균 키는 175cm이다. H_1: 한국 남자의 평균 키는 175cm가 아니다.
단측 검정	- 귀무가설을 $H_0: \theta = \theta_0$, 대립가설을 $H_1: \theta < \theta_0$ (단, θ는 모수, θ_0는 관측치) 예) H_0: 한국 남자의 평균 키는 175cm이다. H_1: 한국 남자의 평균 키는 175cm보다 작다. - 귀무가설을 $H_0: \theta = \theta_0$, 대립가설을 $H_1: \theta > \theta_0$ (단, θ는 모수, θ_0는 관측치) 예) H_0: 한국 남자의 평균 키는 175cm이다. H_1: 한국 남자의 평균 키는 175cm보다 크다.

- 통계학 개론

- 가설 검정

- 가설 검정 오류

- ✓ 통계적 방법에 근거하여 주어진 가설을 검증하는데 있어 모집단 전체를 이용하여 검증하는 것이 아니라 모집단으로 부터 추출된 표본을 기반으로 모집단에 대한 결론을 내리므로 통계적인 오류가 존재함

		참값(실제)	
		H_0	H_1
판정	H_0	올바른 결정($1-\alpha$)	제2종 오류(β)
	H_1	제1종 오류(α)	올바른 결정($1-\beta$)

- ✓ 일반적으로 제1종 오류의 영향이 제2종 오류의 영향보다 크므로

제1종 오류를 기준으로 가설검정을 수행함

• 통계학 개론

- 가설 검정

➤ p값(p-value) = 유의확률

✓ p값은 귀무가설이 참이라는 전제하에 표본에서 구한 검정통계량의 값보다 더 극단적인 값이 나올 확률

귀무가설 채택	$p\text{-값} > \text{유의수준}(\alpha)$
귀무가설 기각	$p\text{-값} < \text{유의수준}(\alpha)$

➤ 임계값


✓ 주어진 유의수준을 검정통계량의 값으로 환산한 값으로 귀무가설을 채택 또는 기각하는 기준

귀무가설 채택	임계값 $>$ 검정통계량
귀무가설 기각	임계값 $<$ 검정통계량

- 통계학 개론

- 가설 검정

- $H_0: \theta = \theta_0$ 하에서의 검정통계량 분포



- 통계학 개론

- 추론 통계

- 추론 통계 개념

- ✓ 모집단의 표본을 가지고 모집단의 특성을 추론하고 그 결과의 신뢰성을 검정하는 통계적 방법
 - ✓ 추정은 표본의 데이터를 사용하여 모집단을 추정하므로 어느 정도의 오차가 존재함
 - ✓ 표본의 개수가 많아질수록 표본의 오차는 감소함
 - ✓ 추정은 점 추정과 구간 추정으로 구분할 수 있음

- 통계학 개론

- 추론 통계

- 점 추정

- ✓ 표본의 정보로부터 모집단의 모수를 **하나의 값**으로 추정하는 기법
 - ✓ 점 추정치로 표본평균, 표본분산, 중위수 등이 있음
 - ✓ 점 추정치의 조건으로 **불편성, 효율성, 일치성, 충분성**이 있음

• 통계학 개론

- 추론 통계

➤ 점 추정

✓ 점 추정치의 조건으로 불편성, 효율성, 일치성, 충분성이 있음

조건	설명
불편성	- 추정치의 기대값이 모집단의 모수와 차이가 없다는 특성 $E(\hat{\theta}) = \theta$ (단, $\hat{\theta}$: 추정치, θ: 모수)
효율성	- 추정치의 분산이 작을수록 좋다는 특성 $V(\hat{\theta}_1) < V(\hat{\theta}_2)$ 일 때 $\hat{\theta}_1$이 $\hat{\theta}_2$보다 효율성이 좋음
일치성	표본의 크기가 아주 커지면 추정량이 모수와 거의 같아진다는 특성
충분성	추정량은 모수에 대한 많은 정보를 제공할수록 좋다는 특성

- 통계학 개론

- 추론 통계

- 표본평균의 표준오차(SE: Standard Error)

- ✓ 추정치는 추출된 표본에 따라 달라질 수 있음

- ✓ 정확도를 측정하기 위해 추정치의 표준편차를 계산하며 추정치의 표준편차를 **표준오차**라 함

- ✓ 표본평균의 표준오차는 $\frac{\sigma}{\sqrt{n}}$ 이며 모표준편차(σ)를 모를 때 **표본표준편차(s)**를 사용함

- ✓ 예) 어느 학교의 남학생 16명의 평균 몸무게의 표본분산이 25라고 할 때 평균 몸무게의 표준오차는?

- ✓ 답안) $\frac{\sigma}{\sqrt{n}} = \frac{\hat{\sigma}=s}{\sqrt{16}} = \frac{5}{4} = 1.25$

• 통계학 개론

- 추론 통계

➤ 구간 추정

- ✓ 구간 추정은 추정값에 대한 신뢰도를 제시하며 구간으로 모수를 추정하는 방법
- ✓ 구간을 추정하기 위해 신뢰수준과 신뢰구간을 제시함

용어	설명
신뢰수준	- 추정값이 존재하는 구간에 모수가 포함될 확률 $100(1 - \alpha)\%$로 계산(단, α는 유의수준으로 오류를 범할 최대 허용확률임)
신뢰구간	신뢰수준을 기준으로 추정된 통계적으로 유의미한 모수의 범위

- 통계학 개론

- 추론 통계

- 구간 추정

- ✓ 점 추정은 'A 후보의 지지율은 40.0%입니다.'와 같이 **하나의 값으로 추정**하는 것이고 구간 추정은 'A 후보의 지지율은 신뢰수준 95%로 신뢰구간 31% ~ 49%에 있다 ' 와 같이 **구간으로 추정**하는 것임
 - ✓ 예) A후보의 지지율을 조사하기 위해 100명의 표본을 대상으로 조사한 결과 40명이 지지한다고 응답하였다. 지지율의 신뢰율 95% 신뢰구간을 구하시오.

- ✓ 답안) $P(\text{모비율}) = p \pm z_{\alpha/2} \sqrt{\frac{p(1-p)}{n}} = 0.4 \pm 1.96 \sqrt{\frac{0.4(1-0.4)}{100}} = 0.4 \pm 0.09 = 31\% \sim 49\%$

• 통계학 개론

- 비모수 검정

- 비모수 통계는 평균이나 분산 같은 모집단의 분포를 가정하지 않고 분석하는 통계적 방법
- 비모수 통계 분석에서 빈도, 부호, 순위 등의 통계량을 사용하여 이상값으로 인한 영향이 적음
- 비모수 통계의 장단점

장점	단점
• 모집단 분포를 가정하지 않으므로 오류의 가능성이 작음 • 모수적 방법에 비해 통계량의 계산이 간편함 • 모집단의 분포에 무관하게 사용할 수 있음 • 이상값으로 인한 영향이 적음	• 모수 통계로 검정이 가능한 데이터를 비모수 통계를 이용하면 효율성이 떨어짐 • 검정통계량의 신뢰성이 부족함 • 데이터의 수가 많은 경우 모수적 통계에 비해 오히려 계산 절차가 복잡

• 통계학 개론

- 비모수 검정

➤ 비모수 통계 검정 방법의 종류

구분	모수 통계	비모수 통계
단일표본 검정	단일표본 t검정(1개의 집단)	- 부호검정 - 윌콕슨 부호 순위 검정
두 표본 검정	독립표본 t검정(독립적인 2개의 집단)	윌콕슨 순위 합 검정
	대응표본 t검정(대응있는 1개의 집단)	- 부호검정 - 윌콕슨 부호 순위 검정
분산 분석	분산분석표(3개 집단이상)	크루스칼-왈리스 검정
상관 분석	피어슨 상관계수	스피어만 순위 상관계수
런검정	비모수 통계로 연속적인 측정값들이 어떤 패턴이나 경향없이 임의로 나타난 것인지를 검정하는 방법	

- 자료의 척도에 대한 설명으로 적절하지 않은 것은?

- ① 명목 척도는 단순히 측정 대상의 특성을 분류하거나 확인하기 위한 목적으로 숫자를 부여한다.
- ② 순서 척도는 대소 또는 높고 낮음 등의 순위만 제공할 뿐 양적인 비교는 할 수 없다.
- ③ 등간 척도는 순위를 부여하되 순위 사이의 간격이 같아 양적인 비교가 가능하다.
- ④ 비율 척도는 측정값 사이의 비율 계산이 가능한 척도이며, 절대 영점이 존재하지 않는다.

- 귀무가설이 참이라는 전제하에 실제 표본에서 구한 표본 통계량의 값보다 더 극단적인 값이 나올 확률은?

- ① 유의수준
- ② p-값(p-value)
- ③ 검정통계량
- ④ 기각역

• 두 집단의 분산이 같은지 검정할 때 사용하는 검정통계량은 어떤 분포를 활용하는가?

- ① 포아송 분포
- ② F-분포
- ③ χ^2 분포
- ④ Z-분포

- 다음이 설명하는 표본추출 방법은 무엇인가?

번호를 부여한 샘플을 나열하여 k 개씩 n 개의 구간으로 나누고 첫 구간(1, 2, 3, ..., k)에서 하나를 임의로 선택한 후 k 개씩 띄어서 n 개의 표본을 선택한다. 즉, 임의 위치에서 매 k 번째 항목을 추출하는 방법이다.

① 계통추출법

② 집락추출법

③ 층화추출법

④ 단순 무작위 추출법

- 다음 중 확률질량함수의 확률변수 x 의 기대값은?

x	1	2	3
$f(x)$	$1/6$	$3/6$	$2/6$

- ① $5/6$
- ② $4/6$
- ③ $13/6$
- ④ $7/10$

- 두 개의 확률변수 X, Y 의 공분산에 대한 설명 중 가장 부적절한 것은?
 - ① 공분산이 0이면 두 변수 간에는 아무런 선형관계가 없으며 두 변수는 서로 독립적인 관계이다.
 - ② 공분산이 음수이면 X 가 증가할 때 Y 는 감소한다.
 - ③ 공분산이 양수이면 X 가 증가할 때 Y 도 증가한다.
 - ④ 공분산의 크기는 0~1사이의 범위를 갖는다.

• 다음 중 이산형 확률변수 x 의 기대값은?

① $E(x) = \sum xf(x)$

② $E(x) = \int xf(x)$

③ $E(x) = E[(x - \mu)^2]$

④ $E(x) = E(x^2) - \mu^2$

• 다음 중 중심극한정리에 대한 설명 중 가장 부적절한 것은?

- ① 표본 크기가 증가할수록 표본의 평균과 표준편차가 모집단의 평균과 표준편차에 가까워짐을 의미하게 된다.
- ② 중심극한정리가 성립하기 위해서는 표본의 크기가 최소 30 이상이어야 한다.
- ③ 모집단이 정규분포가 아닐 때 서로 다른 표본의 크기에 대한 표본평균의 분포들이 표본의 크기가 커짐에 따라 정규분포에 가까워지게 된다.
- ④ 모집단의 분포가 정규분포에 가까워져야 표본평균의 분포가 정규분포로 근사하게 된다.

• 다음 중 거식증 환자 30명의 치료 전·후 평균 체중 변화를 분석하여 치료의 효과 등을 분석하는 방법은?

- ① 독립 표본 t-검정
- ② 분산 분석
- ③ 윌콕슨 부호 순위 검정
- ④ 런 검정

- 다음 중 오른쪽 꼬리가 긴 분포를 가진 분포에서 최빈수, 중위수, 평균값의 크기 순서는?

- ① 중위수 < 최빈수 < 평균
- ② 최빈수 < 중위수 < 평균
- ③ 최빈수 < 평균 < 중위수
- ④ 평균 < 최빈수 < 중위수

- 서비스의 만족도를 조사하고자 하는 설문에서 사용되는 척도는?
 - ① 순서 척도
 - ② 명목 척도
 - ③ 등간 척도
 - ④ 비율 척도

- 모집단의 성격에 따라 몇 개의 집단 또는 층으로 나누고, 각 집단 내에 원하는 크기의 표본을 무작위로 추출하는 표본추출 방법을 무엇이라고 하는가?

- 다음 중 비율 척도에 대한 예시로 가장 적절한 것은?
 - ① 무게, 나이
 - ② 성별, 출생지
 - ③ 온도, 지수
 - ④ 선호도

- 다음 중 공분산과 상관계수에 대한 설명 중 가장 옳바르지 않은 것은?
 - ① 공분산은 측정 단위에 영향을 받지 않는다.
 - ② 상관 분석은 두 변수의 인과 관계 성립 여부를 확인할 수 없다.
 - ③ 공분산이 0이라면 두 변수 간에는 아무런 선형 관계가 없고 서로 독립적인 관계에 있다.
 - ④ 상관계수를 통해 상관관계의 표준화된 크기를 측정할 수 있다.

• 다음 중에서 확률 및 확률분포에 대한 설명 중 가장 적절하지 못한 것은?

- ① 확률변수 x 가 구간 또는 구간들의 모임인 숫자 값을 갖는 확률 분포 함수를 이산형 확률 질량 함수라 한다.
- ② 모든 확률은 0과 1사이의 값을 가진다.
- ③ 확률함수는 확률변수에 의해 정의된 실수를 확률에 대응시키는 함수이다.
- ④ 서로 배반인 사건에 대한 합집합의 확률은 각 사건에 대한 확률의 합이 된다.

- 다음 중 통계적 가설 검정에 관한 내용으로 가장 적절하지 않은 것은 무엇인가?
 - ① 귀무가설이 참이 아닌데도 귀무가설을 채택할 오류의 확률을 검정력이라고 한다.
 - ② 귀무가설을 기각시키는 검정통계량의 범위를 기각역이라고 한다.
 - ③ 귀무가설이 맞다는 가정하에 표본 통계량보다 더 극단적인 결과가 관측될 확률을 유의확률이라고 한다.
 - ④ 귀무가설이 참인데도 기각함으로써 발생하는 오류를 제1종 오류라고 한다.

- 다음 중 가설 검정의 오류에 관한 내용으로 가장 옳바르지 않은 것은?
 - ① 제1종 오류는 귀무가설이 참인데도 귀무가설을 기각하게 되는 오류이다.
 - ② 제2종 오류는 대립가설이 거짓인데도 귀무가설을 채택하게 되는 오류이다.
 - ③ 유의수준은 제1종 오류를 범할 최대 허용 확률을 의미한다.
 - ④ 제1종 오류와 제2종 오류는 표본 크기가 일정한 경우 동시에 감소시킬 수 없다.

- 실험 결과가 단지 성공과 실패만 있는 베르누이 시행에서 성공일 경우의 확률 변수는 1, 실패일 경우의 확률변수가 0의 값을 가진다. 성공일 확률이 0.3으로 주어지면 기대값은 얼마인가?

- 다음 chickwts 데이터 세트에서 무게의 검정 결과에 대한 설명으로 적절하지 않은 것은?

```
> t.test(chickwts$weight, mu=250)

One Sample t-test

data:  chickwts$weight
t = 1.2206, df = 70, p-value = 0.2263
alternative hypothesis: true mean is not equal to 250
95 percent confidence interval:
 242.8301 279.7896
sample estimates:
mean of x
 261.3099
```

- ① 평균 무게는 261.30이다.
- ② 평균 무게에 대한 점 추정량은 261.30이다.
- ③ 무게가 250과 같다는 가설은 기각된다.
- ④ 무게에 대한 95% 신뢰구간은 (242.83, 279.79)이다.

- 이산형 확률분포 중 단위 시간 또는 영역에서 어떤 사건의 발생 횟수를 나타내는 확률분포는 무엇인가?

• 이질적인 원소들로 구성된 모집단에서 각 계층을 고루 대표할 수 있도록 표본을 추출하는 표본 추출 방법은 무엇인가?

- ① 층화추출법
- ② 집락추출법
- ③ 계통추출법
- ④ 단순 랜덤추출법

- 다음 중 비모수 검정이 아닌 것은?

- ① 런검정
- ② 윌콕슨의 부호 순위 합 검정
- ③ 카이제곱 검정
- ④ 부호 검정