

모듈 7-1


통계학 개론

- 통계학 개론

- 통계 분석 개요

- 모집단과 표본집단

- ✓ 통계학은 자료로부터 유용한 정보를 추출하는 학문으로 자료의 수집과 정리, 이를 해석하는 방법 등을 포함함



- 통계학 개론

- 통계 분석 개요

- 모집단과 표본집단

항목	설명
모집단	• 조사의 대상이 되는 전체 집단
표본	• 조사하는 모집단의 일부분
모수	• 모집단의 특성을 나타내는 대표값 • 예) 모평균, 모분산, 모표준편차 등
통계량	• 모수를 추론하기 위해 표본의 특성을 나타내는 대표값 • 예) 표본평균, 표본분산, 표본표준편차 등

• 통계학 개론

- 통계 분석 개요

➤ 표본 추출 오차의 유형

✓ 일반적으로 오차는 **참값**과 **추정값**의 차이를 의미함

구분	내용
표본오차	- 표본에서 얻은 자료를 통해 모집단 전체의 특성을 추론함으로써 생기는 오차 - 표본의 크기가 증가하면 표본오차가 작아짐
비표본오차	- 표본 오차를 제외한 모든 오차로 조사과정 중 발생하는 부주의, 실수, 알 수 없는 원인 등 모든 오차를 의미함 - 조사 대상이 증가하면 오차가 커짐 - 비표본오차 중 표본편의는 표본을 선택하는 과정에서 표본이 체계적/확률적으로 모집단을 대표하지 못하는 경우 발생하는 오차

• 통계학 개론

- 통계 분석 개요

➤ 표본분포 관련 법칙

법칙	설명
큰 수의 법칙	- 데이터를 많이 뽑을수록 표본평균의 분산은 0에 가까워진다는 법칙 $V(\bar{x}) = \frac{\sigma^2}{n}$
중심 극한 정리	- 데이터의 크기가 커지면 그 데이터가 어떠한 형태이든 그 데이터 표본의 분포는 최종적으로 정규분포를 따른다는 법칙 - 표본의 크기가 최소 30이상이어야 하며 표본의 크기가 증가할수록 표본의 평균과 표준편차가 모집단의 평균과 표준편차에 가까워짐

- 통계학 개론

- 표본 추출

- 표본의 추출은 모집단의 일부를 일정한 방법에 따라 **표본으로 선택**하는 과정임
 - 표본추출 기법에는 단순 무작위 추출, 계통 추출, 층화 추출, 군집 추출 기법 등이 있음
 - 단순 무작위 추출
 - ✓ 모집단에서 정해진 규칙없이 표본을 추출하는 방법으로 각 **표본이 선택될 확률이 같음**
 - ✓ 표본의 크기가 커질수록 통계량이 모수의 값에 가까워지며 산포(분산)의 값이 줄어듦
 - ✓ 예) 100개의 제품에서 무작위로 10개의 제품을 추출

- 통계학 개론

- 표본 추출

- 계통 추출

- ✓ 모집단을 **일정한 간격**으로 추출하는 방식임

- ✓ 예시) 100명의 사람에게 1~100의 번호를 부여하고 끝자리가 5로 끝나는 사람들을 선정

- 층화 추출

- ✓ 모집단을 여러 개의 층으로 나누고 **계층별로 무작위 추출**을 수행하는 방식

- ✓ 층화추출의 경우 층 내는 동질적이고 층간은 이질적임

- 통계학 개론

- 표본 추출

- 군집/집락 추출

- ✓ 모집단을 여러 군집으로 나누고 일부 군집의 전체를 추출하는 방식
 - ✓ 집단의 내부는 이질적으로 구성되어 있음

• 통계학 개론

- 자료 측정 척도 종류

구분	설명
명목척도	- 관측대상을 범주로 나누어 분류한 후 이에 따라 기호나 숫자를 부여하는 방법 예) 성별(남, 여), 혈액형, 국가분류 등
순서/서열/ 순위 척도	- 정성적(수치화하지 못함)인 변수를 관측하기 위해 여러 관측 대상을 적당한 기준에 따라 상대적인 비교 및 순위화를 통해 관측하는 방법 - 순서만 의미가 있고 수치의 크기나 차이는 의미가 없음 - 예시) 성적 순위, 만족도, 선호도 등

• 통계학 개론

- 자료 측정 척도 종류


구분	설명
등간/구간/ 간격/거리 척도	• 주로 정성적인 변수를 정량적인 방법으로 측정하기 위해 사용 • 서열척도는 여러 대상을 같이 놓고 이들을 상대적으로 평가하는 방법이며 등간 척도는 각각의 대상을 별도로 평가하는 방법 • 동일 간격화로 크기 간의 차이를 비교할 수 있게 만든 척도(온도, 지능지수 등)
비율 척도	• 균등 간격에 절대 영점이 있고 비율 계산이 가능한 척도 • 가장 일반적인 정량적인 변수로 사용 • 예시) 금액, 거리, 몸무게 등

- 통계학 개론

- 확률

- 확률의 개념

- ✓ 비슷한 현상이 반복해서 일어날 때 어떤 사건이 발생할 가능성을 0과 1사이의 숫자로 표현하는 방법
 - ✓ 확률의 계산은 $P(A) = \frac{n_A}{n_S}$ (S: 표본공간전체, A: 관심있는 사건)
 - ✓ 교사건은 사건 A와 B에 동시에 속하는 결과들로 $A \cap B$ 로 나타낼 수 있음




- 통계학 개론

- 확률

- 확률의 개념

- ✓ 비슷한 현상이 반복해서 일어날 때 어떤 사건이 발생할 가능성을 0과 1사이의 숫자로 표현하는 방법
 - ✓ 확률의 계산은 $P(A) = \frac{n_A}{n_S}$ (S: 표본공간전체, A: 관심있는 사건)
 - ✓ 합사건은 사건 A와 B를 모두 포함하는 결과들로 $A \cup B$ 로 나타낼 수 있음



- 통계학 개론

- 확률

- 조건부 확률

- ✓ 어떤 사건이 일어난다는 조건하에 다른 사건이 일어날 확률을 나타냄
 - ✓ 두 개의 사건 A와 B에 대해 **사건 A가 일어난다는 조건하에 사건 B가 일어날 확률**임
 - ✓ 조건부 확률공식: $P(B|A) = \frac{P(A \cap B)}{P(A)}, P(A) \neq 0$

- 통계학 개론

- 확률

- 조건부 확률


- ✓ 베이즈 정리는 어떤 사건에 대해 관측 전(사전 확률) 원인에 대한 가능성과 관측 후(사후 확률)의 원인 가능성 사이의 관계를 설명하는 확률이론
 - ✓ 베이즈 확률은 어떤 사건 B가 서로 배반인 $A_1, A_2, \dots, A_n$ 중 어느 한가지가 발생하는 경우 실제 B가 일어날 때 A_i 가 발생하는 확률

• 통계학 개론

- 확률

➤ 조건부 확률

✓ 베이즈 정리 공식



$$✓ P(A_i|B) = \frac{P(A_i \cap B)}{P(B)} = \frac{P(A_i \cap B)}{\sum_{i=1}^n P(A_i \cap B)} = \frac{P(A_i) \times P(B|A_i)}{P(A_1) \times P(B|A_1) + P(A_2) \times P(B|A_2) + \dots + P(A_n) \times P(B|A_n)}$$

$$✓ P(B) = P(A_1 \cap B) + P(A_2 \cap B) + \dots + P(A_n \cap B)$$

- 통계학 개론

- 확률

- 조건부 확률

- ✓ 베이즈 정리 예제

- ✓ 회사에서 A공장은 부품을 50% 생산하고 불량률은 2%, B공장은 부품을 30% 생산하고 불량률은 3%, C공장은 부품을 20% 생산하고 불량률은 4%이다. 불량품을 선택했을 때 C공장에서 생산한 부품일 확률은?

- 통계학 개론

- 확률

- 조건부 확률

- ✓ 베이즈 정리 예제

- ✓ 회사에서 A공장은 부품을 50% 생산하고 불량률은 2%, B공장은 부품을 30% 생산하고 불량률은 3%, C공장은 부품을 20% 생산하고 불량률은 4%이다. 불량품을 선택했을 때 C공장에서 생산한 부품일 확률은?

- ✓ A_1 : A공장, A_2 : B공장, A_3 : C공장, B : 불량품 사건

- ✓
$$P(A_3|B) = \frac{P(A_3 \cap B)}{P(B)} = \frac{P(A_3 \cap B)}{\sum_{i=1}^3 P(A_i \cap B)} = \frac{P(A_3) \times P(B|A_3)}{P(A_1) \times P(B|A_1) + P(A_2) \times P(B|A_2) + P(A_3) \times P(B|A_3)}$$

- ✓
$$= \frac{0.2 \times 0.04}{0.5 \times 0.02 + 0.3 \times 0.03 + 0.2 \times 0.04} = 0.296$$

- 통계학 개론

- 확률

- 독립 사건

- ✓ 사건 A가 일어나는 것에 상관없이 사건 B가 발생할 확률이 일정할 때 두 사건 A, B는 서로 독립이라 하며 서로 독립인 두 사건을 독립 사건이라 함

- ✓ A, B 독립 사건의 공식

- ✓ $P(B|A) = \frac{P(A \cap B)}{P(A)} = P(B)$, $P(A \cap B) = P(A)P(B)$

• 통계학 개론

- 확률

➤ 확률변수

- ✓ 특정 확률로 발생하는 결과를 수치적 값으로 표현하는 변수
- ✓ 확률변수는 주로 대문자(X, Y, Z)로 표시함
- ✓ 예시) 1개의 동전을 2번 던지는 실험에서 전체 표본공간은 {(앞, 앞), (앞, 뒤), (뒤, 앞), (뒤, 뒤)}이며 앞면이 나올 개수를 X 라고 하면 X 가 가질 수 있는 값은 0, 1, 2가 됨

앞면의 수(X)	0	1	2	계
확률	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$	1

- 통계학 개론

- 확률

- 확률변수

- ✓ 확률변수는 이산확률변수와 연속확률변수로 나눌 수 있음

확률변수	설명
이산확률변수	• 개수, 인원 수 등 소수점 형태로 표현되지 않는 변수를 의미함
연속확률변수	• 시간, 길이 등 소수점 형태로 표현될 수 있는 변수를 의미함

• 통계학 개론

- 확률

➤ 확률함수

✓ 확률변수의 종류에 따라 확률함수를 나눌 수 있음

구분	함수	설명
이산확률변수	확률 질량 함수	• 이산확률변수에서 특정 값에 대한 확률을 나타내는 함수
	누적 질량 함수	• 이산확률변수가 특정 값보다 작거나 같을 확률을 나타내는 함수
연속확률변수	확률 밀도 함수	• 연속확률변수의 분포를 나타내는 함수
	누적 밀도 함수	• 연속확률변수가 특정 값보다 작거나 같을 확률을 나타내는 함수

- 통계학 개론

- 확률

- 확률변수의 기대값

- ✓ 기대값은 확률변수의 값에 해당하는 확률을 곱하여 모두 더한 값을 의미함
 - ✓ 해당 확률분포에서 **평균적으로 기대할 수 있는 값**이며 해당 확률분포의 **중심 위치**를 설명해주는 값
 - ✓ 이산확률변수의 기대값: $\mu = E(X) = \sum_{x=1}^N xp(x)$, x : 확률변수 X 의 값, $p(x)$: 확률질량함수
 - ✓ 연속확률변수의 기대값: $\mu = E(X) = \int_{-\infty}^{\infty} xf(x)dx$, x : 확률변수 X 의 값, $f(x)$: 확률밀도함수

- 통계학 개론

- 확률

- 확률변수의 분산

- ✓ 분산은 평균으로부터 얼마나 떨어져 있는지를 나타내는 값

- ✓ 확률분포의 산포도를 나타내는 값으로 $V(X)$ 라고 표시함

- ✓ 이산확률변수의 분산: $\sigma^2 = V(X) = E[(X - E(X))^2] = \sum_{x=1}^N (x - E(X))^2 p(x)$, x : 확률변수 X 의 값, $p(x)$: 확률질량함수

- ✓ 연속확률변수의 분산: $\sigma^2 = V(X) = E[(X - E(X))^2] = \int_{-\infty}^{\infty} (x - E(X))^2 f(x) dx$, x : 확률변수 X 의 값, $f(x)$: 확률밀도함수

- 통계학 개론

- 확률

- 공분산

- ✓ 두 확률변수 사이의 **관련성**의 척도
 - ✓ $Cov(X, Y) = \sigma_{XY} = E(XY) - E(X)E(Y)$, $E(XY)$: XY 의 기대값 $E(X)$: X 의 기대값 $E(Y)$: Y 의 기대값
 - ✓ 공분산의 범위는 **음의 무한대에서 양의 무한대**까지임
 - ✓ 공분산이 0이면 두 변수 간에 아무런 선형 관계가 없으며 두 변수는 **서로 독립**적인 관계
 - ✓ 공분산이 음수이면 **X 가 증가할 때 Y 는 감소**하고 공분산이 양수이면 **X 가 증가할 때 Y 도 증가**함
 - ✓ 공분산은 측정 단위에 영향을 받음 → **상관계수**는 측정 단위에 영향을 받지 않음

- 통계학 개론

- 확률분포


- 개념

- ✓ 확률분포는 확률변수가 특정한 값을 가질 확률을 나타내는 분포
 - ✓ 확률변수의 종류에 따라 이산확률변수이면 이산확률분포
 - ✓ 연속확률변수이면 연속확률분포로 나뉠 수 있음

- 통계학 개론

- 확률분포

- 개념



- 통계학 개론

- 확률분포

- 이산확률분포

- ✓ 이산확률변수 X 가 가지는 확률분포
 - ✓ 베르누이분포: 특정 실험의 결과가 **성공 또는 실패**로 두 가지의 결과 중 하나를 얻는 확률분포로
 - ✓ 성공 확률과 실패 확률의 합은 1이며 각 확률실험은 서로 독립적이며
 - ✓ 확률질량함수 $P(x) = p^x(1-p)^{1-x}$ (단, p 는 특정 실험의 결과가 성공할 확률, $x = 0, 1$)
 - ✓ 기대값 $E(X) = p$, 분산 $V(X) = p(1-p)$
 - ✓ 예) 동전 1회 던져서 앞면(관심있는 사건)이 1회 나올 확률은?
 - ✓ 답안) $\left(\frac{1}{2}\right)^1 \left(1 - \frac{1}{2}\right)^{1-1} = \frac{1}{2}$

- 통계학 개론

- 확률분포

- 이산확률분포

- ✓ 이항분포: 베르누이 시행을 n 번 독립적으로 반복 실행하는 분포로

- ✓ 확률질량함수 $P(x) = nCx \times p^x(1-p)^{n-x}$ (단 p 는 특정 실험의 결과가 성공 확률, $x = 0, 1, 2, \dots, n$, n : 시행횟수)

- ✓ 기대값 $E(X) = np, V(X) = np(1-p)$

- ✓ 이항분포의 시행 횟수(n)가 많아지면 정규분포에 근사하게 됨

- ✓ 예) 동전 3회 던져서 앞면(관심있는 사건)이 1회 나올 확률은?

- ✓ 답안) $3C1\left(\frac{1}{2}\right)^1\left(1-\frac{1}{2}\right)^{3-1} = 0.375$

- 통계학 개론

- 확률분포

- 이산확률분포

- ✓ 포아송분포: 단위시간, 단위면적당 발생하는 사건의 분포

- ✓ 확률질량함수 $P(x) = \frac{\lambda^x \times e^{-\lambda}}{x!}$ (단, λ 는 단위시간, 면적당 발생하는 사건의 수, $x = 0, 1, 2 \dots$)

- ✓ 기대값 $E(X) = \lambda, V(X) = \lambda$

- ✓ 예) 어떤 사람은 하루에 휴대폰으로 평균 5회의 문자서비스를 받는다고 한다. 어느 특정한 날에 이 사람이 4회의 문자서비스를 받을 확률은?

- ✓ 답안) $p(x = 4) = \frac{5^4 \times e^{-5}}{4!} = 0.1755$

- 통계학 개론

- 확률분포

- 연속확률분포

- ✓ 확률변수 X 가 실수와 같이 연속적인 값을 취할 때 연속확률변수라 하며 연속확률변수가 가지는 확률분포임

- ✓ 정규분포: 기대값($E(X) = \mu$)이고 모분산($V(X) = \sigma^2$)인 좌우대칭인 분포

- ✓ 확률밀도함수 $f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$ (단, x : 확률변수, e : 자연상수)

- ✓ 분산이 클수록 정규분포곡선이 양옆으로 퍼지는 모양

- 통계학 개론

- 확률분포

- 연속확률분포

- ✓ 확률변수 X 가 실수와 같이 연속적인 값을 취할 때 연속확률변수라 하며 연속확률변수가 가지는 확률분포임

- ✓ 표준정규분포: 기대값($E(X) = 0$)이고 모분산($V(X) = 1$)인 좌우대칭인 분포

- ✓ 정규분포를 표준화한 분포로 확률밀도함수 $f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}}$ (단, x : 확률변수, $z = \frac{x-\mu}{\sigma}$)

- 통계학 개론

- 확률분포

- 연속확률분포

- ✓ 확률변수 X 가 실수와 같이 연속적인 값을 취할 때 연속확률변수라 하며 연속확률변수가 가지는 확률분포임

- ✓ T분포: 모집단이 정규분포의 형태이나 모표준편차(σ)의 값을 모를 때 사용하며

- ✓ 기대값($E(X) = 0$)이고 모분산($V(X) = \frac{v}{v-2}$, 단, $v = n - 1$)인 좌우대칭인 분포

- ✓ 확률밀도함수 $f(x) = \frac{1}{\sqrt{\pi v}} \times \frac{\Gamma(\frac{v+1}{2})}{\Gamma(\frac{v}{2})} \times (1 + \frac{x^2}{v})^{-\frac{v+1}{2}}$ (단, x : 확률변수, v = 자유도)

- ✓ 표본의 크기가 30이상이면 표준정규분포와 비슷해짐

- 통계학 개론

- 확률분포

- 연속확률분포

- ✓ 확률변수 X 가 실수와 같이 연속적인 값을 취할 때 연속확률변수라 하며 연속확률변수가 가지는 확률분포임

- ✓ χ^2 분포: 한 개의 모집단의 모분산을 추정할 때 사용하는 분포로

- ✓ 기대값($E(X) = v$)이고 모분산($V(X) = 2v$)인 좌우비대칭인 분포

- ✓ 확률밀도함수 $f(x) = \frac{1}{2^v \Gamma(\frac{v}{2})} e^{-\frac{x}{2}} \times x^{\frac{v}{2}-1}$ (단, x : 확률변수, v = 자유도)

- 통계학 개론

- 확률분포

- 연속확률분포

- ✓ 확률변수 X 가 실수와 같이 연속적인 값을 취할 때 연속확률변수라 하며 연속확률변수가 가지는 확률분포임

- ✓ F 분포: 두 개 모집단의 모분산비를 추정할 때 사용하는 분포로 좌우비대칭인 분포

- ✓ 기대값($E(X) = \frac{\nu_2}{\nu_2-2}$)이고 모분산($V(X) = (\frac{\nu_2}{\nu_2-2})^2 \frac{2(\nu_1+\nu_2-2)}{\nu_1(\nu_2-4)}$)인 좌우비대칭인 분포

• 통계학 개론

- 가설 검정

➤ 가설

- ✓ 가설은 모집단의 특성, 특히 모수에 대한 가정 혹은 잠정적인 결론임
- ✓ 가설의 종류로 귀무가설과 대립가설이 있음

종류	설명
귀무가설(H_0)	• 현재까지 주장되어 온 것이나 기존과 비교하여 변화 혹은 차이가 없음을 나타내는 가설 • 예시) 모평균은 기존과 비교하여 차이가 없다.
대립가설(H_1)	• 표본을 통해 입증하고자 하는 가설 • 예시) 모평균은 기존과 비교하여 차이가 있다.

• 통계학 개론

- 가설 검정

➤ 가설 검정의 절차


- ✓ 가설 검정은 모집단에 대한 통계적 가설을 세우고 표본을 추출한 후 표본을 통해 얻은 정보를 이용하여 **통계적 가설의 진위 여부**를 판단하는 과정

순서	단계	설명
1	가설 설정	• 귀무가설과 대립가설 설정
2	유의수준 설정	• 검정이 오류를 범할 확률 α 설정(0.05가 많이 사용됨)
3	검정통계량 계산	• 표본집단을 대표하는 값을 구함
4	기각역 설정	• 귀무가설이 기각되는 구간을 설정하거나 p(유의확률)값 계산
5	판정	• 검정통계량이 기각역에 포함되거나 p값이 유의수준보다 작으면 귀무가설 기각

- 통계학 개론

- 가설 검정

- 가설 검정의 절차



• 통계학 개론

- 가설 검정

➤ 가설 검정의 방법

✓ 대립 가설의 형태에 따라 양측 검정과 단측 검정이 있음

검정	설명
양측 검정	- 귀무가설을 $H_0: \theta = \theta_0$, 대립가설을 $H_1: \theta \neq \theta_0$ (단, θ는 모수, θ_0는 관측치) 예) H_0: 한국 남자의 평균 키는 175cm이다. H_1: 한국 남자의 평균 키는 175cm가 아니다.
단측 검정	- 귀무가설을 $H_0: \theta = \theta_0$, 대립가설을 $H_1: \theta < \theta_0$ (단, θ는 모수, θ_0는 관측치) 예) H_0: 한국 남자의 평균 키는 175cm이다. H_1: 한국 남자의 평균 키는 175cm보다 작다. - 귀무가설을 $H_0: \theta = \theta_0$, 대립가설을 $H_1: \theta > \theta_0$ (단, θ는 모수, θ_0는 관측치) 예) H_0: 한국 남자의 평균 키는 175cm이다. H_1: 한국 남자의 평균 키는 175cm보다 크다.

• 통계학 개론

- 가설 검정

➤ 가설 검정 오류

- ✓ 통계적 방법에 근거하여 주어진 가설을 검증하는데 있어 모집단 전체를 이용하여 검증하는 것이 아니라 모집단으로 부터 추출된 표본을 기반으로 모집단에 대한 결론을 내리므로 통계적인 오류가 존재함

		참값(실제)	
		H_0	H_1
판정	H_0	올바른 결정($1-\alpha$)	제2종 오류(β)
	H_1	제1종 오류(α)	올바른 결정($1-\beta$)

- ✓ 일반적으로 제1종 오류의 영향이 제2종 오류의 영향보다 크므로

제1종 오류를 기준으로 가설검정을 수행함

• 통계학 개론

- 가설 검정

➤ p값(p-value) = 유의확률

✓ p값은 귀무가설이 참이라는 전제하에 표본에서 구한 검정통계량의 값보다 더 극단적인 값이 나올 확률

귀무가설 채택	$p\text{-값} > \text{유의수준}(\alpha)$
귀무가설 기각	$p\text{-값} < \text{유의수준}(\alpha)$

➤ 임계값


✓ 주어진 유의수준을 검정통계량의 값으로 환산한 값으로 귀무가설을 채택 또는 기각하는 기준

귀무가설 채택	임계값 $>$ 검정통계량
귀무가설 기각	임계값 $<$ 검정통계량

- 통계학 개론

- 가설 검정

- $H_0: \theta = \theta_0$ 하에서의 검정통계량 분포



- 통계학 개론

- 추론 통계

- 추론 통계 개념

- ✓ 모집단의 표본을 가지고 모집단의 특성을 추론하고 그 결과의 신뢰성을 검정하는 통계적 방법
 - ✓ 추정은 표본의 데이터를 사용하여 모집단을 추정하므로 어느 정도의 오차가 존재함
 - ✓ 표본의 개수가 많아질수록 표본의 오차는 감소함
 - ✓ 추정은 점 추정과 구간 추정으로 구분할 수 있음

- 통계학 개론

- 추론 통계

- 점 추정

- ✓ 표본의 정보로부터 모집단의 모수를 **하나의 값**으로 추정하는 기법
 - ✓ 점 추정치로 표본평균, 표본분산, 중위수 등이 있음
 - ✓ 점 추정치의 조건으로 **불편성, 효율성, 일치성, 충분성**이 있음

• 통계학 개론

- 추론 통계

➤ 점 추정

✓ 점 추정치의 조건으로 불편성, 효율성, 일치성, 충분성이 있음

조건	설명
불편성	- 추정치의 기대값이 모집단의 모수와 차이가 없다는 특성 $E(\hat{\theta}) = \theta$ (단, $\hat{\theta}$: 추정치, θ: 모수)
효율성	- 추정치의 분산이 작을수록 좋다는 특성 $V(\hat{\theta}_1) < V(\hat{\theta}_2)$ 일 때 $\hat{\theta}_1$이 $\hat{\theta}_2$보다 효율성이 좋음
일치성	표본의 크기가 아주 커지면 추정량이 모수와 거의 같아진다는 특성
충분성	추정량은 모수에 대한 많은 정보를 제공할수록 좋다는 특성

- 통계학 개론

- 추론 통계

- 표본평균의 표준오차(SE: Standard Error)

- ✓ 추정치는 추출된 표본에 따라 달라질 수 있음

- ✓ 정확도를 측정하기 위해 추정치의 표준편차를 계산하며 추정치의 표준편차를 **표준오차**라 함

- ✓ 표본평균의 표준오차는 $\frac{\sigma}{\sqrt{n}}$ 이며 모표준편차(σ)를 모를 때 **표본표준편차(s)**를 사용함

- ✓ 예) 어느 학교의 남학생 16명의 평균 몸무게의 표본분산이 25라고 할 때 평균 몸무게의 표준오차는?

- ✓ 답안) $\frac{\sigma}{\sqrt{n}} = \frac{\hat{\sigma}=s}{\sqrt{16}} = \frac{5}{4} = 1.25$

• 통계학 개론

- 추론 통계

➤ 구간 추정

- ✓ 구간 추정은 추정값에 대한 신뢰도를 제시하며 구간으로 모수를 추정하는 방법
- ✓ 구간을 추정하기 위해 신뢰수준과 신뢰구간을 제시함

용어	설명
신뢰수준	- 추정값이 존재하는 구간에 모수가 포함될 확률 $100(1 - \alpha)\%$로 계산(단, α는 유의수준으로 오류를 범할 최대 허용확률임)
신뢰구간	신뢰수준을 기준으로 추정된 통계적으로 유의미한 모수의 범위

- 통계학 개론

- 추론 통계

- 구간 추정

- ✓ 점 추정은 'A 후보의 지지율은 40.0%입니다.'와 같이 **하나의 값으로 추정**하는 것이고 구간 추정은 'A 후보의 지지율은 신뢰수준 95%로 신뢰구간 31% ~ 49%에 있다 ' 와 같이 **구간으로 추정**하는 것임
 - ✓ 예) A후보의 지지율을 조사하기 위해 100명의 표본을 대상으로 조사한 결과 40명이 지지한다고 응답하였다. 지지율의 신뢰율 95% 신뢰구간을 구하시오.

- ✓ 답안) $P(\text{모비율}) = p \pm z_{\alpha/2} \sqrt{\frac{p(1-p)}{n}} = 0.4 \pm 1.96 \sqrt{\frac{0.4(1-0.4)}{100}} = 0.4 \pm 0.09 = 31\% \sim 49\%$

• 통계학 개론

- 비모수 검정

- 비모수 통계는 평균이나 분산 같은 모집단의 분포를 가정하지 않고 분석하는 통계적 방법
- 비모수 통계 분석에서 빈도, 부호, 순위 등의 통계량을 사용하여 이상값으로 인한 영향이 적음
- 비모수 통계의 장단점

장점	단점
• 모집단 분포를 가정하지 않으므로 오류의 가능성이 작음 • 모수적 방법에 비해 통계량의 계산이 간편함 • 모집단의 분포에 무관하게 사용할 수 있음 • 이상값으로 인한 영향이 적음	• 모수 통계로 검정이 가능한 데이터를 비모수 통계를 이용하면 효율성이 떨어짐 • 검정통계량의 신뢰성이 부족함 • 데이터의 수가 많은 경우 모수적 통계에 비해 오히려 계산 절차가 복잡

• 통계학 개론

- 비모수 검정

➤ 비모수 통계 검정 방법의 종류

구분	모수 통계	비모수 통계
단일표본 검정	단일표본 t검정(1개의 집단)	- 부호검정 - 윌콕슨 부호 순위 검정
두 표본 검정	독립표본 t검정(독립적인 2개의 집단)	윌콕슨 순위 합 검정
	대응표본 t검정(대응있는 1개의 집단)	- 부호검정 - 윌콕슨 부호 순위 검정
분산 분석	분산분석표(3개 집단이상)	크루스칼-왈리스 검정
상관 분석	피어슨 상관계수	스피어만 순위 상관계수
런검정	비모수 통계로 연속적인 측정값들이 어떤 패턴이나 경향없이 임의로 나타난 것인지를 검정하는 방법	

- 자료의 척도에 대한 설명으로 적절하지 않은 것은?

- ① 명목 척도는 단순히 측정 대상의 특성을 분류하거나 확인하기 위한 목적으로 숫자를 부여한다.
- ② 순서 척도는 대소 또는 높고 낮음 등의 순위만 제공할 뿐 양적인 비교는 할 수 없다.
- ③ 등간 척도는 순위를 부여하되 순위 사이의 간격이 같아 양적인 비교가 가능하다.
- ④ 비율 척도는 측정값 사이의 비율 계산이 가능한 척도이며, 절대 영점이 존재하지 않는다.

- 귀무가설이 참이라는 전제하에 실제 표본에서 구한 표본 통계량의 값보다 더 극단적인 값이 나올 확률은?

- ① 유의수준
- ② p-값(p-value)
- ③ 검정통계량
- ④ 기각역

• 두 집단의 분산이 같은지 검정할 때 사용하는 검정통계량은 어떤 분포를 활용하는가?

- ① 포아송 분포
- ② F-분포
- ③ χ^2 분포
- ④ Z-분포

- 다음이 설명하는 표본추출 방법은 무엇인가?

번호를 부여한 샘플을 나열하여 k 개씩 n 개의 구간으로 나누고 첫 구간($1, 2, 3, \dots, k$)에서 하나를 임의로 선택한 후 k 개씩 띄어서 n 개의 표본을 선택한다. 즉, 임의 위치에서 매 k 번째 항목을 추출하는 방법이다.

① 계통추출법

② 집락추출법

③ 층화추출법

④ 단순 무작위 추출법

- 다음 중 확률질량함수의 확률변수 x 의 기대값은?

x	1	2	3
$f(x)$	$1/6$	$3/6$	$2/6$

- ① $5/6$
- ② $4/6$
- ③ $13/6$
- ④ $7/10$

- 두 개의 확률변수 X, Y 의 공분산에 대한 설명 중 가장 부적절한 것은?
 - ① 공분산이 0이면 두 변수 간에는 아무런 선형관계가 없으며 두 변수는 서로 독립적인 관계이다.
 - ② 공분산이 음수이면 X 가 증가할 때 Y 는 감소한다.
 - ③ 공분산이 양수이면 X 가 증가할 때 Y 도 증가한다.
 - ④ 공분산의 크기는 0~1사이의 범위를 갖는다.

• 다음 중 이산형 확률변수 x 의 기대값은?

① $E(x) = \sum xf(x)$

② $E(x) = \int xf(x)$

③ $E(x) = E[(x - \mu)^2]$

④ $E(x) = E(x^2) - \mu^2$

• 다음 중 중심극한정리에 대한 설명 중 가장 부적절한 것은?

- ① 표본 크기가 증가할수록 표본의 평균과 표준편차가 모집단의 평균과 표준편차에 가까워짐을 의미하게 된다.
- ② 중심극한정리가 성립하기 위해서는 표본의 크기가 최소 30 이상이어야 한다.
- ③ 모집단이 정규분포가 아닐 때 서로 다른 표본의 크기에 대한 표본평균의 분포들이 표본의 크기가 커짐에 따라 정규분포에 가까워지게 된다.
- ④ 모집단의 분포가 정규분포에 가까워져야 표본평균의 분포가 정규분포로 근사하게 된다.

• 다음 중 거식증 환자 30명의 치료 전·후 평균 체중 변화를 분석하여 치료의 효과 등을 분석하는 방법은?

- ① 독립 표본 t-검정
- ② 분산 분석
- ③ 윌콕슨 부호 순위 검정
- ④ 런 검정

- 다음 중 오른쪽 꼬리가 긴 분포를 가진 분포에서 최빈수, 중위수, 평균값의 크기 순서는?

- ① 중위수 < 최빈수 < 평균
- ② 최빈수 < 중위수 < 평균
- ③ 최빈수 < 평균 < 중위수
- ④ 평균 < 최빈수 < 중위수

- 서비스의 만족도를 조사하고자 하는 설문에서 사용되는 척도는?
 - ① 순서 척도
 - ② 명목 척도
 - ③ 등간 척도
 - ④ 비율 척도

- 모집단의 성격에 따라 몇 개의 집단 또는 층으로 나누고, 각 집단 내에 원하는 크기의 표본을 무작위로 추출하는 표본추출 방법을 무엇이라고 하는가?

- 다음 중 비율 척도에 대한 예시로 가장 적절한 것은?
 - ① 무게, 나이
 - ② 성별, 출생지
 - ③ 온도, 지수
 - ④ 선호도

- 다음 중 공분산과 상관계수에 대한 설명 중 가장 옳바르지 않은 것은?
 - ① 공분산은 측정 단위에 영향을 받지 않는다.
 - ② 상관 분석은 두 변수의 인과 관계 성립 여부를 확인할 수 없다.
 - ③ 공분산이 0이라면 두 변수 간에는 아무런 선형 관계가 없고 서로 독립적인 관계에 있다.
 - ④ 상관계수를 통해 상관관계의 표준화된 크기를 측정할 수 있다.

• 다음 중에서 확률 및 확률분포에 대한 설명 중 가장 적절하지 못한 것은?

- ① 확률변수 x 가 구간 또는 구간들의 모임인 숫자 값을 갖는 확률 분포 함수를 이산형 확률 질량 함수라 한다.
- ② 모든 확률은 0과 1사이의 값을 가진다.
- ③ 확률함수는 확률변수에 의해 정의된 실수를 확률에 대응시키는 함수이다.
- ④ 서로 배반인 사건에 대한 합집합의 확률은 각 사건에 대한 확률의 합이 된다.

- 다음 중 통계적 가설 검정에 관한 내용으로 가장 적절하지 않은 것은 무엇인가?
 - ① 귀무가설이 참이 아닌데도 귀무가설을 채택할 오류의 확률을 검정력이라고 한다.
 - ② 귀무가설을 기각시키는 검정통계량의 범위를 기각역이라고 한다.
 - ③ 귀무가설이 맞다는 가정하에 표본 통계량보다 더 극단적인 결과가 관측될 확률을 유의확률이라고 한다.
 - ④ 귀무가설이 참인데도 기각함으로써 발생하는 오류를 제1종 오류라고 한다.

- 다음 중 가설 검정의 오류에 관한 내용으로 가장 옳바르지 않은 것은?
 - ① 제1종 오류는 귀무가설이 참인데도 귀무가설을 기각하게 되는 오류이다.
 - ② 제2종 오류는 대립가설이 거짓인데도 귀무가설을 채택하게 되는 오류이다.
 - ③ 유의수준은 제1종 오류를 범할 최대 허용 확률을 의미한다.
 - ④ 제1종 오류와 제2종 오류는 표본 크기가 일정한 경우 동시에 감소시킬 수 없다.

- 실험 결과가 단지 성공과 실패만 있는 베르누이 시행에서 성공일 경우의 확률 변수는 1, 실패일 경우의 확률변수가 0의 값을 가진다. 성공일 확률이 0.3으로 주어지면 기대값은 얼마인가?

- 다음 chickwts 데이터 세트에서 무게의 검정 결과에 대한 설명으로 적절하지 않은 것은?

```
> t.test(chickwts$weight, mu=250)

One Sample t-test

data:  chickwts$weight
t = 1.2206, df = 70, p-value = 0.2263
alternative hypothesis: true mean is not equal to 250
95 percent confidence interval:
 242.8301 279.7896
sample estimates:
mean of x
 261.3099
```

- ① 평균 무게는 261.30이다.
- ② 평균 무게에 대한 점 추정량은 261.30이다.
- ③ 무게가 250과 같다는 가설은 기각된다.
- ④ 무게에 대한 95% 신뢰구간은 (242.83, 279.79)이다.

- 이산형 확률분포 중 단위 시간 또는 영역에서 어떤 사건의 발생 횟수를 나타내는 확률분포는 무엇인가?

• 이질적인 원소들로 구성된 모집단에서 각 계층을 고루 대표할 수 있도록 표본을 추출하는 표본 추출 방법은 무엇인가?

- ① 층화추출법
- ② 집락추출법
- ③ 계통추출법
- ④ 단순 랜덤추출법

- 다음 중 비모수 검정이 아닌 것은?

- ① 런검정
- ② 윌콕슨의 부호 순위 합 검정
- ③ 카이제곱 검정
- ④ 부호 검정

모듈 7-2

기초 통계 분석

- 기초 통계 분석

- 기술 통계

- 기술 통계는 데이터 분석 목적으로 수집된 데이터를 확률·통계적으로 정리·요약하는 기초적인 방법
 - 기술 통계는 분석의 초기 단계에서 데이터 분포의 특징을 파악하려는 목적으로 산출됨

- 기초 통계 분석

- 기술 통계값

- 중심위치 측도

- ✓ 모평균: $\mu = \frac{1}{N} \sum_{i=1}^N x_i$ (단, N 은 모집단의 개수)

- ✓ 표본평균: $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ (단, n 은 표본집단의 개수)

- ✓ 중위수: 데이터를 오름차순으로 정렬하여 중앙에 위치한 데이터로 이상값에 대한 영향이 미미함

- ✓ 중위수는 데이터가 홀수개일때는 $\frac{n+1}{2}$ 번째 값이며 짝수개일때는 $\frac{n}{2}, \frac{n}{2} + 1$ 번째 값의 평균임

• 기초 통계 분석

- 기술 통계값

➤ 중심위치 측도

- ✓ 최빈수: 데이터 중 빈도수가 가장 높은 데이터
- ✓ 사분위수: 모든 데이터를 순서대로 배열하였을 때 4등분한 지점에 있는 값

종류	설명
제1사분위수	• 데이터를 오름차순하여 25% 지점에 있는 값
제2사분위수	• 데이터를 오름차순하여 50% 지점에 있는 값
제3사분위수	• 데이터를 오름차순하여 75% 지점에 있는 값

- 기초 통계 분석

- 기술 통계값

- 산포 측도

- ✓ 산포도는 주어진 자료가 **흩어진 정도**를 나타내는 값

- ✓ 분산은 각 데이터가 평균으로부터 얼마나 떨어져 있는지를 나타내는 값

- ✓ 모분산: $\sigma^2 = \frac{\sum_{i=1}^N (x_i - \mu)^2}{N}$ (단, N 은 모집단의 개수)

- ✓ 표본분산: $s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}$ (단, n 은 표본집단의 개수)

- 기초 통계 분석

- 기술 통계값

- 산포 측도

- ✓ 표준편차는 분산에 제곱근을 취한 값

- ✓ 모표준편차: $\sigma = \sqrt{\frac{\sum_{i=1}^N (x_i - \mu)^2}{N}}$ (단, N 은 모집단의 개수)

- ✓ 표본표준편차: $s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}}$ (단, n 은 표본집단의 개수)

- 기초 통계 분석

- 기술 통계값

- 산포 측도

- ✓ 범위: 데이터 중 최대값과 최소값의 차이($R = x_{max} - x_{min}$)
 - ✓ 사분위범위(IQR): $Q_3 - Q_1$ (단, Q_3 는 제3사분위수, Q_1 은 제1사분위수)
 - ✓ 사분편차: 사분위범위의 절반 값($\frac{IQR}{2} = \frac{Q_3 - Q_1}{2}$)

- 기초 통계 분석

- 기술 통계값

- 산포 측도

- ✓ 평균 절대 편차: 평균과 개별 관측치 차이의 평균으로 평균 편차 또는 절대편차라고 불림

- ✓ 모평균 절대편차: $MAD = \frac{1}{N} \sum_{i=1}^N |x_i - \mu|$

- ✓ 표본평균 절대편차: $MAD = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$

- 기초 통계 분석

- 기술 통계값

- 데이터 분포

- ✓ 데이터 분포의 형태와 대칭성을 설명할 수 있는 통계량은 첨도와 왜도가 있음
 - ✓ 첨도: 데이터 분포의 '뽀족한 정도'를 설명하는 통계량

유형	설명
첨도=0	• 데이터의 분포가 표준정규분포와 뽀족한 정도가 같음
첨도>0	• 데이터의 분포가 표준정규분포보다 더 뽀족함
첨도<0	• 데이터의 분포가 표준정규분포보다 덜 뽀족함

• 기초 통계 분석

- 기술 통계값

➤ 데이터 분포

- ✓ 데이터 분포의 형태와 대칭성을 설명할 수 있는 통계량은 첨도와 왜도가 있음
- ✓ 왜도: 데이터 분포의 '기울어진 정도'를 설명하는 통계량

유형	설명
왜도=0	• 좌우대칭, 최빈수=중위수=평균
왜도>0	• 우측으로 긴 꼬리형태, 최빈수<중위수<평균
왜도<0	• 좌측으로 긴 꼬리형태, 평균<중위수<최빈수

- 기초 통계 분석

- 회귀 분석

- 회귀분석의 개념

- ✓ 회귀 분석은 하나 이상의 독립변수들이 종속변수에 미치는 영향을 추정할 수 있는 통계기법
 - ✓ 독립변수와 종속변수의 관계가 선형이고 독립변수의 개수가 하나이면 단순선형회귀분석, 독립변수의 개수가 2개 이상이면 다중선형회귀분석임

• 기초 통계 분석

- 회귀 분석

➤ 단순선형회귀 분석

✓ 회귀식: $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$


✓ y_i : i 번째 종속변수값, x_i : i 번째 독립변수값

✓ β_0 : y 절편으로 $x = 0$ 일때 y 의 값

✓ β_1 : 기울기로 x 가 1변할때 y 의 변화량

✓ ε_i : i 번째 오차항(단, $N(0, \sigma^2)$)

✓ 이상적인 회귀식을 찾기 위해 **최소제곱법(최소 자승법)**을 이용하여 오차의 제곱합이 최소가 되는 회귀선을 찾음



• 기초 통계 분석

- 회귀 분석

➤ 단순선형회귀 분석

✓ 회귀분석의 가정에는 선형성, 독립성, 등분산성, 비상관성, 정상성이 있음

가정	설명
선형성	- 독립변수와 종속변수가 선형적이어야 한다는 특성 - 독립변수의 변화에 따라 종속변수가 일정 크기로 변화
독립성	- 단순선형회귀분석에서 잔차와 독립변수의 값이 서로 독립적이어야 함 - 다중선형회귀분석에서 독립변수 간 상관성이 없어야 함
등분산성	- 잔차의 분산이 독립변수와 무관하게 일정해야 한다는 특성 - 잔차는 표본집단에서 회귀식으로 예측한 값과 실제 값과의 차이를 말함
비상관성	관측값과 잔차는 서로 상관이 없어야 한다는 특성
정상성	잔차항이 정규분포의 형태를 이뤄야 한다는 특성


• 기초 통계 분석

- 회귀 분석

➤ 단순선형회귀 분석

✓ 회귀분석의 가정에는 선형성, 독립성, 등분산성, 비상관성, 정상성이 있음

가정	설명
선형성	• 선형성을 만족하려면 잔차들의 평균값은 일정해야 함 • 정상적이라면 잔차의 평균은 0으로 일직선이 되며 비정상적이라면 U자 형태의 모양이 나옴




• 기초 통계 분석

- 회귀 분석

➤ 단순선형회귀 분석

✓ 회귀분석의 가정에는 선형성, 독립성, 등분산성, 비상관성, 정상성이 있음

가정	설명
등분산성	• 등분산성이 있다면 잔차가 고르게 분포되어야 하며 비정상적이라면 나팔 혹은 깔때기 모양이 나옴



- 기초 통계 분석

- 회귀 분석

- 다중선형회귀 분석

- ✓ 회귀식: $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + \varepsilon$

- ✓ Y : 종속변수 행렬, $x_1, x_2, \cdots, x_k$: 독립변수 행렬

- ✓ β_0 : y 절편으로 $x = 0$ 일때 y 의 값

- ✓ $\beta_1, \beta_2, \cdots, \beta_k$: 독립변수 기울기

- ✓ ε : 오차항(단, $N(0, \sigma^2)$, 서로독립)

• 기초 통계 분석

- 회귀 분석

➤ 다중선형회귀 분석

- ✓ 다중공선성은 회귀분석에서 독립변수들 간 강한 상관관계가 나타나는 문제
- ✓ 다중회귀분석에서 독립변수들 사이에 선형 관계가 존재하면 회귀 계수의 정확한 추정이 난해함
- ✓ 다중 공선성 검사 방법으로 분산팽창요인, 상태지수가 있음

방법	설명
분산팽창요인	• 1에 가까울수록 다중공선성이 낮고 4보다 크면 다중 공선성이 존재 • 10보다 크면 심각한 문제가 있는 것으로 해석
상태지수	• 10이상이면 문제가 있고 30보다 크면 심각한 문제가 있다고 해석

• 기초 통계 분석

- 회귀 분석

➤ 회귀 분석 모형 구축

- ✓ 선형 회귀 분석은 lm함수를 사용하여 분석함
- ✓ `lm(formula, data)`

주요 파라미터	설명
formula	- 회귀식의 종속변수, 독립변수 지정 - 종속변수~독립변수 형태로 지정 - 다중회귀분석은 독립변수 여러 개 지정 예) <code>Salary ~ Experience + Major</code>
data	데이터 프레임 명

• 기초 통계 분석

- 회귀 분석

➤ 회귀 분석 해석

✓ lm함수를 적용하면 summary 정보가 제공됨

항목	설명
Estimate (추정값)	독립변수에 대한 회귀계수 추정값
Std. Error (표준오차)	- 독립변수에 대한 측정값의 표준편차 - 표준오차가 작을수록 추정값과 관측값 차이가 작음
t value (t-값)	- 독립변수와 종속변수 간 선형관계가 존재하는 정도를 나타낸 통계량 - t값의 절대값이 클수록 독립변수가 종속변수에 유의함
Pr(> t) (p-값)	- p-값(유의확률)이 작을수록 독립변수가 종속변수에 유의함 - 예시) 0.01~0.05(*), 0.001~0.01(**)

• 기초 통계 분석

- 회귀 분석

➤ 회귀 분석 평가

✓ 회귀분석은 회귀계수 검정, 회귀모형의 설명력, 적합도 검증 및 통계적 유의성 검증으로 모형을 평가함

구분	설명
잔차의 표준오차	관측값들이 실제 회귀선으로부터 떨어진 정도를 나타내는 통계량
결정계수 (R^2)	- 전체 데이터를 회귀모형이 얼마나 잘 설명하고 있는지를 보여주는 통계량 - 결정계수를 통해 추정된 회귀식이 얼마나 타당한지를 검토함 - 값이 1에 가까울수록 회귀모형이 자료를 잘 설명함
수정된 결정계수	- 독립변수의 개수가 많아짐에 따라 무조건 증가하는 결정계수의 문제점을 보완한 통계량 - 설명력이 떨어지는 독립변수가 추가할 때는 값이 감소하는 특징이 있음

• 기초 통계 분석

- 회귀 분석

➤ 회귀 분석 평가

✓ 회귀분석은 회귀계수 검정, 회귀모형의 설명력, 적합도 검증 및 통계적 유의성 검증으로 모형을 평가함

구분	설명
F-통계량	- 모형의 통계적 유의성을 판단함 - F-통계량의 p-값이 0.05보다 작으면 회귀모형은 통계적으로 유의함 - 귀무가설(H_0): $\beta_1 = \beta_2 = \dots = \beta_k = 0$ - 대립가설(H_1): $\beta_1 \sim \beta_k$ 중에서 적어도 하나는 0이 아니다.

- 기초 통계 분석

- 회귀 분석

- 회귀 분석 평가

- ✓ 회귀분석의 분산분석표(ANOVA: Analysis of Variance)

	df	Sum Sq	Mean Sq	F value	Pr(>F)
x1	1	280	280	756.8	2.2e-16***
Residuals	1923	720	0.37		

- ✓ 결정계수 $R^2 = \frac{SSR}{SST} = \frac{280}{1000}$ 으로 회귀변동/전체변동으로 구해짐

• 기초 통계 분석

- 회귀 분석

➤ 회귀 분석 평가

- ✓ lm (단순선형회귀모형) 적용
- ✓ (Intercept)가 $\Pr(>|t|) < 0.05$, 유의함
- ✓ Examination은 $\Pr(>|t|) > 0.05$ 유의하지 않음
- ✓ 결정계수: 0.7067, p-value < 0.05이므로
- ✓ F통계량은 19.76, p-value는 $5.594e-10$ 으로
0.05보다 작으므로 5%에서 귀무가설 기각
- ✓ 회귀모형이 통계적으로 유의함

```
> summary(lm(Fertility~., data=swiss))

Call:
lm(formula = Fertility ~ ., data = swiss)

Residuals:
    Min       1Q   Median       3Q      Max
-15.2743  -5.2617   0.5032   4.1198  15.3213

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  66.91518   10.70604   6.250 1.91e-07 ***
Agriculture  -0.17211    0.07030  -2.448 0.01873 *
Examination  -0.25801    0.25388  -1.016 0.31546
Education    -0.87094    0.18303  -4.758 2.43e-05 ***
Catholic      0.10412    0.03526   2.953 0.00519 **
Infant.Mortality 1.07705    0.38172   2.822 0.00734 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 7.165 on 41 degrees of freedom
Multiple R-squared:  0.7067,    Adjusted R-squared:  0.671
F-statistic: 19.76 on 5 and 41 DF,  p-value: 5.594e-10
```

- 기초 통계 분석

- 회귀 분석

- 정규화 선형회귀

- ✓ 정규화 선형회귀는 선형회귀계수에 대한 제약 조건을 추가하여 모형이 과도하게 최적화되는 **과대 적합을 막는 방법**
 - ✓ 선형회귀의 과적합 문제를 해결하는 정규화 방법에 라쏘 회귀, 릿지 회귀, 엘라스틱 넷이 있음
 - ✓ 라쏘 회귀: 기존 함수에 모든 가중치들의 절대값 합계를 추가하여 값이 최소가 되도록 함
 - ✓ 릿지 회귀: 기존 함수에 모든 가중치들의 제곱합을 추가함
 - ✓ 엘라스틱 넷: 기존 함수에 거리측정 규제를 추가함

• 기초 통계 분석

- 변수 선택

➤ 변수 선택 기법

- ✓ 변수 선택은 데이터의 독립변수 중 종속변수에 가장 **관련성이 높은 변수만**을 선정하는 방법
- ✓ 변수 선택은 step 함수를 사용하고 direction 옵션을 통해 선택할 수 있음
- ✓ AIC를 기준으로 모델을 선택(AIC: 적합성 비교지수로 낮을수록 좋음)

알고리즘	설명
전진 선택법	• 모델을 가장 많이 향상시키는 변수를 하나씩 점진적으로 추가하는 방법 • 변수 추가 시 선택기준이 향상되지 않을 때 변수 추가를 중단
후진 제거법	• 변수를 모두 포함한 상태에서 시작하며 가장 적은 영향을 주는 변수부터 하나씩 제거하는 방법
단계적 방법	• 전진 선택법과 후진 제거법을 함께 사용

• 기초 통계 분석

- 변수 선택

➤ 변수 선택 기법

- ✓ step 함수
- ✓ step 함수는 AIC가 작아지는 방향으로 단계적으로 변수를 선택하는 함수로 AIC가 가장 작은 값을 가지도록 하는 변수를 제거함
- ✓ `step(object, scope, direction)`

주요 파라미터	설명
object	• 대상 객체
scope	• 탐색할 모델의 범위 지정
direction	• forward: 전진선택법, backward: 후진 제거법, both: 단계적 방법

- 기초 통계 분석

- 변수 선택

- 변수 선택 기법

- ✓ formula 함수

- ✓ formula함수는 step함수를 수행한 뒤 반환 값을 변수로 전달받아 표물려('종속변수~독립변수' 형태)를 구하는 함수

- ✓ formula (x)

주요 파라미터	설명
x	• step 함수의 반환 값을 입력

- 기초 통계 분석

- 변수 선택

- 변수 선택 기법

```
> m1 <- lm(hp~., data=mtcars)
> m2 <- step(m1, direction='both')
Start: AIC=216.97
hp ~ mpg + cyl + disp + drat + wt + qsec + vs + am + gear + carb
```

	Df	Sum of Sq	RSS	AIC	
- qsec	1	39.6	14204	215.06	→ 제거대상
- drat	1	55.6	14220	215.09	
- am	1	140.8	14306	215.28	
- gear	1	164.4	14329	215.34	
- cyl	1	446.2	14611	215.96	
- mpg	1	656.9	14822	216.42	
<none>			14165	216.97	
- vs	1	1140.5	15305	217.45	
- wt	1	1389.7	15554	217.96	
- carb	1	4799.2	18964	224.31	
- disp	1	5839.6	20004	226.01	

- 기초 통계 분석

- 변수 선택

- 변수 선택 기법

Step: AIC=215.06

hp ~ mpg + cyl + disp + drat + wt + vs + am + gear + carb

	Df	Sum of Sq	RSS	AIC	
- drat	1	50.6	14255	213.17	→ 제거대상
- gear	1	184.3	14389	213.47	
- am	1	216.7	14421	213.54	
- cyl	1	565.0	14769	214.31	
- mpg	1	793.5	14998	214.80	
<none>			14204	215.06	
- vs	1	1133.8	15338	215.52	
+ qsec	1	39.6	14165	216.97	
- wt	1	2577.3	16782	218.39	
- carb	1	5653.2	19858	223.78	
- disp	1	7460.7	21665	226.57	

- 기초 통계 분석

- 변수 선택

- 변수 선택 기법

- ✓ 변수를 추가하거나 제거하는 작업보다 아무 작업도 하지 않은 현재 상태가 가장 좋은 AIC를 보임

```
Step:  AIC=207.98
hp ~ disp + wt + carb

      Df Sum of Sq  RSS   AIC
<none>            16564 207.98
+ mpg      1         856 15708 208.28
+ vs       1         388 16176 209.22
+ cyl      1         276 16288 209.44
+ drat     1         239 16325 209.51
+ qsec     1          67 16497 209.85
+ am       1          12 16552 209.95
+ gear     1           4 16560 209.97
- wt       1        4961 21525 214.36
- disp     1       26844 43408 236.81
- carb     1       36686 53250 243.34
```

- summary(mtcars)에 대한 설명 중 적절하지 않은 것은?

```
> summary(mtcars)
```

mpg	cyl	disp	hp
Min. :10.40	Min. :4.000	Min. : 71.1	Min. : 52.0
1st Qu.:15.43	1st Qu.:4.000	1st Qu.:120.8	1st Qu.: 96.5
Median :19.20	Median :6.000	Median :196.3	Median :123.0
Mean :20.09	Mean :6.188	Mean :230.7	Mean :146.7
3rd Qu.:22.80	3rd Qu.:8.000	3rd Qu.:326.0	3rd Qu.:180.0
Max. :33.90	Max. :8.000	Max. :472.0	Max. :335.0

- ① mpg 변수 분포는 왼쪽 꼬리가 긴 분포이다.
- ② hp 변수는 수치형 자료이다.
- ③ cyl 변수는 결측값이 없음을 알 수 있다.
- ④ disp 변수의 최대값은 472이다.

- 다음 데이터의 Education 변수는 약 몇 %가 12보다 큰 값을 가지는가?

```
> summary(swiss$Education)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  1.00   6.00   8.00  10.98  12.00   53.00
```

• 다음 중에서 자료들의 중간 50%에 흠어진 정도를 나타내는 통계량은 무엇인가?

- ① 중위수
- ② 사분위수 범위
- ③ 평균
- ④ 분산

- 다음의 R의 벡터 데이터에서 평균, 최빈수, 중위수, 범위의 값을 모두 더한 값은 얼마인가?

```
data <- c(1, 1, 2, 3, 4, 4, 4, 4, 4, 6, 7, 8)
```

- ① 18
- ② 19
- ③ 20
- ④ 21

- 다음 산포의 척도에 관한 설명 중 적절하지 않은 것은?
 - ① 변동계수는 분포의 퍼짐 정도를 비교하게 해준다.
 - ② IQR은 (3사분위수 - 1사분위수)이다.
 - ③ 평균 절대편차는 관측값에서 평균을 뺀 값에 대한 절대값을 모두 더한 값이다.
 - ④ 사분위 수는 데이터 표본을 4개의 동일한 부분으로 나눈 값이다.

- 100개의 실수 관측값을 수집하여 평균과 표준편차를 구한 결과 각각 10과 2가 나왔다. 모든 관측값에 4를 더한 후에 평균과 표준편차를 구하면 값의 변화는 어떻게 되는가?

- ① 평균은 10, 표준편차는 2로 변화가 없다.
- ② 평균은 14, 표준편차는 4가 된다.
- ③ 평균은 14가 되고 표준편차는 2가 된다.
- ④ 평균은 14가 되고 표준편차는 6이 된다.

• 다음 중 변수의 측정 수준에 따라 집중 경향값과 산포도에 관한 설명으로 틀린 것은?

- ① 중위수는 대표적인 집중 경향값으로 이상값에 의한 영향이 민감하다는 단점이 있다.
- ② 최빈수는 관측된 데이터값 중에서 가장 여러 번 나타난 값이다.
- ③ 표본평균은 데이터의 합을 총 개수로 나눈 값을 의미한다.
- ④ 사분위수는 모든 데이터값을 순서대로 배열하였을 때 4등분한 지점에 있는 값이다.

- 다음 회귀 분석에서 가장 적합한 회귀 모형을 찾기 위한 과정의 설명으로 가장 알맞지 않은 것은?

- ① 회귀식에 대한 검정은 독립변수의 기울기가 0이 아니라는 가정을 귀무가설, 기울기가 0인 것을 대립가설로 놓는다.
- ② 회귀 분석의 가설 검정에서 p-값이 0.05보다 작은 값이 나와야 통계적으로 유의한 결과이다.
- ③ 잔차의 독립성, 등분산성, 정규성을 만족하는지 확인해야 한다.
- ④ 독립변수의 수가 많아지면 독립변수 간에 서로 영향을 미치는 다중 공선성의 문제가 발생하므로 상대적인 조정이 필요하다.

- 회귀 분석 결정계수에 대한 설명으로 가장 알맞지 않은 것은?
 - ① 회귀모형에서 입력 변수가 증가하면 결정계수도 증가한다.
 - ② 결정계수는 총 변동 중에서 회귀 모형에 의하여 설명되지 않은 오차에 의한 변동이 차지하는 비율이다.
 - ③ 수정된 결정계수는 유의하지 않은 독립변수들이 회귀식에 포함되었을 때 그 값이 감소한다.
 - ④ 다중 회귀 분석에서는 최종 모형의 선정기준으로 결정계수 값보다는 수정된 결정계수 값을 사용하는 것이 적절하다.

- 회귀 방정식에서 자료를 가장 잘 설명해주는 추정값을 찾기 위해 잔차의 제곱합을 최소화 하는 방법을 무엇이라고 하는가?

- 다중회귀모형의 통계적 유의성을 확인하는 방법은?
 - ① F 통계량을 확인한다.
 - ② 결정계수를 확인한다.
 - ③ 잔차 통계량을 확인한다.
 - ④ 회귀계수의 t값을 확인한다.

- 회귀 분석의 가정 중 정상성은 ()이/가 정규분포를 이뤄야 함을 가정한다.

- 다음은 회귀 분석의 분산분석표이다. 결정계수의 값은?

	df	Sum Sq	Mean Sq	F value	Pr(>F)
x1	1	280	280	756.8	2.2e-16***
Residuals	1923	720	0.37		

- 다중 공선성에 대한 설명으로 다음 중 가장 옳지 않은 것은 무엇인가?
 - ① 구조적 다중 공선성의 문제가 있는 경우에는 데이터의 평균은 변화한다.
 - ② 일반적으로 VIF값이 10 이상이면 다중공선성에 문제가 있다고 판단한다.
 - ③ VIF 값이 "1"에 가까우면 다중공선성이 존재한다.
 - ④ 다중공선성 문제를 해결하기 위해 중요하지 않지만 다른 변수의 상관성이 높은 변수를 제거한다.

- 다음은 cars데이터 세트에서 속도와 제동거리의 관계를 회귀모형으로 분석한 것이다. 다음 중 옳지 않은 것은 무엇인가?

- ① 회귀 계수는 5% 수준에서 유의하다.
- ② 잔차 분산 σ^2 의 불편추정량은 236.5이다.
- ③ 전체 관측치 수가 49개이다.
- ④ 결정계수는 0.6511이다.

```
Call:
lm(formula = dist ~ speed, data = cars)

Residuals:
    Min       1Q   Median       3Q      Max
-29.069  -9.525  -2.272   9.215  43.201

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -17.5791     6.7584  -2.601   0.0123 *
speed         3.9324     0.4155   9.464 1.49e-12 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 15.38 on 48 degrees of freedom
Multiple R-squared:  0.6511,    Adjusted R-squared:  0.6438
F-statistic: 89.57 on 1 and 48 DF,  p-value: 1.49e-12


> anova(out)
Analysis of Variance Table

Response: dist
      Df Sum Sq Mean Sq F value    Pr(>F)
speed   1  21186  21185.5   89.567 1.49e-12 ***
Residuals 48  11354    236.5
```

- 회귀 분석에서 독립변수 간 상관관계가 높아 많은 문제점을 발생하는 현상을 무엇이라 하는가?

- ① 다중 공선성
- ② 상관행렬
- ③ 능형회귀
- ④ 전진 선택법

- 다음 그림은 회귀분석에서 잔차 분석의 어떤 가정을 위배하고 있는가?




- ① 선형성
- ② 정규성
- ③ 등분산성
- ④ 독립성

- 다중 공선성에 대한 설명 중 옳바르지 않은 것은?

- ① 다중 공선성 문제가 발생하면 문제가 있는 변수를 제거하고 분석할 수 있다.
- ② 다중 공선성 문제로 불확실성이 감소할 수 있다.
- ③ 독립변수 간에 상관관계가 높아서 데이터를 분석할 때 부정적 영향을 미치는 경우가 발생한다.
- ④ VIF가 4보다 크면 다중 공선성이 존재하는 것으로 해석한다.

- 다음은 결과를 생성한 잔차도이다. 다음 중 어떤 회귀분석의 가정이 위배되었다고 판단할 수 있는지 고르시오.

- ① 비정규성
- ② 독립성
- ③ 선형성
- ④ 정상성



- 회귀 분석에서 잔차 분석은 회귀 모형에 대한 가정을 충족하는지에 대한 검정, 이상값이 있는지에 대한 검정을 하는 절차이다. 이와 관련된 가정으로 적합한 것은 무엇인가?

- ① 독립성, 적정성, 유일성
- ② 독립성, 등분산성, 정규성
- ③ 정규성, 효과성, 등분산성
- ④ 정규성, 유일성, 독립성

- 다음 중 잔차 분석에 대한 설명으로 옳지 않은 것은?

- ① 잔차 분석은 회귀 모형에 대한 가정을 충족하는지를 검정하는 절차이다.
- ② 잔차항이 정규분포를 따르는지 알아보는 검정으로 샤피로-윌크 검정이 있다.
- ③ 더빈-왓슨 검정은 등분산성에 대한 검정 기법이다.
- ④ 잔차는 특정한 패턴이 없어야 한다.

- 다음은 다중 회귀의 어떤 단계적 변수 선택에 관한 설명인가?

독립변수 후보 모두를 포함한 모형에서 출발해 제곱합의 기준으로 가장 적은 영향을 주는 변수로부터 하나씩 제거하면서 더 이상 유의하지 않은 변수가 없을 때까지 독립변수를 제거하고, 이때 모형을 선택한다.

• 다음 중 모델의 정확도 및 성능을 향상하기 위한 변수 선택 방법으로 적합하지 않은 것은?

- ① 단계적 방법
- ② 전진 선택법
- ③ 순차적 방법
- ④ 후진 제거법

- Cars데이터에 대해서 종속변수를 dist로, 독립변수는 speed로 회귀분석을 하려고 한다. 적절한 R 코드는 무엇인가?

```
> data(cars)
> summary()

Call:
lm(formula = dist ~ speed, data = cars)

Residuals:
    Min       1Q   Median       3Q      Max
-29.069  -9.525  -2.272   9.215  43.201

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -17.5791     6.7584  -2.601   0.0123 *
speed         3.9324     0.4155   9.464 1.49e-12 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 15.38 on 48 degrees of freedom
Multiple R-squared:  0.6511,    Adjusted R-squared:  0.6438
F-statistic: 89.57 on 1 and 48 DF,  p-value: 1.49e-12
```

- ① glm(dist~speed, data=cars)
- ② lm(speed~dist, data=cars)
- ③ lm(dist~speed, data=cars)
- ④ glm(speed~dist, data=cars)

- 다음의 회귀 방정식의 summary 결과에서 후진 제거법으로 변수 선택법을 사용할 때 가장 먼저 제거되는 변수는 다음 중 무엇인가?

- ① cyl
- ② hp
- ③ wt
- ④ (Intercept)

```
Call:
lm(formula = mpg ~ cyl + hp + wt, data = mtcars)

Residuals:
    Min       1Q   Median       3Q      Max
-3.9290 -1.5598 -0.5311  1.1850  5.8986

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  38.75179    1.78686   21.687  < 2e-16 ***
cyl          -0.94162    0.55092   -1.709  0.098480 .
hp           -0.01804    0.01188   -1.519  0.140015
wt           -3.16697    0.74058   -4.276  0.000199 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.512 on 28 degrees of freedom
Multiple R-squared:  0.8431,    Adjusted R-squared:  0.8263
F-statistic: 50.17 on 3 and 28 DF,  p-value: 2.184e-11
```

• 다음 모형의 변수 선택에 대한 설명으로 부적절한 것은?

- ① Start AIC보다 작은 모든 변수는 다음 Step에서 모두 제외된다.
- ② 한번 제거된 변수는 다시 모형에 포함되지 않는다.
- ③ 후진 제거법으로 변수 선택을 하고 있다.
- ④ 모든 독립변수가 포함된 모형에서 시작한다.

```
> model<-lm(mpg~., data=mtcars)
> step(model, direction='backward')
Start: AIC=70.9
mpg ~ cyl + disp + hp + drat + wt + qsec + vs + am + gear + carb
```

	Df	Sum of Sq	RSS	AIC
- cyl	1	0.0799	147.57	68.915
- vs	1	0.1601	147.66	68.932
- carb	1	0.4067	147.90	68.986
- gear	1	1.3531	148.85	69.190
- drat	1	1.6270	149.12	69.249
- disp	1	3.9167	151.41	69.736
- hp	1	6.8399	154.33	70.348
- qsec	1	8.8641	156.36	70.765
<none>			147.49	70.898
- am	1	10.5467	158.04	71.108
- wt	1	27.0144	174.51	74.280

• 다음 회귀모형에 관한 설명 중 가장 부적절한 것은 무엇인가?

- ① 유의수준 0.05에서 회귀모형은 유의적으로 종속변수를 설명한다.
- ② Examination은 종속변수 변동의 원인이다.
- ③ 회귀식의 y절편은 66.915이다.
- ④ 수정 결정계수는 0.671이다.

```
Call:
lm(formula = Fertility ~ ., data = swiss)

Residuals:
    Min       1Q   Median       3Q      Max
-15.2743  -5.2617   0.5032   4.1198  15.3213

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  66.91518   10.70604   6.250 1.91e-07 ***
Agriculture  -0.17211    0.07030  -2.448  0.01873 *
Examination  -0.25801    0.25388  -1.016  0.31546
Education    -0.87094    0.18303  -4.758 2.43e-05 ***
Catholic      0.10412    0.03526   2.953  0.00519 **
Infant.Mortality 1.07705    0.38172   2.822  0.00734 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 7.165 on 41 degrees of freedom
Multiple R-squared:  0.7067,    Adjusted R-squared:  0.671
F-statistic: 19.76 on 5 and 41 DF,  p-value: 5.594e-10
```


- 다음 중 다중 회귀 분석에서 종속변수에 가장 유의한 변수는?

```
Call:
lm(formula = Fertility ~ ., data = swiss)

Residuals:
    Min       1Q   Median       3Q      Max
-15.2743  -5.2617   0.5032   4.1198  15.3213

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   66.91518   10.70604   6.250 1.91e-07 ***
Agriculture   -0.17211    0.07030  -2.448  0.01873 *
Examination   -0.25801    0.25388  -1.016  0.31546
Education     -0.87094    0.18303  -4.758 2.43e-05 ***
Catholic       0.10412    0.03526   2.953  0.00519 **
Infant.Mortality 1.07705    0.38172   2.822  0.00734 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 7.165 on 41 degrees of freedom
Multiple R-squared:  0.7067,    Adjusted R-squared:  0.671
F-statistic: 19.76 on 5 and 41 DF,  p-value: 5.594e-10
```

모듈 7-3

다변량 분석

- 다변량 분석

- 상관 분석

- 상관분석의 개념

- ✓ 상관분석은 **두 변수** 사이에 어떤 선형적 또는 비선형적 관계가 있는지를 분석하는 방법
 - ✓ 상관분석을 통해 두 변수 사이의 인과관계는 확인할 수 없음

• 다변량 분석

- 상관 분석

➤ 상관관계의 분류

✓ 분석이 되는 변수의 속성에 따라 수치적 데이터, 명목적 데이터, 순서적 데이터 등으로 분류할 수 있음


분류	설명	분석 방법
수치적 데이터	• 수치로 표현을 할 수 있는 측정 가능한 데이터 변수 • 예) 키, 몸무게, 나이 등	피어슨 상관계수
명목적 데이터	• 데이터의 특성을 구분하기 위해 숫자나 기호를 할당한 데이터 변수 • 예) 성별(남/여), 만족도(1점~5점)	카이제곱 검정
순서적 데이터	• 데이터의 순서에 의미를 부여한 데이터 변수 • 예) 성적 순위	스피어만 순위 상관계수

• 다변량 분석


- 상관 분석

➤ 상관계수


- ✓ 상관계수는 두 변수 사이의 연관성을 수치상으로 객관화하여 두 변수 사이의 방향성과 강도를 표현하는 방법임
- ✓ 상관계수만으로 통계적 유의성을 확인할 수 없음
- ✓ 상관계수는 $-1 \sim 1$ 의 값을 가지며 $-$ 값을 가지면 음의 상관관계, $+$ 값을 가지면 양의 상관관계라 함



정(양)상관



부(음)상관



무(영)상관



• 다변량 분석

- 상관 분석

➤ 공분산

- ✓ 공분산은 2개 변수 사이의 관련성을 나타내는 통계량
- ✓ 상관계수의 상승 혹은 하강하는 경향을 파악할 수 있음
- ✓ 공분산 값의 크기는 측정 단위에 따라 달라지므로 선형관계의 강도를 나타내지 못함

공분산 값	설명
$Cov > 0$	• 두 변수 중 하나의 값이 상승할 때 다른 값도 상승하는 경향을 보임
$Cov = 0$	• 두 변수 간 아무런 선형 관계가 없고 독립적인 관계
$Cov < 0$	• 두 변수 중 하나의 값이 상승할 때 다른 값이 하강하는 경향을 보임

- 다변량 분석

- 주성분 분석

- 주성분 분석의 개념

- ✓ 주성분 분석은 상관관계가 있는 고차원 자료를 자료의 변동을 최대한 보존하는 저차원 자료로 변환하는 차원 축소 방법
 - ✓ 주성분 분석은 서로 상관성이 높은 변수들의 선형 결합을 만들어 기존의 상관성이 높은 변수들을 요약, 축소하는 기법
 - ✓ 차원의 축소는 주성분 분석에서 변수의 중요도 기준이 되는 고유값을 정렬하여 높은 고유값을 가진 고유벡터만으로 데이터를 파악함

- 다변량 분석

- 주성분 분석

- 주성분 분석의 구성

- ✓ 제1 주성분: 전체 데이터를 가장 폭넓게 설명할 수 있는 성분으로 분산이 가장 큰 방향에 대한 변수들의 선형 결합
 - ✓ 제2 주성분: 제1 주성분의 영향을 제거한 데이터 중에서 데이터를 가장 폭넓게 설명할 수 있는 축으로 제1 주성분과 독립임
 - ✓ 제k 주성분: 제1 주성분~제 k-1 주성분의 영향을 제거한 데이터 중에서 데이터를 가장 폭넓게 설명할 수 있는 축으로 제1 주성분~제 k-1 주성분과 독립

• 다변량 분석

- 주성분 분석

➤ 주성분 분석의 구축

✓ 주성분 분석은 princomp 함수와 prcomp 함수를 이용함 (해석 결과는 본질적으로 같음)

✓ `princomp(x, cor, ...)`

주요 파라미터	설명
x	주성분 분석 대상 데이터
cor	- 공분산 행렬 또는 상관행렬 사용 여부 - TRUE: 상관계수 행렬 사용(기본값) - FALSE: 공분산 행렬 사용

• 다변량 분석

- 주성분 분석

➤ 주성분 분석의 구축

- ✓ 주성분 분석은 princomp 함수와 prcomp 함수를 이용함
- ✓ `prcomp(x, scale, ...)`

주요 파라미터	설명
x	• 주성분 분석 대상 데이터
scale	• 변수가 단위 분산을 갖도록 해야 하는지 여부(표준화 여부) • TRUE: 상관계수 행렬 사용 • FALSE: 공분산 행렬 사용(기본값)

• 다변량 분석

- 주성분 분석

➤ 주성분 분석의 해석

✓ 성분의 중요도

항목	설명
Standard Deviation (표준편차)	주성분들의 표준편차
Proportion of Variance (분산비율)	- 주성분들이 차지하는 비율 - 분산비율=(주성분 분산)/(전체 분산) - 값이 클수록 영향도가 높음
Cumulative Proportion (누적비율)	분산의 누적 합계

- 다변량 분석

- 주성분 분석

- 주성분 분석의 해석

- ✓ 성분의 중요도(예시)

	PC1	PC2	PC3	PC4
Standard deviation	2.0494	0.4910	0.2787	0.1539
Proportion of Variance	0.9246	0.0531	0.0171	0.0052
Cumulative Proportion	0.9246	0.9777	0.9948	1.0000

• 다변량 분석

- 주성분 분석

➤ 주성분 분석의 해석

- ✓ 성분의 중요도(예시)
- ✓ 분산은 표준편차를 제공하면 구할 수 있음

항목	PC1	PC2	PC3	PC4	합계
표준편차	2.0494	0.4910	0.2787	0.1539	
분산	4.2000	0.2411	0.0777	0.0237	4.5425
분산비율	$\frac{4.2000}{4.5425} = 0.9246$	$\frac{0.2411}{4.5425} = 0.0531$	$\frac{0.0777}{4.5425} = 0.0171$	$\frac{0.0237}{4.5425} = 0.0052$	1
누적	0.9246	0.9777	0.9948	1	

- 다변량 분석

- 주성분 분석

- 주성분 분석의 해석

- ✓ 적재 값
 - ✓ 주성분 분석의 결과를 통해 각 주성분 적재값을 알 수 있음
 - ✓ 주성분 값: $\sum_{i=1}^n \{(\text{적재 값}) \times \text{변수}\}$ (단, n 은 변수 개수)
 - ✓ 변수 값: $\sum_{i=1}^n \{(\text{적재 값}) \times \text{주성분}\}$ (단, k 는 주성분 개수)

- 다변량 분석

- 주성분 분석

- 주성분 분석의 해석

- ✓ 적재 값(예시)

	Comp.1	Comp.2	Comp.3	Comp.4
변수1	0.361	0.657	0.582	0.315
변수2		0.730	-0.598	-0.320
변수3	0.857	-0.173	-0.480	
변수4	0.358	-0.546	0.754	

- 다변량 분석

- 주성분 분석

- 주성분 분석의 해석

- ✓ 적재 값(예시)

- ✓ 주성분 적재 값을 바탕으로 각 주성분을 기존 변수들의 선형 결합으로 나타낼 수 있음

- ✓ 예시) Comp2의 식: $0.657 \times \text{변수1} + 0.730 \times \text{변수2} - 0.173 \times \text{변수3} - 0.546 \times \text{변수4}$

- ✓ 예시) 변수1의 식: $0.361 \times \text{Comp.1} + 0.657 \times \text{Comp.2} + 0.582 \times \text{Comp.3} + 0.315 \times \text{Comp.4}$

• 다변량 분석

- 주성분 분석


➤ 주성분 개수 선택 방법

선택방법	설명				
전체 변이 공헌도	- 주성분들이 설명하는 총 분산의 비율이 70~90% 사이가 되는 주성분의 개수 선택 - 제 1주성분까지의 누적 기여율이 0.9246으로 총 분산 비율이 70~90%이기 때문에 제1주성분까지를 주성분의 수로 결정				
		PC1	PC2	PC3	PC4
	Standard deviation	2.0494	0.4910	0.2787	0.1539
	Proportion of Variance	0.9246	0.0531	0.0171	0.0052
	Cumulative Proportion	0.9246	0.9777	0.9948	1.0000

• 다변량 분석

- 주성분 분석

➤ 주성분 개수 선택 방법

선택방법	설명
스크리 산점도	- x축에 주성분, y축에 각 주성분의 분산을 표현한 그래프 - 기울기가 완만해지기 직전까지를 주성분 수로 결정함 
평균 고유값	고유값들의 평균을 구한 후 고유값이 평균값 이상이 되는 주성분을 선택하는 방법

- 다음은 특정 제품의 Sales와 TV, Radio, Newspaper 광고 예산 간의 피어슨 상관계수 행렬이다. 설명이 가장 알맞지 않은 것은?

	TV	Radio	Newspaper	Sales
TV	1.000	0.054	0.057	0.793
Radio	0.054	1.000	0.333	0.543
Newspaper	0.057	0.333	1.000	0.222
Sales	0.793	0.543	0.222	1.000

- ① 3가지 매체의 광고 예산은 Sales와 양의 상관관계를 가지고 있다.
- ② Newspaper 광고 예산이 증가할 때 Radio 광고 예산이 증가하는 경향이 있다.
- ③ TV 광고 예산을 늘리면 Sales가 증가하는 인과관계가 있다.
- ④ Sales와 가장 상관관계가 높은 변수는 TV이다.

• 스피어만 상관계수를 계산할 때 대상이 되는 자료의 종류는 무엇이어야 하는가?

- ① 서열 척도
- ② 명목 척도
- ③ 비율 척도
- ④ 등간 척도

- 다음 중 상관 분석에 대한 설명으로 부적합한 것은?

- ① 스피어만 상관계수로 두 변수 간의 비선형 관계를 확인할 수 있다.
- ② 두 변수의 상관관계를 연구할 때 상관계수만으로 해석하면 문제가 된다.
- ③ 독립변수와 종속변수 간에 선형적인 관계를 도출해서 하나 이상의 독립변수들이 종속 변수에 미치는 영향을 분석하고 독립변수를 통해 종속변수를 예측하는 기법이다.
- ④ 상관계수는 선형성, 등분산성이라는 가정을 만족시켜야 한다.

- 다중공선성에 대한 설명 중 옳바르지 않은 것은?
 - ① 다중공선성 문제가 발생하면 문제가 있는 변수를 제거하고 분석할 수 있다.
 - ② 다중공선성 문제로 불확실성이 감소할 수 있다.
 - ③ 독립변수 간에 상관관계가 높아서 데이터를 분석할 때 부정적 영향을 미치는 경우 발생한다.
 - ④ VIF가 4보다 크면 다중공선성이 존재하는 것으로 해석한다.

- 다음 주성분 분석에 대한 설명 중 옳바르지 않은 것은?

```
> md_comp<-princomp(swiss, cor=FALSE)
> summary(md_comp)
Importance of components:

            Comp.1      Comp.2      Comp.3      Comp.4
Standard deviation  43.3667866  21.3712016  11.92449843  4.708258751
Proportion of Variance  0.7460284  0.1811752  0.05640546  0.008793495
Cumulative Proportion  0.7460284  0.9272036  0.98360907  0.992402568

            Comp.5      Comp.6
Standard deviation   3.618425207  2.461609258
Proportion of Variance 0.005193739  0.002403694
Cumulative Proportion 0.997596306  1.000000000
```

- ① 첫 번째 주성분은 전체 분산 중 약 74.6%를 설명하고 있다.
- ② 두 번째 주성분까지 포함하면 전체 분산의 약 92.7%까지 설명할 수 있다.
- ③ 모델은 상관 행렬을 사용했다.
- ④ summary의 결과는 6개 주성분의 표준편차, 분산의 비율을 보여준다.

- 스피어만 상관계수에 대한 설명 중 옳바르지 않은 것은?
 - ① 두 변수 간의 비선형적인 관계는 나타내지 못한다.
 - ② 연속형 외에 이산형도 가능하다.
 - ③ 관계가 랜덤이거나 존재하지 않으면 상관계수 모두 0에 가깝다.
 - ④ 스피어만 상관계수는 원시 데이터가 아니라 각 변수에 대해 순위를 매긴 값을 기반으로 한다.

- 다음 중 공분산과 상관계수에 대한 설명 중 가장 옳바르지 않은 것은?
 - ① 공분산은 측정 단위에 영향을 받지 않는다.
 - ② 상관 분석은 두 변수의 인과 관계 성립 여부를 확인할 수 없다.
 - ③ 공분산이 0이라면 두 변수 간에는 아무런 선형 관계가 없고 서로 독립적인 관계에 있다.
 - ④ 상관계수를 통해 상관관계의 표준화된 크기를 측정할 수 있다.

- 다음 중 두 변수 간의 비선형적인 관계도 나타낼 수 있으며 한 변수를 단조 증가 함수로 변환하여 다른 변수를 나타낼 수 있는 정도를 나타내는 상관계수는 무엇인가?

- ① 스피어만 상관계수
- ② 코사인 유사도
- ③ 피어슨 상관계수
- ④ 자카드 인덱스

- 다음은 mtcars 데이터 세트의 변수 간 상관계수를 나타낸 행렬이다. 다음 행렬에 대한 설명으로 가장 옳지 않은 것은 무엇인가?

	mpg	cyl	drat	qsec
mpg	1.00	-0.85	0.68	0.42
cyl	-0.85	1.00	-0.70	-0.59
drat	0.68	-0.70	1.00	0.09
qsec	0.42	-0.59	0.09	1.00

- ① drat와 qsec는 상관관계가 거의 없다고 할 수 있다.
- ② mpg와 cyl은 음의 상관 관계이다.
- ③ 상관계수의 절대값이 크면 두 변수 간의 선형 관계가 크다.
- ④ disp와 cyl의 상관계수는 통계적으로 유의하다.

- 다음이 설명하는 분석 기법은 무엇인가?

상관관계가 있는 고차원 자료를 자료의 변동을 최대한 보존하는 저차원 자료로 변환
서로 상관성이 높은 변수들의 선형 결합으로 만들어 기존의 상관성이 높은 변수들을 요약,
축소하는 기법

- ① 다중 회귀 분석
- ② 판별 분석
- ③ 주성분 분석
- ④ 요인 분석

- 주성분 분석에 대한 설명으로 옳지 않은 내용은?
 - ① 주성분 분석은 수학적으로 직교 선형 변환으로 정의한다.
 - ② 주성분은 선형 결합으로 이루어져 있다.
 - ③ 주성분 분석의 목적 중 하나는 데이터를 이해하기 위한 차원 축소이다.
 - ④ 상관관계가 있는 고차원 자료의 변동을 최대한 제거하는 기법이다.

- 주성분 분석에 대한 설명으로 가장 옳바르지 않은 것은?
 - ① 분산이 가장 작은 것을 제1 주성분으로 한다.
 - ② 상관관계가 있는 고차원의 자료를 자료의 변동을 최대한 보존하는 저차원 자료로 변환하는 차원 축소 방법이다.
 - ③ 누적 기여율이 85% 이상이면 주성분의 수로 결정할 수 있다.
 - ④ 차원 감소 폭의 결정은 스크리 산점도를 활용한다.

- 다음은 princomp(x, cor=TRUE) 함수를 이용한 주성분 분석의 결과이다. 해석으로 가장 올바른 것은?

	PC1	PC2	PC3	PC4
Standard deviation	1.71	0.96	0.38	0.14
Proportion of Variance	0.73	0.23	0.03	0.01
Cumulative Proportion	0.73	0.96	0.99	1.00

- ① 상관 행렬을 활용한 결과이다.
- ② 제1성분의 설명력은 40%이다.
- ③ 제3 주성분일 때 정보손실은 10%이다.
- ④ 85% 이상 설명하려면 주성분 3개 이상 선택하면 된다.

- 주성분 분석에서 변수의 중요도 기준이 되는 값은 무엇인가?
 - ① 고유값
 - ② 특이값
 - ③ 표준오차
 - ④ 스칼라

- 주성분 분석에서 주성분 2개를 수용했을 때 잃는 정보량은 얼마인가?

	PC1	PC2	PC3	PC4
Standard deviation	2.049	0.491	0.278	0.153
Proportion of Variance	0.924	0.053	0.017	0.006
Cumulative Proportion	0.924	0.977	0.994	1.000

- 주성분 분석의 결과에서 두번째 주성분은 전체 분산의 몇 퍼센트를 설명하고 있는가?

	PC1	PC2	PC3	PC4
Standard deviation	2.049	0.491	0.279	0.153
Proportion of Variance	0.924	0.053	0.017	0.006
Cumulative Proportion	0.924	0.977	0.994	1.000

- 다음은 `prcomp(x, scale=TRUE)` 함수를 통한 주성분 분석 결과이다. 설명 중 옳바르지 않은 것은?

	PC1	PC2	PC3	PC4
Standard deviation	1.708	0.956	0.383	0.143
Proportion of Variance	0.729	0.228	0.036	0.007
Cumulative Proportion	0.729	0.957	0.993	1.000

	PC1	PC2	PC3	PC4
변수1	0.521	-0.377	0.719	0.261
변수2	-0.269	-0.923	-0.244	-0.123
변수3	0.580	-0.024	-0.142	-0.801
변수4	0.564	-0.066	-0.634	0.523

- 주성분 분석 결과에 대한 설명 중 옳바르지 않은 것은?

- ① 주성분 분석이란 다변량 자료 분석에 이용하는 독립변수를 분석에 이용한다.
- ② 제3 주성분의 적재 값을 통해 4개의 변수 모두가 제3 주성분과 음의 관련이 있음을 보여준다.
- ③ 위 주성분 분석에서는 상관계수 행렬을 사용하였다.
- ④ 변수1은 PC1~PC4의 선형결합으로 나타낼 수 있다.

- 다음 표는 주성분 분석의 적재 값이다. 제1 주성분의 함수식을 쓰시오.

	PC1	PC2	PC3	PC4
변수1	0.361	0.657	0.582	0.315
변수2		0.730	-0.598	-0.320
변수3	0.857	-0.173		-0.480
변수4	0.358		-0.546	0.754

- 다음 중 주성분 분석에서 주성분을 선택하는 방법에 대한 설명으로 가장 옳지 않은 것은 무엇인가?

- ① 스크리 산점도는 고유값의 크기순으로 산점도를 그린 그래프에서 기울기가 완만해지는 지점에서 1을 뺀 개수를 주성분의 개수로 선택하는 방법이다.
- ② 전체 변이 공헌도 방법은 주성분들이 설명하는 총 분산의 비율이 70~90% 사이가 되는 주성분의 개수를 선택하는 방법이다.
- ③ 평균 고유값 방법은 고유값들의 평균을 구한 후 고유값이 평균값 이상이 되는 주성분을 제거하는 방법이다.
- ④ 주성분은 주성분을 구성하는 변수들의 계수 구조를 파악하여 적절하게 해석한다.