

모듈 7-2

기초 통계 분석

- 기초 통계 분석

- 기술 통계

- 기술 통계는 데이터 분석 목적으로 수집된 데이터를 확률·통계적으로 정리·요약하는 기초적인 방법
 - 기술 통계는 분석의 초기 단계에서 데이터 분포의 특징을 파악하려는 목적으로 산출됨

- 기초 통계 분석

- 기술 통계값

- 중심위치 측도

- ✓ 모평균: $\mu = \frac{1}{N} \sum_{i=1}^N x_i$ (단, N 은 모집단의 개수)

- ✓ 표본평균: $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ (단, n 은 표본집단의 개수)

- ✓ 중위수: 데이터를 오름차순으로 정렬하여 중앙에 위치한 데이터로 이상값에 대한 영향이 미미함

- ✓ 중위수는 데이터가 홀수개일때는 $\frac{n+1}{2}$ 번째 값이며 짝수개일때는 $\frac{n}{2}, \frac{n}{2} + 1$ 번째 값의 평균임

• 기초 통계 분석

- 기술 통계값

➤ 중심위치 측도

- ✓ 최빈수: 데이터 중 빈도수가 가장 높은 데이터
- ✓ 사분위수: 모든 데이터를 순서대로 배열하였을 때 4등분한 지점에 있는 값

종류	설명
제1사분위수	• 데이터를 오름차순하여 25% 지점에 있는 값
제2사분위수	• 데이터를 오름차순하여 50% 지점에 있는 값
제3사분위수	• 데이터를 오름차순하여 75% 지점에 있는 값

- 기초 통계 분석

- 기술 통계값

- 산포 측도

- ✓ 산포도는 주어진 자료가 **흩어진 정도**를 나타내는 값

- ✓ 분산은 각 데이터가 평균으로부터 얼마나 떨어져 있는지를 나타내는 값

- ✓ 모분산: $\sigma^2 = \frac{\sum_{i=1}^N (x_i - \mu)^2}{N}$ (단, N 은 모집단의 개수)

- ✓ 표본분산: $s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}$ (단, n 은 표본집단의 개수)

- 기초 통계 분석

- 기술 통계값

- 산포 측도

- ✓ 표준편차는 분산에 제곱근을 취한 값

- ✓ 모표준편차: $\sigma = \sqrt{\frac{\sum_{i=1}^N (x_i - \mu)^2}{N}}$ (단, N 은 모집단의 개수)

- ✓ 표본표준편차: $s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}}$ (단, n 은 표본집단의 개수)

- 기초 통계 분석

- 기술 통계값

- 산포 측도

- ✓ 범위: 데이터 중 최대값과 최소값의 차이($R = x_{max} - x_{min}$)
 - ✓ 사분위범위(IQR): $Q_3 - Q_1$ (단, Q_3 는 제3사분위수, Q_1 은 제1사분위수)
 - ✓ 사분편차: 사분위범위의 절반 값($\frac{IQR}{2} = \frac{Q_3 - Q_1}{2}$)

- 기초 통계 분석

- 기술 통계값

- 산포 측도

- ✓ 평균 절대 편차: 평균과 개별 관측치 차이의 평균으로 평균 편차 또는 절대편차라고 불림

- ✓ 모평균 절대편차: $MAD = \frac{1}{N} \sum_{i=1}^N |x_i - \mu|$

- ✓ 표본평균 절대편차: $MAD = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$

- 기초 통계 분석

- 기술 통계값

- 데이터 분포

- ✓ 데이터 분포의 형태와 대칭성을 설명할 수 있는 통계량은 첨도와 왜도가 있음
 - ✓ 첨도: 데이터 분포의 '뾰족한 정도'를 설명하는 통계량

유형	설명
첨도=0	• 데이터의 분포가 표준정규분포와 뾰족한 정도가 같음
첨도>0	• 데이터의 분포가 표준정규분포보다 더 뾰족함
첨도<0	• 데이터의 분포가 표준정규분포보다 덜 뾰족함

• 기초 통계 분석

- 기술 통계값

➤ 데이터 분포

- ✓ 데이터 분포의 형태와 대칭성을 설명할 수 있는 통계량은 첨도와 왜도가 있음
- ✓ 왜도: 데이터 분포의 '기울어진 정도'를 설명하는 통계량

유형	설명
왜도=0	• 좌우대칭, 최빈수=중위수=평균
왜도>0	• 우측으로 긴 꼬리형태, 최빈수<중위수<평균
왜도<0	• 좌측으로 긴 꼬리형태, 평균<중위수<최빈수

- 기초 통계 분석

- 회귀 분석

- 회귀분석의 개념

- ✓ 회귀 분석은 하나 이상의 독립변수들이 종속변수에 미치는 영향을 추정할 수 있는 통계기법
 - ✓ 독립변수와 종속변수의 관계가 선형이고 독립변수의 개수가 하나이면 단순선형회귀분석, 독립변수의 개수가 2개 이상이면 다중선형회귀분석임

- 기초 통계 분석

- 회귀 분석

- 단순선형회귀 분석

- ✓ 회귀식: $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$


- ✓ y_i : i 번째 종속변수값, x_i : i 번째 독립변수값

- ✓ β_0 : y 절편으로 $x = 0$ 일때 y 의 값

- ✓ β_1 : 기울기로 x 가 1변할때 y 의 변화량

- ✓ ε_i : i 번째 오차항(단, $N(0, \sigma^2)$)

- ✓ 이상적인 회귀식을 찾기 위해 최소제곱법(최소 자승법)을 이용하여 오차의 제곱합이 최소가 되는 회귀선을 찾음



• 기초 통계 분석

- 회귀 분석

➤ 단순선형회귀 분석

✓ 회귀분석의 가정에는 선형성, 독립성, 등분산성, 비상관성, 정상성이 있음

가정	설명
선형성	- 독립변수와 종속변수가 선형적이어야 한다는 특성 - 독립변수의 변화에 따라 종속변수가 일정 크기로 변화
독립성	- 단순선형회귀분석에서 잔차와 독립변수의 값이 서로 독립적이어야 함 - 다중선형회귀분석에서 독립변수 간 상관성이 없어야 함
등분산성	- 잔차의 분산이 독립변수와 무관하게 일정해야 한다는 특성 - 잔차는 표본집단에서 회귀식으로 예측한 값과 실제 값과의 차이를 말함
비상관성	관측값과 잔차는 서로 상관이 없어야 한다는 특성
정상성	잔차항이 정규분포의 형태를 이뤄야 한다는 특성


• 기초 통계 분석

- 회귀 분석

➤ 단순선형회귀 분석

✓ 회귀분석의 가정에는 선형성, 독립성, 등분산성, 비상관성, 정상성이 있음

가정	설명
선형성	• 선형성을 만족하려면 잔차들의 평균값은 일정해야 함 • 정상적이라면 잔차의 평균은 0으로 일직선이 되며 비정상적이라면 U자 형태의 모양이 나옴




• 기초 통계 분석

- 회귀 분석

➤ 단순선형회귀 분석

✓ 회귀분석의 가정에는 선형성, 독립성, 등분산성, 비상관성, 정상성이 있음

가정	설명
등분산성	• 등분산성이 있다면 잔차가 고르게 분포되어야 하며 비정상적이라면 나팔 혹은 깔때기 모양이 나옴



- 기초 통계 분석

- 회귀 분석

- 다중선형회귀 분석

- ✓ 회귀식: $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + \varepsilon$

- ✓ Y : 종속변수 행렬, $x_1, x_2, \cdots, x_k$: 독립변수 행렬

- ✓ β_0 : y 절편으로 $x = 0$ 일때 y 의 값

- ✓ $\beta_1, \beta_2, \cdots, \beta_k$: 독립변수 기울기

- ✓ ε : 오차항(단, $N(0, \sigma^2)$, 서로독립)

• 기초 통계 분석

- 회귀 분석

➤ 다중선형회귀 분석

- ✓ 다중공선성은 회귀분석에서 독립변수들 간 강한 상관관계가 나타나는 문제
- ✓ 다중회귀분석에서 독립변수들 사이에 선형 관계가 존재하면 회귀 계수의 정확한 추정이 난해함
- ✓ 다중 공선성 검사 방법으로 분산팽창요인, 상태지수가 있음

방법	설명
분산팽창요인	• 1에 가까울수록 다중공선성이 낮고 4보다 크면 다중 공선성이 존재 • 10보다 크면 심각한 문제가 있는 것으로 해석
상태지수	• 10이상이면 문제가 있고 30보다 크면 심각한 문제가 있다고 해석

• 기초 통계 분석

- 회귀 분석

➤ 회귀 분석 모형 구축

- ✓ 선형 회귀 분석은 lm함수를 사용하여 분석함
- ✓ `lm(formula, data)`

주요 파라미터	설명
formula	• 회귀식의 종속변수, 독립변수 지정 • 종속변수~독립변수 형태로 지정 • 다중회귀분석은 독립변수 여러 개 지정 • 예) <code>Salary ~ Experience + Major</code>
data	• 데이터 프레임 명

• 기초 통계 분석

- 회귀 분석

➤ 회귀 분석 해석

✓ lm함수를 적용하면 summary 정보가 제공됨

항목	설명
Estimate (추정값)	독립변수에 대한 회귀계수 추정값
Std. Error (표준오차)	- 독립변수에 대한 측정값의 표준편차 - 표준오차가 작을수록 추정값과 관측값 차이가 작음
t value (t-값)	- 독립변수와 종속변수 간 선형관계가 존재하는 정도를 나타낸 통계량 - t값의 절대값이 클수록 독립변수가 종속변수에 유의함
Pr(> t) (p-값)	- p-값(유의확률)이 작을수록 독립변수가 종속변수에 유의함 - 예시) 0.01~0.05(*), 0.001~0.01(**)

• 기초 통계 분석

- 회귀 분석

➤ 회귀 분석 평가

✓ 회귀분석은 회귀계수 검정, 회귀모형의 설명력, 적합도 검증 및 통계적 유의성 검증으로 모형을 평가함

구분	설명
잔차의 표준오차	관측값들이 실제 회귀선으로부터 떨어진 정도를 나타내는 통계량
결정계수 (R^2)	- 전체 데이터를 회귀모형이 얼마나 잘 설명하고 있는지를 보여주는 통계량 - 결정계수를 통해 추정된 회귀식이 얼마나 타당한지를 검토함 - 값이 1에 가까울수록 회귀모형이 자료를 잘 설명함
수정된 결정계수	- 독립변수의 개수가 많아짐에 따라 무조건 증가하는 결정계수의 문제점을 보완한 통계량 - 설명력이 떨어지는 독립변수가 추가할 때는 값이 감소하는 특징이 있음

• 기초 통계 분석

- 회귀 분석

➤ 회귀 분석 평가

✓ 회귀분석은 회귀계수 검정, 회귀모형의 설명력, 적합도 검증 및 통계적 유의성 검증으로 모형을 평가함

구분	설명
F-통계량	- 모형의 통계적 유의성을 판단함 - F-통계량의 p-값이 0.05보다 작으면 회귀모형은 통계적으로 유의함 - 귀무가설(H_0): $\beta_1 = \beta_2 = \dots = \beta_k = 0$ - 대립가설(H_1): $\beta_1 \sim \beta_k$ 중에서 적어도 하나는 0이 아니다.

- 기초 통계 분석

- 회귀 분석

- 회귀 분석 평가

- ✓ 회귀분석의 분산분석표(ANOVA: Analysis of Variance)

	df	Sum Sq	Mean Sq	F value	Pr(>F)
x1	1	280	280	756.8	2.2e-16***
Residuals	1923	720	0.37		

- ✓ 결정계수 $R^2 = \frac{SSR}{SST} = \frac{280}{1000}$ 으로 회귀변동/전체변동으로 구해짐

• 기초 통계 분석

- 회귀 분석

➤ 회귀 분석 평가

- ✓ lm (단순선형회귀모형) 적용
- ✓ (Intercept)가 $\Pr(>|t|) < 0.05$, 유의함
- ✓ Examination은 $\Pr(>|t|) > 0.05$ 유의하지 않음
- ✓ 결정계수: 0.7067, p-value < 0.05 이므로
- ✓ F통계량은 19.76, p-value는 5.594e-10으로
0.05보다 작으므로 5%에서 귀무가설 기각
- ✓ 회귀모형이 통계적으로 유의함

```
> summary(lm(Fertility~., data=swiss))

Call:
lm(formula = Fertility ~ ., data = swiss)

Residuals:
    Min       1Q   Median       3Q      Max
-15.2743  -5.2617   0.5032   4.1198  15.3213

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   66.91518    10.70604   6.250 1.91e-07 ***
Agriculture   -0.17211     0.07030  -2.448 0.01873 *
Examination   -0.25801     0.25388  -1.016 0.31546
Education     -0.87094     0.18303  -4.758 2.43e-05 ***
Catholic       0.10412     0.03526   2.953 0.00519 **
Infant.Mortality 1.07705     0.38172   2.822 0.00734 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 7.165 on 41 degrees of freedom
Multiple R-squared:  0.7067,    Adjusted R-squared:  0.671
F-statistic: 19.76 on 5 and 41 DF,  p-value: 5.594e-10
```

- 기초 통계 분석

- 회귀 분석

- 정규화 선형회귀

- ✓ 정규화 선형회귀는 선형회귀계수에 대한 제약 조건을 추가하여 모형이 과도하게 최적화되는 **과대 적합을 막는 방법**
 - ✓ 선형회귀의 과적합 문제를 해결하는 정규화 방법에 라쏘 회귀, 릿지 회귀, 엘라스틱 넷이 있음
 - ✓ 라쏘 회귀: 기존 함수에 모든 가중치들의 절대값 합계를 추가하여 값이 최소가 되도록 함
 - ✓ 릿지 회귀: 기존 함수에 모든 가중치들의 제곱합을 추가함
 - ✓ 엘라스틱 넷: 기존 함수에 거리측정 규제를 추가함

• 기초 통계 분석

- 변수 선택

➤ 변수 선택 기법

- ✓ 변수 선택은 데이터의 독립변수 중 종속변수에 가장 **관련성이 높은 변수만**을 선정하는 방법
- ✓ 변수 선택은 step 함수를 사용하고 direction 옵션을 통해 선택할 수 있음
- ✓ AIC를 기준으로 모델을 선택(AIC: 적합성 비교지수로 낮을수록 좋음)

알고리즘	설명
전진 선택법	• 모델을 가장 많이 향상시키는 변수를 하나씩 점진적으로 추가하는 방법 • 변수 추가 시 선택기준이 향상되지 않을 때 변수 추가를 중단
후진 제거법	• 변수를 모두 포함한 상태에서 시작하며 가장 적은 영향을 주는 변수부터 하나씩 제거하는 방법
단계적 방법	• 전진 선택법과 후진 제거법을 함께 사용

• 기초 통계 분석

- 변수 선택

➤ 변수 선택 기법

- ✓ step 함수
- ✓ step 함수는 AIC가 작아지는 방향으로 단계적으로 변수를 선택하는 함수로 AIC가 가장 작은 값을 가지도록 하는 변수를 제거함
- ✓ `step(object, scope, direction)`

주요 파라미터	설명
object	• 대상 객체
scope	• 탐색할 모델의 범위 지정
direction	• forward: 전진선택법, backward: 후진 제거법, both: 단계적 방법

- 기초 통계 분석

- 변수 선택

- 변수 선택 기법

- ✓ formula 함수

- ✓ formula함수는 step함수를 수행한 뒤 반환 값을 변수로 전달받아 표물려('종속변수~독립변수' 형태)를 구하는 함수

- ✓ formula (x)

주요 파라미터	설명
x	• step 함수의 반환 값을 입력

- 기초 통계 분석

- 변수 선택

- 변수 선택 기법

```
> m1 <- lm(hp~., data=mtcars)
> m2 <- step(m1, direction='both')
Start: AIC=216.97
hp ~ mpg + cyl + disp + drat + wt + qsec + vs + am + gear + carb
```

	Df	Sum of Sq	RSS	AIC	
- qsec	1	39.6	14204	215.06	→ 제거대상
- drat	1	55.6	14220	215.09	
- am	1	140.8	14306	215.28	
- gear	1	164.4	14329	215.34	
- cyl	1	446.2	14611	215.96	
- mpg	1	656.9	14822	216.42	
<none>			14165	216.97	
- vs	1	1140.5	15305	217.45	
- wt	1	1389.7	15554	217.96	
- carb	1	4799.2	18964	224.31	
- disp	1	5839.6	20004	226.01	

- 기초 통계 분석

- 변수 선택

- 변수 선택 기법

Step: AIC=215.06

hp ~ mpg + cyl + disp + drat + wt + vs + am + gear + carb

	Df	Sum of Sq	RSS	AIC	
- drat	1	50.6	14255	213.17	→ 제거대상
- gear	1	184.3	14389	213.47	
- am	1	216.7	14421	213.54	
- cyl	1	565.0	14769	214.31	
- mpg	1	793.5	14998	214.80	
<none>			14204	215.06	
- vs	1	1133.8	15338	215.52	
+ qsec	1	39.6	14165	216.97	
- wt	1	2577.3	16782	218.39	
- carb	1	5653.2	19858	223.78	
- disp	1	7460.7	21665	226.57	

- 기초 통계 분석

- 변수 선택

- 변수 선택 기법

- ✓ 변수를 추가하거나 제거하는 작업보다 아무 작업도 하지 않은 현재 상태가 가장 좋은 AIC를 보임

```
Step:  AIC=207.98
hp ~ disp + wt + carb

      Df Sum of Sq  RSS   AIC
<none>            16564 207.98
+ mpg      1         856 15708 208.28
+ vs       1         388 16176 209.22
+ cyl      1         276 16288 209.44
+ drat     1         239 16325 209.51
+ qsec     1          67 16497 209.85
+ am       1          12 16552 209.95
+ gear     1           4 16560 209.97
- wt       1        4961 21525 214.36
- disp     1       26844 43408 236.81
- carb     1       36686 53250 243.34
```

- summary(mtcars)에 대한 설명 중 적절하지 않은 것은?

```
> summary(mtcars)
```

mpg	cyl	disp	hp
Min. :10.40	Min. :4.000	Min. : 71.1	Min. : 52.0
1st Qu.:15.43	1st Qu.:4.000	1st Qu.:120.8	1st Qu.: 96.5
Median :19.20	Median :6.000	Median :196.3	Median :123.0
Mean :20.09	Mean :6.188	Mean :230.7	Mean :146.7
3rd Qu.:22.80	3rd Qu.:8.000	3rd Qu.:326.0	3rd Qu.:180.0
Max. :33.90	Max. :8.000	Max. :472.0	Max. :335.0

- ① mpg 변수 분포는 왼쪽 꼬리가 긴 분포이다.
- ② hp 변수는 수치형 자료이다.
- ③ cyl 변수는 결측값이 없음을 알 수 있다.
- ④ disp 변수의 최대값은 472이다.

- 다음 데이터의 Education 변수는 약 몇 %가 12보다 큰 값을 가지는가?

```
> summary(swiss$Education)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  1.00   6.00   8.00  10.98  12.00   53.00
```

• 다음 중에서 자료들의 중간 50%에 흠어진 정도를 나타내는 통계량은 무엇인가?

- ① 중위수
- ② 사분위수 범위
- ③ 평균
- ④ 분산

- 다음의 R의 벡터 데이터에서 평균, 최빈수, 중위수, 범위의 값을 모두 더한 값은 얼마인가?

```
data <- c(1, 1, 2, 3, 4, 4, 4, 4, 4, 6, 7, 8)
```

- ① 18
- ② 19
- ③ 20
- ④ 21

- 다음 산포의 척도에 관한 설명 중 적절하지 않은 것은?
 - ① 변동계수는 분포의 퍼짐 정도를 비교하게 해준다.
 - ② IQR은 (3사분위수 - 1사분위수)이다.
 - ③ 평균 절대편차는 관측값에서 평균을 뺀 값에 대한 절대값을 모두 더한 값이다.
 - ④ 사분위 수는 데이터 표본을 4개의 동일한 부분으로 나눈 값이다.

- 100개의 실수 관측값을 수집하여 평균과 표준편차를 구한 결과 각각 10과 2가 나왔다. 모든 관측값에 4를 더한 후에 평균과 표준편차를 구하면 값의 변화는 어떻게 되는가?

- ① 평균은 10, 표준편차는 2로 변화가 없다.
- ② 평균은 14, 표준편차는 4가 된다.
- ③ 평균은 14가 되고 표준편차는 2가 된다.
- ④ 평균은 14가 되고 표준편차는 6이 된다.

• 다음 중 변수의 측정 수준에 따라 집중 경향값과 산포도에 관한 설명으로 틀린 것은?

- ① 중위수는 대표적인 집중 경향값으로 이상값에 의한 영향이 민감하다는 단점이 있다.
- ② 최빈수는 관측된 데이터값 중에서 가장 여러 번 나타난 값이다.
- ③ 표본평균은 데이터의 합을 총 개수로 나눈 값을 의미한다.
- ④ 사분위수는 모든 데이터값을 순서대로 배열하였을 때 4등분한 지점에 있는 값이다.

- 다음 회귀 분석에서 가장 적합한 회귀 모형을 찾기 위한 과정의 설명으로 가장 알맞지 않은 것은?

- ① 회귀식에 대한 검정은 독립변수의 기울기가 0이 아니라는 가정을 귀무가설, 기울기가 0인 것을 대립가설로 놓는다.
- ② 회귀 분석의 가설 검정에서 p-값이 0.05보다 작은 값이 나와야 통계적으로 유의한 결과이다.
- ③ 잔차의 독립성, 등분산성, 정규성을 만족하는지 확인해야 한다.
- ④ 독립변수의 수가 많아지면 독립변수 간에 서로 영향을 미치는 다중 공선성의 문제가 발생하므로 상대적인 조정이 필요하다.

- 회귀 분석 결정계수에 대한 설명으로 가장 알맞지 않은 것은?
 - ① 회귀모형에서 입력 변수가 증가하면 결정계수도 증가한다.
 - ② 결정계수는 총 변동 중에서 회귀 모형에 의하여 설명되지 않은 오차에 의한 변동이 차지하는 비율이다.
 - ③ 수정된 결정계수는 유의하지 않은 독립변수들이 회귀식에 포함되었을 때 그 값이 감소한다.
 - ④ 다중 회귀 분석에서는 최종 모형의 선정기준으로 결정계수 값보다는 수정된 결정계수 값을 사용하는 것이 적절하다.

- 회귀 방정식에서 자료를 가장 잘 설명해주는 추정값을 찾기 위해 잔차의 제곱합을 최소로 하는 방법을 무엇이라고 하는가?

- 다중회귀모형의 통계적 유의성을 확인하는 방법은?
 - ① F 통계량을 확인한다.
 - ② 결정계수를 확인한다.
 - ③ 잔차 통계량을 확인한다.
 - ④ 회귀계수의 t값을 확인한다.

- 회귀 분석의 가정 중 정상성은 ()이/가 정규분포를 이뤄야 함을 가정한다.

- 다음은 회귀 분석의 분산분석표이다. 결정계수의 값은?

	df	Sum Sq	Mean Sq	F value	Pr(>F)
x1	1	280	280	756.8	2.2e-16***
Residuals	1923	720	0.37		

- 다중 공선성에 대한 설명으로 다음 중 가장 옳지 않은 것은 무엇인가?
 - ① 구조적 다중 공선성의 문제가 있는 경우에는 데이터의 평균은 변화한다.
 - ② 일반적으로 VIF값이 10 이상이면 다중공선성에 문제가 있다고 판단한다.
 - ③ VIF 값이 "1"에 가까우면 다중공선성이 존재한다.
 - ④ 다중공선성 문제를 해결하기 위해 중요하지 않지만 다른 변수의 상관성이 높은 변수를 제거한다.

- 다음은 cars데이터 세트에서 속도와 제동거리의 관계를 회귀모형으로 분석한 것이다. 다음 중 옳지 않은 것은 무엇인가?

- ① 회귀 계수는 5% 수준에서 유의하다.
- ② 잔차 분산 σ^2 의 불편추정량은 236.5이다.
- ③ 전체 관측치 수가 49개이다.
- ④ 결정계수는 0.6511이다.

```
Call:
lm(formula = dist ~ speed, data = cars)

Residuals:
    Min       1Q   Median       3Q      Max
-29.069  -9.525  -2.272   9.215  43.201

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -17.5791     6.7584  -2.601   0.0123 *
speed         3.9324     0.4155   9.464 1.49e-12 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 15.38 on 48 degrees of freedom
Multiple R-squared:  0.6511,    Adjusted R-squared:  0.6438
F-statistic: 89.57 on 1 and 48 DF,  p-value: 1.49e-12


> anova(out)
Analysis of Variance Table

Response: dist
      Df Sum Sq Mean Sq F value    Pr(>F)
speed   1  21186  21185.5   89.567 1.49e-12 ***
Residuals 48  11354    236.5
```

- 회귀 분석에서 독립변수 간 상관관계가 높아 많은 문제점을 발생하는 현상을 무엇이라 하는가?

- ① 다중 공선성
- ② 상관행렬
- ③ 능형회귀
- ④ 전진 선택법

- 다음 그림은 회귀분석에서 잔차 분석의 어떤 가정을 위배하고 있는가?




- ① 선형성
- ② 정규성
- ③ 등분산성
- ④ 독립성

- 다중 공선성에 대한 설명 중 옳바르지 않은 것은?

- ① 다중 공선성 문제가 발생하면 문제가 있는 변수를 제거하고 분석할 수 있다.
- ② 다중 공선성 문제로 불확실성이 감소할 수 있다.
- ③ 독립변수 간에 상관관계가 높아서 데이터를 분석할 때 부정적 영향을 미치는 경우가 발생한다.
- ④ VIF가 4보다 크면 다중 공선성이 존재하는 것으로 해석한다.

- 다음은 결과를 생성한 잔차도이다. 다음 중 어떤 회귀분석의 가정이 위배되었다고 판단할 수 있는지 고르시오.

- ① 비정규성
- ② 독립성
- ③ 선형성
- ④ 정상성



- 회귀 분석에서 잔차 분석은 회귀 모형에 대한 가정을 충족하는지에 대한 검정, 이상값이 있는지에 대한 검정을 하는 절차이다. 이와 관련된 가정으로 적합한 것은 무엇인가?

- ① 독립성, 적정성, 유일성
- ② 독립성, 등분산성, 정규성
- ③ 정규성, 효과성, 등분산성
- ④ 정규성, 유일성, 독립성

- 다음 중 잔차 분석에 대한 설명으로 옳지 않은 것은?

- ① 잔차 분석은 회귀 모형에 대한 가정을 충족하는지를 검정하는 절차이다.
- ② 잔차항이 정규분포를 따르는지 알아보는 검정으로 샤피로-윌크 검정이 있다.
- ③ 더빈-왓슨 검정은 등분산성에 대한 검정 기법이다.
- ④ 잔차는 특정한 패턴이 없어야 한다.

- 다음은 다중 회귀의 어떤 단계적 변수 선택에 관한 설명인가?

독립변수 후보 모두를 포함한 모형에서 출발해 제곱합의 기준으로 가장 적은 영향을 주는 변수로부터 하나씩 제거하면서 더 이상 유의하지 않은 변수가 없을 때까지 독립변수를 제거하고, 이때 모형을 선택한다.

• 다음 중 모델의 정확도 및 성능을 향상하기 위한 변수 선택 방법으로 적합하지 않은 것은?

- ① 단계적 방법
- ② 전진 선택법
- ③ 순차적 방법
- ④ 후진 제거법

- Cars데이터에 대해서 종속변수를 dist로, 독립변수는 speed로 회귀분석을 하려고 한다. 적절한 R 코드는 무엇인가?

```
> data(cars)
> summary()

Call:
lm(formula = dist ~ speed, data = cars)

Residuals:
    Min       1Q   Median       3Q      Max
-29.069  -9.525  -2.272   9.215  43.201

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -17.5791     6.7584  -2.601   0.0123 *
speed         3.9324     0.4155   9.464 1.49e-12 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 15.38 on 48 degrees of freedom
Multiple R-squared:  0.6511,    Adjusted R-squared:  0.6438
F-statistic: 89.57 on 1 and 48 DF,  p-value: 1.49e-12
```

- ① glm(dist~speed, data=cars)
- ② lm(speed~dist, data=cars)
- ③ lm(dist~speed, data=cars)
- ④ glm(speed~dist, data=cars)

- 다음의 회귀 방정식의 summary 결과에서 후진 제거법으로 변수 선택법을 사용할 때 가장 먼저 제거되는 변수는 다음 중 무엇인가?

- ① cyl
- ② hp
- ③ wt
- ④ (Intercept)

```
Call:
lm(formula = mpg ~ cyl + hp + wt, data = mtcars)

Residuals:
    Min       1Q   Median       3Q      Max
-3.9290 -1.5598 -0.5311  1.1850  5.8986

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  38.75179    1.78686   21.687  < 2e-16 ***
cyl          -0.94162    0.55092   -1.709  0.098480 .
hp           -0.01804    0.01188   -1.519  0.140015
wt           -3.16697    0.74058   -4.276  0.000199 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.512 on 28 degrees of freedom
Multiple R-squared:  0.8431,    Adjusted R-squared:  0.8263
F-statistic: 50.17 on 3 and 28 DF,  p-value: 2.184e-11
```

• 다음 모형의 변수 선택에 대한 설명으로 부적절한 것은?

- ① Start AIC보다 작은 모든 변수는 다음 Step에서 모두 제외된다.
- ② 한번 제거된 변수는 다시 모형에 포함되지 않는다.
- ③ 후진 제거법으로 변수 선택을 하고 있다.
- ④ 모든 독립변수가 포함된 모형에서 시작한다.

```
> model<-lm(mpg~., data=mtcars)
> step(model, direction='backward')
Start: AIC=70.9
mpg ~ cyl + disp + hp + drat + wt + qsec + vs + am + gear + carb
```

	Df	Sum of Sq	RSS	AIC
- cyl	1	0.0799	147.57	68.915
- vs	1	0.1601	147.66	68.932
- carb	1	0.4067	147.90	68.986
- gear	1	1.3531	148.85	69.190
- drat	1	1.6270	149.12	69.249
- disp	1	3.9167	151.41	69.736
- hp	1	6.8399	154.33	70.348
- qsec	1	8.8641	156.36	70.765
<none>			147.49	70.898
- am	1	10.5467	158.04	71.108
- wt	1	27.0144	174.51	74.280

• 다음 회귀모형에 관한 설명 중 가장 부적절한 것은 무엇인가?

- ① 유의수준 0.05에서 회귀모형은 유의적으로 종속변수를 설명한다.
- ② Examination은 종속변수 변동의 원인이다.
- ③ 회귀식의 y절편은 66.915이다.
- ④ 수정 결정계수는 0.671이다.

```
Call:
lm(formula = Fertility ~ ., data = swiss)

Residuals:
    Min       1Q   Median       3Q      Max
-15.2743  -5.2617   0.5032   4.1198  15.3213

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   66.91518   10.70604   6.250 1.91e-07 ***
Agriculture   -0.17211    0.07030  -2.448  0.01873 *
Examination   -0.25801    0.25388  -1.016  0.31546
Education     -0.87094    0.18303  -4.758 2.43e-05 ***
Catholic       0.10412    0.03526   2.953  0.00519 **
Infant.Mortality 1.07705    0.38172   2.822  0.00734 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 7.165 on 41 degrees of freedom
Multiple R-squared:  0.7067,    Adjusted R-squared:  0.671
F-statistic: 19.76 on 5 and 41 DF,  p-value: 5.594e-10
```

- 다음 중 다중 회귀 분석에서 종속변수에 가장 유의한 변수는?

```
Call:
lm(formula = Fertility ~ ., data = swiss)

Residuals:
    Min       1Q   Median       3Q      Max
-15.2743  -5.2617   0.5032   4.1198  15.3213

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   66.91518   10.70604   6.250 1.91e-07 ***
Agriculture   -0.17211    0.07030  -2.448  0.01873 *
Examination   -0.25801    0.25388  -1.016  0.31546
Education     -0.87094    0.18303  -4.758 2.43e-05 ***
Catholic       0.10412    0.03526   2.953  0.00519 **
Infant.Mortality 1.07705    0.38172   2.822  0.00734 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 7.165 on 41 degrees of freedom
Multiple R-squared:  0.7067,    Adjusted R-squared:  0.671
F-statistic: 19.76 on 5 and 41 DF,  p-value: 5.594e-10
```

모듈 7-3

다변량 분석

- 다변량 분석

- 상관 분석

- 상관분석의 개념

- ✓ 상관분석은 **두 변수** 사이에 어떤 선형적 또는 비선형적 관계가 있는지를 분석하는 방법
 - ✓ 상관분석을 통해 두 변수 사이의 인과관계는 확인할 수 없음

• 다변량 분석

- 상관 분석

➤ 상관관계의 분류

✓ 분석이 되는 변수의 속성에 따라 수치적 데이터, 명목적 데이터, 순서적 데이터 등으로 분류할 수 있음


분류	설명	분석 방법
수치적 데이터	• 수치로 표현을 할 수 있는 측정 가능한 데이터 변수 • 예) 키, 몸무게, 나이 등	피어슨 상관계수
명목적 데이터	• 데이터의 특성을 구분하기 위해 숫자나 기호를 할당한 데이터 변수 • 예) 성별(남/여), 만족도(1점~5점)	카이제곱 검정
순서적 데이터	• 데이터의 순서에 의미를 부여한 데이터 변수 • 예) 성적 순위	스피어만 순위 상관계수

• 다변량 분석


- 상관 분석

➤ 상관계수


- ✓ 상관계수는 두 변수 사이의 연관성을 수치상으로 객관화하여 두 변수 사이의 방향성과 강도를 표현하는 방법임
- ✓ 상관계수만으로 통계적 유의성을 확인할 수 없음
- ✓ 상관계수는 -1 ~ 1의 값을 가지며 - 값을 가지면 음의 상관관계, + 값을 가지면 양의 상관관계라 함



정(양)상관



부(음)상관



무(영)상관



• 다변량 분석

- 상관 분석

➤ 공분산

- ✓ 공분산은 2개 변수 사이의 관련성을 나타내는 통계량
- ✓ 상관계수의 상승 혹은 하강하는 경향을 파악할 수 있음
- ✓ 공분산 값의 크기는 측정 단위에 따라 달라지므로 선형관계의 강도를 나타내지 못함

공분산 값	설명
$Cov > 0$	• 두 변수 중 하나의 값이 상승할 때 다른 값도 상승하는 경향을 보임
$Cov = 0$	• 두 변수 간 아무런 선형 관계가 없고 독립적인 관계
$Cov < 0$	• 두 변수 중 하나의 값이 상승할 때 다른 값이 하강하는 경향을 보임

- 다변량 분석

- 주성분 분석

- 주성분 분석의 개념

- ✓ 주성분 분석은 상관관계가 있는 고차원 자료를 자료의 변동을 최대한 보존하는 저차원 자료로 변환하는 차원 축소 방법
 - ✓ 주성분 분석은 서로 상관성이 높은 변수들의 선형 결합을 만들어 기존의 상관성이 높은 변수들을 요약, 축소하는 방법
 - ✓ 차원의 축소는 주성분 분석에서 변수의 중요도 기준이 되는 고유값을 정렬하여 높은 고유값을 가진 고유벡터만으로 데이터를 파악함

- 다변량 분석

- 주성분 분석

- 주성분 분석의 구성

- ✓ 제1 주성분: 전체 데이터를 가장 폭넓게 설명할 수 있는 성분으로 분산이 가장 큰 방향에 대한 변수들의 선형 결합
 - ✓ 제2 주성분: 제1 주성분의 영향을 제거한 데이터 중에서 데이터를 가장 폭넓게 설명할 수 있는 축으로 제1 주성분과 독립임
 - ✓ 제k 주성분: 제1 주성분~제 k-1 주성분의 영향을 제거한 데이터 중에서 데이터를 가장 폭넓게 설명할 수 있는 축으로 제1 주성분~제 k-1 주성분과 독립

• 다변량 분석

- 주성분 분석

➤ 주성분 분석의 구축

✓ 주성분 분석은 princomp 함수와 prcomp 함수를 이용함 (해석 결과는 본질적으로 같음)

✓ `princomp(x, cor, ...)`

주요 파라미터	설명
x	주성분 분석 대상 데이터
cor	- 공분산 행렬 또는 상관행렬 사용 여부 - TRUE: 상관계수 행렬 사용(기본값) - FALSE: 공분산 행렬 사용

• 다변량 분석

- 주성분 분석

➤ 주성분 분석의 구축

- ✓ 주성분 분석은 princomp 함수와 prcomp 함수를 이용함
- ✓ `prcomp(x, scale, ...)`

주요 파라미터	설명
x	• 주성분 분석 대상 데이터
scale	• 변수가 단위 분산을 갖도록 해야 하는지 여부(표준화 여부) • TRUE: 상관계수 행렬 사용 • FALSE: 공분산 행렬 사용(기본값)

• 다변량 분석

- 주성분 분석

➤ 주성분 분석의 해석

✓ 성분의 중요도

항목	설명
Standard Deviation (표준편차)	주성분들의 표준편차
Proportion of Variance (분산비율)	- 주성분들이 차지하는 비율 - 분산비율=(주성분 분산)/(전체 분산) - 값이 클수록 영향도가 높음
Cumulative Proportion (누적비율)	분산의 누적 합계

- 다변량 분석

- 주성분 분석

- 주성분 분석의 해석

- ✓ 성분의 중요도(예시)

	PC1	PC2	PC3	PC4
Standard deviation	2.0494	0.4910	0.2787	0.1539
Proportion of Variance	0.9246	0.0531	0.0171	0.0052
Cumulative Proportion	0.9246	0.9777	0.9948	1.0000

• 다변량 분석

- 주성분 분석

➤ 주성분 분석의 해석

- ✓ 성분의 중요도(예시)
- ✓ 분산은 표준편차를 제공하면 구할 수 있음

항목	PC1	PC2	PC3	PC4	합계
표준편차	2.0494	0.4910	0.2787	0.1539	
분산	4.2000	0.2411	0.0777	0.0237	4.5425
분산비율	$\frac{4.2000}{4.5425} = 0.9246$	$\frac{0.2411}{4.5425} = 0.0531$	$\frac{0.0777}{4.5425} = 0.0171$	$\frac{0.0237}{4.5425} = 0.0052$	1
누적	0.9246	0.9777	0.9948	1	

- 다변량 분석

- 주성분 분석

- 주성분 분석의 해석

- ✓ 적재 값
 - ✓ 주성분 분석의 결과를 통해 각 주성분 적재값을 알 수 있음
 - ✓ 주성분 값: $\sum_{i=1}^n \{(\text{적재 값}) \times \text{변수}\}$ (단, n 은 변수 개수)
 - ✓ 변수 값: $\sum_{i=1}^n \{(\text{적재 값}) \times \text{주성분}\}$ (단, k 는 주성분 개수)

- 다변량 분석

- 주성분 분석

- 주성분 분석의 해석

- ✓ 적재 값(예시)

	Comp.1	Comp.2	Comp.3	Comp.4
변수1	0.361	0.657	0.582	0.315
변수2		0.730	-0.598	-0.320
변수3	0.857	-0.173	-0.480	
변수4	0.358	-0.546	0.754	

- 다변량 분석

- 주성분 분석

- 주성분 분석의 해석

- ✓ 적재 값(예시)

- ✓ 주성분 적재 값을 바탕으로 각 주성분을 기존 변수들의 선형 결합으로 나타낼 수 있음

- ✓ 예시) Comp2의 식: $0.657 \times \text{변수1} + 0.730 \times \text{변수2} - 0.173 \times \text{변수3} - 0.546 \times \text{변수4}$

- ✓ 예시) 변수1의 식: $0.361 \times \text{Comp.1} + 0.657 \times \text{Comp.2} + 0.582 \times \text{Comp.3} + 0.315 \times \text{Comp.4}$

• 다변량 분석

- 주성분 분석


➤ 주성분 개수 선택 방법

선택방법	설명				
전체 변이 공헌도	- 주성분들이 설명하는 총 분산의 비율이 70~90% 사이가 되는 주성분의 개수 선택 - 제 1주성분까지의 누적 기여율이 0.9246으로 총 분산 비율이 70~90%이기 때문에 제1주성분까지를 주성분의 수로 결정				
		PC1	PC2	PC3	PC4
	Standard deviation	2.0494	0.4910	0.2787	0.1539
	Proportion of Variance	0.9246	0.0531	0.0171	0.0052
	Cumulative Proportion	0.9246	0.9777	0.9948	1.0000

• 다변량 분석

- 주성분 분석

➤ 주성분 개수 선택 방법

선택방법	설명
스크리 산점도	- x축에 주성분, y축에 각 주성분의 분산을 표현한 그래프 - 기울기가 완만해지기 직전까지를 주성분 수로 결정함 
평균 고유값	고유값들의 평균을 구한 후 고유값이 평균값 이상이 되는 주성분을 선택하는 방법

- 다음은 특정 제품의 Sales와 TV, Radio, Newspaper 광고 예산 간의 피어슨 상관계수 행렬이다. 설명이 가장 알맞지 않은 것은?

	TV	Radio	Newspaper	Sales
TV	1.000	0.054	0.057	0.793
Radio	0.054	1.000	0.333	0.543
Newspaper	0.057	0.333	1.000	0.222
Sales	0.793	0.543	0.222	1.000

- ① 3가지 매체의 광고 예산은 Sales와 양의 상관관계를 가지고 있다.
- ② Newspaper 광고 예산이 증가할 때 Radio 광고 예산이 증가하는 경향이 있다.
- ③ TV 광고 예산을 늘리면 Sales가 증가하는 인과관계가 있다.
- ④ Sales와 가장 상관관계가 높은 변수는 TV이다.

• 스피어만 상관계수를 계산할 때 대상이 되는 자료의 종류는 무엇이어야 하는가?

- ① 서열 척도
- ② 명목 척도
- ③ 비율 척도
- ④ 등간 척도

- 다음 중 상관 분석에 대한 설명으로 부적합한 것은?

- ① 스피어만 상관계수로 두 변수 간의 비선형 관계를 확인할 수 있다.
- ② 두 변수의 상관관계를 연구할 때 상관계수만으로 해석하면 문제가 된다.
- ③ 독립변수와 종속변수 간에 선형적인 관계를 도출해서 하나 이상의 독립변수들이 종속 변수에 미치는 영향을 분석하고 독립변수를 통해 종속변수를 예측하는 기법이다.
- ④ 상관계수는 선형성, 등분산성이라는 가정을 만족시켜야 한다.

- 다중공선성에 대한 설명 중 옳바르지 않은 것은?
 - ① 다중공선성 문제가 발생하면 문제가 있는 변수를 제거하고 분석할 수 있다.
 - ② 다중공선성 문제로 불확실성이 감소할 수 있다.
 - ③ 독립변수 간에 상관관계가 높아서 데이터를 분석할 때 부정적 영향을 미치는 경우 발생한다.
 - ④ VIF가 4보다 크면 다중공선성이 존재하는 것으로 해석한다.

- 다음 주성분 분석에 대한 설명 중 옳바르지 않은 것은?

```
> md_comp<-princomp(swiss, cor=FALSE)
> summary(md_comp)
Importance of components:

                Comp.1      Comp.2      Comp.3      Comp.4
Standard deviation  43.3667866  21.3712016  11.92449843  4.708258751
Proportion of Variance  0.7460284  0.1811752  0.05640546  0.008793495
Cumulative Proportion  0.7460284  0.9272036  0.98360907  0.992402568

                Comp.5      Comp.6
Standard deviation   3.618425207  2.461609258
Proportion of Variance 0.005193739 0.002403694
Cumulative Proportion 0.997596306 1.000000000
```

- ① 첫 번째 주성분은 전체 분산 중 약 74.6%를 설명하고 있다.
- ② 두 번째 주성분까지 포함하면 전체 분산의 약 92.7%까지 설명할 수 있다.
- ③ 모델은 상관 행렬을 사용했다.
- ④ summary의 결과는 6개 주성분의 표준편차, 분산의 비율을 보여준다.

- 스피어만 상관계수에 대한 설명 중 옳바르지 않은 것은?
 - ① 두 변수 간의 비선형적인 관계는 나타내지 못한다.
 - ② 연속형 외에 이산형도 가능하다.
 - ③ 관계가 랜덤이거나 존재하지 않으면 상관계수 모두 0에 가깝다.
 - ④ 스피어만 상관계수는 원시 데이터가 아니라 각 변수에 대해 순위를 매긴 값을 기반으로 한다.

- 다음 중 공분산과 상관계수에 대한 설명 중 가장 옳바르지 않은 것은?
 - ① 공분산은 측정 단위에 영향을 받지 않는다.
 - ② 상관 분석은 두 변수의 인과 관계 성립 여부를 확인할 수 없다.
 - ③ 공분산이 0이라면 두 변수 간에는 아무런 선형 관계가 없고 서로 독립적인 관계에 있다.
 - ④ 상관계수를 통해 상관관계의 표준화된 크기를 측정할 수 있다.

- 다음 중 두 변수 간의 비선형적인 관계도 나타낼 수 있으며 한 변수를 단조 증가 함수로 변환하여 다른 변수를 나타낼 수 있는 정도를 나타내는 상관계수는 무엇인가?

- ① 스피어만 상관계수
- ② 코사인 유사도
- ③ 피어슨 상관계수
- ④ 자카드 인덱스

- 다음은 mtcars 데이터 세트의 변수 간 상관계수를 나타낸 행렬이다. 다음 행렬에 대한 설명으로 가장 옳지 않은 것은 무엇인가?

	mpg	cyl	drat	qsec
mpg	1.00	-0.85	0.68	0.42
cyl	-0.85	1.00	-0.70	-0.59
drat	0.68	-0.70	1.00	0.09
qsec	0.42	-0.59	0.09	1.00

- ① drat와 qsec는 상관관계가 거의 없다고 할 수 있다.
- ② mpg와 cyl은 음의 상관 관계이다.
- ③ 상관계수의 절대값이 크면 두 변수 간의 선형 관계가 크다.
- ④ disp와 cyl의 상관계수는 통계적으로 유의하다.

- 다음이 설명하는 분석 기법은 무엇인가?

상관관계가 있는 고차원 자료를 자료의 변동을 최대한 보존하는 저차원 자료로 변환
서로 상관성이 높은 변수들의 선형 결합으로 만들어 기존의 상관성이 높은 변수들을 요약,
축소하는 기법

- ① 다중 회귀 분석
- ② 판별 분석
- ③ 주성분 분석
- ④ 요인 분석

- 주성분 분석에 대한 설명으로 옳지 않은 내용은?
 - ① 주성분 분석은 수학적으로 직교 선형 변환으로 정의한다.
 - ② 주성분은 선형 결합으로 이루어져 있다.
 - ③ 주성분 분석의 목적 중 하나는 데이터를 이해하기 위한 차원 축소이다.
 - ④ 상관관계가 있는 고차원 자료의 변동을 최대한 제거하는 기법이다.

- 주성분 분석에 대한 설명으로 가장 옳바르지 않은 것은?
 - ① 분산이 가장 작은 것을 제1 주성분으로 한다.
 - ② 상관관계가 있는 고차원의 자료를 자료의 변동을 최대한 보존하는 저차원 자료로 변환하는 차원 축소 방법이다.
 - ③ 누적 기여율이 85% 이상이면 주성분의 수로 결정할 수 있다.
 - ④ 차원 감소 폭의 결정은 스크리 산점도를 활용한다.

- 다음은 princomp(x, cor=TRUE) 함수를 이용한 주성분 분석의 결과이다. 해석으로 가장 올바른 것은?

	PC1	PC2	PC3	PC4
Standard deviation	1.71	0.96	0.38	0.14
Proportion of Variance	0.73	0.23	0.03	0.01
Cumulative Proportion	0.73	0.96	0.99	1.00

- ① 상관 행렬을 활용한 결과이다.
- ② 제1성분의 설명력은 40%이다.
- ③ 제3 주성분일 때 정보손실은 10%이다.
- ④ 85% 이상 설명하려면 주성분 3개 이상 선택하면 된다.

- 주성분 분석에서 변수의 중요도 기준이 되는 값은 무엇인가?
 - ① 고유값
 - ② 특이값
 - ③ 표준오차
 - ④ 스칼라

- 주성분 분석에서 주성분 2개를 수용했을 때 잃는 정보량은 얼마인가?

	PC1	PC2	PC3	PC4
Standard deviation	2.049	0.491	0.278	0.153
Proportion of Variance	0.924	0.053	0.017	0.006
Cumulative Proportion	0.924	0.977	0.994	1.000

- 주성분 분석의 결과에서 두번째 주성분은 전체 분산의 몇 퍼센트를 설명하고 있는가?

	PC1	PC2	PC3	PC4
Standard deviation	2.049	0.491	0.279	0.153
Proportion of Variance	0.924	0.053	0.017	0.006
Cumulative Proportion	0.924	0.977	0.994	1.000

- 다음은 `prcomp(x, scale=TRUE)` 함수를 통한 주성분 분석 결과이다. 설명 중 옳바르지 않은 것은?

	PC1	PC2	PC3	PC4
Standard deviation	1.708	0.956	0.383	0.143
Proportion of Variance	0.729	0.228	0.036	0.007
Cumulative Proportion	0.729	0.957	0.993	1.000

	PC1	PC2	PC3	PC4
변수1	0.521	-0.377	0.719	0.261
변수2	-0.269	-0.923	-0.244	-0.123
변수3	0.580	-0.024	-0.142	-0.801
변수4	0.564	-0.066	-0.634	0.523

- 주성분 분석 결과에 대한 설명 중 옳바르지 않은 것은?

- ① 주성분 분석이란 다변량 자료 분석에 이용하는 독립변수를 분석에 이용한다.
- ② 제3 주성분의 적재 값을 통해 4개의 변수 모두가 제3 주성분과 음의 관련이 있음을 보여준다.
- ③ 위 주성분 분석에서는 상관계수 행렬을 사용하였다.
- ④ 변수1은 PC1~PC4의 선형결합으로 나타낼 수 있다.

- 다음 표는 주성분 분석의 적재 값이다. 제1 주성분의 함수식을 쓰시오.

	PC1	PC2	PC3	PC4
변수1	0.361	0.657	0.582	0.315
변수2		0.730	-0.598	-0.320
변수3	0.857	-0.173		-0.480
변수4	0.358		-0.546	0.754

- 다음 중 주성분 분석에서 주성분을 선택하는 방법에 대한 설명으로 가장 옳지 않은 것은 무엇인가?

- ① 스크리 산점도는 고유값의 크기순으로 산점도를 그린 그래프에서 기울기가 완만해지는 지점에서 1을 뺀 개수를 주성분의 개수로 선택하는 방법이다.
- ② 전체 변이 공헌도 방법은 주성분들이 설명하는 총 분산의 비율이 70~90% 사이가 되는 주성분의 개수를 선택하는 방법이다.
- ③ 평균 고유값 방법은 고유값들의 평균을 구한 후 고유값이 평균값 이상이 되는 주성분을 제거하는 방법이다.
- ④ 주성분은 주성분을 구성하는 변수들의 계수 구조를 파악하여 적절하게 해석한다.