

모듈 7-4

시계열 예측

- 시계열 예측

- 시계열 분석

- 시계열 분석의 개념

- ✓ 시계열 분석은 연도별, 분기별, 월별 등 시계열로 관측되는 자료를 분석하여 미래를 예측하기 위한 분석 기법임
 - ✓ 시계열 분석의 주요 목적은 계절적인 패턴과 같은 외부인자 요소를 설명할 수 있는 모델을 결정하는 것임

- 시계열 분석의 특징

- ✓ x축에 시간, y축에 관측값을 나타내어 추세를 빠르게 분석함
 - ✓ 시계열 데이터는 시간의 흐름에 따라 관측되는 자료로 대체로 독립적이지 않음

• 시계열 예측

- 시계열 분석

➤ 시계열 데이터 분석 절차

순서	절차	설명
1	시간 그래프 작성	• 관측값을 관측 시간에 따라 인접한 관측값을 직선으로 연결하여 그래프 작성
2	추세와 계절성 제거	• 시간 그래프를 통해 나타나는 추세와 계절성을 차분을 이용해 제거하여 정상 시계열로 변환
3	잔차 예측	• 잔차가 서로 상관관계가 없고, 잔차의 평균은 0인 특성을 갖는지 확인함
4	잔차에 대한 모델 적합	• 잔차에 근거하여 모델을 추정
5	미래 예측	• 앞에서 제거했던 추세와 계절성을 더해 미래를 예측

✓ 차분: 비정상 시계열을 정상 시계열 자료로 바꾸기 위해 평균이 일정하지 않은 경우 **현시점에서 이전 시점의 자료를 빼는 방법**

- 시계열 예측

- 정상성

- 정상성의 개념

- ✓ 정상성은 시점에 상관없이 시계열의 특성이 일정하다는 특성임
 - ✓ 시계열 분석을 위해 정상성을 만족해야 함

- 정상성의 조건

- ✓ 평균이 일정해야 함
 - ✓ 분산이 시점에 의존하지 않음
 - ✓ 공분산은 단지 시차에만 의존하고 시점 자체에는 의존하지 않음
 - ✓ 정상 시계열(= 안정 시계열)은 데이터의 어떤 구간에서도 평균값과 분산이 일정한 시계열임



- 시계열 예측

- 정상성

- 정상성의 조건

- ✓ 평균이 일정해야 하며 그렇지 않다면 차분을 통해 정상화할 수 있음

- ✓ 예) 매월 환율데이터, 평균이 일정하지 않으므로 1회 차분을 실시함





- 시계열 예측

- 정상성

- 정상성의 조건

- ✓ 분산이 시점에 의존하지 않음, 그렇지 않다면 변환을 통해 정상화할 수 있음



- 시계열 예측

- 정상성

- 정상성의 조건

- ✓ 공분산은 단지 시차에만 의존하고 시점 자체에는 의존하지 않으므로 특정시점에서 공분산은 동일하며 시차에 따라 공분산 값은 다를 수 있음
 - ✓ 시점은 특정한 시간의 관점이며 시차는 시점과 시점 간의 차이를 의미함
 - ✓ 정상 시계열(= 안정 시계열)은 데이터의 어떤 구간에서도 **평균값과 분산이 일정한 시계열임**

- 시계열 예측

- 시계열 모형

- 자기회귀모형(AR모형: Auto-Regressive Model)

- ✓ 자기회귀모형은 현재시점의 자료가 **p시점 전의 유한개의 과거 자료로 설명**될 수 있는 모형임
 - ✓ 자기회귀모형은 $Z_t = \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + \dots + \phi_p Z_{t-p} + a_t$
 - ✓ Z_t : 현재 시점의 시계열 자료, Z_{t-p} : p시점 이전의 시계열 자료
 - ✓ ϕ_p : p시점이 현재 시점에 어느 정도 영향을 주는지 나타내는 모수(가중치)
 - ✓ a_t : 백색잡음 (시계열 분석의 오차항으로 평균이 0, 분산이 σ^2 인 정규분포를 따름)
 - ✓ 잡음은 **무작위적인 변동**으로 일반적으로 원인이 알려져 있지 않으며 모형에 사용하는 시계열 자료의 시점에 따라 1차, 2차, ..., p차를 사용하지만 정상시계열 모형에서는 **주로 1, 2차**를 사용함

- 시계열 예측

- 시계열 모형

- 이동평균모형(MA모형: Moving Average Model)

- ✓ 이동평균모형은 주기나 불규칙성을 가지고 있는 시계열 데이터의 특성을 토대로 과거의 몇 개 관측치를 평균하여 전반적인 추세를 파악하는 방법임
 - ✓ 이동평균모형은 시간이 지날수록 관측치의 평균값이 지속해서 증가하거나 감소하는 시계열 모형임
 - ✓ 이동평균모형은 $Z_t = a_t - \theta_1 a_{t-1} + \theta_2 a_{t-2} + \dots + \theta_q a_{t-q}$ (Z_t : 현재 시점의 시계열 자료)
 - ✓ θ_q : q시점이 현재 시점에 어느 정도 영향을 주는지 나타내는 모수(가중치), a_t : 백색잡음(시계열 분석에서 오차항)
 - ✓ 현재 시점의 자료를 유한개의 백색잡음 선형 결합으로 표현하여 항상 정상성을 만족하므로 정상성 가정이 필요 없음

- 시계열 예측

- 시계열 모형

- 지수평활법(Exponential Smoothing)


- ✓ 지수평활법은 모든 시계열 자료를 사용하여 평균을 구하며 시간의 흐름에 따라 **최근 시계열에 더 많은 가중치**를 부여하여 미래를 예측하는 방법
 - ✓ 지수평활법은 단순 지수평활법, 이중 지수평활법, 홀트 모형의 종류가 있음

- 시계열 예측

- 시계열 모형

- 자기 회귀 누적 이동 평균 모형(ARIMA 모형: Auto Regressive Integrated Moving Average Model)

- ✓ ARIMA 모형은 분기/반기/연간 단위로 다음 지표를 예측하거나 주간/월간 단위로 지표를 리뷰하여 트렌드를 분석하는 기법
 - ✓ 기본적으로 **비정상 시계열 모형**이기 때문에 차분이나 변환을 통해 AR모형이나 MA모형, ARMA모형으로 정상화할 수 있음



- 시계열 예측

- 시계열 모형

- 자기 회귀 누적 이동 평균 모형 차수

- ✓ ARIMA(p, d, q)모형은 차수 p, d, q 가 있음

차수	설명
p	• AR모형과 관련이 있는 차수
d	• ARIMA에서 ARMA로 정상화할 때 차분 횟수
q	• MA모형과 관련이 있는 차수

- ✓ 차분: 비정상 시계열을 정상 시계열 자료로 바꾸기 위해 평균이 일정하지 않은 경우

현시점에서 이전 시점의 자료를 빼는 방법

- 시계열 예측

- 시계열 모형

- 자기 회귀 누적 이동 평균 모형과 다른 모형과의 관계

- ✓ ARIMA(p, d, q)모형은 차수 p, d, q의 값에 따라 모형의 이름이 다르게 됨

차수	설명
$p = 0$	• IMA(d, q)모형이라 부르고, 이 모형을 d번 차분하면 MA(q) 모형이 됨
$q = 0$	• ARI(p, d)모형이며, 이를 d번 차분한 시계열 모형이 AR(p)모형을 따르게 됨
$d = 0$	• ARMA(p, q)모형이라 부르고, 이 모형은 정상성을 만족

- 시계열 예측

- 시계열 모형

- 자기 회귀 누적 이동 평균 모형과 다른 모형과의 관계

- ✓ ARIMA 차수에 따른 모형

구분	모형
ARIMA(0,0,0)	• 백색 잡음 모형
ARIMA(0,1,0)	• 확률 보행 모형
ARIMA(p,0,0)	• 자기 회귀 모형
ARIMA(0,0,q)	• 이동 평균 모형

- ✓ 확률보행모형: 정상성을 나타내지 않는 데이터로서 누가 봐도 알 수 있는 긴 주기를 갖는 상향 또는 하향 추세가 있으며 갑작스럽고 예측할 수 없는 방향 변화가 있는 모형으로 금융 시계열 데이터 모형으로 활용됨

- 시계열 예측

- 분해 시계열

- 분해 시계열의 개념

- ✓ 분해 시계열은 시계열에 영향을 주는 일반적인 요인을 시계열에서 분리해 분석하는 방법
 - ✓ 시계열을 분리하는 분해 식을 사용함
 - ✓ $Z_t = f(T_t, S_t, C_t, I_t)$
 - ✓ Z_t : 시계열 값, f : 미지의 함수, T_t : 경향(추세) 요인, S_t : 계절요인, C_t : 순환요인, I_t : 불규칙 요인
 - ✓ 회귀분석적인 방법을 주로 사용하고 있음
 - ✓ 회귀분석적인 방법: 관찰된 연속형 변수들에 대해 두 변수 사이의 모형을 구한 뒤
적합도를 측정해내는 분석방법

• 시계열 예측

- 분해 시계열

➤ 시계열 구성요소

구성요소	설명
추세 요인	• 자료가 어떤 특정한 형태를 취하는 요인 • 예) 선형적 추세, 이차식 형태, 지수적 형태 등
계절 요인	• 고정된 주기에 따라 자료가 변화하는 요인 • 예) 요일마다 반복, 일년 중 각 월에 의한 변화, 사분기 자료에서 각 분기에 의한 변화 등
순환 요인	• 알려지지 않은 주기를 가지고 자료가 변화하는 요인 • 예) 명백한 경제적이나 자연적인 이유 없이 알려지지 않은 주기를 가지고 변화
불규칙 요인	• 추세, 계절, 순환 요인으로 설명할 수 없는 회귀 분석에서 잔차에 해당하는 요인

- 연도별, 분기별, 월별 등 시계열로 관측되는 자료를 분석하여 미래를 예측하기 위한 분석 기법은?

- ① 주성분 분석
- ② 회귀 분석
- ③ 시계열 분석
- ④ 군집 분석

- 다음 () 안에 들어갈 용어를 쓰시오.

()은/는 시점에 상관없이 시계열의 특성이 일정한 것을 의미한다. 평균이 일정하고 분산이 시점에 의존하지 않으며 공분산은 단지 시차에만 의존하고 시점 자체에는 의존하지 않는다.

- 분해 시계열에 대한 설명 중 적절하지 않은 것은?

- ① 추세요인: 자료의 형태가 오르거나 내리는 등 자료가 어떤 특정한 형태를 취할 때
- ② 계절요인: 고정된 주기에 따라 자료가 변화하는 경우
- ③ 순환요인: 물가상승률, 급격한 인구 증가 등의 이유로 인하여 주기를 가지고 변화하는 자료
- ④ 불규칙요인: 추세, 계절, 순환 요인으로 설명할 수 없는 요인에 의해 발생

- 다음 중 시계열 예측에서 정상성을 만족한다는 것이 의미하는 것은?
 - ① 평균이 시점에 의존한다.
 - ② 분산이 시점에 의존한다.
 - ③ 평균이 시점에 의존하지 않는다.
 - ④ 분산이 시점에 의존하지 않는다.

- 분해 시계열의 요인에 해당하지 않은 것은?
 - ① 정상 요인
 - ② 추세 요인
 - ③ 계절 요인
 - ④ 불규칙 요인

- 시계열 분석을 위해서는 정상성을 만족해야 하는데 자료가 추세를 보일 때 현 시점의 자료에서 이전 시점의 자료를 빼는 방법을 통해 비정상 시계열을 정상 시계열로 바꾸어 준다. 현시점에서 이전 시점의 자료를 빼는 방법은 무엇인가?

- 시계열 분해 중에서 고정된 주기에 의해 자료가 변환하는 요인을 무엇이라 하는가?

- 다음 내용이 설명하고 있는 것을 적으시오.

현시점의 자료가 p시점 전의 유한개의 과거 자료로 설명될 수 있는 모형이다.

모형에 사용하는 시계열 자료의 시점에 따라 1차, 2차, ..., p차 등을 사용하나 정상 시계열 모형에서는 주로 1, 2차를 사용한다.

- 다음 내용이 설명하는 시계열 모형은 무엇인가?

현시점의 자료를 유한개의 백색잡음의 선형 결합으로 표현되었기 때문에 항상 정상성을 만족하므로 정상성 가정이 필요 없다.

현시점의 자료를 유한개의 백색잡음의 선형 결합으로 표현되어 항상 정상성을 만족한다.

- 시계열에 영향을 주는 일반적인 요인을 시계열에서 분리해 분석하는 방법은?

• 다음 중 시계열 분석에 대한 설명으로 가장 옳바르지 않은 것은?

- ① 잡음에 대한 원인을 알 수 있다.
- ② 연도별, 분기별, 월별 등 시계열로 관측되는 자료를 분석한다.
- ③ 시계열 분석을 위해서는 정상성을 만족해야 한다.
- ④ 시계열 분해는 시계열에 영향을 주는 일반적인 요인을 시계열에서 분리해 분석하는 방법이다.

• 시간의 흐름에 따라 일정한 간격마다 기록한 데이터는 다음 중 무엇에 대한 설명인가?

- ① 시계열 데이터
- ② 횡단면 데이터
- ③ 패널 데이터
- ④ 정형 데이터

• 다음 중 시계열 분석 기법 중 최근 시계열 데이터에 더 많은 가중치를 부여하는 분석 방법은?

- ① 시계열 요소 분해법
- ② 이동 평균
- ③ 지수평활법
- ④ 회귀 분석법

- 다음은 자기 회귀 누적 이동평균모형(ARIMA 모형)을 나타낸 것이다. 다음 모형은 ARIMA에서 ARMA로 정상화할 때 몇 번 차분을 하였는가?

ARIMA(1, 2, 3)

- ① 1번
- ② 2번
- ③ 3번
- ④ 4번

- 다음 중 시계열 데이터를 분석하기 위한 절차로 적합한 것은?

- ① 추세와 계절성 제거하기 → 시간 그래프 그리기 → 잔차 예측하기 → 잔차에 대한 모델 적합하기 → 예측된 잔차에 추세와 계절성을 더하여 미래 예측하기
- ② 시간 그래프 그리기 → 추세와 계절성 제거하기 → 잔차 예측하기 → 잔차에 대한 모델 적합하기 → 예측된 잔차에 추세와 계절성을 더하여 미래 예측하기
- ③ 시간 그래프 그리기 → 잔차 예측하기 → 추세와 계절성 제거하기 → 잔차에 대한 모델 적합하기 → 예측된 잔차에 추세와 계절성을 더하여 미래 예측하기
- ④ 잔차 예측하기 → 시간 그래프 그리기 → 잔차에 대한 모델 적합하기 → 예측된 잔차에 추세와 계절성을 더하여 미래 예측하기 → 추세와 계절성 제거하기

- 다음 중 시계열 분석에 대한 설명으로 가장 옳바르지 않은 것은?
 - ① 시계열 자료가 추세를 보이는 경우 변환을 통해서 정상 시계열로 바꾸어 준다.
 - ② 시계열에 영향을 주는 일반적인 요인을 시계열에서 분리해 분석하는 방법을 분해 시계열이라 한다.
 - ③ 시계열 자료는 시간의 흐름에 따라 관측되는 자료이므로 대체로 독립적이지 않다.
 - ④ 대부분의 시계열 자료는 비정상 시계열 자료이므로 정상 시계열로 만든 후 시계열 분석을 한다.

정형 데이터 마이닝

• MODULE 8

모듈 8-1

데이터 마이닝 개요

- 데이터 마이닝 개요

- 데이터 마이닝 개념

- 데이터 마이닝은 기업이 보유하고 있는 내부 데이터와 외부 데이터를 포함하는 모든 사용 가능한 데이터를 기반으로 감춰진 **지식, 기대하지 못했던 경향이나 새로운 규칙** 등을 발견하여 비즈니스 의사결정 등에 유용한 정보로 활용하는 일련의 작업
 - 대용량 데이터로부터 데이터 내에 존재하는 패턴, 관계 혹은 규칙 등을 탐색하고 통계적인 기법들을 활용하여 모델화하며 이를 통해 데이터 분석 및 더 나아가 **유용한 정보, 지식 등을 추출**하는 과정

• 데이터 마이닝 개요

- 데이터 마이닝 기능

기능	설명
분류	• 새롭게 발생한 현상을 검토 후 기존의 분류 및 정의된 집합에 배정 • 주요 기법은 의사결정나무가 있음
추정	• 주어진 데이터를 이용하여 알려지지 않은 연속된 결과의 값 추정 • 주요 기법은 인공 신경망 모형이 있음
예측	• 미래의 양상 예측 또는 미래의 값을 추정한다는 것을 제외하면 분류나 추정과 같은 의미 • 주요 기법은 의사결정나무, 인공 신경망 모형 등이 있음
연관 분석	• '같이 팔리는 물건'과 같은 아이템의 연관성을 파악하며 소매점에서 물건 배열 계획, 카탈로그 배열 및 교차 판매, 공격적 판촉 행사 등의 마케팅 계획 수립에 적용 • 흔히 장바구니 분석이라고 불림
군집	• 이질적인 모집단을 동질성을 지닌 그룹별로 세분화 • 미리 정의되어 있는 기준에 의존하지 않고 다른 레코드와의 유사성의 의해 그룹화
기술	• 사람 및 상품에 대한 이해를 증가시키기 위해 가지고 있는 의미를 설명하고 설명에 대한 답을 제공

• 데이터 마이닝 개요

- 데이터 마이닝 단계

➤ 데이터 마이닝은 **소프트웨어 도입 등의 적절한 환경을 구축한 후** 다음 단계에 따라 수행함

기능	설명
목적 정의	- 데이터 마이닝 도입의 목적 설정 단계 - 전문가 참여를 통해 목적에 따른 데이터 마이닝 기법과 필요한 데이터 정의
데이터 준비	- 데이터 마이닝 수행에 필요한 데이터 수집 단계 - 기업 내부데이터(고객정보, 거래정보 등), 외부데이터(웹로그 데이터 등)도 활용가능 - 데이터 정제를 통한 데이터의 품질 보장 필요 - 필요시 보강 작업을 거쳐 데이터 마이닝 기법 적용에 문제가 없도록 충분한 데이터의 양 확보
데이터 가공	모델링 목적에 따른 목적(종속)변수 정의, 필요한 데이터를 데이터 마이닝 소프트웨어에 적용 가능한 적합한 형식으로 가공하는 단계

• 데이터 마이닝 개요

- 데이터 마이닝 단계

➤ 데이터 마이닝은 **소프트웨어 도입 등의 적절한 환경을 구축한 후** 다음 단계에 따라 수행함

기능	설명
데이터 마이닝 기법 적용	- 준비한 데이터와 데이터 마이닝 소프트웨어를 활용하여 목적하는 정보를 추출하는 단계 - 목적에 맞는 데이터 마이닝 모델 선택, 소프트웨어 사용에 필요한 값 지정 - 분석 전문가의 전문성이 필요
검증	- 테스트 마케팅이나 과거 데이터 등을 이용하여 데이터 마이닝을 통해 추출한 정보를 검증하는 단계 - 검증 단계 후 자동화 방안을 IT부서와 협의하여 상시적으로 데이터 마이닝 결과를 업무에 적용하고 경영진에게 기대 효과를 알릴 수 있도록 보고서 작성

- 기업이 보유하고 있는 내부 데이터와 외부 데이터를 포함하는 모든 사용 가능한 데이터를 기반으로 감춰진 지식, 기대하지 못했던 경향이나 새로운 규칙 등을 발견하여 비즈니스 의사결정 등에 유용한 정보로 활용하는 일련의 작업은?

- ① 연관 분석
- ② 군집 분석
- ③ 데이터 마이닝
- ④ 분류 분석

- 데이터 마이닝의 단계 중 모델링 목적에 따라 목적 변수를 정의하고 필요한 데이터를 데이터 마이닝 소프트웨어에 적용 가능한 적합한 형식으로 준비하는 단계는?

- ① 목적 정의
- ② 데이터 마이닝 기법 적용
- ③ 데이터 준비
- ④ 데이터 가공

• 다음 중 카탈로그 배열 및 교차 판매, 공격적 판촉 행사 등에 적용하기에 가장 적합한 데이터 마이닝 기법은?

- ① 군집 분석
- ② 연관 분석
- ③ 추정
- ④ 분류 분석

- 데이터 마이닝의 대표적인 기능 중 하나로 사람 및 상품에 대한 이해를 증가시키기 위해 데이터가 가지고 있는 의미를 설명하고 설명에 대한 답을 제공할 수 있는 데이터 마이닝의 기능으로 가장 적절한 것은?

- ① 분류
- ② 기술
- ③ 연관
- ④ 예측

모듈 8-2

분류 분석

- 분류 분석

- 분류 분석은 종속변수가 알려진 다변량 자료를 이용하여 모델을 구축하고 이를 통해 새로운 자료에 대한 **예측 및 분류**를 수행하는 것이 목적임
- 예측 모형의 주목적은 반응변수(종속변수)가 범주형인 경우 새로운 자료에 대한 **범주 분류 (범주 예측)**이며, 반응변수(종속변수)가 연속형인 경우 **반응 변수를 예측**하는 것임. 예측과 분류는 유사한 의미로 사용됨

- 분류 분석

- 로지스틱 회귀 분석

- 로지스틱 회귀분석은 독립변수가 **수치형**이고 반응변수(종속변수)가 **범주형**인 경우 적용되는 회귀분석모형
 - 새로운 설명변수의 값이 주어질 때 반응변수의 **각 범주에 속할 확률**이 얼마인지를 추정하여 추정 확률을 기준치에 따라 분류하는 목적임
 - 모형의 적합을 통해 추정된 확률을 사후 확률로 부름
 - ✓ 사후확률: 사건 발생 후에 그것이 어떤 원인이라고 생각되는 확률

- 분류 분석

- 로지스틱 회귀 분석

- $Y = \frac{e^X}{1+e^X} = \frac{\exp(\beta_0 + \beta_1 X_1 + \dots + \beta_k X_k)}{1 + \exp(\beta_0 + \beta_1 X_1 + \dots + \beta_k X_k)}$

- Y : 종속변수, X : 독립변수 행렬, $X_1, X_1, \dots, X_k$: 독립변수

- β_0 : 회귀식 절편(상수항), $\beta_1, \beta_2, \dots, \beta_k$: 회귀식 기울기

- 분류 분석

- 로지스틱 회귀 분석

- 로지스틱 회귀분석은 대상이 되는 데이터의 종속변수(y)의 결과가 0과 1 두 개의 경우만 존재함
 - 로지스틱 모형 식은 독립변수가 $(-\infty, +\infty)$ 의 어느 숫자이든 상관없이 종속변수 또는 결과값이 항상 범위 $[0,1]$ 사이에 있도록 하는데 이는 로짓(Logit) 변환을 수행함으로써 얻어짐
 - ✓ $[a,b] \rightarrow a \leq \text{범위} \leq b$ 이고 $(a,b) \rightarrow a < \text{범위} < b$
 - 분석 대상이 되는 종속 변수인 0, 1은 로짓을 이용해서 연속변수인 것처럼 바꿔줌으로써 활용할 수 있음
 - 그러나 바로 로짓으로 변환하지 못하고 먼저 오즈, 오즈비를 거쳐 로짓으로 변환해야 함

- 분류 분석

- 로지스틱 회귀 분석

- $\exp(\beta_1)$ 의 의미는 나머지 변수($x_2, \dots, x_k$)가 주어질 때 x_1 이 한 단위 증가할 때마다 성공($Y=1$)의 **오즈가 몇 배 증가하는지를 나타내는 값**

- **오즈(Odds)**

- ✓ 오즈는 특정 사건이 발생할 확률과 그 사건이 발생하지 않을 확률의 비율임

- ✓ $Odds(p) = \frac{p}{1-p}$ (p: 특정사건의 발생 확률)

- ✓ 예) 한국이 축구에서 브라질에 승리할 확률이 20%라고 할때 $Odds(p) = \frac{p}{1-p} = \frac{\text{이길확률}}{1-\text{이길확률}} = \frac{0.2}{0.8} = \frac{1}{4}$

- 분류 분석


- 로지스틱 회귀 분석

- 로짓(Logit) 변환

- ✓ 로짓 변환은 오즈에 로그를 취한 함수로 입력값의 범위가 $[0,1]$ 일 때 출력값의 범위를 $(-\infty, +\infty)$ 로 조정함

- ✓ $Logit(p) = \log \frac{p}{1-p} = \log Odds(p)$ (p : 특정사건의 발생 확률)

- ✓ 로짓 변환도 $[0,1]$ 에 대한 확률값으로 $(-\infty, +\infty)$ 의 값을 갖는다는 한계점이 있어 이러한 한계를 극복하기 위해 로짓 함수의 식을 조작하여 최종적으로 **시그모이드 함수**를 사용하여 로지스틱 회귀 분석을 구현함



- 분류 분석

- 로지스틱 회귀 분석


- 시그모이드 함수

- ✓ 시그모이드 함수는 S자형 곡선을 갖는 수학 함수임

- ✓ 로짓 함수에 역함수를 취하면 시그모이드 함수가 됨

- ✓ $\text{sigmoid}(x) = \frac{1}{1+e^{-x}}$ (x 의 값이 $(-\infty, +\infty)$ 일 때 y 값은 $[0,1]$ 의 값을 가짐)

- ✓ 시그모이드 함수에서 x 값이 ∞ 에 가까울수록 1에 가깝고 x 값이 $-\infty$ 에 가까울수록 0에 가까움



- 분류 분석

- 로지스틱 회귀 분석


- 검정

- ✓ 로지스틱 회귀분석의 유의성 검정은 카이제곱 검정을 이용함
 - ✓ 영 이탈도, 잔차 이탈도의 값으로 카이제곱 검정을 실시함
 - ✓ 이탈도: 모형이 데이터를 얼마나 설명하지 못하는지에 대한 척도임
 - ✓ 영 이탈도: 독립변수 없이 상수항만 있는 모형의 이탈도
 - ✓ 잔차 이탈도: 선택된 모형의 이탈도

- 분류 분석

- 인공신경망

- 인공신경망은 사람 두뇌의 신경세포인 뉴런이 **전기신호를 전달**하는 모습을 모방한 기계학습 모델임
 - 인공신경망은 입력값을 받아 출력값을 만들기 위해 **활성화 함수**를 사용함
 - 인공신경망은 **가중치**를 알아내는 것이 목적임



• 분류 분석

- 인공신경망

➤ 인공신경망은 1세대, 2세대, 3세대로 구분할 수 있음

구분	주요 내용
1세대(1943~1986년)	- 인공신경망이라는 개념이 최초로 제안됨 - 퍼셉트론이라는 선형 분류가 가능한 순방향 신경망을 제안 - XOR 선형 분리 불가 문제가 발생




✓ 순방향신경망: 입력데이터가 **입력층** → **은닉층** → **출력층**의 순서로 전파되어 판별함수 값으로 변환되는 신경망

- 분류 분석

- 인공신경망

- XOR 선형 분리 불가

- ✓ 결과값이 0이면 흰점으로 1이면 검은점으로 나타낸 후 색이 같은 점끼리 나눌 수 있는지 확인
 - ✓ XOR의 경우 선을 그어 흰점과 검은점을 구분할 수 없음



• 분류 분석

- 인공신경망

➤ 인공신경망은 1세대, 2세대, 3세대로 구분할 수 있음

구분	주요 내용
2세대(1986~2006년)	• 다층 퍼셉트론과 역전파 알고리즘 등장 • 은닉층을 통해 XOR 문제를 해결 • 과적합 문제, 사라지는 경사 현상 문제 발생

- ✓ 다층 퍼셉트론: 입력층과 출력층 사이에 하나 이상의 은닉층을 두어 비선형적으로 분리되는 데이터에 대해 학습이 가능한 퍼셉트론
- ✓ 역전파 알고리즘: 역방향으로 가중치 갱신을 통해 오차를 최소화하도록 학습시키는 알고리즘
- ✓ 과적합 문제: 데이터가 많지 않은 경우 특정 학습데이터에만 학습이 잘 되어 새로운 데이터에 대한 추론 성능이 낮아지는 현상
- ✓ 사라지는 경사 현상 문제: 은닉층의 층수를 늘릴 때 데이터가 사라져 학습이 잘 되지 않는 현상

• 분류 분석

- 인공지능망

➤ 인공지능망은 1세대, 2세대, 3세대로 구분할 수 있음

구분	주요 내용
3세대(2006~현재)	- 알파고와 이세돌의 바둑 대결로 인공지능 부각 - 딥러닝(CNN, RNN 등) 활용 - 과적합 문제 및 기울기 소실 문제 해결


- ✓ 기울기 소실문제: 오차 역전파에서 계산 결과와 정답과의 오차를 통해 가중치를 수정하는데 **입력층으로 갈수록 기울기가 작아져** 가중치들이 업데이트되지 않아 최적의 모델을 찾을 수 없는 문제
- ✓ 계층을 이동할 때마다 노드의 활성화 함수의 미분 값을 곱하게 되는데 시그모이드 함수는 미분 값이 0~0.25로 입력층으로 갈수록 0에 가까워져 기울기가 사라져 **가중치가 적용되지 않음**

• 분류 분석

- 인공신경망의 구조

➤ 퍼셉트론

- ✓ 퍼셉트론은 인간의 신경망에 있는 뉴런의 모델을 모방하여 **입력층**, **출력층**으로 구성된 인공신경망 모델임
- ✓ 퍼셉트론의 구조는 입력값, 가중치, 순입력함수, 활성화 함수, 예측값으로 되어 있음
- ✓ 입력값과 가중치를 순 입력함수에서 각각 곱하고 모두 더함
- ✓ 순 입력함수 값을 활성화 함수의 임계값과 비교하여 예측값을 1 또는 -1로 출력함
- ✓ 활성화 함수의 예측값이 실제 결과와 다를 경우 가중치를 업데이트하며 위 과정을 반복함




- 분류 분석

- 인공신경망의 구조

- 다층 퍼셉트론

- ✓ 다층 퍼셉트론은 입력층과 출력층 사이에 하나 이상의 은닉층을 두어 비선형적으로 분리되는 데이터에 대해 학습이 가능한 퍼셉트론임
 - ✓ 다층 퍼셉트론 구조에서는 입력층, 은닉층, 출력층으로 구성하고 역전파 알고리즘을 통해 다층으로 만들어진 퍼셉트론의 학습이 가능함
 - ✓ 다층 퍼셉트론에서 활성화 함수로 시그모이드 함수를 사용함



• 분류 분석

- 인공신경망의 구조

➤ 다층퍼셉트론의 문제점

문제점	주요 내용
과대 적합	• 훈련 데이터가 부족한 경우 훈련 데이터에는 잘 동작하지만 실제 데이터에는 예측을 못하는 문제점이 존재함 • 훈련 데이터 부족으로 인한 과대적합은 빅데이터 시대가 열리면서 데이터 확보가 쉬워져 해결됨
기울기 소실	• 역전파 알고리즘은 학습하는 과정에서 출력층 → 은닉층 → 입력층 방향으로 편미분을 진행함 • 다층 퍼셉트론의 활성화 함수인 시그모이드 함수는 편미분을 진행할수록 0으로 근접해져 기울기가 소실되는 문제점이 발생 • 기울기 소실은 시그모이드 함수 대신 ReLU 함수를 사용하여 문제를 해결




- 분류 분석

- 뉴런의 활성화 함수

- 활성화 함수는 순 입력함수로부터 전달받은 값을 **출력값으로 변환해 주는 함수**임
 - 활성화 함수의 종류에는 계단함수, 부호함수, 선형함수, 시그모이드 함수, tanh 함수, ReLU 함수 등이 있음
 - 시그모이드 함수는 기울기 소실의 원인이었으며 **ReLU함수**를 통해 기울기 소실의 문제를 해결하였음




• 분류 분석

- 뉴런의 활성화 함수

활성화 함수	그래프	설명
계단함수		- 임계값을 기준으로 활성화(y축 1) or 비활성화(y축 0)가 됨 $Y = 0, if X < 0$ $Y = 1, if X \geq 0$
부호함수		- 임계값을 기준으로 양의 부호(+1) or 음의 부호(-1)을 출력 $Y = -1, if X < 0$ $Y = 1, if X \geq 0$
시그모이드 함수		- 모든 점에서 음이 아닌 미분 값을 가지며 단 하나의 변곡점을 가지는 함수 $Y = \frac{1}{1+e^{-X}} (0 \leq Y \leq 1)$

• 분류 분석

- 뉴런의 활성화 함수


활성화 함수	그래프	설명
tanh 함수		- 하이퍼볼릭 탄젠트 함수로 시그모이드 함수와 유사한 활성화 함수 $Y = \frac{e^X - e^{-X}}{e^X + e^{-X}}$
ReLU 함수		$X \leq 0$인 경우 기울기가 0이기 때문에 뉴런이 죽을 수 있는 단점이 존재 $Y = 0, \text{ if } X \leq 0$ $Y = X, \text{ if } X > 0$
Leaky ReLU 함수		- ReLU 함수의 뉴런이 죽는 현상 해결 $Y = 0.01X \text{ if } X < 0$ $Y = X, \text{ if } X \geq 0$

- 분류 분석

- 인공신경망의 학습

- 순전파

- ✓ 순전파는 입력층에서 출력층까지 정보가 전달되는 과정임
 - ✓ 입력층에서 은닉층 방향으로 이동하면서 각 입력값의 가중치를 곱함
 - ✓ 은닉층에서는 가중치가 반영된 입력값의 합계를 활성화 함수로 계산하고 결과값을 출력층으로 전달함



- 분류 분석

- 인공신경망의 학습

- 손실 함수


- ✓ 손실 함수는 실제값과 예측값의 차이를 비교하는 지표임
 - ✓ 손실 함수는 **값이 낮을수록** 학습이 잘 된 것이라고 볼 수 있고 정답과 알고리즘 출력을 비교할 때 사용됨
 - ✓ 인공신경망 학습에서 최적의 매개변수를 탐색할 때 손실함수의 값을 가능한 한 작게 하는 매개변수 값(가중치)을 찾음
 - ✓ 인공신경망의 가중치 매개변수는 훈련 데이터와 학습 알고리즘에 의해 **자동으로 획득됨**

- 분류 분석

- 인공신경망의 학습

- 경사하강법

- ✓ 기울기를 낮은 쪽으로 계속 이동시켜 최적의 매개 변수를 찾는 기법으로 함수의 기울기를 구하고 경사의 절대값이 낮은 쪽으로 계속 이동시켜 극값에 이를 때까지 반복시킴
 - ✓ 학습률은 갱신하는 양(한 번 학습할 때 학습해야 하는 양)으로 사람이 직접 설정하는 초 매개변수




- 분류 분석

- 인공신경망의 학습

- 경사하강법의 한계

- ✓ 전체 데이터를 모두 사용해서 기울기를 계산하기 때문에 학습하는데 **많은 시간이 필요하며** 랜덤하게 선택된 가중치의 위치가 지역 최소 점에 근접해 있으면 전역 최소값이 아닌 지역 최소값에 수렴할 수 있음
 - ✓ 경사하강법의 단점을 극복하기 위해 확률적 경사하강법, 모멘텀 등의 매개변수 최적화 기법을 사용함



- 분류 분석

- 인공신경망의 학습

- 오차 역전파

- ✓ 오차 역전파는 계산 결과와 정답의 오차를 구하고 오차와 관련된 값들의 가중치를 수정하여 오차가 작아지는 방향으로 일정 횟수를 반복해서 수정하는 방법
 - ✓ 가중치 매개변수의 기울기는 수치 미분으로 구할 수 있으며 수치 미분은 단순하고 구현하기 쉽지만 계산 시간이 오래 걸려 **오차 역전파**를 사용하여 효율적으로 기울기를 구함
 - ✓ 수치 미분과 오차 역전파의 결과를 비교하여 두 방식으로 구한 기울기의 차이가 거의 없는지를 확인하는 작업을 **기울기 확인(Gradient Check)**이라 함

- 다음 중 인공지능망에 대한 설명으로 가장 부적합한 것은?

- ① 데이터를 정규화하지 않으면 전역 최소값이 아닌 지역 최소값에 빠질 위험이 있다.
- ② 인공지능망의 학습률은 신경망 모형에서 자동으로 설정된다.
- ③ 모형은 결과에 대한 해석이 쉽지 않다.
- ④ 모형이 복잡하면 훈련 과정에 시간이 많이 소요될 수 있다.

- 다음 중 인공신경망에서 은닉층의 노드 수가 너무 적을 경우 나타나는 문제에 대한 설명으로 가장 올바른 것은?
 - ① 훈련에 많은 시간이 소요된다.
 - ② 네트워크의 일반화가 어렵다.
 - ③ 네트워크가 복잡한 의사결정 경계를 만들 수 없다.
 - ④ 기울기 소실 문제가 발생한다.

- 다음 중 로지스틱 회귀 모형의 유의성 검정 방법은 무엇인가?
 - ① T-검정
 - ② F-검정
 - ③ 윌콕슨 순위 합 검정
 - ④ 카이제곱 검정

• 에어컨 회사에서 고객군을 지역별 온도, 습도에 따라 세분화하여 마케팅 전략을 수립하려고 할 때 적합한 분석 방법은 무엇인가?

- ① 주성분 분석
- ② 연관 분석
- ③ 분류 분석
- ④ 군집 분석

- 컴퓨터가 스스로 데이터를 분석해서 패턴과 규칙을 찾아내어 학습하고 학습된 패턴과 규칙을 활용하여 분류나 예측을 하는 인공지능의 한 분야는?

- 제한된 훈련 데이터 세트에 너무 지나치게 특화되어 새로운 데이터에 대한 오차가 매우 커지는 현상은 무엇인가?

- 사람 두뇌의 신경세포인 뉴런이 전기신호를 전달하는 모습을 모방한 기계학습 모델은?

- 의사결정나무

- 의사결정나무의 개념

- 의사결정나무 모형은 의사결정 규칙을 나무 구조로 나타내어 전체 자료를 몇 개의 소집단으로 **분류하거나 예측**하는 분석 방법임
 - 의사결정나무 기법은 분석의 대상을 **분류함수**를 활용하여 의사결정 규칙으로 이루어진 나무 모양으로 그리는 기법임
 - ✓ 분류함수: 어느 모집단에서 추출된 것인지 모르는 새로운 데이터가 관측되었을 때 이 데이터를 여러 모집단 중 어느 하나의 모집단으로 분류해주기 위해 분류의 기준으로 사용되는 함수

- 의사결정나무


- 의사결정나무의 개념

- 의사결정나무 구조는 연속적으로 발생하는 의사결정 문제를 시각화해서 의사결정이 이루어지는 시점과 성과 파악을 쉽게 해줌
 - 의사결정나무 기법의 해석이 쉬운 이유는 계산 결과가 의사결정나무에 직접 나타나기 때문임

- 의사결정나무

- 의사결정나무의 구성요소

- 의사결정나무는 뿌리마디, 자식마디, 부모마디, 끝마디, 중간마디, 가지, 깊이 등의 요소로 구성되어 있음
 - 가지분할은 나무의 가지를 생성하는 과정이며 가지치기는 생성된 가지를 잘라내어 모델을 단순화하는 과정



• 의사결정나무

- 의사결정나무의 구성요소

➤ 의사결정나무는 뿌리 마디, 자식마디, 부모마디, 끝마디, 중간마디, 가지, 깊이 등의 요소로 구성되어 있음

구성요소	설명
부모 마디	• 주어진 마디의 상위에 있는 마디
자식 마디	• 하나의 마디로부터 분리되어 나간 2개 이상의 마디들
뿌리 마디	• 시작되는 마디로 전체 자료를 포함
끝마디	• 잎 노드라고도 불림 • 자식 마디가 없는 마디
중간 마디	• 부모 마디와 자식 마디가 모두 있는 마디
깊이	• 뿌리 마디부터 끝마디까지의 중간 마디들의 수

- 의사결정나무

- 해석력과 예측력

- 은행의 신용평가에서는 평가 결과 부적격 판정이 나온 경우 대상자에게 부적격 이유를 설명해야 하므로

- 의사결정나무의 **해석력**에 집중함

- ✓ 해석력은 결과를 해석하고 설명할 수 있는 정도

- 기대 집단의 사람 중 가장 큰 반응을 보일 상품 구매 고객의 모집방안을 예측하고자 하는 경우 의사결정나

- 무의 **예측력**에 집중함

- ✓ 예측력은 실제 예측의 정확도를 나타내는 정도

• 의사결정나무

- 의사결정나무의 분석

➤ 의사결정나무의 분석과정

순서	단계	수행 내용
1	설명변수 선택	• 목표변수와 관계가 있는 설명변수들의 선택
2	의사결정나무 생성	• 분석의 목적과 자료구조에 따라서 적절한 분리기준과 정지 규칙을 정하여 의사결정나무 생성
3	가지치기	• 부적절한 나뭇가지는 가지치기로 제거
4	모형 평가	• 이익, 위험, 비용 등을 고려하여 모형을 평가
5	분류 및 예측	• 데이터의 분류 및 예측에 활용

- 의사결정나무

- 분리 기준

- 분리 기준은 하나의 부모 마디로부터 자식 마디들이 형성될 때 입력변수의 선택과 범주의 병합이 이루어지는 **기준**을 의미함
 - 어떤 입력변수를 이용하여 어떻게 분리하는 것이 목표변수의 분포를 가장 잘 구별해주는지를 파악하여 자식 마디가 형성되는데 목표변수 분포를 구별하는 정도를 **순수도**, 또는 **불순도**에 의해 측정함
 - 의사결정나무는 목표변수가 이산형인 경우 **분류나무**, 연속형인 경우 **회귀나무**로 구분되며 이에 따라 다른 분리 기준을 사용함

- 의사결정나무

- 분리 기준

➤ 분류나무(이산형 목표변수)에서 사용되는 분리 기준

분리 기준	설명
카이제곱 통계량의 p-값	• p-값이 가장 작은 예측변수와 그 당시의 최적 분리를 통해 자식 마디 형성
지니 지수	• 불순도를 측정하는 하나의 지수로 지니 지수를 가장 많이 감소시켜주는 예측변수와 그 당시의 최적 분리를 통해 자식 마디 선택
엔트로피 지수	• 엔트로피 지수가 가장 작은 예측변수와 그 당시의 최적 분리를 통해 자식 마디를 형성

- 의사결정나무

- 분리 기준

➤ 회귀나무(연속형 목표변수)에서 사용되는 분리 기준

분리 기준	설명
분산 분석에서 F통계량	• p-값이 가장 작은 예측변수와 그 당시의 최적 분리를 통해 자식 마디 형성
분산의 감소량	• 오차를 최소화하는 것과 같은 기준으로 분산의 감소량을 최대화하는 기준의 최적 분리를 통해 자식 마디 형성

- 의사결정나무

- 정지 규칙

- 의사결정나무의 절차 중 정지 규칙과 가지치기라는 순서가 있는데 정지 규칙은 **더는 분리가 일어나지 않고 현재의 마디가 끝마디가 되도록** 하는 규칙
 - 정지기준은 의사결정나무의 **깊이를 지정하거나, 끝마디 데이터 수의 최소 개수를 지정**할 수 있음

- 의사결정나무

- 가지 치기

- 가지 치기는 분류 오류를 크게 할 위험이 높거나 부적절한 추론 규칙을 가지고 있는 가지 또는 불필요한 가지를 제거하는 과정
 - 의사결정나무에서 너무 큰 나무 모형은 자료를 과대 적합하고 너무 작은 나무 모형은 과소 적합할 위험성이 있음
 - ✓ 과대적합: 제한된 훈련데이터 세트에 지나치게 특화되어 새로운 데이터에 대한 오차가 매우 커지는 현상으로 모델의 매개변수 수가 많거나 훈련 데이터 세트의 양이 부족한 경우 발생함
 - ✓ 과소적합: 적정 수준의 학습이 부족하여 실제 성능이 떨어지는 현상으로 데이터 수집시 단편화된 방법으로 인한 학습 부족 현상임

• 의사결정나무

- 불순도의 여러 가지 척도

- 목표변수가 이산형 변수인 의사결정나무의 분류 규칙을 선택하기 위해 **카이제곱 통계량, 지니 지수, 엔트로피 지수**를 활용함

척도	공식	설명
카이제곱 통계량	$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}$	카이제곱 통계량의 값이 클수록 순수도가 낮다고 볼 수 있음
지니 지수	$Gini(T) = 1 - \sum_{i=1}^k P_i^2$	- 노드의 불순도를 나타내는 값 - 지니 지수의 값이 클수록 순수도가 낮다고 볼 수 있음
엔트로피 지수	$Entropy(T) = -\left(\sum_{i=1}^k P_i \log_2 P_i\right)$	무질서 정도에 대한 측정값으로 엔트로피 지수의 값이 클수록 순수도가 낮다고 볼 수 있음

• 의사결정나무

- 의사결정나무 알고리즘

알고리즘	설명
CART (이진분할)	• 각 독립변수를 이분화하는 과정을 반복하여 이진 트리 형태를 형성함으로써 분류를 수행하는 알고리즘 • 불순도를 지니지수로 계산하는 알고리즘
C4.5와 C5.0	• CART와는 다르게 각 마디에서 다지분리를 할 수 있으며 범주형 독립변수에 대해서 범주의 수만큼 분리가 일어남 • 불순도를 엔트로피 지수로 계산하는 알고리즘
CHAID (다지분할)	• 가지치기하지 않고 나무가 적당한 크기에서 성장을 중지하며 독립변수가 이산형 변수이어야 함 • 불순도의 척도로 카이제곱 통계량을 사용함
QUEST	• 변수의 선택에서 범주의 개수가 많은 범주형 변수로의 편향이 심각한 CART의 문제점을 개선한 알고리즘


• 의사결정나무

- 의사결정나무의 장점

장점	설명
해석의 용이성	- 나무 구조에 의해 모형이 표현되기 때문에 모형을 사용자가 쉽게 이해 가능함 - 새로운 개체에 대한 분류 또는 예측을 하기 위해서 뿌리 마디로부터 끝마디까지를 단순히 따라가면 되기에 새로운 자료에 모형을 적합시키기 쉬움 - 나무구조에서 어떤 입력변수가 목표변수를 설명하기 더 중요한지 쉽게 파악이 가능
상호작용 효과의 해석 가능	- 두 개 이상의 변수가 결합하여 목표변수에 어떻게 영향을 주는지 쉽게 파악이 가능함 - 의사결정나무는 유용한 입력변수나 상호작용의 효과 또는 비선형성을 자동으로 찾아내는 알고리즘
비모수적 모형	- 선형성이나 정규성 또는 등분산성 등의 가정을 필요로 하지 않은 비모수적인 방법 - 순서형 또는 연속형 변수는 단지 순위만 분석에 영향을 주기 때문에 이상값에 민감하지 않음
유연성과 정확도가 높음	- 대용량 데이터에서도 빠르게 만들 수 있음 - 설명변수나 목표변수에 수치형 변수와 범주형 변수를 모두 사용 가능 - 모형 분류 정확도가 높음

• 의사결정나무

- 의사결정나무의 단점

단점	설명
비연속성	연속형 변수를 비연속적인 값으로 취급하기 때문에 분리의 경계점 근방에서 예측 오류가 클 가능성이 있음
선형성 또는 주 효과의 결여	선형모형에서 주효과는 다른 예측변수와 관련시키지 않고서도 각 변수의 영향력을 해석할 수 있다는 장점이 있는데 의사결정나무에서는 선형 또는 주효과 모형에서와 같은 결과를 얻을 수 없다는 한계점이 있음 

- 의사결정나무

- 의사결정나무의 단점

단점	설명
비안정성	• 훈련용 데이터에만 의존하는 의사결정나무는 새로운 자료의 예측에는 불안정하여 과대 적합이 발생할 가능성이 있음 • 분석용 자료의 크기가 너무 작은 경우나 너무 많은 가지를 가지는 의사결정나무를 얻는 경우 비안정적임

• 의사결정나무에서 과대 적합을 방지하는 방법은?

① 랜덤 포레스트

② 배깅

③ 가지치기

④ 부스팅


- 의사결정나무는 선형성, 정규성 또는 등분산성 등의 가정을 필요로 하지 않는 () 모형이다. 빈칸에 알맞은 용어는?

- 의사결정나무에서 더 이상 트리가 분리되지 않게 하기 위한 규칙을 무엇이라 하는가?

- 다음 중 의사결정나무의 분류 기준에 대한 설명으로 가장 적절하지 않은 것은?
 - ① 지니 지수의 값이 작을수록 이질적이며 순수도가 낮다고 할 수 있다.
 - ② 지니 지수는 이진 분류로 나눌 때 사용한다.
 - ③ 엔트로피 지수의 값이 클수록 순수도가 낮다고 볼 수 있다.
 - ④ 카이제곱 통계량의 p-값이 작을수록 자식노드 간의 이질성이 크다.

- 다음 중 목표변수가 연속형인 회귀 나무의 경우에 사용하는 분류 기준은?
 - ① 지니 지수, 엔트로피 지수
 - ② 카이제곱 통계량, 지니 지수
 - ③ 분산 감소량, F통계량의 p값
 - ④ 카이제곱 통계량, 분산 감소량

- 다음 의사결정나무에서 노드 C의 지니지수는 다음 중 얼마인가?



- ① 0.4 ② 0.6 ③ 0.48 ④ 0.38

• 앙상블 모형


- 앙상블의 개념

- 앙상블은 여러 가지 같은 종류 또는 서로 다른 모형들의 예측/분류 결과를 **종합**하여 최종적인 의사결정에 활용하는 기법
- 앙상블은 본래 프랑스어로 '**통일, 조화**'등을 나타내는 용어임

특징	설명
더 높은 신뢰성 확보	• 다양한 모형의 예측 결과를 결합 함으로써 단일 모형으로 분석했을 때 보다 높은 신뢰성이 있음
정확도 상승	• 이상값에 대한 대응력이 높아지고 전체 분산(산포)을 감소시킴 • 모형 간의 상호 연관성이 높을수록 정확도는 떨어짐
원인 분석에 부적합	• 단일 모형이 아니기에 모형의 투명성이 떨어지게 되어 정확한 현상의 원인 분석에는 부적합

- 앙상블 모형

- 앙상블 기법의 종류




- 앙상블 모형

- 앙상블 기법의 종류

- 배깅(Bagging; Bootstrap Aggregating)

- ✓ 배깅은 훈련 데이터에서 다수의 부트스트랩 자료를 생성하고 각 자료를 모델링한 후 결합하여 최종 예측 모형을 만드는 알고리즘
 - ✓ 부트스트랩은 주어진 자료에서 같은 크기의 표본을 랜덤 복원 추출로 뽑은 자료를 의미함



• 앙상블 모형

- 앙상블 기법의 종류

➤ 배깅(Bagging; Bootstrap Aggregating)

- ✓ 배깅은 훈련 데이터에서 다수의 부트스트랩 자료를 생성하고 각 자료를 모델링한 후 결합하여 최종 예측 모형을 만드는 알고리즘
- ✓ 부트스트랩은 주어진 자료에서 같은 크기의 표본을 랜덤 복원 추출로 뽑은 자료를 의미함


순서	절차	설명
1	부트스트랩 데이터 추출	분석 데이터로부터 n개의 부트스트랩 데이터 추출(동일 크기)
2	단일 분류기 생성	부트스트랩 데이터에 적합한 모델(예: 의사결정나무)을 적용하여 n개 단일 분류기 생성
3	최종 모델 결정	- n개의 단일 분류기 중 다수결 또는 평균을 통해 최종 모델 결정 - 범주형 변수: 다수결, 연속형 변수: 평균

• 앙상블 모형

- 앙상블 기법의 종류

➤ 부스팅(Boosting)

- ✓ 부스팅은 여러 개의 모형을 구축한다는 점에서 배깅과 유사하지만 배깅은 각 분류기(모델)가 독립적인 데 비해 부스팅은 독립적이지 않음
- ✓ 부스팅은 이전 모델을 구축한 뒤 다음 모델을 구축할 때 이전 분류기에 의해 잘못 분류된 데이터에 더 큰 가중치를 주어 붓스트랩을 구성함



• 앙상블 모형

- 앙상블 기법의 종류

➤ 부스팅(Boosting)

- ✓ 예측력이 **약한 모형들을 결합**하여 나감으로써 점차적으로 강한 분류기를 만들어 나가는 과정임
- ✓ 붓스트랩을 재구성하는 과정에서 잘못 분류된 데이터에 더 큰 가중치를 주어 표본을 추출하기 때문에 **훈련 오차를 빠르게 줄여** 예측 성능은 배깅보다 뛰어나다고 할 수 있음

순서	절차	설명
1	동일 가중치 분류기 생성	• 같은 가중치의 분석 데이터로부터 분류기 생성
2	가중치 변경을 통한 분류기 생성	• 이전 분석 데이터의 분류 결과에 따라 가중치 변경(오분류 데이터에 가중치 확대)을 통해 분류기 생성
3	최종 분류기 결정	• 목표하는 정확성이 나올 때까지 N회 반복 후 최종 분류기 결정

- 앙상블 모형

- 앙상블 기법의 종류

- 랜덤 포레스트(Random Forest)


- ✓ 랜덤 포레스트는 서로 상관성이 없는 나무들로 이루어진 숲을 의미하며 방법은 배깅과 유사하나 배깅에 더 많은 무작위성을 주는 분석기법임
 - ✓ 많은 무작위성으로 생성된 서로 다른 여러 개의 트리로 구성되어 있기 때문에 포레스트(Forest, 숲)라 명명되었으며 여러 개의 약한 트리들의 선형 결합으로 최종 결과를 얻는 모델임
 - ✓ 분류의 경우 다수결로 최종 결과를 구하며 회귀의 경우 평균 or 중앙값을 구하여 선택함

- 앙상블 모형

- 앙상블 기법의 종류

- 랜덤 포레스트(Random Forest)

- ✓ 랜덤 포레스트는 큰 분산을 가지고 있다는 의사결정나무의 단점을 보완하기 위해 붓스트랩 데이터에서 표본추출 과정을 거쳐 분산을 감소시키고 모든 분류기들이 높은 비상관성을 갖기 때문에 일반화의 성능을 향상시킬 수 있음



- 앙상블 모형

- 앙상블 기법의 종류

- 랜덤 포레스트(Random Forest)의 특징


- ✓ 분류기를 여러 개 쓸수록 성능이 좋아짐
 - ✓ 트리의 개수가 많을수록 **과대 적합** 문제를 피할 수 있음
 - ✓ 여러 개의 의사결정나무가 모여서 **랜덤 포레스트** 구조가 됨

• 앙상블 모형

- 앙상블 기법의 종류

➤ 스택킹

- ✓ 일반적 앙상블 기법은 각 분류기간의 결과를 활용하여 보팅(다수결)방식에 의해 최종결과를 선정하는 방식이지만 스택킹은 보팅(다수결)방식이 아닌 여러 분류기간의 결과를 다시 훈련용 데이터로 사용하여 최종모형을 구축함
- ✓ 여러 개의 분류기는 서로 다른 알고리즘으로 작성될 수 있으며 여러 기초모델에서 예측된 결과로부터 구축된 최종모형을 **메타모델**이라 함



- 앙상블 모형

- 모형 평가

- 모형 평가는 **과대 적합**에 대해 신뢰할 만한 추정값을 구하기 위해 훈련용, 평가용 데이터를 나누어 이용함
 - 빅데이터 분석 모형을 검증하기 위한 대표적인 평가방법은 홀드 아웃 방법, K-Fold Cross Validation, LOOCV, LpOCV, 부트스트랩 등이 있음
 - ✓ 과대적합: 분석 모델을 만들 때 주어진 데이터 집합의 특성을 지나치게 반영하여 **발생하는 오류**

- 앙상블 모형

- 모형 평가

- 홀드아웃 방법

- ✓ 홀드아웃 방법은 전체 데이터를 **비복원 추출** 방법을 이용하여 랜덤하게 훈련용 데이터, 평가용 데이터로 나눠 검증하는 기법
 - ✓ 훈련용 데이터로 분석 모형을 구축하고, 평가용 데이터를 이용하여 분석 모형을 평가하는 기법
 - ✓ 계산량이 많지 않아 모형을 쉽게 평가할 수 있으나 전체 데이터에서 평가용 데이터만큼 학습에 사용할 수 없으므로 **데이터 손실**이 발생함

- 양상블 모형

- 모형 평가

- 홀드아웃 방법

- ✓ 데이터를 어떻게 나누느냐에 따라 결과가 많이 달라질 수 있음
 - ✓ 홀드아웃 방법은 데이터의 양이 충분한 경우 **훈련용 데이터**, **검증용 데이터**, **평가용 데이터**로 나누기도 함

데이터 구분	설명
훈련용 데이터	• 분석 모델을 만들기 위해 사용하는 데이터 세트
검증용 데이터	• 훈련용 데이터로 만든 모델이 잘 예측하는지 성능을 평가하기 위한 데이터 세트
평가용 데이터	• 검증용 데이터로 최종 모델을 선택하고 그 성능을 테스트하기 위해 사용되는 데이터 세트

• 앙상블 모형

- 모형 평가

➤ K-Fold Cross Validation

- ✓ K-Fold Cross Validation은 데이터 집합을 무작위로 동일 크기를 갖는 **K개의 부분 집합**으로 나누고, 그중 1개의 집합을 평가용 데이터로, 나머지 (K-1)개 집합을 훈련용 데이터로 선정하여 분석 모형을 평가하는 기법
- ✓ 모든 데이터를 훈련과 평가에 사용할 수 있으나 K값이 증가하면 **수행 시간과 계산량도 많아짐**
- ✓ K번 반복을 수행하며, 결과를 K번 성능에 대한 다수결 또는 평균으로 분석함

순서	절차	설명
1	동등 분할	• 전체 데이터를 K개 같은 크기의 부분 집합으로 랜덤하게 나눔
2	훈련용/평가용 데이터 구성	• (K-1)개 부분 집합들은 훈련용 데이터로, 나머지 1개 부분 집합은 평가용 데이터로 하는 K개의 실험 데이터를 구성
3	분류기 학습	• 각 실험 데이터마다 훈련용 데이터로 분류기를 학습시키고 평가용 데이터로 분류기의 성능을 평가
4	분류기 성능 확인	• 실험 결과 K개를 종합하여 해당 분류기의 최종 성능을 구함

정형 데이터 마이닝

- 앙상블 모형

- 모형 평가

- K-Fold Cross Validation($k=4$)



- 앙상블 모형

- 모형 평가

- LOOCV(Leave-One-Out Cross Validation)

- ✓ LOOCV는 전체 데이터 N 개 중에서 1개의 샘플만을 평가용 데이터에 사용하고 나머지 $(N-1)$ 개는 훈련용 데이터로 사용하는 과정을 N 번 반복하는 교차 검증 기법임
 - ✓ K-Fold와 같은 방법을 사용하며 이때 K 는 전체 데이터 N 과 같음($K=N$)
 - ✓ 가능한 한 많은 데이터를 훈련에 사용할 수 있지만 수행 시간과 계산량이 많음
 - ✓ 작은 크기의 데이터에 사용하기 좋음

- 앙상블 모형

- 모형 평가

- LpOCV(Leave-p-Out Cross Validation)

- ✓ LpOCV는 LOOCV에서 1개의 샘플이 아닌 **p개의 샘플**을 평가에 사용하는 교차 검증 기법임

- ✓ $nCp = \left(\frac{n!}{(n-p)!p!}\right)$ 만큼 교차 검증이 반복되므로 계산 시간에 대한 부담이 매우 큼

- ✓ 예) n (표본의 개수) = 100, p (평가용 데이터) = 4, 교차검증횟수 = $100C4 = \frac{100!}{(100-4)!4!} = 3,921,225$)

- 앙상블 모형

- 모형 평가

- 부트스트랩

- ✓ 부트스트랩은 주어진 자료에서 단순 랜덤 복원 추출 방법을 활용하여 같은 크기의 표본을 여러 개 생성하는 샘플링 방법임
 - ✓ 무작위 복원 추출 방법으로 전체 데이터에서 중복을 허용하여 표본 크기만큼 샘플을 추출하고 이를 훈련용 데이터로 하는 방법으로 전체 데이터 샘플이 N 개이고 부트스트랩으로 n 개의 샘플을 추출하는 경우 특정 샘플이 훈련용 데이터에 포함될 확률은 약 63.2%임
 - ✓ 부트스트랩을 통해 1,000번의 샘플을 추출하더라도 샘플에 한 번도 선택되지 않는 원 데이터가 발생할 수 있는데 전체 샘플의 약 36.8%가 이에 해당함
 - ✓ 한 번도 포함되지 않은 OOB(Out-Of-Bag)데이터는 검증에 사용함

- 앙상블 모형

- 모형 평가

- 분류 모형의 평가지표

- ✓ 분류 모형의 결과를 평가하기 위해 혼동 행렬(Confusion Matrix)을 이용한 평가지표와 ROC 곡선의 AUC를 많이 사용함
 - ✓ 혼동행렬은 분석 모델에서 구한 분류의 예측 범주와 데이터의 실제 분류 범주를 교차 표 형태로 정리한 행렬임

		예측 범주 값	
		Predicted Positive	Predicted Negative
실제 범주 값	Actual Positive	True Positive(TP)	False Negative(FN)
	Actual Negative	False Positive(FP)	True Negative(TN)

• 앙상블 모형

- 모형 평가

➤ 분류 모형의 평가지표

- ✓ 혼동 행렬을 통한 분류 모형의 평가지표는 여러가지가 있으며 그 중 **정확도**, **민감도**, **정밀도**는 많이 사용되는 지표

평가지표	계산식	설명
정확도	$\frac{TP + TN}{TP + TN + FP + FN}$	- 실제 분류 범주를 정확하게 예측한 비율 - 전체 예측에서 참 긍정(TP)과 참 부정(TN)이 차지하는 비율
오차 비율	$\frac{FP + FN}{TP + TN + FP + FN}$	실제 분류 범주를 잘못 분류한 비율
재현율 or 민감도	$\frac{TP}{TP + FN}$	- 실제로 긍정적인 범주 중에서 긍정으로 올바르게 예측한 비율 - Hit Rate으로도 지칭함(참 긍정률이라고도 불림)
특이도	$\frac{TN}{TN + FP}$	실제로 부정인 범주 중에서 부정으로 올바르게 예측한 비율
거짓 긍정률	$\frac{FP}{TN + FP}$	실제로 부정인 범주 중에서 긍정으로 잘못 예측한 비율

• 앙상블 모형

- 모형 평가

➤ 분류 모형의 평가지표

- ✓ 혼동 행렬을 통한 분류 모형의 평가지표가 여러가지가 있으며 그중 정확도, 민감도, 정밀도는 많이 사용되는 지표


평가지표	계산식	설명
정밀도	$\frac{TP}{TP + FP}$	• 긍정으로 예측한 비율 중에 실제로 긍정인 비율
F1 지표	$2 \times \frac{\text{정밀도} \times \text{재현율}}{\text{정밀도} + \text{재현율}}$	• 정밀도와 민감도(재현율)을 하나로 합한 성능평가 지표 • 0~1의 범위를 가짐 • 정밀도와 민감도 양쪽이 모두 클 때 큰 값을 가짐
카파 통계량	$K = \frac{\text{Pr}(a) - \text{Pr}(e)}{1 - \text{Pr}(e)}$	• 두 관찰자가 측정한 범주 값에 대한 일치도를 측정하는 방법 • 0~1의 값을 가지며 1에 가까울수록 모델의 예측값과 실제값이 정확히 일치하며 0에 가까울수록 모델의 예측값과 실제값이 불일치 • K: 카파계수, Pr(a): 예측이 일치할 확률, Pr(e): 예측이 우연히 일치할 확률

- 앙상블 모형

- 모형 평가

- ROC 곡선

- ✓ ROC 곡선은 가로축을 혼동 행렬의 거짓 긍정률(FP Rate)로 두고 세로축을 참 긍정률(TP Rate)(재현율)로 두어 이진 분류(0 또는 1) 모형의 성능을 평가하기 위해 사용됨
 - ✓ ROC 곡선은 그래프가 **왼쪽 꼭대기에 가깝게 그려질수록** 분류 성능이 우수함



- 앙상블 모형

- 모형 평가

- ROC 곡선

- ✓ ROC 곡선에서 거짓 긍정률(FP Rate)과 참 긍정률(TP Rate)은 어느 정도 비례 관계에 있음
 - ✓ AUC(Area Under the ROC Curve)는 진단의 정확도를 측정할 때 사용하는 것으로 ROC곡선 아래의 면적을 모형의 평가지표로 삼음
 - ✓ AUC의 값은 항상 0.5~1의 값을 가지며 1에 가까울수록 좋은 모형임

AUC	판단 기준 설명
0.9~1.0	뛰어남
0.8~0.9	우수
0.7~0.8	보통
0.6~0.7	불량
0.5~0.6	실패

- 양상블 모형

- 모형 평가

- 이익 도표(Gain Chart)

- ✓ 분류 모형의 성능을 평가하기 위해 사용되는 도표 형태의 그림
 - ✓ 이익은 목표 범주에 속하는 개체들이 임의로 나눈 등급별로 얼마나 분포하고 있는지를 나타내는 값
 - ✓ 해당 등급에 따라 계산된 이익 값을 누적으로 연결한 도표가 이익 도표임

- 양상블 모형

- 모형 평가

- 이익 도표(Gain Chart)


- ✓ 예시) 새로운 카드 상품을 홍보하기 위해 전체 고객(1,000명) 중 메시지를 보낼 고객(200명)을 선정해야 함
 - ✓ 가입할 고객에게 메시지를 보내면 3,000원 이익, 가입하지 않을 고객에게 메시지를 보내면 1,000원 손해라 가정
 - ✓ 목표는 '신규 카드에 실제로 가입할 확률이 높은 고객을 고르는 것'으로 예측 모델을 통해 각 고객의 '가입확률'을 구해 가입 가능성이 높은 순서대로 내림차순 정렬을 수행함
 - ✓ 위에서부터 10%, 20%, ... 구간을 선택하여 각 구간마다 메시지를 보냈을 때 총이익을 계산함
 - ✓ 이익이 가장 높은 구간이 최적의 데이터 구간이 될 수 있음

- 앙상블 모형

- 모형 평가

- 이익 도표(Gain Chart)와 향상도 곡선(Lift Curve)

- ✓ 향상도 곡선은 랜덤 모델과 비교했을 때 해당 모델의 성과가 얼마나 향상되었는지를 구간별로 파악하는 그래프
 - ✓ 좋은 모델일수록 큰 값에서 시작하여 급격히 감소함(상위 20% 데이터가 2배 좋은 예측력을 가지고 있음)



- 다음 혼동 행렬에서 오차 비율을 구하면?

실제값 \ 예측치	참	거짓
	참	거짓
참	60	25
거짓	5	10

- ① 0.2
- ② 0.3
- ③ 0.4
- ④ 0.5

- 다음 중 앙상블 모형의 부스팅에 대한 설명으로 가장 옳은 것은?

- ① 의사결정나무의 단점으로 훈련 데이터에 과대 적합 되는 경향을 보완하였다.
- ② 분류가 잘못된 분류기에 더 큰 가중치를 부여하여 표본을 추출하는 방법을 사용하여 표본을 추출한다.
- ③ 원 데이터 집합으로부터 크기가 같은 표본을 여러 번 단순임의 복원추출하여 각 표본에 대한 분류기를 생성한 후 그 결과를 앙상블한다.
- ④ 반복 추출 방법을 사용하기 때문에 같은 데이터가 한 표본에 여러 번 추출 될 수도 있고 어떤 데이터는 추출되지 않을 수도 있다.

- 다음 중 ROC Curve에 대한 설명으로 가장 옳바르지 않은 것은?
 - ① ROC Curve의 가장 이상적으로 완벽한 분류 모형은 x축은 0, y축은 1일때이다.
 - ② ROC Curve의 면적이 0.5 이하이면 거의 랜덤에 가까운 성능이라고 할 수 있다.
 - ③ ROC Curve의 밑부분 면적이 높을수록 좋은 모형으로 평가한다.
 - ④ ROC Curve의 x축은 특이도, y축은 민감도로 나타낸다.

- 구축된 모형의 과대 적합 또는 과소 적합 등에 대한 미세 조정 절차를 위해 사용하는 데이터는?

- 앙상블 모형은 여러 개의 분류 모형에 의한 결과를 종합하여 분류의 정확도를 높이는 방법이다. 원 데이터 집합으로부터 크기가 같은 표본을 여러 번 단순 임의 복원 추출하여 각 표본에 대한 분류기를 생성한 후 그 결과를 앙상블하는 방법을 무엇이라고 하는가?

- 다음 중 앙상블 모형의 특징으로 가장 부적합한 것은?

- ① 이상값에 대한 대응력이 높다.
- ② 다양한 모형 간의 상호 연관성이 높을수록 정확도가 향상된다.
- ③ 전체적인 예측값의 분산을 감소시켜 정확도를 높일 수 있다.
- ④ 정확한 현상의 원인 분석에 적합하지 않다.

- 여러 개의 분류 모형에 의한 결과를 종합하여 분류의 정확도를 향상시키는 방법은?

- 혼동 행렬에서 실제/예측 True의 합과 실제/예측 False의 합이 100으로 동일하다고 한다. 재현율이 0.8이라고 할 때 정밀도는 얼마인가?

- 다음 중 부트스트랩 표본을 구성하는 재표본 과정에서 분류가 잘못된 데이터에 더 큰 가중치를 주어 표본을 추출하는 앙상블 모형은 무엇인가?

- ① 랜덤 포레스트
- ② 배깅
- ③ 부스팅
- ④ 홀드 아웃

- 다음 혼동 행렬에서 특이도를 계산한 식은?

실제값 \ 예측치	참	거짓	합계
참	TP	FN	N1
거짓	FP	TN	N2
합계	S1	S2	N3

- ① $TN/N2$ ② $TP/N1$ ③ $TP/S1$ ④ $TN/S2$

• 모형 평가에서 K-Fold Cross Validation의 설명으로 가장 옳바르지 않은 것은?

- ① 데이터 집합을 무작위로 동일 크기를 갖는 k개의 부분 집합으로 나눈다.
- ② k 값이 증가하면 수행 시간과 계산량도 많아진다.
- ③ k번 반복 수행하며 결과를 K에 다수결 또는 평균으로 분석한다.
- ④ k=2일 경우 LOOCV 교차 검증 기법과 같다.

- 분류 분석 모형의 성과 평가 방법 중 랜덤모델과 비교하여 해당 모델의 성과가 얼마나 향상되었는지를 등급별로 파악하는 그래프는?