

• 앙상블 모형


- 앙상블의 개념

- 앙상블은 여러 가지 같은 종류 또는 서로 다른 모형들의 예측/분류 결과를 **종합**하여 최종적인 의사결정에 활용하는 기법
- 앙상블은 본래 프랑스어로 '**통일, 조화**'등을 나타내는 용어임

특징	설명
더 높은 신뢰성 확보	• 다양한 모형의 예측 결과를 결합 함으로써 단일 모형으로 분석했을 때 보다 높은 신뢰성이 있음
정확도 상승	• 이상값에 대한 대응력이 높아지고 전체 분산(산포)을 감소시킴 • 모형 간의 상호 연관성이 높을수록 정확도는 떨어짐
원인 분석에 부적합	• 단일 모형이 아니기에 모형의 투명성이 떨어지게 되어 정확한 현상의 원인 분석에는 부적합

- 앙상블 모형

- 앙상블 기법의 종류




• 앙상블 모형

- 앙상블 기법의 종류

➤ 배깅(Bagging; Bootstrap Aggregating)

- ✓ 배깅은 훈련 데이터에서 다수의 부트스트랩 자료를 생성하고 각 자료를 모델링한 후 결합하여 최종 예측 모형을 만드는 알고리즘
- ✓ 부트스트랩은 주어진 자료에서 같은 크기의 표본을 랜덤 복원 추출로 뽑은 자료를 의미함



• 앙상블 모형

- 앙상블 기법의 종류

➤ 배깅(Bagging; Bootstrap Aggregating)

- ✓ 배깅은 훈련 데이터에서 다수의 부트스트랩 자료를 생성하고 각 자료를 모델링한 후 결합하여 최종 예측 모형을 만드는 알고리즘
- ✓ 부트스트랩은 주어진 자료에서 같은 크기의 표본을 랜덤 복원 추출로 뽑은 자료를 의미함


순서	절차	설명
1	부트스트랩 데이터 추출	분석 데이터로부터 n개의 부트스트랩 데이터 추출(동일 크기)
2	단일 분류기 생성	부트스트랩 데이터에 적합한 모델(예: 의사결정나무)을 적용하여 n개 단일 분류기 생성
3	최종 모델 결정	- n개의 단일 분류기 중 다수결 또는 평균을 통해 최종 모델 결정 - 범주형 변수: 다수결, 연속형 변수: 평균

• 앙상블 모형

- 앙상블 기법의 종류

➤ 부스팅(Boosting)

- ✓ 부스팅은 여러 개의 모형을 구축한다는 점에서 배깅과 유사하지만 배깅은 각 분류기(모델)가 독립적인 데 비해 부스팅은 독립적이지 않음
- ✓ 부스팅은 이전 모델을 구축한 뒤 다음 모델을 구축할 때 이전 분류기에 의해 잘못 분류된 데이터에 더 큰 가중치를 주어 붓스트랩을 구성함



• 앙상블 모형

- 앙상블 기법의 종류

➤ 부스팅(Boosting)

- ✓ 예측력이 **약한 모형들을 결합**하여 나감으로써 점차적으로 강한 분류기를 만들어 나가는 과정임
- ✓ 붓스트랩을 재구성하는 과정에서 잘못 분류된 데이터에 더 큰 가중치를 주어 표본을 추출하기 때문에 **훈련 오차를 빠르게 줄여** 예측 성능은 배깅보다 뛰어나다고 할 수 있음

순서	절차	설명
1	동일 가중치 분류기 생성	• 같은 가중치의 분석 데이터로부터 분류기 생성
2	가중치 변경을 통한 분류기 생성	• 이전 분석 데이터의 분류 결과에 따라 가중치 변경(오분류 데이터에 가중치 확대)을 통해 분류기 생성
3	최종 분류기 결정	• 목표하는 정확성이 나올 때까지 N회 반복 후 최종 분류기 결정

- 앙상블 모형

- 앙상블 기법의 종류

- 랜덤 포레스트(Random Forest)


- ✓ 랜덤 포레스트는 서로 상관성이 없는 나무들로 이루어진 숲을 의미하며 방법은 배깅과 유사하나 배깅에 더 많은 무작위성을 주는 분석기법임
 - ✓ 많은 무작위성으로 생성된 서로 다른 여러 개의 트리로 구성되어 있기 때문에 포레스트(Forest, 숲)라 명명되었으며 여러 개의 약한 트리들의 선형 결합으로 최종 결과를 얻는 모델임
 - ✓ 분류의 경우 다수결로 최종 결과를 구하며 회귀의 경우 평균 or 중앙값을 구하여 선택함

- 앙상블 모형

- 앙상블 기법의 종류

- 랜덤 포레스트(Random Forest)

- ✓ 랜덤 포레스트는 큰 분산을 가지고 있다는 의사결정나무의 단점을 보완하기 위해 붓스트랩 데이터에서 표본추출 과정을 거쳐 분산을 감소시키고 모든 분류기들이 높은 비상관성을 갖기 때문에 일반화의 성능을 향상시킬 수 있음




- 앙상블 모형

- 앙상블 기법의 종류

- 랜덤 포레스트(Random Forest)의 특징

- ✓ 분류기를 여러 개 쓸수록 성능이 좋아짐
 - ✓ 트리의 개수가 많을수록 **과대 적합** 문제를 피할 수 있음
 - ✓ 여러 개의 의사결정나무가 모여서 **랜덤 포레스트** 구조가 됨



- 앙상블 모형

- 모형 평가

- 모형 평가는 **과대 적합**에 대해 신뢰할 만한 추정값을 구하기 위해 훈련용, 평가용 데이터를 나누어 이용함
 - 빅데이터 분석 모형을 검증하기 위한 대표적인 평가방법은 홀드 아웃 방법, K-Fold Cross Validation, LOOCV, LpOCV, 부트스트랩 등이 있음
 - ✓ 과대적합: 분석 모델을 만들 때 주어진 데이터 집합의 특성을 지나치게 반영하여 **발생하는 오류**

- 앙상블 모형

- 모형 평가

- 홀드아웃 방법

- ✓ 홀드아웃 방법은 전체 데이터를 **비복원 추출** 방법을 이용하여 랜덤하게 훈련용 데이터, 평가용 데이터로 나눠 검증하는 기법
 - ✓ 훈련용 데이터로 분석 모형을 구축하고, 평가용 데이터를 이용하여 분석 모형을 평가하는 기법
 - ✓ 계산량이 많지 않아 모형을 쉽게 평가할 수 있으나 전체 데이터에서 평가용 데이터만큼 학습에 사용할 수 없으므로 **데이터 손실**이 발생함

- 양상블 모형

- 모형 평가

- 홀드아웃 방법

- ✓ 데이터를 어떻게 나누느냐에 따라 결과가 많이 달라질 수 있음
 - ✓ 홀드아웃 방법은 데이터의 양이 충분한 경우 **훈련용 데이터**, **검증용 데이터**, **평가용 데이터**로 나누기도 함

데이터 구분	설명
훈련용 데이터	• 분석 모델을 만들기 위해 사용하는 데이터 세트
검증용 데이터	• 훈련용 데이터로 만든 모델이 잘 예측하는지 성능을 평가하기 위한 데이터 세트
평가용 데이터	• 검증용 데이터로 최종 모델을 선택하고 그 성능을 테스트하기 위해 사용되는 데이터 세트

• 앙상블 모형

- 모형 평가

➤ K-Fold Cross Validation

- ✓ K-Fold Cross Validation은 데이터 집합을 무작위로 동일 크기를 갖는 **K개의 부분 집합**으로 나누고, 그중 1개의 집합을 평가용 데이터로, 나머지 (K-1)개 집합을 훈련용 데이터로 선정하여 분석 모형을 평가하는 기법
- ✓ 모든 데이터를 훈련과 평가에 사용할 수 있으나 K값이 증가하면 **수행 시간과 계산량도 많아짐**
- ✓ K번 반복을 수행하며, 결과를 K번 성능에 대한 다수결 또는 평균으로 분석함

순서	절차	설명
1	동등 분할	• 전체 데이터를 K개 같은 크기의 부분 집합으로 랜덤하게 나눔
2	훈련용/평가용 데이터 구성	• (K-1)개 부분 집합들은 훈련용 데이터로, 나머지 1개 부분 집합은 평가용 데이터로 하는 K개의 실험 데이터를 구성
3	분류기 학습	• 각 실험 데이터마다 훈련용 데이터로 분류기를 학습시키고 평가용 데이터로 분류기의 성능을 평가
4	분류기 성능 확인	• 실험 결과 K개를 종합하여 해당 분류기의 최종 성능을 구함

정형 데이터 마이닝

- 앙상블 모형

- 모형 평가

- K-Fold Cross Validation($k=4$)



- 앙상블 모형

- 모형 평가

- LOOCV(Leave-One-Out Cross Validation)

- ✓ LOOCV는 전체 데이터 N 개 중에서 1개의 샘플만을 평가용 데이터에 사용하고 나머지 $(N-1)$ 개는 훈련용 데이터로 사용하는 과정을 N 번 반복하는 교차 검증 기법임
 - ✓ K-Fold와 같은 방법을 사용하며 이때 K 는 전체 데이터 N 과 같음($K=N$)
 - ✓ 가능한 한 많은 데이터를 훈련에 사용할 수 있지만 수행 시간과 계산량이 많음
 - ✓ 작은 크기의 데이터에 사용하기 좋음

- 앙상블 모형

- 모형 평가

- LpOCV(Leave-p-Out Cross Validation)

- ✓ LpOCV는 LOOCV에서 1개의 샘플이 아닌 **p개의 샘플**을 평가에 사용하는 교차 검증 기법임

- ✓ $nCp = \left(\frac{n!}{(n-p)!p!}\right)$ 만큼 교차 검증이 반복되므로 계산 시간에 대한 부담이 매우 큼

- ✓ 예) n (표본의 개수) = 100, p (평가용 데이터) = 4, 교차검증횟수 = $100C4 = \frac{100!}{(100-4)!4!} = 3,921,225$)

- 앙상블 모형

- 모형 평가

- 부트스트랩

- ✓ 부트스트랩은 주어진 자료에서 단순 랜덤 복원 추출 방법을 활용하여 같은 크기의 표본을 여러 개 생성하는 샘플링 방법임
 - ✓ 무작위 복원 추출 방법으로 전체 데이터에서 중복을 허용하여 표본 크기만큼 샘플을 추출하고 이를 훈련용 데이터로 하는 방법으로 전체 데이터 샘플이 N 개이고 부트스트랩으로 n 개의 샘플을 추출하는 경우 특정 샘플이 훈련용 데이터에 포함될 확률은 약 63.2%임
 - ✓ 부트스트랩을 통해 1,000번의 샘플을 추출하더라도 샘플에 한 번도 선택되지 않는 원 데이터가 발생할 수 있는데 전체 샘플의 약 36.8%가 이에 해당함
 - ✓ 한 번도 포함되지 않은 OOB(Out-Of-Bag)데이터는 검증에 사용함

- 앙상블 모형

- 모형 평가

- 분류 모형의 평가지표

- ✓ 분류 모형의 결과를 평가하기 위해 혼동 행렬(Confusion Matrix)을 이용한 평가지표와 ROC 곡선의 AUC를 많이 사용함
 - ✓ 혼동행렬은 분석 모델에서 구한 분류의 예측 범주와 데이터의 실제 분류 범주를 교차 표 형태로 정리한 행렬임

		예측 범주 값	
		Predicted Positive	Predicted Negative
실제 범주 값	Actual Positive	True Positive(TP)	False Negative(FN)
	Actual Negative	False Positive(FP)	True Negative(TN)

• 앙상블 모형

- 모형 평가

➤ 분류 모형의 평가지표

- ✓ 혼동 행렬을 통한 분류 모형의 평가지표는 여러가지가 있으며 그 중 **정확도**, **민감도**, **정밀도**는 많이 사용되는 지표

평가지표	계산식	설명
정확도	$\frac{TP + TN}{TP + TN + FP + FN}$	- 실제 분류 범주를 정확하게 예측한 비율 - 전체 예측에서 참 긍정(TP)과 참 부정(TN)이 차지하는 비율
오차 비율	$\frac{FP + FN}{TP + TN + FP + FN}$	실제 분류 범주를 잘못 분류한 비율
재현율 or 민감도	$\frac{TP}{TP + FN}$	- 실제로 긍정인 범주 중에서 긍정으로 올바르게 예측한 비율 - Hit Rate으로도 지칭함(참 긍정률이라고도 불림)
특이도	$\frac{TN}{TN + FP}$	실제로 부정인 범주 중에서 부정으로 올바르게 예측한 비율
거짓 긍정률	$\frac{FP}{TN + FP}$	실제로 부정인 범주 중에서 긍정으로 잘못 예측한 비율

• 앙상블 모형

- 모형 평가

➤ 분류 모형의 평가지표

- ✓ 혼동 행렬을 통한 분류 모형의 평가지표가 여러가지가 있으며 그중 정확도, 민감도, 정밀도는 많이 사용되는 지표


평가지표	계산식	설명
정밀도	$\frac{TP}{TP + FP}$	• 긍정으로 예측한 비율 중에 실제로 긍정인 비율
F1 지표	$2 \times \frac{\text{정밀도} \times \text{재현율}}{\text{정밀도} + \text{재현율}}$	• 정밀도와 민감도(재현율)을 하나로 합한 성능평가 지표 • 0~1의 범위를 가짐 • 정밀도와 민감도 양쪽이 모두 클 때 큰 값을 가짐
카파 통계량	$K = \frac{\text{Pr}(a) - \text{Pr}(e)}{1 - \text{Pr}(e)}$	• 두 관찰자가 측정한 범주 값에 대한 일치도를 측정하는 방법 • 0~1의 값을 가지며 1에 가까울수록 모델의 예측값과 실제값이 정확히 일치하며 0에 가까울수록 모델의 예측값과 실제값이 불일치 • K: 카파계수, Pr(a): 예측이 일치할 확률, Pr(e): 예측이 우연히 일치할 확률

- 앙상블 모형

- 모형 평가

- ROC 곡선

- ✓ ROC 곡선은 가로축을 혼동 행렬의 거짓 긍정률(FP Rate)로 두고 세로축을 참 긍정률(TP Rate)(재현율)로 두어 이진 분류(0 또는 1) 모형의 성능을 평가하기 위해 사용됨
 - ✓ ROC 곡선은 그래프가 **왼쪽 꼭대기에 가깝게 그려질수록** 분류 성능이 우수함



- 앙상블 모형

- 모형 평가

- ROC 곡선

- ✓ ROC 곡선에서 거짓 긍정률(FP Rate)과 참 긍정률(TP Rate)은 어느 정도 비례 관계에 있음
 - ✓ AUC(Area Under the ROC Curve)는 진단의 정확도를 측정할 때 사용하는 것으로 ROC곡선 아래의 면적을 모형의 평가지표로 삼음
 - ✓ AUC의 값은 항상 0.5~1의 값을 가지며 1에 가까울수록 좋은 모형임

AUC	판단 기준 설명
0.9~1.0	뛰어남
0.8~0.9	우수
0.7~0.8	보통
0.6~0.7	불량
0.5~0.6	실패

- 양상블 모형

- 모형 평가

- 이익 도표(Gain Chart)

- ✓ 분류 모형의 성능을 평가하기 위해 사용되는 도표 형태의 그림
 - ✓ 이익은 목표 범주에 속하는 개체들이 임의로 나눈 등급별로 얼마나 분포하고 있는지를 나타내는 값
 - ✓ 해당 등급에 따라 계산된 이익 값을 누적으로 연결한 도표가 이익 도표임

- 양상블 모형

- 모형 평가

- 이익 도표(Gain Chart)


- ✓ 예시) 새로운 카드 상품을 홍보하기 위해 전체 고객(1,000명) 중 메시지를 보낼 고객(200명)을 선정해야 함
 - ✓ 가입할 고객에게 메시지를 보내면 3,000원 이익, 가입하지 않을 고객에게 메시지를 보내면 1,000원 손해라 가정
 - ✓ 목표는 '신규 카드에 실제로 가입할 확률이 높은 고객을 고르는 것'으로 예측 모델을 통해 각 고객의 '가입확률'을 구해 가입 가능성이 높은 순서대로 내림차순 정렬을 수행함
 - ✓ 위에서부터 10%, 20%, ... 구간을 선택하여 각 구간마다 메시지를 보냈을 때 총이익을 계산함
 - ✓ 이익이 가장 높은 구간이 최적의 데이터 구간이 될 수 있음

- 앙상블 모형

- 모형 평가

- 이익 도표(Gain Chart)와 향상도 곡선(Lift Curve)

- ✓ 향상도 곡선은 랜덤 모형과 비교했을 때 해당 모형의 성과가 얼마나 향상되었는지를 구간별로 파악하는 그래프
 - ✓ 좋은 모델일수록 큰 값에서 시작하여 급격히 감소함(상위 20% 데이터가 2배 좋은 예측력을 가지고 있음)



- 다음 혼동 행렬에서 오차 비율을 구하면?

실제값 \ 예측치	참	거짓
	참	거짓
참	60	25
거짓	5	10

- ① 0.2
- ② 0.3
- ③ 0.4
- ④ 0.5

- 다음 중 앙상블 모형의 부스팅에 대한 설명으로 가장 옳은 것은?

- ① 의사결정나무의 단점으로 훈련 데이터에 과대 적합 되는 경향을 보완하였다.
- ② 분류가 잘못된 분류기에 더 큰 가중치를 부여하여 표본을 추출하는 방법을 사용하여 표본을 추출한다.
- ③ 원 데이터 집합으로부터 크기가 같은 표본을 여러 번 단순임의 복원추출하여 각 표본에 대한 분류기를 생성한 후 그 결과를 앙상블한다.
- ④ 반복 추출 방법을 사용하기 때문에 같은 데이터가 한 표본에 여러 번 추출 될 수도 있고 어떤 데이터는 추출되지 않을 수도 있다.

- 다음 중 ROC Curve에 대한 설명으로 가장 옳바르지 않은 것은?
 - ① ROC Curve의 가장 이상적으로 완벽한 분류 모형은 x축은 0, y축은 1일때이다.
 - ② ROC Curve의 면적이 0.5 이하이면 거의 랜덤에 가까운 성능이라고 할 수 있다.
 - ③ ROC Curve의 밑부분 면적이 높을수록 좋은 모형으로 평가한다.
 - ④ ROC Curve의 x축은 특이도, y축은 민감도로 나타낸다.

- 구축된 모형의 과대 적합 또는 과소 적합 등에 대한 미세 조정 절차를 위해 사용하는 데이터는?

- 앙상블 모형은 여러 개의 분류 모형에 의한 결과를 종합하여 분류의 정확도를 높이는 방법이다. 원 데이터 집합으로부터 크기가 같은 표본을 여러 번 단순 임의 복원 추출하여 각 표본에 대한 분류기를 생성한 후 그 결과를 앙상블하는 방법을 무엇이라고 하는가?

- 다음 중 앙상블 모형의 특징으로 가장 부적합한 것은?

- ① 이상값에 대한 대응력이 높다.
- ② 다양한 모형 간의 상호 연관성이 높을수록 정확도가 향상된다.
- ③ 전체적인 예측값의 분산을 감소시켜 정확도를 높일 수 있다.
- ④ 정확한 현상의 원인 분석에 적합하지 않다.

- 여러 개의 분류 모형에 의한 결과를 종합하여 분류의 정확도를 향상시키는 방법은?

- 혼동 행렬에서 실제/예측 True의 합과 실제/예측 False의 합이 100으로 동일하다고 한다. 재현율이 0.8이라고 할 때 정밀도는 얼마인가?

- 다음 중 부트스트랩 표본을 구성하는 재표본 과정에서 분류가 잘못된 데이터에 더 큰 가중치를 주어 표본을 추출하는 앙상블 모형은 무엇인가?

- ① 랜덤 포레스트
- ② 배깅
- ③ 부스팅
- ④ 홀드 아웃

- 다음 혼동 행렬에서 특이도를 계산한 식은?

실제값 \ 예측치	참	거짓	합계
참	TP	FN	N1
거짓	FP	TN	N2
합계	S1	S2	N3

- ① $TN/N2$ ② $TP/N1$ ③ $TP/S1$ ④ $TN/S2$

• 모형 평가에서 K-Fold Cross Validation의 설명으로 가장 옳바르지 않은 것은?

- ① 데이터 집합을 무작위로 동일 크기를 갖는 k개의 부분 집합으로 나눈다.
- ② k 값이 증가하면 수행 시간과 계산량도 많아진다.
- ③ k번 반복 수행하며 결과를 K에 다수결 또는 평균으로 분석한다.
- ④ k=2일 경우 LOOCV 교차 검증 기법과 같다.

- 분류 분석 모형의 성과 평가 방법 중 랜덤모델과 비교하여 해당 모델의 성과가 얼마나 향상되었는지를 등급별로 파악하는 그래프는?


모듈 8-3

군집 분석

- 군집 분석

- 군집 분석의 개념

- 군집분석은 관측된 여러 개의 변수값으로부터 유사성에만 기초하여 n개의 군집으로 **집단화**하여 집단의 특성을 분석하여 다변량 분석(상관분석, 회귀분석 등)을 활용하여 군집에 대한 특징을 파악함
 - 군집 분석의 목적은 레이블이 없는 데이터 세트의 요약 정보를 추출하고, 요약 정보를 통해 전체 데이터 세트가 가지고 있는 **특징**을 발견하는 것임



- 군집 분석

- 군집 분석의 가정

- 군집 내에 속한 개체들의 특성은 **동질적**이고 서로 다른 군집에 속한 개체 간의 특성은 **이질적**임
 - 군집 분석은 이질적인 모집단을 **세분화시키는 방법**임
 - 군집 내의 응집도는 최대화하고 군집 간의 분리도는 최대화함
 - 군집의 개수 또는 구조와 관계없이 **개체 간 거리**를 기준으로 분류함
 - 개별 군집의 특성은 군집에 속한 개체들의 **평균값**으로 나타냄

- 군집 분석

- 군집 분석의 특징

- 군집분석은 데이터에 분류의 기준이 없는 비지도 학습 방법을 사용함
 - 군집분석은 신뢰성과 타당성을 점검하기 어려움
 - 군집을 만든 결과가 얼마나 유용한지 따지는 군집 타당성 지표에는 군집 간 거리, 군집의 지름, 군집 간 분산과 군집 내 분산 등이 있음
 - 군집 분석의 품질을 정량적으로 평가하는 군집의 타당성 지표는 Dunn Index와 실루엣 지수가 있음

• 군집 분석

- 군집 분석의 특징

➤ 군집 분석의 품질을 정량적으로 평가하는 군집의 타당성 지표는 **Dunn Index**와 **실루엣 지수**가 있음

군집 타당성 지표	설명
Dunn Index	• (군집과 군집 사이 거리 중 최소값)/(군집 내 데이터들 거리 중 최대값) • 분자가 클수록 군집간 거리가 멀고 분모 값이 작을수록 군집 내 데이터가 모여 있으므로 좋은 군집화라고 할 수 있음(모든 군집을 고려함)
실루엣 지수 (계수)	• 군집 내의 거리와 군집 간의 거리를 기준으로 한 클러스터 안의 데이터들이 다른 클러스터와 비교해서 얼마나 비슷한가를 나타내어 군집 분할의 성과를 나타내는 군집 모형의 평가 기준 • 군집 내의 데이터 응집도와 군집 간 분리도를 계산하여 군집 내의 데이터의 거리가 짧을수록 군집 간 거리가 멀수록 값이 커지는 지표(인접한 군만을 고려) • 완벽한 분리일 경우 1의 값을 가지며 군집화가 잘 되었다고 판단함

- 군집 분석

- 군집 분석의 유형

- 군집 분석의 유형에는 계층 기반, 비 계층 기반 군집 분석으로 나눌 수 있음
 - 계층 기반 군집 분석에는 군집 간 연결법(최단, 최장, 평균, 중심, 와드 연결법)이 있으며 비 계층 기반 군집 분석에 분할, 분포, 밀도, 그래프 기반 등의 분석기법이 있음
 - 비계층 기반 군집 분석의 상세 기법에는 k-평균 군집, 혼합 분포 군집(가우시안 혼합 모델, EM 알고리즘), DBSCAN, SOM 등이 있음

- 군집 분석

- 군집 분석의 유형

➤ 계층적 군집 분석과 비 계층적 군집 분석의 특징은 다음과 같음

계층적 군집 분석의 특징	비계층적 군집 분석의 특징
• 군집의 개수를 미리 정하지 않고 유사한 개체를 묶어 나가는 과정을 반복하여 원하는 개수의 군집을 형성하는 방법 • 이상값에 민감함 • 한번 군집이 형성되면 다른 군집으로 이동할 수 없음 • 덴드로그램으로 표현할 수 있음	• 미리 군집의 개수를 지정해야 함 • 사용자가 사전 지식 없이 그룹의 수를 정해주는 일이 많아 결과가 잘 나오지 않을 수 있음

• 군집 분석

- 계층적 군집




- 계층적 군집은 유사한 개체를 군집화하는 과정을 반복하여 군집을 형성하는 방법
- 계층적 군집을 형성하는 방법에 병합적 방법과 분할적 방법이 있음

형성방법	설명
병합적 방법	• 각 데이터를 하나의 군집으로 간주하고 가까운 데이터부터 순차적으로 병합해 나감 • 대표적인 방법으로 몇 개의 군집으로 나눌 것인지 사전에 정할 필요 없음
분할적 방법	• 전체 데이터를 하나의 군집으로 간주하고 각각의 관측치가 하나의 군집이 될 때까지 군집을 순차적으로 분할함

• 군집 분석

- 계층적 군집



➤ 군집 간의 연결법

연결법	개념	설명
최단 연결법 (=단일 연결법)		- 각 군집에서 하나씩 관측값을 뽑았을 때 거리의 최소값을 측정하여 가장 유사성이 큰 군집으로 병합해 나감 - 길게 늘어진 사슬 형태의 군집이 형성될 수 있고 고립된 군집을 찾는데 중점을 둔 방법
최장 연결법 (=완전 연결법)		- 각 군집에서 하나씩 관측값을 뽑았을 때 거리의 최대값을 측정하여 가장 유사성이 큰 군집으로 병합해 나감 - 내부 응집성에 중점을 둔 방법으로 둥근 형태의 군집이 형성됨
중심연결법		- 두 군집의 중심 간의 거리를 측정하여 가장 유사성이 큰 군집으로 병합해 나가는 방법으로 두 군집이 결합할 때 새로운 군집의 평균은 가중평균을 통해 구함 - 평균연결법보다 계산량이 적고 모든 관측치 사이의 거리를 측정할 필요가 없음

• 군집 분석

- 계층적 군집

➤ 군집 간의 연결법

연결법	개념	설명
평균 연결법		- 모든 항목에 대한 거리 평균을 구하면서 가장 유사성이 큰 군집을 병합해 나가는 방법 - 계산량이 불필요하게 많아질 수 있음 - 최단연결법과 최장연결법보다 이상치에 덜 민감함
와드 연결법		- 군집 내의 편차 제곱 합에 기초하여 군집을 수행하는 방법으로 편차 제곱합의 증가량이 최소가 되는 방향으로 군집을 형성해 나가는 방법 크기가 비슷한 군집끼리 병합하는 경향이 있음

• 군집 분석

- 계층적 군집

➤ 군집 간의 거리 계산

- ✓ 계층적 군집은 두 군집간 거리에 기반하여 군집을 형성해 나가므로 거리에 대한 정의가 필요함
- ✓ 거리는 값이 작을수록 **관측치가 유사**함
- ✓ 연속형 변수 거리에는 유클리디안 거리, 맨하탄 거리, 민코프스키 거리, 표준화 거리, 마할라노비스 거리 등이 있음

구분	종류	공식	설명
수학적 거리	유클리디안 거리	$d(i, j) = \sqrt{\sum_{f=1}^p (x_{if} - x_{jf})^2}$ (p : 차원, x_{if} : 시작점, x_{jf} : 끝점)	• 두 점 간 차를 제곱하여 모두 더한 값의 양의 제곱근
	맨하탄 거리	$d(i, j) = \sum_{f=1}^p x_{if} - x_{jf} $ (p : 차원, x_{if} : 시작점, x_{jf} : 끝점)	• 두 점 간 차의 절대값을 합한 값
	민코프스키 거리	$d(i, j) = \left[\sum_{f=1}^p (x_{if} - x_{jf})^m \right]^{1/m}$	• $m=1$ 맨하탄 거리 • $m=2$ 유클리드거리

• 군집 분석

- 계층적 군집

➤ 군집 간의 거리 계산

- ✓ 계층적 군집은 두 군집간 거리에 기반하여 군집을 형성해 나가므로 거리에 대한 정의가 필요함
- ✓ 거리는 값이 작을수록 관측치가 유사함
- ✓ 연속형 변수 거리에는 유클리드디안거리, 맨하탄 거리, 민코프스키 거리, 표준화 거리, 마할라노비스 거리 등이 있음



구분	종류	공식	설명
통계적 거리	표준화 거리	$d(i, j) = \sqrt{(X_i - X_j)^T D^{-1} (X_i - X_j)}$ (X_i : 시작점 행렬, X_j : 끝점 행렬, D : 표본 분산 행렬)	유클리디안 거리에서 변수 간 단위 차이 문제를 해결하기 위한 거리
	마할라노비스 거리	$d(i, j) = \sqrt{(X_i - X_j)^T S^{-1} (X_i - X_j)}$ (X_i : 시작점 행렬, X_j : 끝점 행렬, S : 표본 공분산 행렬)	변수의 표준화와 함께 변수 간의 상관성(분포형태)을 동시에 고려한 통계적 거리

- 군집 분석

- 계층적 군집

- 군집 간의 거리 계산

- ✓ 유클리디안 거리와 맨하탄 거리

종류	계산	
유클리디안 거리		$d(A, B) = \sqrt{(1 - 3)^2 + (2 - 4)^2} = \sqrt{8}$
맨하탄 거리		$d(A, B) = 3 - 1 + 4 - 2 = 4$

• 군집 분석

- 계층적 군집

➤ 군집 간의 거리 계산

✓ dist() 함수와 hclust() 함수

dist() 함수	- 거리 행렬을 제공하는 함수로 method 옵션을 통해 다양한 방식으로 거리를 정의할 수 있음 - method 옵션에는 "euclidean", "maximum", "manhattan", "binary", "minkowski" 등이 있음
hclust() 함수	- 계층적 군집분석을 수행하는 함수로 method 옵션을 통해 병합 방법을 지정할 수 있음 - method 옵션에는 "ward", "single", "complete", "average", "centroid" 등이 있음

• 군집 분석

- 계층적 군집

➤ 범주형 변수 거리

✓ 데이터가 범주형 변수인 경우 얼마나 많은 공통된 요소를 가지고 있는지 판단할 수 있음

거리	내용																		
단순 일치 계수	- p는 변수의 총 개수이며, m은 객체 i와 j가 같은 상태인 변수의 수(일치한 수) $d(i, j) = m/p$																		
	<table><tr><th></th><th>Var1</th><th>Var2</th><th>Var3</th><th>Var4</th><th>Var5</th></tr><tr><th>A</th><td>1</td><td>1</td><td>1</td><td>0</td><td>0</td></tr><tr><th>B</th><td>0</td><td>1</td><td>0</td><td>1</td><td>0</td></tr></table>		Var1	Var2	Var3	Var4	Var5	A	1	1	1	0	0	B	0	1	0	1	0
		Var1	Var2	Var3	Var4	Var5													
	A	1	1	1	0	0													
B	0	1	0	1	0														
$d(i, j) = \frac{m}{p} = \frac{2}{5}$																			

• 군집 분석

- 계층적 군집

➤ 범주형 변수 거리

✓ 데이터가 범주형 변수인 경우 얼마나 많은 공통된 요소를 가지고 있는지 판단할 수 있음

거리	내용																		
자카드 계수	- 두 집합 사이의 유사도를 측정하는 방법으로 0과 1사이의 값을 가지며 두 집합이 같으면 1, 공통의 원소가 하나도 없으면 0의 값을 가짐 $J(X, Y) = \frac{n(A \cap B)}{n(A \cup B)}$																		
	<table><tr><th></th><th>Var1</th><th>Var2</th><th>Var3</th><th>Var4</th><th>Var5</th></tr><tr><th>A</th><td>1</td><td>1</td><td>1</td><td>0</td><td>0</td></tr><tr><th>B</th><td>0</td><td>1</td><td>0</td><td>1</td><td>0</td></tr></table>		Var1	Var2	Var3	Var4	Var5	A	1	1	1	0	0	B	0	1	0	1	0
		Var1	Var2	Var3	Var4	Var5													
	A	1	1	1	0	0													
B	0	1	0	1	0														
- A={Var1, Var2, Var3}, B={Var2, Var4} $J(X, Y) = \frac{n(A \cap B)}{n(A \cup B)} = \frac{1}{4}$																			

• 군집 분석

- 계층적 군집

➤ 범주형 변수 거리

✓ 데이터가 범주형 변수인 경우 얼마나 많은 공통된 요소를 가지고 있는지 판단할 수 있음

거리	내용												
코사인 유사도	문서(텍스트)의 유사도를 측정하기 위한 지표로서 크기가 아닌 방향성을 측정하는 지표로 완전히 일치하면 1의 값을 가지며 완전히 다른 방향이면 -1의 값을 가짐												
	<table><tr><th></th><th>apple</th><th>banana</th><th>melon</th></tr><tr><th>A</th><td>4</td><td>2</td><td>0</td></tr><tr><th>B</th><td>2</td><td>1</td><td>3</td></tr></table>		apple	banana	melon	A	4	2	0	B	2	1	3
		apple	banana	melon									
A	4	2	0										
B	2	1	3										
코사인 유사도 = $\frac{(4 \times 2) + (2 \times 1) + (0 \times 3)}{\sqrt{4^2 + 2^2 + 0^2} \sqrt{2^2 + 1^2 + 3^2}} = 0.598$													

- 군집 분석

- 계층적 군집

- 순서형 변수 거리

- ✓ 순위 상관계수를 이용하여 거리를 측정함

거리	내용
순위 상관 계수	• 값에 순위를 매겨 그 순위에 대해 상관계수를 구하는 방법

- 군집 분석

- 계층적 군집

- 계층적 군집모형의 특징

- ✓ 계층적 군집 방법은 군집을 형성하는 매 단계에서 **지역적 최적화**를 수행하는 방법을 사용하므로 그 결과가 전역적인 최적해라고는 볼 수 없음
 - ✓ 병합적 방법에서 한번 군집이 형성되면 군집에 속한 개체는 **다른 군집으로 이동할 수 없음**
 - ✓ 중심연결법, 와드 연결법 등에서 **군집의 크기에 가중을 두어** 병합을 시도하므로 크기가 큰 군집과의 병합이 유도될 수도 있음

- 군집 분석

- 비계층적 군집

- 계층적으로 군집을 형성하지 않고 구하고자 하는 군집의 수를 사전에 정의해 정해진 군집의 수만큼 형성하는 방법
 - 비계층적 군집분석은 계층적 군집분석과 다르게 데이터 간 거리행렬을 사용하여 분석을 수행하지 않음
 - 또한 원하는 군집의 수(k)의 초기값을 설정하고 분석을 수행하게 됨
 - 대표적인 방법으로 **k-means(k-평균) 군집**이 있음

- 군집 분석

- 비계층적 군집


- K-평균 군집의 개념

- ✓ K-평균 군집은 주어진 데이터를 k개 군집으로 묶는 알고리즘으로 k개만큼 군집 수를 초기값으로 지정하고, 각 개체를 가까운 초기값에 할당하여 군집을 형성하고 각 군집의 평균을 재계산하여 초기값을 갱신하는 과정을 반복하여 k개의 최종군집을 형성함
 - ✓ K-평균 군집에서 **군집의 수(k)**는 초 매개변수(하이퍼 파라미터)로서 분석자가 미리 정해주어야 함

- 군집 분석

- 비계층적 군집


- K-평균 군집의 절차

절차	설명
k개 객체 선택	• 초기 군집 중심으로 k개의 객체를 임의로 선택함(K=3 가정)  A scatter plot on a yellow background showing numerous black data points. Three red dots are placed at different locations, representing the initial selection of k=3 cluster centroids for K-means clustering.

- 군집 분석

- 비계층적 군집


- K-평균 군집의 절차

절차	설명
할당	• 자료를 가장 가까운 군집 중심에 할당 • 자료를 군집의 중심점으로부터 오차 제곱합이 최소가 되도록 각 자료를 할당하는 과정 

- 군집 분석

- 비계층적 군집


- K-평균 군집의 절차

절차	설명
중심 갱신	• 각 군집 내의 자료들의 평균을 계산하여 군집의 중심을 갱신 • 한 개체가 속해 있던 군집에서 다른 군집으로 이동해서 재배치가 가능 

- 군집 분석

- 비계층적 군집

- K-평균 군집의 절차

절차	설명
반복	• 군집 중심의 변화가 거의 없을때(또는 최대 반복 수)까지 단계2와 3을 반복 

• 군집 분석

- K-평균 군집


➤ K-평균 군집의 특징

구분	설명
알고리즘	• 군집의 수는 분석자가 미리 정해주어야 하는 초 매개변수 • K개의 초기 중심값은 임의로 선택될 수 있으나 데이터 중에서 무작위로 선택하는 것이 더 편리 • 군집의 수를 정하기 위해 군집 수에 따른 집단 내 제곱 합의 그래프를 그려보는 방법도 활용 • K-평균 군집은 군집 과정 중에 개체가 속해 있던 군집에서 다른 군집으로 이동해서 재배치가 가능함
성능	• 초기 군집 수를 결정하기 어렵고, 초기값 선택이 최종군집 선택에 영향을 미침 • 안정된 군집은 보장하나 최적의 군집이라는 것은 보장하지 못함 • 알고리즘이 단순하며 빠르게 수행되며 계층적 군집보다 많은 양의 자료를 다룰 수 있음 • 평균 등 거리 계산에 기반하므로 모든 변수가 연속적이어야 하고 잡음이나 이상값에 민감하는 반응하는 단점이 존재 • 단점을 보완하는 방법으로 k-중앙값 군집을 사용하거나 이상값을 미리 제거할 수도 있음

- 군집 분석

- K-평균 군집

- K-평균 군집의 k값 선정 기법

구분	설명												
엘보우 기법	• X축에 클러스터의 개수(k값)를 y축에 SSE(오차제곱합)를 두었을 때 기울기가 완만한 부분(팔꿈치 부분)에 해당하는 클러스터를 선택하는 기법  <table border="1"><thead><tr><th>k (클러스터 개수)</th><th>SSE (오차제곱합)</th></tr></thead><tbody><tr><td>1</td><td>1000</td></tr><tr><td>2</td><td>600</td></tr><tr><td>3</td><td>400</td></tr><tr><td>4</td><td>300</td></tr><tr><td>5</td><td>250</td></tr></tbody></table>	k (클러스터 개수)	SSE (오차제곱합)	1	1000	2	600	3	400	4	300	5	250
k (클러스터 개수)	SSE (오차제곱합)												
1	1000												
2	600												
3	400												
4	300												
5	250												

• 군집 분석

- K-평균 군집


➤ K-평균 군집의 k값 선정 기법

구분	설명
실루엣 기법	• 각 군집 간의 거리가 얼마나 분리되어 있는지를 나타내는 기법 • 실루엣 계수는 1에 가까울수록 군집 간 거리가 멀어서 최적화가 잘 되어 있고 0에 가까울수록 군집 간 거리가 가까워서 최적화가 잘 안되어 있음 • 실루엣 계수는 군집 내의 데이터 응집도와 군집 간 분리도를 계산하여 군집 내의 데이터의 거리가 짧을수록 군집 간 거리가 멀수록 값이 커지는 지표
덴드로그램	• 계층적 군집 분석의 덴드로그램 시각화를 이용하여 군집의 개수 결정

- 군집 분석

- K-평균 군집

- K-평균 군집의 k값 선정 기법

구분	설명
덴드로그램	• 계층적 군집 분석의 덴드로그램 시각화를 이용하여 군집의 개수 결정 

- 군집 분석

- 혼합 분포 군집

- 혼합 분포 군집의 개념

- ✓ 혼합 분포 군집은 데이터가 여러 분포를 확률적으로 선형 결합한 k 개 모형의 합으로 표현되는 모집단으로부터 나왔다는 가정 하에 같은 확률분포에서 추출된 데이터들끼리 군집화하는 분석 기법임
 - ✓ 데이터들이 몇 개의 확률 분포로 구성되어 있는지 각각의 확률 분포의 **모수(평균, 분산)**와 그 확률 분포가 전체 데이터에서 차지하는 **비중(가중치)**을 찾는 것이 혼합 분포 군집의 핵심 개념임
 - ✓ 모수와 가중치를 추정하는 방법으로 **EM 알고리즘**을 사용함

- 군집 분석

- 혼합 분포 군집

- 혼합 분포 군집의 특징

- ✓ 확률 분포를 도입하여 군집을 수행함
 - ✓ 군집을 몇 개의 모수로 표현할 수 있고 서로 다른 크기의 군집을 찾을 수 있음
 - ✓ EM알고리즘을 이용한 모수 추정에서 데이터가 커지면 수렴에 시간이 걸릴 수 있음
 - ✓ 군집의 크기가 너무 작으면 추정의 정밀도가 떨어지거나 어려울 수 있음
 - ✓ 이상값에 민감하므로 이상값 제거 등의 사전 조치가 필요함

- 군집 분석

- 혼합 분포 군집

- 가우시안 혼합 모델(GMM; Gaussian Mixture Model)

- ✓ 전체 데이터의 확률 분포가 **k개의 가우시안 분포(정규분포)의 선형 결합**으로 이루어졌음을 가정하고 각 분포에 속할 확률이 높은 데이터 간의 군집을 형성하는 방법
 - ✓ 가우시안 혼합모델에서는 주어진 데이터 $X=\{x_1, x_2, \dots, x_N\}$ 에 대해 적절한 k개 가우시안 분포의 가중치, 평균, 공분산을 추정함
 - ✓ 데이터들이 k개의 가우시안 분포 중에서 어디에 속하는 것이 최적인지 추정하기 위해 **EM알고리즘**을 이용할 수 있음

- 군집 분석

- 혼합 분포 군집

- EM 알고리즘

- ✓ EM(Expectation Maximization), 기대값 최대화) 알고리즘은 확률 모델의 최대가능도를 갖는 모수와 함께 그 확률모델의 가중치를 추정하고자 할 때 사용할 수 있음
 - ✓ 각 데이터가 어느 분포에서 추출된 데이터인지 각 집단(잠재변수, Z)으로부터 기대값을 구할 수 있으며 추정된 기대값을 활용하여 로그-가능도 함수가 최대로 되게 하는 모수를 찾을 수 있음
 - ✓ 최대 가능도란 어떤 모수가 주어졌을 때 원하는 값들이 나올 가능도를 최대로 만드는 모수를 선택하는 방법

- 군집 분석

- 혼합 분포 군집

- EM 알고리즘

- ✓ EM알고리즘은 E-단계(E-step), M단계(M-step)로 진행됨
 - ✓ 단계1[E-단계]: 파라미터(모수) 설정으로 2개의 정규분포로 혼합된다고 가정할 경우 초기 파라미터(각 정규분포의 평균과 표준편차, 가중치) 값을 임의로 설정함
 - ✓ 단계2[E-단계]: Z(잠재변수)의 기대값을 계산하기 위해 설정된 파라미터 값을 가진 분포로부터 실제 데이터가 얼마나 나올지를 알아보기 위해 로그 가능도 함수의 기대값을 계산함

- 군집 분석

- 혼합 분포 군집

- EM 알고리즘


- ✓ EM알고리즘은 E-단계(E-step), M단계(M-step)로 진행됨
 - ✓ 단계3[M-단계]: 새로운 파라미터를 추정하기 위해 2단계에서 얻은 기대값을 사용하여 새로운 파라미터 값을 추정함
 - ✓ 단계4[M-단계]: 이전 가능도에 비해 가능도 증가량이 특정 기준값보다 낮으면 가능도가 최대가 되었다고 판단하여 알고리즘을 종료하고 그렇지 않으면 2,3단계를 반복하여 진행함

정형 데이터 마이닝

- 군집 분석

- 혼합 분포 군집

- EM 알고리즘



- 군집 분석

- DBSCAN 알고리즘(밀도기반 군집)


- DBSCAN의 개념

- ✓ 개체들의 밀도 계산을 기반으로 밀접하게 분포된 개체들끼리 그룹핑하는 알고리즘
 - ✓ 군집의 개수를 미리 지정할 필요가 없고 군집 밀도에 따라 군집을 서로 연결하기 때문에 기하학적이고 노이즈가 포함된 모양의 군집 분석이 가능함
 - ✓ 기하학적: 도형 및 공간의 성질에 관련된
 - ✓ DBSCAN은 데이터가 많은 지역을 중심으로 클러스터(군집)를 구성하며 임의적인 모양의 군집 탐색에 효과적임

- 군집 분석

- DBSCAN 알고리즘(밀도기반 군집)

- DBSCAN의 구성요소



• 군집 분석

- DBSCAN 알고리즘(밀도기반 군집)

➤ DBSCAN의 구성요소

구성요소	설명
중심점	- 주변 반경 내에 최소 데이터 개수 이상의 다른 데이터를 가지고 있는 데이터 - 반경 내에 존재해야 하는 최소 데이터 개수는 일종의 초 매개변수로 설정해주어야 함
이웃점	특정 데이터 주변 반경 내에 존재하는 다른 데이터
경계점	- 중심점은 아니지만 중심점의 주변 반경 내에 존재하는 데이터 - 중심점을 중심으로 하는 군집에는 포함되며 주로 군집의 외곽을 이룸
잡음점	중심점도 아니고 경계점 조건도 만족하지 못하는 이웃점, 이상값이라고 함

- 군집 분석

- SOM(Self-Organizing Maps), 자기 조직화 지도


- 개념

- ✓ SOM은 대뇌피질과 시각피질의 학습 과정을 기반으로 모델화한 인공신경망으로 차원 축소와 군집화를 동시에 수행할 수 있는 알고리즘
 - ✓ 고차원 데이터를 한눈에 파악하기 쉬운 저차원 공간에 정렬하여 지도의 형태로 나타내는 시각화 방법임
 - ✓ 입력변수의 속성을 보존한다는 특징이 있어 실제 유사한 데이터는 2차원 격자에서도 가깝게 표현됨
 - ✓ SOM은 단 하나의 전방 패스(feed-forward flow)를 사용함으로써 속도가 매우 빠름

• 군집 분석

- SOM(Self-Organizing Maps), 자기 조직화 지도

- 은닉층을 보유한 다층신경망과 달리 은닉층이 없이 데이터를 입력받는 **입력층**과 이를 n개의 노드(뉴런)로 표현하고자 하는 **경쟁층**으로 구성되어 입력층의 모든 데이터가 경쟁층의 모든 노드와 **완전연결**되어 있음
- 각 학습 단계마다 임의의 프로토타입 벡터(경쟁층의 각각의 뉴런)와의 거리를 유클리디안 거리에 의해 계산하고 비교하며 최종적으로 경쟁층에 있는 노드들 중 가장 가까운 하나의 노드에 도달하는데 그 노드를 **승자 노드**라 부름



• 군집 분석

- SOM(Self-Organizing Maps), 자기 조직화 지도

➤ SOM 학습 알고리즘

절차	설명
초기화	• 초기 학습률과 임의의 값의 가중치 행렬, 경쟁층의 노드 개수를 지정함
입력 벡터	• 입력 벡터를 제시하고 가중치 행렬에 의해 가장 가까운 노드를 나타냄
유사도 계산	• 유클리드 거리를 사용하여 입력 벡터와 프로토타입 벡터(경쟁층의 뉴런) 사이의 유사도를 계산
프로토타입 벡터 탐색	• 입력 벡터와 가장 거리가 짧은 프로토타입 벡터(경쟁층의 뉴런) 탐색
강도 재조정	• BMU(입력층과 가장 가까운 뉴런)와 그 이웃들의 연결 강도(가중치)를 재조정
반복	• 단계 2로 가서 지정된 반복 횟수에 도달할 때까지 수행함

• 군집 분석

- SOM(Self-Organizing Maps), 자기 조직화 지도

➤ SOM 학습 알고리즘의 장점/단점

장점	단점
• 역전파 알고리즘을 사용하지 않는 순전파 방식으로 속도가 매우 빠름 • 저차원의 지도로 형상화되어 시각적 이해가 쉬움 • 패턴 발견 및 이미지 분석에서 성능이 우수함 • 입력 데이터에 대한 속성을 그대로 보존함	• 초기 학습률 및 초기 가중치에 많은 영향을 받음 • 경쟁층의 이상적인 노드의 개수를 결정하기 어려움

• 다음 중 이질적인 모집단을 세분화시키는 방법은?

- ① 연관 분석
- ② 군집 분석
- ③ 분류 분석
- ④ 주성분 분석

- 다음 중 군집 분석에 관한 설명 중 옳바르지 않은 것은?

- ① 비 계층적 군집 분석의 경우 사용자가 사전 지식 없이 그룹의 수를 정해주는 일이 많아서 결과가 잘 나오지 않을 수 있다.
- ② 계층적 군집 분석은 이상값에 민감하다.
- ③ 군집 결과에 대한 안정성을 검토하는 방법이 지도학습과 같은 교차 타당성을 이용한다.
- ④ 군집 분석은 신뢰성과 타당성을 점검하기 어렵다.

- 다음 중 군집 분석에 대한 설명으로 가장 옳바르지 않은 것은?
 - ① 군집 분석은 데이터에 분류의 기준이 없는 비지도 학습 방법을 사용한다.
 - ② 계층적 군집 분석은 덴드로그램으로 표현할 수 있다.
 - ③ 군집 분석에서는 군집을 두 개로 나누어 교차 타당성 검증을 사용한다.
 - ④ 계층적 군집은 한번 군집이 형성되면 다른 군집으로 이동할 수 없다.

• 다음 중 분석 방법이 나머지와 다른 것은 무엇인가?

① PCA

② DBSCAN

③ Single Linkage Method

④ K-Means Clustering

• 다음 중 군집의 개수를 미리 정하지 않아도 되는 장점으로 탐색적 분석에 사용하는 군집모형은?

- ① SOM 모형
- ② 계층적 군집모형
- ③ 혼합 분포 군집모형
- ④ K-평균 군집모형

• 다음 중 군집 간의 거리에 기반하는 다른 연결법과는 다르게 군집 내의 오차 제공 합에 기초하여 군집을 수행하는 계층적 군집분석의 거리 측정 방법은?

- ① 최단 연결법
- ② 평균 연결법
- ③ 와드 연결법
- ④ 최장 연결법

- 다음은 계층적 군집을 수행하기 위한 거리 측정 방법 중 어떤 방법을 사용한 것인가?

두 군집 사이의 거리를 각 군집에서 하나씩 관측값을 뽑았을 때 나타날 수 있는 거리의 최소값으로 측정해서 가장 유사성이 큰 군집으로 병합해 나가는 방법

- 다음 중 계층적 군집에 관한 설명 중 적절하지 않은 것은?

- ① 최단연결법 또는 단일연결법은 두 군집 사이의 거리를 각 군집에서 하나씩 관측값을 뽑았을 때 나타날 수 있는 거리의 최소값으로 측정한다.
- ② 최단연결법은 최단 거리를 사용할 때 사슬 모양으로 생길 수 있으며 고립된 군집을 찾는데 중점을 둔 방법이다.
- ③ 중심연결법은 두 군집의 중심 간의 거리를 측정하여 가장 유사성이 큰 군집으로 병합해 나가는 방법으로 두 군집이 결합할 때 새로운 군집의 평균은 가중평균을 통해 구해진다.
- ④ 최단 연결법은 평균 연결법보다 계산량이 많아질 수 있다.

- 다음 중 아래의 위치 데이터를 이용하여 계층적 군집 분석 중 최단 연결법을 통해 3개의 군집으로 나눌 때 가장 적절한 것은?

데이터	(x_1, x_2)
a	(1, 5)
b	(2, 4)
c	(4, 6)
d	(4, 3)
e	(5, 3)

- ① (d,e), (a,b), c
- ② (a,c), (b,d), e
- ③ (a,b), (e,d), c
- ④ (a,d), (b,c), e

- 1단계: 유클리드 제곱 거리 구하기

데이터	(x_1, x_2)
A	(1, 5)
B	(2, 4)
C	(4, 6)
D	(4, 3)
E	(5, 3)

	A	B	C	D	E
A	0				
B	2	0			
C	10	8	0		
D	13	5	9	0	
E	20	10	10	1	0

$$d(d, e) = \sqrt{(4 - 5)^2 + (3 - 3)^2} = \sqrt{1}$$

숫자를 단순하게 처리하기 위해 루트가 없다고 생각

- 2단계: 유클리드 제곱 거리 구하기

	A	B	C	(D,E)
A	0			
B	2	0		
C	10	8	0	
(D,E)	13	5	9	0

A,B,C 데이터와 (D,E) 군집의 거리 계산은 D,E중 가까운 데이터의 거리를 계산
A,B가 가장 가깝다는 것을 파악

$$d(a, b) = \sqrt{(1 - 2)^2 + (5 - 4)^2} = \sqrt{2}$$

- 3단계: 유클리드 제곱 거리 구하기

	(A,B)	C	(D,E)
(A,B)	0		
C	8	0	
(D,E)	5	9	0


(A,B) 데이터와 (D,E) 군집의 거리 계산은 D,E중 가까운 데이터의 거리를 계산
B,D의 거리가 가장 가까움

$$d(b, d) = \sqrt{(2 - 4)^2 + (4 - 3)^2} = \sqrt{5}$$

C 데이터와 (A,B)와 (D,E) 군집의 거리 계산은 가까운 데이터의 거리를 계산
B,C의 거리가 가장 가까움

$$d(b, c) = \sqrt{(2 - 4)^2 + (4 - 6)^2} = \sqrt{8}$$

- 4단계: 덴드로그램 그리기



- 다음은 5개의 관측값에 대한 유클리디안 거리를 표로 나타낸 것이다. 최단 연결법을 사용하여 계층적 군집을 시행하면 처음에 형성되는 군집과 관측값 a의 거리는 얼마인가?

	A	B	C	D
B	3.2			
C	3.5	5.2		
D	3.2	2.6	3.4	
E	4.8	3.4	5.3	2.2

• 다음 중 군집 분석에서의 유사도 측정에 대한 설명으로 가장 옳바르지 않은 것은?

- ① 맨하탄 거리는 각 방향 직각의 이동 거리 합으로 계산된다.
- ② 표준화 거리는 각 변수를 해당 변수의 표준편차로 변환한 후 유클리드 거리를 계산한 거리이다.
- ③ 마할라노비스 거리는 변수의 표준편차를 고려한 거리 척도이나 변수 간에 상관성이 있는 경우에는 표준화 거리 사용을 검토해야 한다.
- ④ 유클리드 거리는 두 점을 잇는 가장 짧은 직선거리이다.

- 다음은 학생들의 키와 몸무게를 정규화한 데이터이다. 맨하탄 거리를 이용하여 A와 B의 거리를 구하시오.

사람	(키, 몸무게)
A	(1,5)
B	(2,4)

- 계층적 군집은 두 개체 간의 거리에 기반하므로 거리 측정에 대한 정의가 필요하다. 다음 중 `dist()` 함수에서 지원하지 않는 거리는?

- ① 유클리드
- ② 맨하탄
- ③ 민코프스키
- ④ 코사인

- 명목형 변수의 두 개체 간 거리 측도 중에서 두 벡터 사이의 각도를 이용하여 개체 간의 유사도를 측정하는 측도는 무엇인가?
 - ① 코사인 유사도
 - ② 피어슨 유사도
 - ③ 자카드 유사도
 - ④ 맨하탄 거리

- 다음 데이터 세트에서 A,B간의 유클리드 거리를 계산하면?

	A	B
키	175	180
몸무게	45	50

① 0

② $\sqrt{5}$

③ $\sqrt{25}$

④ $\sqrt{50}$

• 다음 중 민코프스키 거리를 나타내는 수식은 무엇인가?

① $d(x, y) = \max |x_i - y_i|$

② $d(x, y) = \sqrt{\sum_{i=1}^p (x_i - y_i)^2}$

③ $d(x, y) = [\sum_{i=1}^p |x_i - y_i|^m]^{1/m}$

④ $d(x, y) = \sum_{i=1}^p |x_i - y_i|$

- 계층적 군집 방법의 거리에 대한 정의 중 변수의 표준화와 변수 간의 상관성을 동시에 고려한 통계적 거리는?

- ① 자카드 계수
- ② 마할라노비스 거리
- ③ 민코우스키 거리
- ④ 맨하탄 거리

- 다음 중 k평균 군집에 대한 설명으로 올바른 것은?

- ① k평균 군집에서 군집의 수는 지정하지 않는다.
- ② k평균 군집은 한번 군집이 형성되면 군집에 속한 개체는 다른 군집으로 이동할 수 없다.
- ③ k평균 군집 결과는 덴드로그램의 형태로 표현된다.
- ④ 알고리즘이 단순하며 빠르게 수행되며 계층적 군집보다 많은 양의 자료를 다룰 수 있다.

- 다음 중 k 평균 군집에서 단점을 보완하는 방법으로 올바른 것은?

- ① 이상값 자료에 민감한 k -평균 군집의 단점을 보완하기 위해 군집을 형성하는 단계마다 평균 대신 중앙값을 사용하는 k -중앙값 군집을 사용한다.
- ② k 평균은 군집의 수를 미리 정할 필요가 없다.
- ③ 불룩한 형태가 아닌 군집이 존재할 때 군집 성능이 높아진다.
- ④ 조화평균을 사용한다.

- 군집 분석의 품질을 정량적으로 평가하는 대표적인 지표로 군집 내의 데이터 응집도와 군집 간 분리도를 계산하여 군집 내의 데이터의 거리가 짧을수록, 군집 간 거리가 멀수록 값이 커지며 완벽한 분리일 경우 1의 값을 가지는 지표는?

- K평균 군집으로 대표되는 비 계층적 군집 방법에서 군집의 개수인 k 를 미리 정해주어야 한다. 다음 중 군집 수를 정하는 데 활용할 수 있는 그래프로 가장 적절한 것은?

- ① ROC 그래프
- ② 향상도 곡선
- ③ 오차제곱합
- ④ 집단 내 제곱합 그래프

- 다음은 K평균 군집을 수행하는 절차이다. 다음 중 K-평균 군집의 수행 절차를 순서대로 올바르게 나열한 것은?

- ㉠ 각 자료를 가장 가까운 군집의 중심에 할당한다.
- ㉡ 군집 중심의 변화가 거의 없을 때(또는 최대 반복 수)까지 단계2와 단계3을 반복한다.
- ㉢ 초기(군집의) 중심으로 k개의 객체를 임의로 선택한다.
- ㉣ 각 군집 내의 자료들의 평균을 계산하여 군집의 중심을 갱신한다.

- ① ㉢ → ㉣ → ㉠ → ㉡
- ② ㉢ → ㉠ → ㉣ → ㉡
- ③ ㉠ → ㉣ → ㉢ → ㉡
- ④ ㉠ → ㉢ → ㉣ → ㉡

- 비 계층적 군집 방법인 K-평균 군집은 이상값 자료에 민감하다는 단점이 있다.
다음 중 이러한 단점을 극복하기 위해 등장한 비 계층적 군집 방법으로 가장 적절한 것은?

- ① EM Clustering
- ② 혼합 분포 군집
- ③ Density Based Clustering
- ④ K-Medoids Clustering

- 다음이 설명하는 군집 분석 방법은?

여러 분포를 확률적으로 선형 결합하여 데이터가 k 개의 모수적 모형의 가중 합으로 표현되는 모집단 모형으로부터 나왔다는 가정하에 자료로부터 모수와 가중치를 추정하는 방법

- ① DBSCAN
- ② 혼합 분포 군집
- ③ EM 알고리즘
- ④ SOM

- 다음 중 EM알고리즘의 진행 과정 중 임의의 파라미터의 값을 정한 후 Z의 기대치를 계산하는 단계는?
 - ① 파라미터 추정 단계
 - ② E-단계
 - ③ M-단계
 - ④ 조건부 기대값 대입 단계

- 혼합 분포 군집은 모형기반의 군집 방법으로 데이터가 K개의 모수적 모형의 가중 합으로 표현되는 모집단 모형으로부터 나왔다는 가정하에 분석하는 방법이다. K개의 각 모형은 군집을 의미하며 이 혼합모형으로 모수와 가중치의 최대 가능도 추정에 사용되는 알고리즘은?

- ① 역전파 알고리즘
- ② 전방 패스 알고리즘
- ③ EM 알고리즘
- ④ 탐욕적 알고리즘

- 다음 중 데이터가 많은 지역을 중심으로 클러스터를 구성하여 비교적 비어있는 지역을 경계로 하는 군집기법으로 임의적인 모양의 군집 탐색에 효과적인 군집기법은?

- ① 계층적 군집기법
- ② 격자 기반 군집기법
- ③ 분리 군집기법
- ④ 밀도기반 군집기법

- SOM 프로세스에서 입력 벡터와 경쟁층 노드 간의 유클리드 거리를 계산하여 그중에서 제일 가까운 뉴런을 무엇이라고 하는가?

- 코호넨의 의해 제시되었으며 비지도 신경망으로 고차원의 데이터를 이해하기 쉬운 저차원의 뉴런으로 정렬하여 지도의 형태로 형상화하는 클러스터링 방법은?

- 다음 중 SOM 방법에 대한 설명으로 옳바르지 않은 것은?

- ① 경쟁 학습으로 각각의 뉴런이 입력 벡터와 얼마나 가까운지를 계산하여 연결 강도를 반복적으로 재조정하는 학습 과정을 거치면서 연결 강도는 입력 패턴과 가장 유사한 경쟁층 뉴런이 승자가 된다.
- ② 고차원의 데이터를 저차원의 지도형태로 형상화하기 때문에 시각적으로 이해하기 쉬울 뿐 아니라 변수의 위치 관계를 그대로 보존하기 때문에 실제 데이터가 유사하면 지도상 가깝게 표현된다.
- ③ 입력변수의 위치 관계를 그대로 보존하여 입력변수의 정보와 그들의 관계가 지도상에 그대로 나타난다.
- ④ SOM을 이용한 군집 분석은 역전파 알고리즘을 사용함으로써 군집의 성능이 우수하고 수행속도가 빠르다.

- 다음 중 Self-Organizing Maps에서 입력 벡터의 특성에 따라 벡터의 한 점으로 클러스터링 되는 층은?

- ① 입력층
- ② 은닉층
- ③ 경쟁층
- ④ 출력층

• 다음 중 비지도 학습 기법은 무엇인가?

① SOM

② 인공신경망

③ SVM

④ 랜덤 포레스트

모듈 8-4

연관 분석

- 연관 분석

- 연관 규칙

- 연관규칙의 개념

- ✓ 연관규칙은 항목 간의 '조건-결과' 식으로 표현되는 유용한 패턴을 말함
 - ✓ 패턴, 규칙을 발견해내는 것을 연관 분석이라고 하며 흔히 장바구니 분석이라고도 불림
 - ✓ 사용하는 데이터의 형태는 장바구니 데이터라고 하며 장바구니 하나에 해당하는 정보를 트랜잭션이라고 함
 - ✓ 연관 분석은 데이터 내부에 존재하는 항목 간의 상호 관계 혹은 종속 관계를 찾아내는 기법이라고 할 수 있음

• 연관 분석

- 연관 규칙

➤ 연관규칙의 장점

장점	설명
탐색적인 기법	• 데이터 간의 관계를 조건반응(if-then)으로 연결하고 표현하는 분석으로 장바구니 분석, 서열(순차)분석이라고도 불림
강력한 비목적성 분석기법	• 목적변수가 없어서 분석 방향이나 목적이 없어도 적용이 가능
사용한 편리한 분석데이터 형태	• 거래 내용에 대한 데이터를 변환 없이 그 자체로 이용할 수 있는 간단한 자료구조를 갖는 분석 방법
계산의 용이성	• 분석을 위한 계산이 상당히 간단함
다양한 활용성	• 마케팅 분야에서 가장 많이 활용됨 • 교차판매(관련상품을 추가로 판매), 묶음판매, 카탈로그 배열, 상품진열, 거래 후 쿠폰 제공, 온라인 쇼핑의 상품 추천 등에 활용됨

- 연관 분석

- 연관 규칙

- 연관규칙의 단점

단점	설명
상당한 수의 계산과정 필요	• 품목 수가 증가하면 분석에 필요한 계산은 기하급수적으로 증가
적절한 품목의 결정 필요	• 적절한 세분화로 인한 품목 결정이 장점이지만 너무 세분화된 품목은 의미 없는 결과를 도출
품목의 비율 차이 존재	• 상대적으로 거래량이 적은 품목은 당연히 포함된 거래 수가 적고 규칙 발견시 제외되기 쉬움

- 연관 분석

- 연관규칙의 측정지표(지지도)

- 전체 거래 중 항목 A와 B를 동시에 포함하는 거래의 비율
 - 전체 구매 경향을 파악할 수 있는 지표
 - 연관규칙이 나왔을 때 적용성이 있는지를 판단할 수 있고 불필요한 분석을 대폭 줄일 수 있음
 - $P(A \cap B) = \frac{A와 B를 동시에 포함하는 거래수}{전체 거래수}$

- 연관 분석

- 연관규칙의 측정지표(신뢰도)

- A상품을 샀을 때 B상품을 살 조건부 확률에 대한 척도

- A를 포함하는 거래 중 A와 B를 함께 포함하는 거래 수

- 신뢰도 = $\frac{P(A \cap B)}{P(A)} = \frac{A \text{와 } B \text{를 동시에 포함하는 거래수}}{A \text{포함 거래수}}$

- 값이 클수록 A를 구매했을 때 B의 구매율이 높음

• 연관 분석

- 연관규칙의 측정지표(향상도)

- 규칙이 우연에 의해 발생한 것인지를 판단하기 위해 연관성의 정도를 측정하는 지표
- 품목 B를 구매한 고객 대비 품목 A를 구매한 후 품목 B를 구매하는 고객에 대한 확률
- A와 B가 독립적으로 발생한 거래비율 중 **A와 B를 함께 포함하는 거래**의 비율
- 향상도 = $\frac{P(B|A)}{P(B)} = \frac{P(A \cap B)}{P(A) \times P(B)}$ $\frac{A와 B를 동시에 포함하는 거래비율}{A를 포함하는 거래비율 \times B를 포함하는 거래비율}$

향상도	의미
1	두 품목이 독립
1보다 크다	두 품목이 서로 양의 상관관계
1보다 작다	두 품목이 서로 음의 상관관계

- 지지도, 신뢰도, 향상도의 산출

- 청소기와 공기청정기와의 관계


- 총 거래내역 수 10,000건

- 지지도 = $1000 / 10000 = 0.1 (=10\%)$

- 신뢰도 = $1000 / 4000 = 0.25 (=25\%)$

- 향상도 = $\frac{(\frac{1000}{10000})}{(\frac{4000}{10000}) \times (\frac{2000}{10000})} = 1.25$

- 산출된 향상도가 1보다 큰 수 이므로 “청소기와 공기청정기간 양의 상관관계가 있다고 할 수 있음



- 연관 분석

- 순차 패턴

- 시간 순서에 따른 정보로 연관성을 측정하여 유용한 **연관규칙을 찾는 기법**
 - 순차 패턴은 고객 데이터에서 **구매 시점별**로 정보를 확인하여 발견할 수 있음
 - 시간이 지남에 따라 어떤 소비형태를 보이는가에 대한 순차 패턴에 대한 분석을 **시차 연관 분석**이라고 함
 - ✓ 예) 노트북을 구매한 고객 중에서 30%는 다음 달에 복합기를 구매할 것이다.

- 연관 분석

- 연관 분석 알고리즘

- 아프리오리(Apriori) 알고리즘 개념

- ✓ 아프리오리 알고리즘은 가능한 모든 경우의 수를 탐색하는 방식을 개선하기 위해 데이터들의 발생빈도가 높은 것을 찾는 알고리즘
 - ✓ 분석대상이 되는 항목의 대상을 최소화하여 연관성 도출을 효율화한 연관분석 알고리즘으로 최소 지지도보다 큰 지지도 값을 갖는 빈발항목 집합에 대해서만 연관규칙을 계산하는 알고리즘

- 연관 분석

- 연관 분석 알고리즘

- 아프리오리(Apriori) 알고리즘 개념

- ✓ 연관성 분석 시 항목이 많아질수록 조합할 수 있는 연관성 규칙은 기하급수적으로 늘어나기 때문에 항목을 줄여주는 것이 필요하고 아프리오리 알고리즘을 통해 이를 줄여줄 수 있음
 - ✓ $\{A, B\}$ 에 대한 지지도가 0.35라 가정하면 $\{A, B\}$ 의 지지도가 사용자가 정한 최소 지지도(예: 0.4) 요건을 충족시키지 못하기에 $\{A, B\}$ 가 포함된 경우의 수($\{A, B, C\}, \{A, B, D\}$ 등)를 제외함

• 연관 분석

- 연관 분석 알고리즘

➤ 아프리오리(Apriori) 알고리즘 분석 절차

구분	설명
1단계	• 데이터베이스로부터 최소 지지도를 설정
2단계	• 개별 품목들 중 최소 지지도를 넘는 모든 항목들을 찾음
3단계	• 이전 단계에서 찾은 개별 항목만을 이용하여 최소 지지도를 넘는 두 가지 항목을 찾음
4단계	• 이전 단계에서 찾은 항목의 집합을 결합하여 최소 지지도를 넘는 세 가지 항목 집합을 찾음
5단계	• 반복적으로 수행하여 최소 지지도가 넘는 빈발항목 을 찾음

- 연관 분석

- 연관 분석 알고리즘

- FP-Growth 알고리즘

- ✓ 아프리오리 알고리즘을 개선한 알고리즘으로 FP-Tree라는 구조를 통해 최소 지지도를 만족하는 빈발아이템 집합을 추출하는 알고리즘
 - ✓ 데이터 세트가 큰 경우 모든 후보아이템 세트들에 대해 반복적으로 계산하는 단점이 있는 아프리오리 알고리즘을 개선한 알고리즘
 - ✓ 지지도가 낮은 품목부터 지지도가 높은 품목 순으로 차츰 올라가면서 빈도수가 높은 아이템 집합을 생성하는 상향식 알고리즘

• 다음 중 데이터마이닝 기법 중 항목 간의 조건-결과 식으로 표현되는 유용한 패턴을 발견해내는 방법을 무엇이라고 하는가?

- ① 연관규칙
- ② 의사결정나무
- ③ 인공신경망
- ④ SOM

• 데이터마이닝 기법 중 카탈로그 배열, 교차 판매 등의 마케팅을 계획할 때 분석하는 방법으로 가장 적절한 것은?

- ① 예측
- ② 연관분석
- ③ 군집
- ④ 분류

- 다음 중 연관규칙의 측정지표인 향상도에 대한 설명으로 올바른 것은?
 - ① 품목 B에 대한 품목 A의 조건부 확률로 나타낸다.
 - ② 품목 A와 B의 구매가 서로 관련이 없는 경우 향상도는 0이다.
 - ③ 향상도가 1보다 크면 해당 규칙은 결과를 예측하는 데 있어 우수하다.
 - ④ 전체거래 중에서 품목 A, B가 동시에 포함된 거래의 비율이다.

- 다음은 상점의 판매 상품 데이터이다. 판매 상품 중 “사과→딸기”에 대한 향상도는 얼마인가?

거래 번호	판매 상품
1	배, 사과, 딸기
2	배, 사과, 포도
3	배, 자몽
4	사과, 딸기
5	배, 사과, 딸기, 포도
6	자몽

① 1.2 ② 1.5 ③ 1.7 ④ 2.0

- 다음은 어떤 편의점의 품목별 거래 건수이다. 연관규칙 커피→김밥에 대한 향상도는?

품목	거래 건수
커피	100
김밥	100
생수	100
커피, 김밥, 생수	50
김밥, 생수	200
커피, 김밥	250
커피, 생수	200

① 30.5% ② 50.0% ③ 83.3% ④ 93.3%

• 다음 중 A제품 구매→B제품 구매의 연관규칙 측정지표 중 지지도에 대한 설명으로 올바른 것은?

- ① A와 B가 동시에 포함된 거래 수/전체 거래 수
- ② A와 B가 동시에 포함된 거래 수/A가 포함된 거래 수
- ③ A와 B가 동시에 포함된 거래 수/B가 포함된 거래 수
- ④ A가 포함된 거래 수/전체 거래 수

- 다음 중 연관규칙 지표에 대한 설명 중 올바른 것은?
 - ① 향상도가 1보다 크면 이 규칙은 결과를 예측하는 데 우수하다는 것을 의미한다.
 - ② 향상도가 1보다 작으면 품목 간에 독립적인 관계로 본다.
 - ③ 지지도는 조건확률로 품목 a를 구매한 사람이 품목 b도 구매한다고 해석한다.
 - ④ 향상도가 1이면 두 품목 간에 상호 연관성이 높다는 것으로 해석한다.

- 다음 중 어떤 슈퍼마켓에서 고객 5명의 장바구니별 구매 품목이 다음과 같다.

연관규칙 빵→우유에 대한 신뢰도는 몇 퍼센트인가?

거래 번호	판매 상품
1	빵, 맥주
2	빵, 우유, 계란
3	맥주, 우유
4	빵, 맥주, 계란
5	빵, 맥주, 우유, 계란

① 50% ② 55% ③ 60% ④ 65%

- 다음의 거래 데이터에서 추출된 연관규칙 중 하나인 “사과→치즈”의 지지도를 구하시오.

거래 번호	판매 상품
1	토마토, 사과, 치즈
2	토마토, 사과, 우유
3	토마토, 주스
4	사과, 주스
5	토마토, 사과, 치즈, 우유
6	주스

- 연관규칙의 측정지표로 두 품목의 상관관계를 기준으로 도출된 규칙의 예측력을 평가하는 지표는?

- 다음은 피자와 햄버거의 거래 관계를 나타낸 표로 피자와 햄버거는 피자와 햄버거를 포함하는 거래 수를 의미하고 (피자)와 (햄버거)는 피자와 햄버거를 포함하지 않은 거래 수를 의미한다. 피자 구매와 햄버거 구매에 대한 설명으로 옳바른 것은?

구분	피자	(피자)	합계
햄버거	2,000	500	2,500
(햄버거)	1,000	1,500	2,500
합계	3,000	2,000	5,000

- ① 지지도가 0.6으로 전체 구매 중 햄버거와 피자가 같이 구매되는 경향이 높다.
- ② 정확도가 0.7로 햄버거와 피자의 구매 관련성은 높다.
- ③ 향상도가 1보다 크므로 햄버거와 피자 사이에 연관성이 높다고 할 수 있다.
- ④ 연관규칙 중 “햄버거→피자”보다 “피자→햄버거”의 신뢰도가 더 높다.

- 다음은 피자와 햄버거의 거래 관계를 나타낸 표로 피자와 햄버거는 피자와 햄버거를 포함하는 거래 수를 의미하고 (피자)와 (햄버거)는 피자와 햄버거를 포함하지 않은 거래 수를 의미한다. 피자 구매와 햄버거 구매에 대한 설명으로 올바른 것은?

구분	피자	(피자)	합계
햄버거	2,000	500	2,500
(햄버거)	1,000	1,500	2,500
합계	3,000	2,000	5,000

$$\rightarrow \text{지지도} = P(\text{피자} \cap \text{햄버거}) = \frac{2000}{5000} = 0.4$$

$$\rightarrow \text{향상도} = \frac{P(\text{피자} \cap \text{햄버거})}{P(\text{피자}) \times P(\text{햄버거})} = \frac{0.4}{3000/5000 \times 2500/5000} = \frac{4}{3}$$

$$\rightarrow \text{신뢰도}(\text{피자} \rightarrow \text{햄버거}) = \frac{P(\text{피자} \cap \text{햄버거})}{P(\text{피자})} = \frac{2/5}{3/5} = 0.67, \text{신뢰도}(\text{햄버거} \rightarrow \text{피자}) = \frac{P(\text{피자} \cap \text{햄버거})}{P(\text{햄버거})} = \frac{2/5}{1/2} = 0.8$$

- 다음은 피자와 햄버거의 거래 관계를 나타낸 표로 피자와 햄버거는 피자와 햄버거를 포함하는 거래 수를 의미하고 (피자)와 (햄버거)는 피자와 햄버거를 포함하지 않은 거래 수를 의미한다. 피자 구매와 햄버거 구매에 대한 설명으로 옳바른 것은?

구분	피자	(피자)	합계
햄버거	2,000	500	2,500
(햄버거)	1,000	1,500	2,500
합계	3,000	2,000	5,000

- ① 지지도가 0.6으로 전체 구매 중 햄버거와 피자가 같이 구매되는 경향이 높다.
- ② 정확도가 0.7로 햄버거와 피자의 구매 관련성은 높다.
- ③ 향상도가 1보다 크므로 햄버거와 피자 사이에 연관성이 높다고 할 수 있다.
- ④ 연관규칙 중 “햄버거→피자”보다 “피자→햄버거”의 신뢰도가 더 높다.

- 마트에서 팔고 있는 A제품과 B제품에 대한 지지도는 0.3, 신뢰도는 0.6이다.
A제품과 B제품의 판매량이 같을 때(만약 A제품의 판매량이 100일 경우 B제품의 판매량도 100이다). A제품→B제품의 향상도는?

- 다음 중 연관분석에 대한 설명으로 옳바르지 않은 것은?

- ① 품목수가 증가하면 분석에 필요한 계산은 기하급수적으로 늘어난다.
- ② 너무 세분화된 품목을 가지고 연관규칙을 찾으려고 하면 의미 없는 분석 결과가 나올 수도 있다.
- ③ 향상도가 1이면 두 품목 간에 연관성이 없는 서로 독립적인 관계이고 1보다 작으면 서로 음의 관계로 품목 간에 연관성이 없다.
- ④ 시차 연관 분석은 인과관계 분석이 가능하다.

• 다음 중 구매순서가 고려되어 상품 간의 연관성이 측정되고 유용한 연관규칙을 찾는 기법은?

- ① 회귀 분석
- ② 군집 분석
- ③ 순차 패턴
- ④ 의사결정나무

- 다음 중 연관분석의 특징으로 옳지 않은 것은?
 - ① 조건반응(if then)으로 표현되는 연관 분석의 결과를 이해하기 쉽다.
 - ② 비목적성 분석기법이다.
 - ③ 세분화 분석 품목 없이 연관규칙을 찾을 수 있다.
 - ④ 분석 계산이 간편하다.

- 연관 분석을 수행하기 위해 빈발 아이템 집합과 연관규칙이라고 하는 두 가지 형태로 표현하는 연관성 분석을 수행하는 대표적인 알고리즘은?

- 다음 중 연관분석의 대표적 알고리즘인 아프리오리 알고리즘의 단점을 보완하기 위해 트리와 노드 링크라는 특별한 자료구조를 사용하는 알고리즘은?

- ① FP-Growth
- ② arules
- ③ kohonen
- ④ spade