

- summary(mtcars)에 대한 설명 중 적절하지 않은 것은?

```
> summary(mtcars)
```

mpg	cyl	disp	hp
Min. :10.40	Min. :4.000	Min. : 71.1	Min. : 52.0
1st Qu.:15.43	1st Qu.:4.000	1st Qu.:120.8	1st Qu.: 96.5
Median :19.20	Median :6.000	Median :196.3	Median :123.0
Mean :20.09	Mean :6.188	Mean :230.7	Mean :146.7
3rd Qu.:22.80	3rd Qu.:8.000	3rd Qu.:326.0	3rd Qu.:180.0
Max. :33.90	Max. :8.000	Max. :472.0	Max. :335.0

① mpg 변수 분포는 왼쪽 꼬리가 긴 분포이다.

② hp 변수는 수치형 자료이다.

③ cyl 변수는 결측값이 없음을 알 수 있다.

④ disp 변수의 최대값은 472이다.

→ 평균>중위수이면 왼쪽에 치우친 분포 또는 오른쪽 꼬리를 가진 분포이다.

- 다음 데이터의 Education 변수는 약 몇 %가 12보다 큰 값을 가지는가?

```
> summary(swiss$Education)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  1.00   6.00   8.00  10.98  12.00   53.00
```

→ 12보다 작은 값의 비율은 75%이므로 나머지 25%는 12보다 큰 값을 가진다.

• 다음 중에서 자료들의 중간 50%에 흠어진 정도를 나타내는 통계량은 무엇인가?

① 중위수

② 사분위수 범위

③ 평균

④ 분산

→ 사분위수 범위는 제3사분위수-제1사분위수로 중간 50%의 흠어진 정도를 나타낸다.

- 다음의 R의 벡터 데이터에서 평균, 최빈수, 중위수, 범위의 값을 모두 더한 값은 얼마인가?

```
data <- c(1, 1, 2, 3, 4, 4, 4, 4, 4, 6, 7, 8)
```

① 18

② 19

③ 20

④ 21

→ 평균: $\frac{\sum_{i=1}^{12} x_i}{12} = 4$, 최빈값: 4, 중위수: $\frac{12}{2}, \frac{12}{2} + 1$ 번째 평균, 4, 범위: $x_{max} - x_{min} = 7$

- 다음 산포의 척도에 관한 설명 중 적절하지 않은 것은?

① 변동계수는 분포의 퍼짐 정도를 비교하게 해준다.

② IQR은 (3사분위수 - 1사분위수)이다.

③ 평균 절대편차는 관측값에서 평균을 뺀 값에 대한 절대값을 모두 더한 값이다.

④ 사분위 수는 데이터 표본을 4개의 동일한 부분으로 나눈 값이다.

→ 평균 절대편차는 관측값에서 평균을 뺀 값에 대한 절대값에 대한 평균이다.

- 100개의 실수 관측값을 수집하여 평균과 표준편차를 구한 결과 각각 10과 2가 나왔다. 모든 관측값에 4를 더한 후에 평균과 표준편차를 구하면 값의 변화는 어떻게 되는가?

① 평균은 10, 표준편차는 2로 변화가 없다.

② 평균은 14, 표준편차는 4가 된다.

③ 평균은 14가 되고 표준편차는 2가 된다.

④ 평균은 14가 되고 표준편차는 6이 된다.

→ 평균은 더한 값만큼 증가하며 표준편차는 더하기/빼기 관계없이 같다.

• 다음 중 변수의 측정 수준에 따라 집중 경향값과 산포도에 관한 설명으로 틀린 것은?

① 중위수는 대표적인 집중 경향값으로 이상값에 의한 영향이 민감하다는 단점이 있다.

② 최빈수는 관측된 데이터값 중에서 가장 여러 번 나타난 값이다.

③ 표본평균은 데이터의 합을 총 개수로 나눈 값을 의미한다.

④ 사분위수는 모든 데이터값을 순서대로 배열하였을 때 4등분한 지점에 있는 값이다.

→ 중위수는 이상값 및 다른 관측값에 의한 영향에 덜 민감하다.

- 다음 회귀 분석에서 가장 적합한 회귀 모형을 찾기 위한 과정의 설명으로 가장 알맞지 않은 것은?

- ① 회귀식에 대한 검정은 독립변수의 기울기가 0이 아니라는 가정을 귀무가설, 기울기가 0인 것을 대립가설로 놓는다.
 - ② 회귀 분석의 가설 검정에서 p-값이 0.05보다 작은 값이 나와야 통계적으로 유의한 결과이다.
 - ③ 잔차의 독립성, 등분산성, 정규성을 만족하는지 확인해야 한다.
 - ④ 독립변수의 수가 많아지면 독립변수 간에 서로 영향을 미치는 다중 공선성의 문제가 발생하므로 상대적인 조정이 필요하다.
- 회귀식에 대한 검정은 독립변수의 기울기가 0이라는 가정을 귀무가설, 기울이가 적어도 하나는 0이 아니라는 것을 대립가설로 놓는다.
- $H_0: \beta_1 = \beta_2 = \dots = \beta_k = 0, H_1: \beta_1 \sim \beta_k$ 중 적어도 하나는 0이 아니다.

- 회귀 분석 결정계수에 대한 설명으로 가장 알맞지 않은 것은?

- ① 회귀모형에서 입력 변수가 증가하면 결정계수도 증가한다.

- ② 결정계수는 총 변동 중에서 회귀 모형에 의하여 설명되지 않은 오차에 의한 변동이 차지하는 비율이다.

- ③ 수정된 결정계수는 유의하지 않은 독립변수들이 회귀식에 포함되었을 때 그 값이 감소한다.

- ④ 다중 회귀 분석에서는 최종 모형의 선정기준으로 결정계수 값보다는 수정된 결정계수 값을 사용하는 것이 적절하다.

- 결정계수는 총 변동 중 회귀모형에 의해 설명되는 변동의 비율이다.

- 회귀 방정식에서 자료를 가장 잘 설명해주는 추정값을 찾기 위해 잔차의 제곱합을 최소화 하는 방법을 무엇이라고 하는가?

최소 제곱법 or 최소 자승법

- 다중회귀모형의 통계적 유의성을 확인하는 방법은?

- ① F통계량을 확인한다.

- ② 결정계수를 확인한다.

- ③ 잔차 통계량을 확인한다.

- ④ 회귀계수의 t값을 확인한다.

→ 회귀분석 결과로 산출되는 F통계량의 p-값이 0.05보다 작으면 회귀 모형은 통계적으로 유의하다.

- 회귀 분석의 가정 중 정상성은 ()이/가 정규분포를 이뤄야 함을 가정한다.

잔차항

- 다음은 회귀 분석의 분산분석표이다. 결정계수의 값은?

	df	Sum Sq	Mean Sq	F value	Pr(>F)
x1	1	280	280	756.8	2.2e-16***
Residuals	1923	720	0.37		

전체 변동(SST)은 280+720이며 잔차에 대한 변동(SSE)은 720으로

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST} = 1 - \frac{720}{1000} = \frac{280}{1000}$$

- 다중 공선성에 대한 설명으로 다음 중 가장 옳지 않은 것은 무엇인가?

- ① 구조적 다중 공선성의 문제가 있는 경우에는 데이터의 평균은 변화한다.
 - ② 일반적으로 VIF값이 10 이상이면 다중공선성에 문제가 있다고 판단한다.
 - ③ VIF 값이 "1"에 가까우면 다중공선성이 존재한다.
 - ④ 다중공선성 문제를 해결하기 위해 중요하지 않지만 다른 변수의 상관성이 높은 변수를 제거한다.
- 분산팽창요인(VIF)은 다중회귀모형에서 독립변수 간 상관관계가 있는지 측정하는 척도로 1에 가까울수록 다중 공선성이 낮고 4보다 크면 다중공선성이 존재, 10보다 크면 심각한 문제가 있는 것으로 해석한다.

- 다음은 cars데이터 세트에서 속도와 제동거리의 관계를 회귀모형으로 분석한 것이다. 다음 중 옳지 않은 것은 무엇인가?

- ① 회귀 계수는 5% 수준에서 유의하다.
 - ② 잔차 분산 σ^2 의 불편추정량은 236.5이다.
 - ③ 전체 관측치 수가 49개이다.
 - ④ 결정계수는 0.6511이다.
- 전체 관측치 수는 50개이다.

```
Call:
lm(formula = dist ~ speed, data = cars)

Residuals:
    Min       1Q   Median       3Q      Max
-29.069  -9.525  -2.272   9.215  43.201

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -17.5791     6.7584  -2.601   0.0123 *
speed         3.9324     0.4155   9.464 1.49e-12 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 15.38 on 48 degrees of freedom
Multiple R-squared:  0.6511,    Adjusted R-squared:  0.6438
F-statistic: 89.57 on 1 and 48 DF,  p-value: 1.49e-12

> anova(out)
Analysis of Variance Table

Response: dist
      Df Sum Sq Mean Sq F value    Pr(>F)
speed   1  21186  21185.5   89.567 1.49e-12 ***
Residuals 48  11354    236.5
```

- 회귀 분석에서 독립변수 간 상관관계가 높아 많은 문제점을 발생하는 현상을 무엇이라 하는가?


① 다중 공선성

② 상관행렬

③ 능형회귀

④ 전진 선택법

- 다음 그림은 회귀분석에서 잔차 분석의 어떤 가정을 위배하고 있는가?



- ① 선형성
- ② 정규성
- ③ 등분산성
- ④ 독립성

→ 등분산성을 만족하려면 잔차의 분산이 독립변수와 무관하게 일정해야 한다.

- 다중 공선성에 대한 설명 중 옳바르지 않은 것은?

① 다중 공선성 문제가 발생하면 문제가 있는 변수를 제거하고 분석할 수 있다.

② 다중 공선성 문제로 불확실성이 감소할 수 있다.


③ 독립변수 간에 상관관계가 높아서 데이터를 분석할 때 부정적 영향을 미치는 경우가 발생한다.

④ VIF가 4보다 크면 다중 공선성이 존재하는 것으로 해석한다.

→ 다중 공선성이 발생하면 불확실성은 커진다.

- 다음은 결과를 생성한 잔차도이다. 다음 중 어떤 회귀분석의 가정이 위배되었다고 판단할 수 있는지 고르시오.

- ① 비정규성
- ② 독립성
- ③ 선형성
- ④ 정상성



- 선형성을 만족하려면 잔차들의 평균값은 일정해야 한다.
- 정상적이라면 평균값들을 선으로 이었을 때 일직선이 되고 비정상적이라면 U자 형태의 모양이 나온다.

- 회귀 분석에서 잔차 분석은 회귀 모형에 대한 가정을 충족하는지에 대한 검정, 이상값이 있는지에 대한 검정을 하는 절차이다. 이와 관련된 가정으로 적합한 것은 무엇인가?

- ① 독립성, 적정성, 유일성
- ② 독립성, 등분산성, 정규성
- ③ 정규성, 효과성, 등분산성
- ④ 정규성, 유일성, 독립성

→ 회귀분석의 가정은 선형성/독립성/등분산성/비상관성/정상성이 있음

- 다음 중 잔차 분석에 대한 설명으로 옳지 않은 것은?

- ① 잔차 분석은 회귀 모형에 대한 가정을 충족하는지를 검정하는 절차이다.
 - ② 잔차항이 정규분포를 따르는지 알아보는 검정으로 샤피로-윌크 검정이 있다.
 - ③ 더빈-왓슨 검정은 등분산성에 대한 검정 기법이다.
 - ④ 잔차는 특정한 패턴이 없어야 한다.
- 더빈-왓슨 검정은 회귀모형 오차항의 자기 상관에 있는지에 대한 검정으로 독립성 검정 기법이다.

- 다음은 다중 회귀의 어떤 단계적 변수 선택에 관한 설명인가?

독립변수 후보 모두를 포함한 모형에서 출발해 제곱합의 기준으로 가장 적은 영향을 주는 변수로부터 하나씩 제거하면서 더 이상 유의하지 않은 변수가 없을 때까지 독립변수를 제거하고, 이때 모형을 선택한다.

후진제거법

• 다음 중 모델의 정확도 및 성능을 향상하기 위한 변수 선택 방법으로 적합하지 않은 것은?

- ① 단계적 방법
- ② 전진 선택법
- ③ 순차적 방법
- ④ 후진 제거법

- cars데이터에 대해서 종속변수를 dist로, 독립변수는 speed로 회귀분석을 하려고 한다. 적절한 R 코드는 무엇인가?

```
> data(cars)
> summary()

Call:
lm(formula = dist ~ speed, data = cars)

Residuals:
    Min       1Q   Median       3Q      Max
-29.069  -9.525  -2.272   9.215  43.201

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -17.5791     6.7584  -2.601   0.0123 *
speed         3.9324     0.4155   9.464 1.49e-12 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 15.38 on 48 degrees of freedom
Multiple R-squared:  0.6511,    Adjusted R-squared:  0.6438
F-statistic: 89.57 on 1 and 48 DF,  p-value: 1.49e-12
```

- ① glm(dist~speed, data=cars)
- ② lm(speed~dist, data=cars)
- ③ lm(dist~speed, data=cars)
- ④ glm(speed~dist, data=cars)

- 다음의 회귀 방정식의 summary 결과에서 후진 제거법으로 변수 선택법을 사용할 때 가장 먼저 제거되는 변수는 다음 중 무엇인가?

① cyl

② hp

③ wt

④ (Intercept)

```
Call:
lm(formula = mpg ~ cyl + hp + wt, data = mtcars)

Residuals:
    Min       1Q   Median       3Q      Max
-3.9290 -1.5598 -0.5311  1.1850  5.8986

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  38.75179    1.78686   21.687  < 2e-16 ***
cyl          -0.94162    0.55092   -1.709  0.098480 .
hp           -0.01804    0.01188   -1.519  0.140015
wt           -3.16697    0.74058   -4.276  0.000199 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.512 on 28 degrees of freedom
Multiple R-squared:  0.8431,    Adjusted R-squared:  0.8263
F-statistic: 50.17 on 3 and 28 DF,  p-value: 2.184e-11
```

→ 후진제거법은 모든 변수를 포함한 상태에서 가장 적은 영향을 주는 변수부터 제거하는 방식으로 p-값이 가장 큰 변수부터 제거하게 됨

- 다음 모형의 변수 선택에 대한 설명으로 부적절한 것은?

① Start AIC보다 작은 모든 변수는 다음 Step에서 모두 제외된다.

② 한번 제거된 변수는 다시 모형에 포함되지 않는다.

③ 후진 제거법으로 변수 선택을 하고 있다.

④ 모든 독립변수가 포함된 모형에서 시작한다.

→ 후진제거법은 가장 적은 영향을 주는 변수부터 하나씩 제거하는 방법으로 AIC값이 Start보다 작은 변수 중 가장 작은 값을 하나씩 제거한다.

```
> model<-lm(mpg~., data=mtcars)
> step(model, direction='backward')
Start: AIC=70.9
mpg ~ cyl + disp + hp + drat + wt + qsec + vs + am + gear + carb
```

	Df	Sum of Sq	RSS	AIC
- cyl	1	0.0799	147.57	68.915
- vs	1	0.1601	147.66	68.932
- carb	1	0.4067	147.90	68.986
- gear	1	1.3531	148.85	69.190
- drat	1	1.6270	149.12	69.249
- disp	1	3.9167	151.41	69.736
- hp	1	6.8399	154.33	70.348
- qsec	1	8.8641	156.36	70.765
<none>			147.49	70.898
- am	1	10.5467	158.04	71.108
- wt	1	27.0144	174.51	74.280

• 다음 회귀모형에 관한 설명 중 가장 부적절한 것은 무엇인가?

- ① 유의수준 0.05에서 회귀모형은 유의적으로 종속변수를 설명한다.
- ② Examination은 종속변수 변동의 원인이다.
- ③ 회귀식의 y절편은 66.915이다.
- ④ 수정 결정계수는 0.671이다.

```
Call:
lm(formula = Fertility ~ ., data = swiss)

Residuals:
    Min       1Q   Median       3Q      Max
-15.2743  -5.2617   0.5032   4.1198  15.3213

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  66.91518   10.70604   6.250 1.91e-07 ***
Agriculture  -0.17211    0.07030  -2.448  0.01873 *
Examination  -0.25801    0.25388  -1.016  0.31546
Education    -0.87094    0.18303  -4.758 2.43e-05 ***
Catholic      0.10412    0.03526   2.953  0.00519 **
Infant.Mortality 1.07705    0.38172   2.822  0.00734 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 7.165 on 41 degrees of freedom
Multiple R-squared:  0.7067,    Adjusted R-squared:  0.671
F-statistic: 19.76 on 5 and 41 DF,  p-value: 5.594e-10
```

- 다음 중 다중 회귀 분석에서 종속변수에 가장 유의한 변수는?

Education

```
Call:
lm(formula = Fertility ~ ., data = swiss)

Residuals:
    Min       1Q   Median       3Q      Max
-15.2743  -5.2617   0.5032   4.1198  15.3213

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   66.91518   10.70604     6.250 1.91e-07 ***
Agriculture   -0.17211    0.07030    -2.448  0.01873  *
Examination   -0.25801    0.25388    -1.016  0.31546
Education     -0.87094    0.18303    -4.758 2.43e-05 ***
Catholic       0.10412    0.03526     2.953  0.00519  **
Infant.Mortality 1.07705    0.38172     2.822  0.00734  **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 7.165 on 41 degrees of freedom
Multiple R-squared:  0.7067,    Adjusted R-squared:  0.671
F-statistic: 19.76 on 5 and 41 DF, p-value: 5.594e-10
```

- 다음은 특정 제품의 Sales와 TV, Radio, Newspaper 광고 예산 간의 피어슨 상관계수 행렬이다. 설명이 가장 알맞지 않은 것은?

	TV	Radio	Newspaper	Sales
TV	1.000	0.054	0.057	0.793
Radio	0.054	1.000	0.333	0.543
Newspaper	0.057	0.333	1.000	0.222
Sales	0.793	0.543	0.222	1.000

- ① 3가지 매체의 광고 예산은 Sales와 양의 상관관계를 가지고 있다.
 - ② Newspaper 광고 예산이 증가할 때 Radio 광고 예산이 증가하는 경향이 있다.
 - ③ TV 광고 예산을 늘리면 Sales가 증가하는 인과관계가 있다.
 - ④ Sales와 가장 상관관계가 높은 변수는 TV이다.
- 상관 분석으로 인과관계는 알 수 없다.

- 스피어만 상관계수를 계산할 때 대상이 되는 자료의 종류는 무엇이어야 하는가?

① 서열 척도

② 명목 척도

③ 비율 척도

④ 등간 척도

→ 피어슨 상관계수는 비율/등간 척도, 스피어만 상관계수는 서열 척도, 카이제곱 검정은 명목 척도이다.

- 다음 중 상관 분석에 대한 설명으로 부적합한 것은?

- ① 스피어만 상관계수로 두 변수 간의 비선형 관계를 확인할 수 있다.
 - ② 두 변수의 상관관계를 연구할 때 상관계수만으로 해석하면 문제가 된다.
 - ③ 독립변수와 종속변수 간에 선형적인 관계를 도출해서 하나 이상의 독립변수들이 종속 변수에 미치는 영향을 분석하고 독립변수를 통해 종속변수를 예측하는 기법이다.
 - ④ 상관계수는 선형성, 등분산성이라는 가정을 만족시켜야 한다.
- 독립변수와 종속변수 사이의 인과관계를 밝히고 모형을 적합하여 관심 있는 변수를 예측하거나 추론하는 것은 회귀 분석에 대한 설명이다.

- 다중공선성에 대한 설명 중 옳바르지 않은 것은?

① 다중공선성 문제가 발생하면 문제가 있는 변수를 제거하고 분석할 수 있다.

② 다중공선성 문제로 불확실성이 감소할 수 있다.

③ 독립변수 간에 상관관계가 높아서 데이터를 분석할 때 부정적 영향을 미치는 경우 발생한다.

④ VIF가 4보다 크면 다중공선성이 존재하는 것으로 해석한다.

→ 다중공선성이 발생하면 불확실성은 커진다.

- 다음 주성분 분석에 대한 설명 중 옳바르지 않은 것은?

```
> md_comp<-princomp(swiss, cor=FALSE)
> summary(md_comp)
Importance of components:

            Comp.1      Comp.2      Comp.3      Comp.4
Standard deviation  43.3667866  21.3712016  11.92449843  4.708258751
Proportion of Variance  0.7460284  0.1811752  0.05640546  0.008793495
Cumulative Proportion  0.7460284  0.9272036  0.98360907  0.992402568

            Comp.5      Comp.6
Standard deviation  3.618425207  2.461609258
Proportion of Variance  0.005193739  0.002403694
Cumulative Proportion  0.997596306  1.000000000
```

- ① 첫 번째 주성분은 전체 분산 중 약 74.6%를 설명하고 있다.
- ② 두 번째 주성분까지 포함하면 전체 분산의 약 92.7%까지 설명할 수 있다.
- ③ 모델은 상관 행렬을 사용했다.
- ④ summary의 결과는 6개 주성분의 표준편차, 분산의 비율을 보여준다.
→ cor=TRUE일때 상관 행렬을 이용한 것이다.

- 스피어만 상관계수에 대한 설명 중 옳바르지 않은 것은?

① 두 변수 간의 비선형적인 관계는 나타내지 못한다.

② 연속형 외에 이산형도 가능하다.

③ 관계가 랜덤이거나 존재하지 않으면 상관계수 모두 0에 가깝다.

④ 스피어만 상관계수는 원시 데이터가 아니라 각 변수에 대해 순위를 매긴 값을 기반으로 한다.

→ 스피어만 상관계수는 정규성 가정이 필요하지 않은 비모수 통계 기법으로 두 변수 간의 비선형적인(곡선) 관계를 나타낼 수 있다.

• 다음 중 공분산과 상관계수에 대한 설명 중 가장 옳바르지 않은 것은?

① 공분산은 측정 단위에 영향을 받지 않는다.

② 상관 분석은 두 변수의 인과 관계 성립 여부를 확인할 수 없다.

③ 공분산이 0이라면 두 변수 간에는 아무런 선형 관계가 없고 서로 독립적인 관계에 있다.

④ 상관계수를 통해 상관관계의 표준화된 크기를 측정할 수 있다.

→ 공분산은 측정 단위에 영향을 받는다. 이를 표준화해서 -1~1로 바꾸어 준 것이 상관계수이다.

- 다음 중 두 변수 간의 비선형적인 관계도 나타낼 수 있으며 한 변수를 단조 증가 함수로 변환하여 다른 변수를 나타낼 수 있는 정도를 나타내는 상관계수는 무엇인가?

① 스피어만 상관계수

② 코사인 유사도

③ 피어슨 상관계수

④ 자카드 인덱스

→ 단조함수는 주어진 순서를 보존하는 함수로 스피어만 상관계수는 한 변수의 값이 커지면 다른 변수의 값도 단조롭게 커지는지 또는 작아지는지 알아보기 위한 값이다.

- 다음은 mtcars 데이터 세트의 변수 간 상관계수를 나타낸 행렬이다. 다음 행렬에 대한 설명으로 가장 옳지 않은 것은 무엇인가?

	mpg	cyl	drat	qsec
mpg	1.00	-0.85	0.68	0.42
cyl	-0.85	1.00	-0.70	-0.59
drat	0.68	-0.70	1.00	0.09
qsec	0.42	-0.59	0.09	1.00

- ① drat와 qsec는 상관관계가 거의 없다고 할 수 있다.
 - ② mpg와 cyl은 음의 상관 관계이다.
 - ③ 상관계수의 절대값이 크면 두 변수 간의 선형 관계가 크다.
 - ④ disp와 cyl의 상관계수는 통계적으로 유의하다.
- 상관계수만으로 통계적 유의성을 확인할 수 없다.

- 다음이 설명하는 분석 기법은 무엇인가?

상관관계가 있는 고차원 자료를 자료의 변동을 최대한 보존하는 저차원 자료를 변환
서로 상관성이 높은 변수들의 선형 결합으로 만들어 기존의 상관성이 높은 변수들을 요약,
축소하는 기법

① 다중 회귀 분석

② 판별 분석

③ 주성분 분석

④ 요인 분석

- 주성분 분석에 대한 설명으로 옳지 않은 내용은?

- ① 주성분 분석은 수학적으로 직교 선형 변환으로 정의한다.

- ② 주성분은 선형 결합으로 이루어져 있다.

- ③ 주성분 분석의 목적 중 하나는 데이터를 이해하기 위한 차원 축소이다.

- ④ 상관관계가 있는 고차원 자료의 변동을 최대한 제거하는 기법이다.

→ 상관관계가 있는 고차원 자료를 자료의 변동을 최대한 보존하는 저차원 자료로 변환하는 차원 축소 방법이다.

- 주성분 분석에 대한 설명으로 가장 옳바르지 않은 것은?

① 분산이 가장 작은 것을 제1 주성분으로 한다.

② 상관관계가 있는 고차원의 자료를 자료의 변동을 최대한 보존하는 저차원 자료로 변환하는 차원 축소 방법이다.

③ 누적 기여율이 85% 이상이면 주성분의 수로 결정할 수 있다.

④ 차원 감소 폭의 결정은 스크리 산점도를 활용한다.

→ 제1 주성분은 데이터의 변동을 최대로 설명해주는 변수들의 선형 결합이다.

- 다음은 princomp(x, cor=TRUE) 함수를 이용한 주성분 분석의 결과이다. 해석으로 가장 올바른 것은?

	PC1	PC2	PC3	PC4
Standard deviation	1.71	0.96	0.38	0.14
Proportion of Variance	0.73	0.23	0.03	0.01
Cumulative Proportion	0.73	0.96	0.99	1.00

- ① 상관 행렬을 활용한 결과이다. → cor=TRUE이면 상관계수 행렬 사용
- ② 제1성분의 설명력은 40%이다. → 제1성분의 설명력은 73%이다.
- ③ 제3 주성분일 때 정보손실은 10%이다. → 제3 주성분일때 정보손실은 1%이다.
- ④ 85% 이상 설명하려면 주성분 3개 이상 선택하면 된다. → 주성분 2개 이상 선택하면 된다

• 주성분 분석에서 변수의 중요도 기준이 되는 값은 무엇인가?

① 고유값

② 특이값

③ 표준오차

④ 스칼라

→ 주성분 분석은 차원을 축소할 때 변동 폭이 큰 축을 선택한다. 차원 축소는 고유값이 높은 순으로 정렬해서 높은 고유값을 가진 고유벡터만으로 데이터를 복원한다.

- 주성분 분석에서 주성분 2개를 수용했을 때 잃는 정보량은 얼마인가?

	PC1	PC2	PC3	PC4
Standard deviation	2.049	0.491	0.278	0.153
Proportion of Variance	0.924	0.053	0.017	0.006
Cumulative Proportion	0.924	0.977	0.994	1.000

100%-97.7%인 2.3%의 정보량을 잃게 된다.

- 주성분 분석의 결과에서 두번째 주성분은 전체 분산의 몇 퍼센트를 설명하고 있는가?

	PC1	PC2	PC3	PC4
Standard deviation	2.049	0.491	0.279	0.153
Proportion of Variance	0.924	0.053	0.017	0.006
Cumulative Proportion	0.924	0.977	0.994	1.000

분산비율이 전체 분산에서 해당 분산이 차지하는 비율이므로 두번째 분산은 0.053으로 5.3%이다.

- 다음은 `prcomp(x, scale=TRUE)` 함수를 통한 주성분 분석 결과이다. 설명 중 옳바르지 않은 것은?

	PC1	PC2	PC3	PC4
Standard deviation	1.708	0.956	0.383	0.143
Proportion of Variance	0.729	0.228	0.036	0.007
Cumulative Proportion	0.729	0.957	0.993	1.000

	PC1	PC2	PC3	PC4
변수1	0.521	-0.377	0.719	0.261
변수2	-0.269	-0.923	-0.244	-0.123
변수3	0.580	-0.024	-0.142	-0.801
변수4	0.564	-0.066	-0.634	0.523

- 주성분 분석 결과에 대한 설명 중 옳바르지 않은 것은?

- ① 주성분 분석이란 다변량 자료 분석에 이용하는 독립변수를 분석에 이용한다.
 - ② 제3 주성분의 적재 값을 통해 4개의 변수 모두가 제3 주성분과 음의 관련이 있음을 보여준다.
 - ③ 위 주성분 분석에서는 상관계수 행렬을 사용하였다.
 - ④ 변수1은 PC1~PC4의 선형결합으로 나타낼 수 있다.
- 제3 주성분의 적재값에 0.719라는 음의 관련이 없는 적재값이 있다.

- 다음 표는 주성분 분석의 적재 값이다. 제1 주성분의 함수식을 쓰시오.

	PC1	PC2	PC3	PC4
변수1	0.361	0.657	0.582	0.315
변수2		0.730	-0.598	-0.320
변수3	0.857	-0.173		-0.480
변수4	0.358		-0.546	0.754

$$0.361*변수1 + 0.857*변수3 + 0.358*변수4$$

- 다음 중 주성분 분석에서 주성분을 선택하는 방법에 대한 설명으로 가장 옳지 않은 것은 무엇인가?

- ① 스크리 산점도는 고유값의 크기순으로 산점도를 그린 그래프에서 기울기가 완만해지는 지점에서 1을 뺀 개수를 주성분의 개수로 선택하는 방법이다.
- ② 전체 변이 공헌도 방법은 주성분들이 설명하는 총 분산의 비율이 70~90% 사이가 되는 주성분의 개수를 선택하는 방법이다.
- ③ 평균 고유값 방법은 고유값들의 평균을 구한 후 고유값이 평균값 이상이 되는 주성분을 제거하는 방법이다.
- ④ 주성분은 주성분을 구성하는 변수들의 계수 구조를 파악하여 적절하게 해석한다.
→ 평균 고유값 방법은 고유값들의 평균을 구한 후 고유값이 평균값 이상이 되는 주성분을 선택하는 방법이다.

• 다음 중 이질적인 모집단을 세분화시키는 방법은?

① 연관 분석

② 군집 분석

③ 분류 분석

④ 주성분 분석

- 다음 중 군집 분석에 관한 설명 중 옳바르지 않은 것은?

- ① 비 계층적 군집 분석의 경우 사용자가 사전 지식 없이 그룹의 수를 정해주는 일이 많아서 결과가 잘 나오지 않을 수 있다.
 - ② 계층적 군집 분석은 이상값에 민감하다.
 - ③ 군집 결과에 대한 안정성을 검토하는 방법이 지도학습과 같은 교차 타당성을 이용한다.
 - ④ 군집 분석은 신뢰성과 타당성을 점검하기 어렵다.
- 군집 분석은 비지도학습으로 지도학습처럼 교차 검증을 통해 군집결과에 대한 안정성을 검토하지 않는다.

- 다음 중 군집 분석에 대한 설명으로 가장 옳바르지 않은 것은?

① 군집 분석은 데이터에 분류의 기준이 없는 비지도 학습 방법을 사용한다.

② 계층적 군집 분석은 덴드로그램으로 표현할 수 있다.

③ 군집 분석에서는 군집을 두 개로 나누어 교차 타당성 검증을 사용한다.

④ 계층적 군집은 한번 군집이 형성되면 다른 군집으로 이동할 수 없다.

→ 군집 분석은 비지도학습으로 지도학습처럼 교차 검증을 통해 군집결과에 대한 안정성을 검토하지 않는다.

• 다음 중 분석 방법이 나머지와 다른 것은 무엇인가?

① PCA

② DBSCAN

③ Single Linkage Method

④ K-Means Clustering

→ ①은 주성분 분석이며 ②③④는 군집분석 방법이다.

• 다음 중 군집의 개수를 미리 정하지 않아도 되는 장점으로 탐색적 분석에 사용하는 군집모형은?

① SOM 모형

② 계층적 군집모형

③ 혼합 분포 군집모형

④ K-평균 군집모형

→ 계층적 군집은 군집의 개수를 미리 정하지 않고 유사한 개체를 묶어 나가는 과정을 반복하여 원하는 개수의 군집을 형성하는 방법이다. 비계층적 군집은 미리 군집의 개수를 지정한다.

• 다음 중 군집 간의 거리에 기반하는 다른 연결법과는 다르게 군집 내의 오차 제공 합에 기초하여 군집을 수행하는 계층적 군집분석의 거리 측정 방법은?

- ① 최단 연결법
- ② 평균 연결법
- ③ 와드 연결법
- ④ 최장 연결법

- 다음은 계층적 군집을 수행하기 위한 거리 측정 방법 중 어떤 방법을 사용한 것인가?

두 군집 사이의 거리를 각 군집에서 하나씩 관측값을 뽑았을 때 나타날 수 있는 거리의 최소값으로 측정해서 가장 유사성이 큰 군집으로 병합해 나가는 방법

→ 최단 연결법

- 다음 중 계층적 군집에 관한 설명 중 적절하지 않은 것은?

- ① 최단연결법 또는 단일연결법은 두 군집 사이의 거리를 각 군집에서 하나씩 관측값을 뽑았을 때 나타날 수 있는 거리의 최소값으로 측정한다.
- ② 최단연결법은 최단 거리를 사용할 때 사슬 모양으로 생길 수 있으며 고립된 군집을 찾는데 중점을 둔 방법이다.
- ③ 중심연결법은 두 군집의 중심 간의 거리를 측정하여 가장 유사성이 큰 군집으로 병합해 나가는 방법으로 두 군집이 결합할 때 새로운 군집의 평균은 가중평균을 통해 구해진다.
- ④ 최단연결법은 평균연결법보다 계산량이 많아질 수 있다.

- 다음 중 아래의 위치 데이터를 이용하여 계층적 군집 분석 중 최단 연결법을 통해 3개의 군집으로 나눌 때 가장 적절한 것은?

데이터	(x_1, x_2)
a	(1, 5)
b	(2, 4)
c	(4, 6)
d	(4, 3)
e	(5, 3)

- ① (d,e), (a,b), c
- ② (a,c), (b,d), e
- ③ (a,b), (e,d), c
- ④ (a,d), (b,c), e

- 1단계: 유클리드 제곱 거리 구하기

데이터	(x_1, x_2)
A	(1, 5)
B	(2, 4)
C	(4, 6)
D	(4, 3)
E	(5, 3)

	A	B	C	D	E
A	0				
B	2	0			
C	10	8	0		
D	13	5	9	0	
E	20	10	10	1	0

$$d(d, e) = \sqrt{(4 - 5)^2 + (3 - 3)^2} = \sqrt{1}$$

숫자를 단순하게 처리하기 위해 루트가 없다고 생각

- 2단계: 유클리드 제곱 거리 구하기

	A	B	C	(D,E)
A	0			
B	2	0		
C	10	8	0	
(D,E)	13	5	9	0

A,B,C 데이터와 (D,E) 군집의 거리 계산은 D,E중 가까운 데이터의 거리를 계산
A,B가 가장 가깝다는 것을 파악

$$d(a, b) = \sqrt{(1 - 2)^2 + (5 - 4)^2} = \sqrt{2}$$

- 3단계: 유클리드 제곱 거리 구하기

	(A,B)	C	(D,E)
(A,B)	0		
C	8	0	
(D,E)	5	9	0


(A,B) 데이터와 (D,E) 군집의 거리 계산은 D,E중 가까운 데이터의 거리를 계산
B,D의 거리가 가장 가까움

$$d(b, d) = \sqrt{(2 - 4)^2 + (4 - 3)^2} = \sqrt{5}$$

C 데이터와 (A,B)와 (D,E) 군집의 거리 계산은 가까운 데이터의 거리를 계산
B,C의 거리가 가장 가까움

$$d(b, c) = \sqrt{(2 - 4)^2 + (4 - 6)^2} = \sqrt{8}$$

- 4단계: 덴드로그램 그리기



- 다음은 5개의 관측값에 대한 유클리디안 거리를 표로 나타낸 것이다. 최단 연결법을 사용하여 계층적 군집을 시행하면 처음에 형성되는 군집과 관측값 a의 거리는 얼마인가?

	A	B	C	D
B	3.2			
C	3.5	5.2		
D	3.2	2.6	3.4	
E	4.8	3.4	5.3	2.2

- 다음은 5개의 관측값에 대한 유클리디안 거리를 표로 나타낸 것이다. 최단 연결법을 사용하여 계층적 군집을 시행하면 처음에 형성되는 군집과 관측값 a의 거리는 얼마인가?

→ 최초 형성 군집 (D,E)

→ D와 A의 거리는 3.2, E와 A의 거리는 4.8

→ 둘 중 더 가까운 것으로 계산되는 방법이 최단연결법으로 3.2가 됨

	A	B	C	D
B	3.2			
C	3.5	5.2		
D	3.2	2.6	3.4	
E	4.8	3.4	5.3	2.2

• 다음 중 군집 분석에서의 유사도 측정에 대한 설명으로 가장 옳바르지 않은 것은?

① 맨하탄 거리는 각 방향 직각의 이동 거리 합으로 계산된다.

② 표준화 거리는 각 변수를 해당 변수의 표준편차로 변환한 후 유클리드 거리를 계산한 거리이다.

③ 마할라노비스 거리는 변수의 표준편차를 고려한 거리 척도이나 변수 간에 상관성이 있는 경우에는 표준화 거리 사용을 검토해야 한다.

④ 유클리드 거리는 두 점을 잇는 가장 짧은 직선거리이다.

→ 마할라노비스 거리는 변수의 표준화와 함께 변수 간의 상관성을 고려한 통계적 거리임

- 다음은 학생들의 키와 몸무게를 정규화한 데이터이다. 맨하탄 거리를 이용하여 A와 B의 거리를 구하시오.

사람	(키, 몸무게)
A	(1,5)
B	(2,4)

맨하탄 거리는 두 점 간 차의 절대값을 합한 값이다.

$$d(i,j) = \sum_{f=1}^p |x_{if} - y_{jf}| = |2 - 1| + |4 - 5| = 1 + 1 = 2$$

- 계층적 군집은 두 개체 간의 거리에 기반하므로 거리 측정에 대한 정의가 필요하다. 다음 중 `dist()` 함수에서 지원하지 않는 거리는?

- ① 유클리드
- ② 맨하탄
- ③ 민코프스키
- ④ 코사인

- 명목형 변수의 두 개체 간 거리 측도 중에서 두 벡터 사이의 각도를 이용하여 개체 간의 유사도를 측정하는 측도는 무엇인가?

① 코사인 유사도

② 피어슨 유사도

③ 자카드 유사도

④ 맨하탄 거리

- 다음 데이터 세트에서 A,B간의 유클리드 거리를 계산하면?

	A	B
키	175	180
몸무게	45	50

① 0 ② $\sqrt{5}$ ③ $\sqrt{25}$ ④ $\sqrt{50}$

→ 유클리드 거리는 두 점을 잇는 가장 짧은 직선거리로

$$\rightarrow \sqrt{(175 - 180)^2 + (45 - 50)^2} = \sqrt{50}$$

• 다음 중 민코프스키 거리를 나타내는 수식은 무엇인가?

① $d(x, y) = \max |x_i - y_i|$

② $d(x, y) = \sqrt{\sum_{i=1}^p (x_i - y_i)^2}$

③ $d(x, y) = [\sum_{i=1}^p |x_i - y_i|^m]^{1/m}$

④ $d(x, y) = \sum_{i=1}^p |x_i - y_i|$

- 계층적 군집 방법의 거리에 대한 정의 중 변수의 표준화와 변수 간의 상관성을 동시에 고려한 통계적 거리는?

- ① 자카드 계수
- ② 마할라노비스 거리
- ③ 민코우스키 거리
- ④ 맨하탄 거리

- 다음 중 k평균 군집에 대한 설명으로 올바른 것은?
 - ① k평균 군집에서 군집의 수는 지정하지 않는다.
 - ② k평균 군집은 한번 군집이 형성되면 군집에 속한 개체는 다른 군집으로 이동할 수 없다.
 - ③ k평균 군집 결과는 덴드로그램의 형태로 표현된다.
 - ④ 알고리즘이 단순하며 빠르게 수행되며 계층적 군집보다 많은 양의 자료를 다룰 수 있다.

• 다음 중 k 평균 군집에서 단점을 보완하는 방법으로 올바른 것은?

- ① 이상값 자료에 민감한 k -평균 군집의 단점을 보완하기 위해 군집을 형성하는 단계마다 평균 대신 중앙값을 사용하는 k -중앙값 군집을 사용한다.
- ② k 평균은 군집의 수를 미리 정할 필요가 없다.
- ③ 불룩한 형태가 아닌 군집이 존재할 때 군집 성능이 높아진다.
- ④ 조화평균을 사용한다.

- 군집 분석의 품질을 정량적으로 평가하는 대표적인 지표로 군집 내의 데이터 응집도와 군집 간 분리도를 계산하여 군집 내의 데이터의 거리가 짧을수록, 군집 간 거리가 멀수록 값이 커지며 완벽한 분리일 경우 1의 값을 가지는 지표는?

→ 실루엣 계수(지수)

- K평균 군집으로 대표되는 비 계층적 군집 방법에서 군집의 개수인 k 를 미리 정해주어야 한다. 다음 중 군집 수를 정하는 데 활용할 수 있는 그래프로 가장 적절한 것은?

① ROC 그래프

② 향상도 곡선

③ 오차제곱합

④ 집단 내 제곱합 그래프

→ 군집 수에 따른 집단 내 제곱 합의 그래프를 그려보는 방법을 활용할 수 있음

- 다음은 K평균 군집을 수행하는 절차이다. 다음 중 K-평균 군집의 수행 절차를 순서대로 올바르게 나열한 것은?

- ㉠ 각 자료를 가장 가까운 군집의 중심에 할당한다.
- ㉡ 군집 중심의 변화가 거의 없을 때(또는 최대 반복 수)까지 단계2와 단계3을 반복한다.
- ㉢ 초기(군집의) 중심으로 k개의 객체를 임의로 선택한다.
- ㉣ 각 군집 내의 자료들의 평균을 계산하여 군집의 중심을 갱신한다.

① ㉢ → ㉣ → ㉠ → ㉡

② ㉢ → ㉠ → ㉣ → ㉡

③ ㉠ → ㉣ → ㉢ → ㉡

④ ㉠ → ㉢ → ㉣ → ㉡

- 비 계층적 군집 방법인 K-평균 군집은 이상값 자료에 민감하다는 단점이 있다.
다음 중 이러한 단점을 극복하기 위해 등장한 비 계층적 군집 방법으로 가장 적절한 것은?

- ① EM Clustering
- ② 혼합 분포 군집
- ③ Density Based Clustering
- ④ K-Medoids Clustering

→ 군집을 형성하는 단계마다 평균값 대신 중앙값을 사용하여 군집을 형성하는 비 계층적 군집 방법은 k-중앙값 군집이다.

- 다음이 설명하는 군집 분석 방법은?

여러 분포를 확률적으로 선형 결합하여 데이터가 k 개의 모수적 모형의 가중 합으로 표현되는 모집단 모형으로부터 나왔다는 가정하에 자료로부터 모수와 가중치를 추정하는 방법

① DBSCAN

② 혼합 분포 군집

③ EM 알고리즘

④ SOM

→ EM알고리즘은 혼합모형으로부터 모수와 가중치를 추정하는 알고리즘이다.

• 다음 중 EM알고리즘의 진행 과정 중 임의의 파라미터의 값을 정한 후 Z 의 기대치를 계산하는 단계는?

① 파라미터 추정 단계

② E-단계

③ M-단계

④ 조건부 기대값 대입 단계

→ E-단계는 잠재변수 Z 의 기대치를 계산하고 M-단계는 잠재변수 Z 의 기대치를 이용하여 파라미터를 추정한다.

- 혼합 분포 군집은 모형기반의 군집 방법으로 데이터가 K개의 모수적 모형의 가중 합으로 표현되는 모집단 모형으로부터 나왔다는 가정하에 분석하는 방법이다. K개의 각 모형은 군집을 의미하며 이 혼합모형으로 모수와 가중치의 최대 가능도 추정에 사용되는 알고리즘은?

- ① 역전파 알고리즘
- ② 전방 패스 알고리즘
- ③ EM 알고리즘
- ④ 탐욕적 알고리즘

- 다음 중 데이터가 많은 지역을 중심으로 클러스터를 구성하여 비교적 비어있는 지역을 경계로 하는 군집기법으로 임의적인 모양의 군집 탐색에 효과적인 군집기법은?

① 계층적 군집기법

② 격자 기반 군집기법

③ 분리 군집기법

④ 밀도기반 군집기법

→ 밀도기반 군집은 DBSCAN이라고도 부름

- SOM 프로세스에서 입력 벡터와 경쟁층 노드 간의 유클리드 거리를 계산하여 그중에서 제일 가까운 뉴런을 무엇이라고 하는가?

→ BMU(Best-Matching Unit)

- 코호넨의 의해 제시되었으며 비지도 신경망으로 고차원의 데이터를 이해하기 쉬운 저차원의 뉴런으로 정렬하여 지도의 형태로 형상화하는 클러스터링 방법은?

→ 자기 조직화 지도(SOM; Self-Organizing Maps)

- 다음 중 SOM 방법에 대한 설명으로 옳바르지 않은 것은?

- ① 경쟁 학습으로 각각의 뉴런이 입력 벡터와 얼마나 가까운지를 계산하여 연결 강도를 반복적으로 재조정하는 학습 과정을 거치면서 연결 강도는 입력 패턴과 가장 유사한 경쟁층 뉴런이 승자가 된다.
- ② 고차원의 데이터를 저차원의 지도형태로 형상화하기 때문에 시각적으로 이해하기 쉬울 뿐 아니라 변수의 위치 관계를 그대로 보존하기 때문에 실제 데이터가 유사하면 지도상 가깝게 표현된다.
- ③ 입력변수의 위치 관계를 그대로 보존하여 입력변수의 정보와 그들의 관계가 지도상에 그대로 나타난다.
- ④ SOM을 이용한 군집 분석은 역전파 알고리즘을 사용함으로써 군집의 성능이 우수하고 수행속도가 빠르다.

- 다음 중 Self-Organizing Maps에서 입력 벡터의 특성에 따라 벡터의 한 점으로 클러스터링 되는 층은?

- ① 입력층
- ② 은닉층
- ③ 경쟁층
- ④ 출력층

• 다음 중 비지도 학습 기법은 무엇인가?

① SOM

② 인공신경망

③ SVM

④ 랜덤 포레스트

- 다음 중 데이터마이닝 기법 중 항목 간의 조건-결과 식으로 표현되는 유용한 패턴을 발견해내는 방법을 무엇이라고 하는가?

① 연관규칙

② 의사결정나무

③ 인공신경망

④ SOM

→ SOM은 자기 조직화 지도를 의미하며 비계층적 군집분석의 종류 중 하나이다.

• 데이터마이닝 기법 중 카탈로그 배열, 교차 판매 등의 마케팅을 계획할 때 분석하는 방법으로 가장 적절한 것은?

① 예측

② 연관분석

③ 군집

④ 분류

• 다음 중 연관규칙의 측정지표인 향상도에 대한 설명으로 올바른 것은?

① 품목 B에 대한 품목 A의 조건부 확률로 나타낸다.

② 품목 A와 B의 구매가 서로 관련이 없는 경우 향상도는 0이다.

③ 향상도가 1보다 크면 해당 규칙은 결과를 예측하는 데 있어 우수하다.

④ 전체거래 중에서 품목 A, B가 동시에 포함된 거래의 비율이다.

→ ① 신뢰도에 대한 설명이다. ② 향상도가 1일때 서로 독립적인 관계이다. ④ 지지도에 대한 설명이다.

- 다음은 상점의 판매 상품 데이터이다. 판매 상품 중 “사과→딸기”에 대한 향상도는 얼마인가?

거래 번호	판매 상품
1	배, 사과, 딸기
2	배, 사과, 포도
3	배, 자몽
4	사과, 딸기
5	배, 사과, 딸기, 포도
6	자몽

① 1.2 ② 1.5 ③ 1.7 ④ 2.0

→ A를 사과, B를 딸기로 가정했을 때 향상도 = $\frac{P(A \cap B)}{P(A) \times P(B)} = \frac{3/6}{4/6 \times 3/6} = 1.5$

- 다음은 어떤 편의점의 품목별 거래 건수이다. 연관규칙 커피→김밥에 대한 향상도는?

품목	거래 건수
커피	100
김밥	100
생수	100
커피, 김밥, 생수	50
김밥, 생수	200
커피, 김밥	250
커피, 생수	200

① 30.5% ② 50.0% ③ 83.3% ④ 93.3%

→ A를 커피, B를 김밥이라고 할 때 향상도 = $\frac{P(A \cap B)}{P(A) \times P(B)} = \frac{300/1000}{600/1000 \times 600/1000} = 0.833$

- 다음 중 A제품 구매→B제품 구매의 연관규칙 측정지표 중 지지도에 대한 설명으로 올바른 것은?

- ① A와 B가 동시에 포함된 거래 수/전체 거래 수
- ② A와 B가 동시에 포함된 거래 수/A가 포함된 거래 수
- ③ A와 B가 동시에 포함된 거래 수/B가 포함된 거래 수
- ④ A가 포함된 거래 수/전체 거래 수

- 다음 중 연관규칙 지표에 대한 설명 중 올바른 것은?

- ① 향상도가 1보다 크면 이 규칙은 결과를 예측하는 데 우수하다는 것을 의미한다.
- ② 향상도가 1보다 작으면 품목 간에 독립적인 관계로 본다.
- ③ 지지도는 조건확률로 품목 a를 구매한 사람이 품목 b도 구매한다고 해석한다.
- ④ 향상도가 1이면 두 품목 간에 상호 연관성이 높다는 것으로 해석한다.

- 다음 중 어떤 슈퍼마켓에서 고객 5명의 장바구니별 구매 품목이 다음과 같다.

연관규칙 빵→우유에 대한 신뢰도는 몇 퍼센트인가?

거래 번호	판매 상품
1	빵, 맥주
2	빵, 우유, 계란
3	맥주, 우유
4	빵, 맥주, 계란
5	빵, 맥주, 우유, 계란

① 50% ② 55% ③ 60% ④ 65%

→ A를 빵, B를 우유라고 할때 신뢰도 = $\frac{P(A \cap B)}{P(A)} = \frac{2}{4} = 0.5$

- 다음의 거래 데이터에서 추출된 연관규칙 중 하나인 “사과→치즈”의 지지도를 구하시오.

거래 번호	판매 상품
1	토마토, 사과, 치즈
2	토마토, 사과, 우유
3	토마토, 주스
4	사과, 치즈
5	토마토, 사과, 치즈, 우유
6	주스

→ 사과를 A, 치즈를 B라 할때 지지도= $P(A \cap B) = \frac{3}{6} = 0.5$

- 연관규칙의 측정지표로 두 품목의 상관관계를 기준으로 도출된 규칙의 예측력을 평가하는 지표는?

→ 향상도

- 다음은 피자와 햄버거의 거래 관계를 나타낸 표로 피자와 햄버거는 피자와 햄버거를 포함하는 거래 수를 의미하고 (피자)와 (햄버거)는 피자와 햄버거를 포함하지 않은 거래 수를 의미한다. 피자 구매와 햄버거 구매에 대한 설명으로 옳바른 것은?

구분	피자	(피자)	합계
햄버거	2,000	500	2,500
(햄버거)	1,000	1,500	2,500
합계	3,000	2,000	5,000

- ① 지지도가 0.6으로 전체 구매 중 햄버거와 피자가 같이 구매되는 경향이 높다.
- ② 정확도가 0.7로 햄버거와 피자의 구매 관련성은 높다.
- ③ 향상도가 1보다 크므로 햄버거와 피자 사이에 연관성이 높다고 할 수 있다.
- ④ 연관규칙 중 “햄버거→피자”보다 “피자→햄버거”의 신뢰도가 더 높다.

- 다음은 피자와 햄버거의 거래 관계를 나타낸 표로 피자와 햄버거는 피자와 햄버거를 포함하는 거래 수를 의미하고 (피자)와 (햄버거)는 피자와 햄버거를 포함하지 않은 거래 수를 의미한다. 피자 구매와 햄버거 구매에 대한 설명으로 올바른 것은?

구분	피자	(피자)	합계
햄버거	2,000	500	2,500
(햄버거)	1,000	1,500	2,500
합계	3,000	2,000	5,000

$$\rightarrow \text{지지도} = P(\text{피자} \cap \text{햄버거}) = \frac{2000}{5000} = 0.4$$

$$\rightarrow \text{향상도} = \frac{P(\text{피자} \cap \text{햄버거})}{P(\text{피자}) \times P(\text{햄버거})} = \frac{0.4}{3000/5000 \times 2500/5000} = \frac{4}{3}$$

$$\rightarrow \text{신뢰도}(\text{피자} \rightarrow \text{햄버거}) = \frac{P(\text{피자} \cap \text{햄버거})}{P(\text{피자})} = \frac{2/5}{3/5} = 0.67, \text{신뢰도}(\text{햄버거} \rightarrow \text{피자}) = \frac{P(\text{피자} \cap \text{햄버거})}{P(\text{햄버거})} = \frac{2/5}{1/2} = 0.8$$

- 다음은 피자와 햄버거의 거래 관계를 나타낸 표로 피자와 햄버거는 피자와 햄버거를 포함하는 거래 수를 의미하고 (피자)와 (햄버거)는 피자와 햄버거를 포함하지 않은 거래 수를 의미한다. 피자 구매와 햄버거 구매에 대한 설명으로 옳바른 것은?

구분	피자	(피자)	합계
햄버거	2,000	500	2,500
(햄버거)	1,000	1,500	2,500
합계	3,000	2,000	5,000

- ① 지지도가 0.6으로 전체 구매 중 햄버거와 피자가 같이 구매되는 경향이 높다.
- ② 정확도가 0.7로 햄버거와 피자의 구매 관련성은 높다.
- ③ 향상도가 1보다 크므로 햄버거와 피자 사이에 연관성이 높다고 할 수 있다.
- ④ 연관규칙 중 “햄버거→피자”보다 “피자→햄버거”의 신뢰도가 더 높다.

- 마트에서 팔고 있는 A제품과 B제품에 대한 지지도는 0.3, 신뢰도는 0.6이다. A제품과 B제품의 판매량이 같을 때(만약 A제품의 판매량이 100일 경우 B제품의 판매량도 100이다). A제품→B제품의 향상도는?

→ A제품의 판매량과 B제품의 판매량이 같으므로 $P(A) = P(B)$

→ 지지도 $P(A \cap B) = 0.3$

→ 신뢰도 $\frac{P(A \cap B)}{P(A)} = \frac{P(A \cap B)}{P(B)} = 0.6, P(A) = P(B) = 0.5$

→ 향상도 $\frac{P(A \cap B)}{P(A) \times P(B)} = \frac{0.3}{0.25} = 1.2$

- 다음 중 연관분석에 대한 설명으로 옳바르지 않은 것은?

- ① 품목수가 증가하면 분석에 필요한 계산은 기하급수적으로 늘어난다.
 - ② 너무 세분화된 품목을 가지고 연관규칙을 찾으려고 하면 의미 없는 분석 결과가 나올 수도 있다.
 - ③ 향상도가 1이면 두 품목 간에 연관성이 없는 서로 독립적인 관계이고 1보다 작으면 서로 음의 관계로 품목 간에 연관성이 없다.
 - ④ 시차 연관 분석은 인과관계 분석이 가능하다.
- 시간이 지남에 따라 어떤 소비형태를 보이는가에 대한 순차 패턴에 대한 분석을 시차 연관 분석이라고 하며 연관성을 파악할 수 있다.

• 다음 중 구매순서가 고려되어 상품 간의 연관성이 측정되고 유용한 연관규칙을 찾는 기법은?

- ① 회귀 분석
- ② 군집 분석
- ③ 순차 패턴
- ④ 의사결정나무

- 다음 중 연관분석의 특징으로 옳지 않은 것은?

- ① 조건반응(if then)으로 표현되는 연관 분석의 결과를 이해하기 쉽다.

- ② 비목적성 분석기법이다.

- ③ 세분화 분석 품목 없이 연관규칙을 찾을 수 있다.

- ④ 분석 계산이 간편하다.

- 적절한 세분화로 인한 품목 결정이 장점이지만 너무 세분화된 품목은 의미 없는 결과를 도출한다.

- 연관 분석을 수행하기 위해 빈발 아이템 집합과 연관규칙이라고 하는 두 가지 형태로 표현하는 연관성 분석을 수행하는 대표적인 알고리즘은?

→ 아프리오리 알고리즘

- 다음 중 연관분석의 대표적 알고리즘인 아프리오리 알고리즘의 단점을 보완하기 위해 트리와 노드 링크라는 특별한 자료구조를 사용하는 알고리즘은?

① FP-Growth

② arules

③ kohonen

④ spade